

Fiches de Cours

Master IMA

Axel PIGEON

axel.pigeon@univ-tlse3.fr

Université Toulouse III – Paul Sabatier

Années universitaires 2025–2027

25 septembre 2026

Table des matières

I Mathématiques du Machine Learning	4
1 Introduction à l'Apprentissage Supervisé	5
1.1 Des données et des prédictions	5
1.2 Formalisation mathématique	6
1.3 Risque et prédicteur de Bayes	7
1.4 Paradigmes classiques d'apprentissage	8
2 Régression Linéaire et Régression Ridge	12
2.1 Moindres Carrés	12
2.2 Analyse statistique – design fixe	13
2.3 Régression Ridge – design fixe	15
3 Méthodes à Noyaux	17
3.1 De la similarité au Théorème du Représentant	17
3.2 Noyaux définis positifs, Théorème de Bochner, et Théorème d'Aronszajn	19
3.3 Séparateurs à Vaste Marge (SVM)	23
4 Théorie de l'Apprentissage et Minimisation du Risque Empirique	26
4.1 Convexification du risque et substituts convexes	27
4.2 Décomposition du Risque et Classes Finies	28
4.3 Complexité de Rademacher	32
4.4 Théorèmes d'excès de risque pour les modèles linéaires	38
A Inégalités de concentration et régime sous-gaussien	40
II Traitement du signal	41
1 Signaux à temps discrets et Systèmes	42
1.1 Systèmes et signaux à temps discret	42
1.2 Convolution et corrélation	45
2 Transformée de Fourier et TFD	48
2.1 Transformée de Fourier des signaux à temps discret (TFTD)	48
2.2 Transformée de Fourier Discrète (TFD) et Algorithme FFT	50
2.3 Troncature spectrale et Fenêtres d'apodisation	51
3 Filtrage par Transformée de Fourier	52
3.1 Transformée en Z	52
3.2 Description des SLIT et Fonctions de Transfert	53
3.3 Filtres sélectifs et Synthèse de filtres RIF	54

4	Traitement d'images 2D	55
4.1	Numérisation, Représentation de l'Image 2D et Traitements Points-à-Points . . .	56
4.2	Premiers filtres spatiaux	58
4.3	Analyse fréquentielle bidimensionnelle (TFD 2D)	60
4.4	Filtrage Sélectif et Réhaussement fréquentiel 2D	62
4.5	Modélisation des Dégradations et Filtres de Débruitage	63
4.6	Bruit périodique, Problèmes Inverses et Défloutage	65
5	Analyse du son et Reconnaissance vocale	68
5.1	Architecture des Systèmes de Reconnaissance Vocale (RAP)	68
5.2	Paramétrisation Acoustique : Coefficients MFCC	69
5.3	Modélisation Statistique et Modèles de Mélanges de Gaussiennes (GMM)	69
5.4	Alignement Temporel Dynamique (DTW)	70
5.5	Modèles de Markov Cachés (HMM / MMC)	71
5.6	Modèles Connexionnistes (Réseaux de Neurones Récurents)	71

Mathématiques du Machine Learning

Chapitre 1

Introduction à l'Apprentissage Supervisé

Contents

1.1	Des données et des prédictions	5
1.2	Formalisation mathématique	6
1.2.1	Fonction de Perte	6
1.2.2	Les Risques	6
1.3	Risque et prédicteur de Bayes	7
1.3.1	Forme explicite selon la tâche	8
1.4	Paradigmes classiques d'apprentissage	8
1.4.1	Minimisation du Risque Empirique (ERM)	8
1.4.2	Méthodes probabilistes et Maximum de Vraisemblance	9
1.4.3	Méthodes par moyennage local (k -plus proches voisins)	10
1.4.4	Méthodes génératives	10
1.4.5	Théorème No Free Lunch	11

L'objectif de ce cours est de formaliser le processus d'apprentissage d'un modèle dans le cas d'un apprentissage supervisé. On commencera par définir ce qu'est ce type d'apprentissage puis ce que l'on entend par "apprendre". Différentes métriques seront introduites pour le quantifier.

1.1 Des données et des prédictions

L'ensemble du processus d'apprentissage s'appuie sur les concepts de *données* et de *prédictions*.

Définition (Observations) . Formellement, on définira les *données* d'un problème de machine learning par un ensemble de couples $(x, y) \in \mathcal{X} \times \mathcal{Y}$ que l'on appellera *données d'entraînement* ou *observations*. On notera cet ensemble D qui contiendra N couples.

Ces entrées et sorties attendues peuvent être de différents types en fonction du problème considéré. Les entrées peuvent être des images, des vidéos, du son ou un texte. On les modélisera en général par des vecteurs de $\mathbb{R}^d$ lorsque c'est possible. On appellera donc $d \in \mathbb{N}$ la dimension des données à l'entrée du modèle.

Les sorties peuvent être de deux types différents en apprentissage supervisé :

- Un ensemble d'entiers $\{1, \dots, k\}$. On parlera alors de problème de *classification*.

- Un vecteur de $\mathbb{R}^{d'}$. On parlera alors d'un problème de *régression*.

L'objectif est d'être capable, à partir d'une nouvelle donnée $x \in \mathcal{X}$ d'inférer/prédire le y qui lui correspond le mieux. Plus formellement, on cherche à *apprendre* une fonction f à partir des données d'entraînement telle que :

$$y \simeq f(x) \quad (1.1.1)$$

1.2 Formalisation mathématique

Pour apprendre une telle fonction, nous devons admettre différentes hypothèses sur le jeu de données de départ D . La première est que ce jeu de données suit une certaine loi de probabilité $\mathbb{P}$. La seconde est que chaque échantillon $(x_i, y_i), i \in \llbracket 1, N \rrbracket$ est indépendant des autres (D est un ensemble de réalisation i.i.d de la loi $\mathbb{P}$).

1.2.1 Fonction de Perte

Pour effectuer cet apprentissage, nous devons être capable de savoir à quel point notre modèle se trompe sur une prédiction donnée par rapport à la vraie valeur issue du jeu de données. Nous définissons pour cela une *fonction de perte*.

Définition (Fonction de perte) . La *fonction de perte*, notée l , calcule l'erreur induite par la prédiction de $z \in \mathcal{Y}$ alors que la valeur attendue était $y \in \mathcal{Y}$ pour une entrée $x \in \mathcal{X}$. Elle vérifie donc :

$$l : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}. \quad (1.2.1)$$

Exemple Dans le cas d'une classification binaire (i.e $\mathcal{Y} = \{0, 1\}$), on peut simplement utiliser la *Zero/One Loss* définie par $l(y, z) = \mathbb{1}_{z \neq y}$.

Dans le cas de la régression, on utilisera plutôt les L^1 Loss ou L^2 Loss définies par :

$$l(y, z) = \|y - z\|^2, \quad \text{et} \quad l(y, z) = \|y - z\|$$

1.2.2 Les Risques

Ces différentes fonctions de pertes, aussi bien définies soient-elles, ne nous donnent d'un aperçu des erreurs du modèle en temps réel. Nous avons aussi besoin d'avoir une idée plus fine des performances du modèle vis-à-vis de la distribution de probabilité $\mathbb{P}$ du jeu de données D . On définit pour cela les *risques*.

Définition (Risque Moyen) . On définit le *risque moyen*, noté $\mathcal{R}(f)$, d'une fonction f sur l'espace $\mathcal{X} \times \mathcal{Y}$ par l'espérance de la perte du ce même jeu de données.

$$\mathcal{R}(f) := \int_{\mathcal{X} \times \mathcal{Y}} l(y, f(x)) dp(x, y) dx dy = \mathbb{E}(l(y, f(x))) \quad (1.2.2)$$

où p est le densité de la probabilité $\mathbb{P}$.

Exemple Dans le cas de la classification binaire, le risque moyen se simplifie facilement :

$$\begin{aligned} \mathcal{R}(f) &= \int_{\mathcal{X} \times \mathcal{Y}} \mathbb{1}_{y \neq f(x)} d\mathbb{P}(x, y) \\ &= 0 \times \mathbb{P}(f(x) = y) + 1 \times \mathbb{P}(f(x) \neq y) \\ &= \mathbb{P}(f(x) \neq y) \end{aligned}$$

À noter que ce risque est calculé sur l'espace entier des données possibles. En pratique, si celui-ci est infini, il est incalculable. On préférera donc utiliser le *risque empirique*.

Définition (Risque Empirique) . Le risque empirique, noté $\hat{\mathcal{R}}(f)$ est donné par la moyenne empirique des pertes sur un jeu de données D .

$$\hat{\mathcal{R}}(f) := \frac{1}{N} \sum_{i=1}^N l(y_i, f(x_i)). \quad (1.2.3)$$

Proposition (Convergence) Grâce aux hypothèses précédentes, on peut invoquer des théorèmes de convergence sur les suites de variables aléatoires pour caractériser la limite de ce risque empirique.

Ainsi, si $f \in L^1$ alors, d'après la *Loi Forte des Grands Nombres*, on a que :

$$\hat{\mathcal{R}}(f) \xrightarrow[n \rightarrow \infty]{\text{p.s.}} \mathcal{R}(f). \quad (1.2.4)$$

Si, de plus $f \in L^2$, alors on a une idée de la vitesse de convergence de ce risque empirique :

$$\sqrt{n}(\hat{\mathcal{R}}(f) - \mathcal{R}(f)) \xrightarrow[n \rightarrow \infty]{\text{Loi}} \mathcal{N}(0, \mathbb{V}(l(y, f(x)))). \quad (1.2.5)$$

Remarque (Indépendance) En pratique, pour toute fonction apprise f , on aura $\hat{\mathcal{R}}(f) \simeq \mathcal{R}(f)$. Or, lorsque l'on calcule f sur des données empiriques (ex : jeu de données), on casse l'indépendance de la suite de variables aléatoires et donc le TCL. Formellement, en prenant l'estimateur :

$$\frac{1}{n} \sum_{i=1}^n l(x_i, \hat{f}(x_i)),$$

on remarque que le $\hat{f}$ est calculé à partir des $(x_1, y_1), \dots, (x_n, y_n)$. On peut solutionner ce problème en séparant le jeu de données en deux : *entraînement* et *test* (et éventuellement *validation*). Puisque le modèle ne voit pas les données de test et de validation, la fonction apprise ne dépend pas de ces données, ce qui permet de conserver l'indépendance des variables. On peut ensuite utiliser le TCL pour estimer le risque $\mathcal{R}$ à partir du risque empirique $\hat{\mathcal{R}}$.

1.3 Risque et prédicteur de Bayes

L'objectif théorique de l'apprentissage statistique est de trouver une fonction f qui minimise le risque moyen $\mathcal{R}(f)$ parmi l'ensemble $\mathcal{F}_{\text{all}}$ de toutes les fonctions mesurables de $\mathcal{X}$ dans $\mathcal{Y}$.

Définition (Prédicteur et Risque de Bayes) . On appelle *prédicteur de Bayes*, noté f^* , la fonction optimale (si elle existe) qui minimise le risque moyen sur l'espace de toutes les fonctions mesurables :

$$f^* \in \arg \min_{f \in \mathcal{F}_{\text{all}}} \mathcal{R}(f) \quad (1.3.1)$$

Le risque associé, noté $\mathcal{R}^* = \mathcal{R}(f^*)$, est appelé le *risque de Bayes* (ou erreur irréductible). Pour toute fonction mesurable f , on a trivialement :

$$\mathcal{R}(f) \geq \mathcal{R}^* \quad (1.3.2)$$

Pour calculer explicitement f^* , on utilise la loi des espérances itérées (conditionnement par rapport à X) :

$$\mathcal{R}(f) = \mathbb{E}_{(X,Y)} [l(Y, f(X))] = \mathbb{E}_X [\mathbb{E}_{Y|X} [l(Y, f(X)) | X]] \quad (1.3.3)$$

Minimiser $\mathcal{R}(f)$ revient donc à minimiser l'espérance conditionnelle point par point pour chaque $x \in \mathcal{X}$:

$$f^*(x) \in \arg \min_{z \in \mathcal{Y}} \mathbb{E}_{Y|X=x} [l(Y, z) \mid X = x] \quad (1.3.4)$$

1.3.1 Forme explicite selon la tâche

Proposition (Cas de la régression quadratique (L^2)) Pour la perte quadratique $l(y, z) = (y - z)^2$, le prédicteur de Bayes est l'espérance conditionnelle de Y sachant X :

$$f^*(x) = \mathbb{E}[Y \mid X = x] \quad (1.3.5)$$

Démonstration Fixons $x \in \mathcal{X}$. On cherche $z \in \mathbb{R}$ minimisant $\phi(z) = \mathbb{E}[(Y - z)^2 \mid X = x]$.

$$\phi(z) = \mathbb{E}[Y^2 \mid X = x] - 2z\mathbb{E}[Y \mid X = x] + z^2$$

ϕ est une fonction convexe et dérivable en z . En annulant la dérivée :

$$\phi'(z) = -2\mathbb{E}[Y \mid X = x] + 2z = 0 \iff z = \mathbb{E}[Y \mid X = x]$$

Proposition (Cas de la classification binaire (perte 0/1)) Pour $\mathcal{Y} = \{0, 1\}$ et la perte 0/1 $l(y, z) = \mathbb{1}_{y \neq z}$, le prédicteur de Bayes attribue la classe la plus probable a posteriori :

$$f^*(x) = \mathbb{1}_{\mathbb{P}(Y=1|X=x) \geq 1/2} \quad (1.3.6)$$

Démonstration Pour un $x \in \mathcal{X}$ donné et pour $z \in \{0, 1\}$:

$$\begin{aligned} \mathbb{E}[\mathbb{1}_{Y \neq z} \mid X = x] &= \mathbb{P}(Y \neq z \mid X = x) \\ &= 1 - \mathbb{P}(Y = z \mid X = x) \end{aligned}$$

Minimiser cette quantité revient à maximiser $\mathbb{P}(Y = z \mid X = x)$, ce qui donne la règle du maximum a posteriori (MAP).

Pour résumer, dans le cas d'une *classification*, le prédicteur de Bayes associe la classe la plus probable selon la distribution de probabilité simulée. Dans le cas d'une *régression*, ce prédicteur retournera la moyenne de la distribution de probabilité générée sur les y_i .

1.4 Paradigmes classiques d'apprentissage

Le prédicteur de Bayes f^* étant inconnu car il dépend de la distribution $\mathbb{P}$, différentes stratégies existent pour l'approcher à partir du jeu de données $S = ((x_1, y_1), \dots, (x_n, y_n))$.

1.4.1 Minimisation du Risque Empirique (ERM)

Définition (Estimateur ERM) . On restreint la recherche à une classe paramétrique de fonctions $\mathcal{F}_\Theta = \{f_\theta : \mathcal{X} \rightarrow \mathcal{Y}, \theta \in \Theta\}$. L'estimateur par *minimisation du risque empirique* (ERM) est défini par :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \hat{\mathcal{R}}_S(f_\theta) = \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n l(y_i, f_\theta(x_i)) \quad (1.4.1)$$

Exemple (Régression linéaire et polynomiale) Pour $f_\theta(x) = \theta^\top \varphi(x)$ (où φ est un morphisme d'extraction de caractéristiques / *feature map*) et la perte quadratique L^2 , le problème s'écrit :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - \theta^\top \varphi(x_i))^2 \quad (1.4.2)$$

Si $\varphi(x) = (1, x, x^2, \dots, x^k)^\top$, on retrouve la régression polynomiale de degré k .

Proposition (Décomposition de l'erreur d'excès de risque) Pour tout estimateur $\hat{\theta}$, l'excès de risque par rapport au risque de Bayes se décompose canoniquement en :

$$\mathcal{R}(f_{\hat{\theta}}) - \mathcal{R}^* = \underbrace{\left(\mathcal{R}(f_{\hat{\theta}}) - \inf_{\theta \in \Theta} \mathcal{R}(f_\theta) \right)}_{\text{Erreur d'estimation}} + \underbrace{\left(\inf_{\theta \in \Theta} \mathcal{R}(f_\theta) - \mathcal{R}^* \right)}_{\text{Erreur d'approximation}} \quad (1.4.3)$$

- **Erreur d'approximation** : Déterministe et indépendante de n , elle mesure la perte due au choix de la classe restreinte Θ (diminue si la richesse de Θ augmente).
- **Erreur d'estimation** : Aléatoire (dépend de S), elle mesure le coût lié au nombre fini d'échantillons n (décroît avec n , croît avec la richesse/complexité de Θ).

Remarque (Contrôle de l'erreur d'estimation) En notant $\theta^* \in \arg \min_{\theta \in \Theta} \mathcal{R}(f_\theta)$, on majore l'erreur d'estimation par :

$$\mathcal{R}(f_{\hat{\theta}}) - \mathcal{R}(f_{\theta^*}) \leq 2 \sup_{\theta \in \Theta} |\hat{\mathcal{R}}_S(f_\theta) - \mathcal{R}(f_\theta)| + \sup_{\theta \in \Theta} (\hat{\mathcal{R}}_S(f_{\hat{\theta}}) - \hat{\mathcal{R}}_S(f_\theta)) \quad (1.4.4)$$

Le premier terme est une déviation uniforme (objet central de la théorie de l'apprentissage statistique), et le second représente l'erreur d'optimisation numérique (nulle si le minimum empirique est calculé exactement).

La décomposition du risque comme présentée ci-dessus peut être observée sur l'apprentissage du modèle. On parlera alors de sur-apprentissage ou de sous-apprentissage en fonction de la complexité du modèle.

- **Sous-apprentissage (*Underfitting*)** : Modèle trop simple (faible complexité de Θ), dominé par l'erreur d'approximation.
- **Sur-apprentissage (*Overfitting*)** : Modèle trop expressif (par exemple interpolation polynomiale de Lagrange de degré $n-1$), l'erreur empirique est quasi-nulle mais l'erreur d'estimation explose sur les nouvelles données.

Pour contrôler ce phénomène, on introduit une pénalisation de complexité $\Omega(\theta)$:

$$\hat{\theta}_{\text{reg}} \in \arg \min_{\theta \in \Theta} \left\{ \hat{\mathcal{R}}_S(f_\theta) + \lambda \Omega(\theta) \right\} \quad (1.4.5)$$

où $\lambda > 0$ est un hyperparamètre calibré sur le jeu de validation (exemples : Ridge avec $\Omega(\theta) = \|\theta\|_2^2$, Lasso avec $\Omega(\theta) = \|\theta\|_1$).

1.4.2 Méthodes probabilistes et Maximum de Vraisemblance

L'idée consiste à postuler une famille paramétrique de densités conditionnelles $\{p_\theta(y | x) : \theta \in \Theta\}$ et à choisir le paramètre qui maximise la log-vraisemblance sur l'échantillon i.i.d :

$$\hat{\theta}_{\text{MLE}} \in \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \ln p_\theta(x_i, y_i) \quad (1.4.6)$$

Exemple (Régression Logistique) Pour des labels $y \in \{-1, 1\}$, en posant la fonction sigmoïde $\sigma(z) = \frac{1}{1+e^{-z}}$, le modèle postule :

$$p_\theta(y | x) = \sigma(y\theta^\top x) = \frac{1}{1 + e^{-y\theta^\top x}} \quad (1.4.7)$$

Maximiser la vraisemblance revient exactement à un problème d'ERM :

$$\hat{\theta} \in \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ln \left(1 + e^{-y_i \theta^\top x_i} \right) \quad (1.4.8)$$

avec la perte logistique convexe $l(y, z) = \ln(1 + e^{-yz})$.

Remarque (Pont entre Maximum de Vraisemblance et ERM) En posant $l(y, \hat{y}) = -\ln p_\theta(y | x)$, toute maximisation de vraisemblance s'interprète comme une minimisation de risque empirique :

- Bruit gaussien $\varepsilon \sim \mathcal{N}(0, \sigma^2) \implies$ Perte quadratique (moindres carrés).
- Loi de Bernoulli $\implies$ Perte logistique.

En classification, on utilise ces fonctions de perte convexes (surrogates) car minimiser directement la perte 0/1 est un problème NP-difficile et non dérivable (gradient nul presque partout).

1.4.3 Méthodes par moyennage local (k -plus proches voisins)

Ces méthodes non paramétriques exploitent une hypothèse de régularité locale : des points proches dans $\mathcal{X}$ partagent des distributions conditionnelles $\mathbb{P}_{y|x}$ similaires.

Définition (k -Nearest Neighbours – k -NN) . Pour une entrée x' , on considère l'ensemble $\mathcal{V}_k(x')$ de ses k plus proches voisins dans le jeu d'entraînement :

- **En classification** : Règle du vote majoritaire :

$$\hat{f}(x') = \arg \max_{c \in \mathcal{Y}} \sum_{i \in \mathcal{V}_k(x')} \mathbb{1}_{y_i=c} \quad (1.4.9)$$

- **En régression** : Moyenne empirique locale :

$$\hat{f}(x') = \frac{1}{k} \sum_{i \in \mathcal{V}_k(x')} y_i \quad (1.4.10)$$

Remarque (Compromis biais-variance pour k -NN) Pour k -NN, l'axe de complexité est inversé :

- k petit (ex. $k = 1$) $\implies$ Modèle très flexible, risque de sur-apprentissage (faible approximation, forte estimation).
- k grand $\implies$ Modèle rigide/lissé, risque de sous-apprentissage (forte approximation, faible estimation).

1.4.4 Méthodes génératives

Au lieu de modéliser directement $f(x)$ ou $\mathbb{P}(Y | X)$, les modèles génératifs estiment la loi conjointe en modélisant :

1. La loi a priori des classes $p(y)$.
2. Les densités conditionnelles de chaque classe $p(x | y)$.

On en déduit ensuite la loi a posteriori par la règle de Bayes :

$$p(y | x) = \frac{p(x | y)p(y)}{\sum_c p(x | y = c)p(y = c)} \propto p(x | y)p(y) \quad (1.4.11)$$

La règle de décision optimale est donnée par le maximum a posteriori (MAP) : $\hat{f}(x') = \arg \max_{\hat{y}} p(x' | \hat{y})p(\hat{y})$.

1.4.5 Théorème No Free Lunch

Il n'existe pas d'algorithme d'apprentissage universel optimal sur toutes les distributions possibles sans hypothèse préalable sur les données.

Théorème (No Free Lunch (Devroye, Györfi, Lugosi)) . Soit le problème de classification binaire avec la perte 0/1 et $\mathcal{X}$ un ensemble infini. Soit $\mathcal{P}$ l'ensemble de toutes les lois de probabilité sur $\mathcal{X} \times \{0, 1\}$. Pour tout entier n et tout algorithme d'apprentissage $\mathcal{A}$, on a :

$$\sup_{\mathbb{P} \in \mathcal{P}} \{\mathbb{E}_{S \sim \mathbb{P}^{\otimes n}} [\mathcal{R}_{\mathbb{P}}(\mathcal{A}(S))] - \mathcal{R}_{\mathbb{P}}^*\} \geq \frac{1}{2} \quad (1.4.12)$$

Ce résultat implique que pour n'importe quel algorithme fixé, il existe une distribution sous-jacente défavorable pour laquelle l'algorithme ne fait pas mieux qu'un choix aléatoire (même si le risque de Bayes $\mathcal{R}^* = 0$). Il est donc mathématiquement indispensable de poser des hypothèses régularité, marge, séparabilité ou compacité pour garantir des résultats d'apprentissage.

Chapitre 2

Régression Linéaire et Régression Ridge

Contents

2.1	Moindres Carrés	12
2.2	Analyse statistique – design fixe	13
2.3	Régression Ridge – design fixe	15

On pose ici le contexte d'une *régression linéaire*. On cherche donc à apprendre une fonction pour décrire un jeu de données $(x_1, y_1), \dots, (x_n, y_n) \in \mathcal{X} \times \mathcal{Y}$. Dans le cas du modèle linéaire, on fera l'hypothèse forte suivante :

$$(H) : f_\theta = \varphi(x)^t \theta, \quad \theta \in \mathbb{R}^d. \quad (2.0.1)$$

Pour construire cette fonction, on utilisera l'estimateur du risque empirique (ERM) défini par :

$$\hat{R}(\theta) \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - f_\theta(x_i))^2. \quad (2.0.2)$$

Exemple La forme de l'application φ caractérisera la *feature map* (i.e l'ensemble des fonctions possibles pour interpoler le nuage de points).

- si $\varphi(x) = x$, alors on aura une estimation linéaire en x ,
- si $\varphi(x) = \begin{pmatrix} x \\ 1 \end{pmatrix}$ alors l'estimation sera *affine* en x ,
- si $\varphi(x) \in \mathbb{R}^d[x]$, alors l'estimation sera *polynomiale* en x . On pourra aller jusqu'au degré d pour utiliser des polynômes de Lagrange.

Notation On notera $y = \begin{pmatrix} y_1 \\ \dots \\ y_n \end{pmatrix}$ le vecteur des étiquettes du jeu de données et $\Phi = \begin{pmatrix} \varphi(x_1)^t \\ \dots \\ \varphi(x_n)^t \end{pmatrix} \in$

$\mathbb{R}^{n \times d}$ la matrice contenant toutes les prédictions données par la *feature map*. On aura donc : $\hat{R}(\theta) = \frac{1}{n} \|y - \Phi\theta\|_2^2$.

2.1 Moindres Carrés

Nous sommes en présence d'un problème de régression. Grâce aux notations matricielles précédemment posées, nous sommes capable de calculer une solution explicite à la main.

On cherche à calculer explicitement $\hat{\theta} \in \arg \min_{\theta \in \mathbb{R}^d} \hat{R}(\theta)$. Pour cela, on utilise la condition nécessaire d'optimalité d'ordre 1 : $\nabla_{\theta} \hat{R}(\hat{\theta}) = 0$. Commençons donc par calculer le gradient :

$$\hat{R}(\theta) = \frac{1}{n} \|y - \Phi\theta\|_2^2 \quad (2.1.1)$$

$$\nabla_{\theta} \hat{R}(\theta) = \frac{2}{n} \Phi^{\top} (\Phi\theta - y) \quad (2.1.2)$$

En résolvant l'équation $\nabla_{\theta} \hat{R}(\hat{\theta}) = 0$, on obtient les *équations normales* :

$$(*) : \Phi^{\top} \Phi \hat{\theta} = \Phi^{\top} y \quad (2.1.3)$$

En supposant que Φ est de rang plein ($rg(\Phi) = d$, soit des colonnes linéairement indépendantes), la matrice de Gram $\Phi^{\top} \Phi \in \mathbb{R}^{d \times d}$ est inversible, ce qui donne :

$$(*) \iff \boxed{\hat{\theta} = (\Phi^{\top} \Phi)^{-1} \Phi^{\top} y} \quad (2.1.4)$$

La fonction $\hat{R}$ étant convexe, ce point stationnaire est un minimum global. On calcule ainsi explicitement l'estimateur des moindres carrés (OLS), qui fournit le prédicteur linéaire optimal sur l'échantillon d'entraînement.

Proposition Géométriquement, les prédictions $\hat{y} = \Phi \hat{\theta}$ correspondent à la projection orthogonale du vecteur d'observations $y \in \mathbb{R}^n$ sur le sous-espace vectoriel $\text{Im}(\Phi) \subset \mathbb{R}^n$ engendré par les colonnes de Φ :

$$\hat{\theta} \in \arg \min_{\theta \in \mathbb{R}^d} \frac{1}{n} \|y - \Phi\theta\|_2^2 \iff \hat{y} \in \arg \min_{z \in \text{Im}(\Phi)} \frac{1}{n} \|y - z\|_2^2 \quad (2.1.5)$$




FIGURE 2.1 – Projection orthogonale du vecteur d'observations y sur le sous-espace affine $\text{Im}(\phi)$ et décomposition de l'erreur résiduelle $y - \hat{y} \perp \text{Im}(\phi)$.

2.2 Analyse statistique – design fixe

Dans cette section, on se place sous l'hypothèse du *design fixe* : les points $x_i \in \mathcal{X}$ (et donc la matrice $\Phi \in \mathbb{R}^{n \times d}$) sont déterministes et fixés. Seules les étiquettes y_i sont aléatoires.

Définition (Modèle à design fixe) . Le modèle probabiliste d'observation s'écrit :

1. $y = \Phi\theta_* + \varepsilon$, avec $\theta_* \in \mathbb{R}^d$ le paramètre vrai inconnu.
2. Le vecteur de bruit $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^\top \in \mathbb{R}^n$ vérifie $\mathbb{E}(\varepsilon) = 0$ et $\text{Var}(\varepsilon) = \mathbb{E}(\varepsilon\varepsilon^\top) = \sigma^2 I_n$.

Le risque moyen sous design fixe est défini par :

$$R(\theta) = \frac{1}{n} \mathbb{E}_y \left[\|y - \Phi\theta\|_2^2 \right]. \quad (2.2.1)$$

On introduit la matrice de covariance empirique $\hat{\Sigma} := \frac{1}{n} \Phi^\top \Phi \in \mathbb{R}^{d \times d}$, associée à la semi-norme $\|u\|_{\hat{\Sigma}}^2 := u^\top \hat{\Sigma} u = \frac{1}{n} \|\Phi u\|_2^2$.

Proposition (Décomposition Biais-Variance) Pour tout vecteur fixe $\theta \in \mathbb{R}^d$:

$$\begin{aligned} R(\theta) &= \frac{1}{n} \mathbb{E}_\varepsilon \left[\|\Phi(\theta_* - \theta) + \varepsilon\|_2^2 \right] \\ &= \frac{1}{n} \|\Phi(\theta_* - \theta)\|_2^2 + \frac{1}{n} \mathbb{E} \left[\|\varepsilon\|_2^2 \right] + \frac{2}{n} (\theta_* - \theta)^\top \Phi^\top \mathbb{E}[\varepsilon] \\ &= \|\theta - \theta_*\|_{\hat{\Sigma}}^2 + \sigma^2. \end{aligned}$$

Le risque de Bayes est atteint en θ_* : $R^* = R(\theta_*) = \sigma^2$. Par conséquent, pour un estimateur aléatoire $\hat{\theta}$ dépendant de y (donc de ε) :

$$\mathbb{E}_{\hat{\theta}} \left[R(\hat{\theta}) \right] - R^* = \underbrace{\left\| \mathbb{E}(\hat{\theta}) - \theta_* \right\|_{\hat{\Sigma}}^2}_{\text{Biais}^2} + \underbrace{\mathbb{E}_{\hat{\theta}} \left[\left\| \hat{\theta} - \mathbb{E}(\hat{\theta}) \right\|_{\hat{\Sigma}}^2 \right]}_{\text{Variance}} \quad (2.2.2)$$

Théorème (Biais et Variance des Moindres Carrés) . Dans le cas de l'estimateur des moindres carrés $\hat{\theta} = (\Phi^\top \Phi)^{-1} \Phi^\top y$:

$$\text{Biais}^2 = 0 \quad \text{et} \quad \mathbb{E} \left[R(\hat{\theta}) \right] - R^* = \frac{\sigma^2 d}{n}. \quad (2.2.3)$$

Démonstration • *Calcul du biais* :

$$\begin{aligned} \mathbb{E}(\hat{\theta}) &= \mathbb{E} \left[(\Phi^\top \Phi)^{-1} \Phi^\top (\Phi\theta_* + \varepsilon) \right] \\ &= \theta_* + (\Phi^\top \Phi)^{-1} \Phi^\top \mathbb{E}[\varepsilon] = \theta_*. \end{aligned}$$

L'estimateur est sans biais, d'où $\text{Biais}^2 = 0$.

- *Calcul de la variance* : On exprime la variance sous forme de trace :

$$\begin{aligned} \text{Variance} &= \mathbb{E} \left[(\hat{\theta} - \theta_*)^\top \hat{\Sigma} (\hat{\theta} - \theta_*) \right] \\ &= \mathbb{E} \left[\text{tr} \left(\hat{\Sigma} (\hat{\theta} - \theta_*) (\hat{\theta} - \theta_*)^\top \right) \right] \\ &= \text{tr} \left(\hat{\Sigma} \mathbb{E} \left[(\hat{\theta} - \theta_*) (\hat{\theta} - \theta_*)^\top \right] \right). \end{aligned}$$

Or, $\hat{\theta} - \theta_* = (\Phi^\top \Phi)^{-1} \Phi^\top \varepsilon$, donc :

$$\begin{aligned} \mathbb{E} \left[(\hat{\theta} - \theta_*)(\hat{\theta} - \theta_*)^\top \right] &= (\Phi^\top \Phi)^{-1} \Phi^\top \mathbb{E}[\varepsilon \varepsilon^\top] \Phi (\Phi^\top \Phi)^{-1} \\ &= \sigma^2 (\Phi^\top \Phi)^{-1} \Phi^\top I_n \Phi (\Phi^\top \Phi)^{-1} \\ &= \sigma^2 (\Phi^\top \Phi)^{-1} = \frac{\sigma^2}{n} \hat{\Sigma}^{-1}. \end{aligned}$$

En réinjectant dans l'expression de la trace :

$$\text{Variance} = \text{tr} \left(\hat{\Sigma} \cdot \frac{\sigma^2}{n} \hat{\Sigma}^{-1} \right) = \frac{\sigma^2}{n} \text{tr}(I_d) = \frac{\sigma^2 d}{n}.$$

2.3 Régression Ridge – design fixe

Dans le modèle linéaire usuel, l'erreur de variance vaut $\frac{\sigma^2 d}{n}$. Lorsque les covariables sont fortement corrélées (multicolinéarité), la matrice $\hat{\Sigma}$ possède des valeurs propres très proches de 0, ce qui rend $(\Phi^\top \Phi)^{-1}$ instable et fait exploser la norme du paramètre appris.

La régression Ridge (pénalisation de Tikhonov / régularisation L^2) remédie à ce problème en contractant les coefficients vers zéro via une pénalisation quadratique. On accepte d'introduire un léger biais en échange d'une réduction drastique de la variance.

Définition (Estimateur Ridge) . Pour un paramètre de régularisation $\lambda > 0$, l'estimateur Ridge est défini par :

$$\hat{\theta}_\lambda \in \arg \min_{\theta \in \mathbb{R}^d} \frac{1}{n} \|y - \Phi \theta\|_2^2 + \lambda \|\theta\|_2^2. \quad (2.3.1)$$

En annulant le gradient, la solution explicite est unique et donnée par :

$$\hat{\theta}_\lambda = \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \frac{1}{n} \Phi^\top y = \left(\Phi^\top \Phi + n \lambda I_d \right)^{-1} \Phi^\top y \quad (2.3.2)$$

où $\hat{\Sigma} = \frac{1}{n} \Phi^\top \Phi$. La matrice $\hat{\Sigma} + \lambda I_d$ est symétrique définie positive pour tout $\lambda > 0$, donc inversible même si $\Phi^\top \Phi$ ne l'est pas.

Proposition (Décomposition Biais-Variance de Ridge) Sous le modèle à design fixe $y = \Phi \theta_* + \varepsilon$:

- *Biais* : L'espérance de l'estimateur vaut $\mathbb{E}(\hat{\theta}_\lambda) = (\hat{\Sigma} + \lambda I_d)^{-1} \hat{\Sigma} \theta_*$. Le terme de biais s'écrit donc :

$$\text{Biais}^2 = \left\| \mathbb{E}(\hat{\theta}_\lambda) - \theta_* \right\|_{\hat{\Sigma}}^2 = \lambda^2 \theta_*^\top \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \hat{\Sigma} \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \theta_*. \quad (2.3.3)$$

- *Variance* : En utilisant $\text{Var}(\hat{\theta}_\lambda) = \frac{\sigma^2}{n} (\hat{\Sigma} + \lambda I_d)^{-1} \hat{\Sigma} (\hat{\Sigma} + \lambda I_d)^{-1}$, on obtient :

$$\text{Variance} = \frac{\sigma^2}{n} \text{tr} \left(\hat{\Sigma}^2 \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \right). \quad (2.3.4)$$

Le risque d'excès s'écrit donc :

$$\mathbb{E} \left[R(\hat{\theta}_\lambda) \right] - R^* = \lambda^2 \theta_*^\top \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \hat{\Sigma} \theta_* + \frac{\sigma^2}{n} \text{tr} \left(\hat{\Sigma}^2 \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \right). \quad (2.3.5)$$

Remarque (Degrés de liberté effectifs) La quantité $df(\lambda) = \text{tr} \left(\hat{\Sigma}(\hat{\Sigma} + \lambda I_d)^{-1} \right) = \sum_{j=1}^d \frac{\mu_j}{\mu_j + \lambda}$ mesure les *degrés de liberté effectifs* du modèle. Pour $\lambda = 0$, on retrouve $df(0) = d$ et la variance des moindres carrés $\frac{\sigma^2 d}{n}$. Lorsque $\lambda \rightarrow \infty$, $df(\lambda) \rightarrow 0$.

Proposition (Contrôle spectral et borne d'erreur) Soit $\hat{\Sigma} = U \text{diag}(\mu_1, \dots, \mu_d) U^\top$ la décomposition spectrale de $\hat{\Sigma}$ (avec $\mu_j \geq 0$).

- Pour le biais : pour tout $\mu \geq 0$ et $\lambda > 0$, on a $\frac{\lambda^2 \mu}{(\mu + \lambda)^2} \leq \frac{\lambda}{4}$ (car $(\mu + \lambda)^2 \geq 4\lambda\mu$), d'où :

$$\text{Biais}^2 \leq \frac{\lambda}{4} \|\theta_*\|_2^2. \quad (2.3.6)$$

- Pour la variance : comme $\frac{\mu_j^2}{(\mu_j + \lambda)^2} \leq \frac{\mu_j}{\lambda}$, on a :

$$\text{Variance} \leq \frac{\sigma^2}{n\lambda} \text{tr}(\hat{\Sigma}). \quad (2.3.7)$$

En équilibrant les deux bornes avec le choix optimal $\lambda^* \propto \frac{\sigma}{\sqrt{n}}$, on garantit une vitesse de convergence de l'excès de risque en $\mathcal{O}(1/\sqrt{n})$, indépendante du plus petit spectre de $\hat{\Sigma}$.

Chapitre 3

Méthodes à Noyaux

Contents

3.1	De la similarité au Théorème du Représentant	17
3.1.1	Intuition géométrique et plongement	17
3.1.2	Le Théorème du Représentant	18
3.2	Noyaux définis positifs, Théorème de Bochner, et Théorème d’Aronszajn	19
3.2.1	Noyau SDP : Définition et propriétés	19
3.2.2	Construire des noyaux SDP : Théorème de Bochner	20
3.2.3	Théorème d’Aronszajn	21
3.3	Séparateurs à Vaste Marge (SVM)	23
3.3.1	Cas linéairement séparable : Maximisation de la marge	23
3.3.2	Cas non séparable : Variables d’écart et perte charnière	23
3.3.3	Dualité de Wolfe et formulation duale	24
3.3.4	Le Kernel SVM (SVM à noyau)	24

L’objectif des méthodes à noyaux est de transformer une mesure heuristique de similarité entre données en un algorithme d’apprentissage non linéaire. En s’appuyant implicitement sur un espace de Hilbert de dimension arbitraire (potentiellement infinie), on conserve toute la simplicité de l’optimisation linéaire tout en évitant d’avoir à calculer explicitement les plongements.

3.1 De la similarité au Théorème du Représentant

3.1.1 Intuition géométrique et plongement

La plupart des jeux de données ne sont pas linéairement séparables dans leur espace d’entrée d’origine $\mathcal{X}$. L’idée fondamentale consiste à envoyer les données dans un espace de caractéristiques de plus grande dimension (un espace de Hilbert $\mathcal{H}$) via une *feature map* :

$$\varphi : \mathcal{X} \longrightarrow \mathcal{H} \quad (3.1.1)$$

Dans $\mathcal{H}$, un hyperplan linéaire peut alors séparer des classes qui formaient des régions géométriques complexes ou intriquées dans $\mathcal{X}$. On formule alors le problème sous la forme d’une minimisation de risque empirique régularisé sur la totalité de l’espace hilbertien $\mathcal{H}$:

$$\hat{\theta}_S \in \arg \min_{\theta \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n l(y_i, \langle \varphi(x_i), \theta \rangle_{\mathcal{H}}) + \frac{\lambda}{2} \|\theta\|_{\mathcal{H}}^2 \quad (3.1.2)$$

où $\lambda > 0$ contrôle la régularisation.

Remarque (Obstruction numérique) Si $\mathcal{H}$ est de dimension infinie, on ne peut ni représenter le vecteur de paramètres $\theta \in \mathcal{H}$, ni évaluer explicitement $\varphi(x)$ par descente de gradient standard. Le théorème suivant résout ce paradoxe.

3.1.2 Le Théorème du Représentant

Théorème (Théorème du Représentant) . Soit $\mathcal{X}$ un ensemble, $\mathcal{H}$ un espace de Hilbert réel muni du produit scalaire $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ et $\varphi : \mathcal{X} \rightarrow \mathcal{H}$. Soit un échantillon $S = (x_1, \dots, x_n)$ et le sous-espace engendré par les observations :

$$\mathcal{H}_D := \text{vect}\{\varphi(x_1), \dots, \varphi(x_n)\} \subset \mathcal{H} \quad (3.1.3)$$

Soit $\Psi : \mathbb{R}^n \times \mathbb{R}_+ \rightarrow \mathbb{R}$ une fonction croissante par rapport à son second argument. En notant $u(\theta) = (\langle \varphi(x_1), \theta \rangle_{\mathcal{H}}, \dots, \langle \varphi(x_n), \theta \rangle_{\mathcal{H}})^\top \in \mathbb{R}^n$, on a :

$$\inf_{\theta \in \mathcal{H}} \Psi(u(\theta), \|\theta\|_{\mathcal{H}}^2) = \inf_{\theta \in \mathcal{H}_D} \Psi(u(\theta), \|\theta\|_{\mathcal{H}}^2) \quad (3.1.4)$$

Si l'infimum est atteint, il l'est en un point $\hat{\theta}_S \in \mathcal{H}_D$. De plus, si Ψ est *strictement croissante* par rapport à son second argument, tout minimiseur appartient nécessairement à $\mathcal{H}_D$.

Grâce à ce théorème, on cherche donc $\hat{\theta}_S \in \mathcal{H}_D$ de dimension finie. Puisque l'on en connaît une famille génératrice, on cherche donc :

$$\alpha = (\alpha_1, \dots, \alpha_n)^\top \in \mathbb{R}^n, \quad \text{tels que} \quad \hat{\theta}_S = \sum_{i=1}^n \alpha_i \varphi(x_i).$$

Ainsi, la dimension du problème d'optimisation ne dépend plus de celle de $\mathcal{H}$ mais seulement du nombre de d'échantillons n . Déterminons maintenant comment trouver ce $\hat{\alpha}_S$.

Proposition (Kernel Trick) Remplaçons θ par sa nouvelle expression dans le problème de départ 3.1.2 :

- La norme devient :

$$\begin{aligned} \|\theta\|_{\mathcal{H}}^2 &= \left\langle \sum_{i=1}^n \alpha_i \varphi(x_i), \sum_{j=1}^n \alpha_j \varphi(x_j) \right\rangle_{\mathcal{H}} = \sum_{i,j=1}^n \alpha_i \alpha_j \langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}} \\ &= \sum_{i,j=1}^n \alpha_i \alpha_j K_{i,j} \quad \text{avec} \quad K = (\langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}})_{i,j} \end{aligned}$$

- Les prédictions deviennent :

$$\langle \varphi(x_i), \theta \rangle_{\mathcal{H}} = \sum_{j=1}^n \alpha_j \langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}} = (K\alpha)_i$$

On a donc le problème réécrit suivant :

$$\hat{\alpha}_S \in \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n l(y_i, (K\alpha)_i) + \frac{\lambda}{2} \alpha^\top K \alpha. \quad (3.1.5)$$

On remarque que l'on a plus besoin de calculer explicitement φ ni f : tout dépend de ce que l'on appellera le *noyau* K . Notons ici $K = (k(x_i, x_j))_{i,j}$ tel que $k(x, x_j) = \langle \varphi(x), \varphi(x_j) \rangle_{\mathcal{H}}$. Ainsi, pour l'entraînement nous n'avons besoin que de la matrice de Gram K de taille $n \times n$. Pour l'inférence sur un x donné, nous notons $k_x = (k(x, x_1), \dots, k(x, x_n)) \in \mathbb{R}^n$ tel que $f_{\hat{\theta}_S} = \hat{\alpha}_S^\top k_x$.

On peut maintenant remarquer que la *feature map* φ n'est jamais calculée et que les prédictions en x utilisent seulement les n valeurs $\langle \varphi(x), \varphi(x_i) \rangle_{\mathcal{H}}$. Ainsi, au lieu de définir un espace $\mathcal{H}$ dans lequel nous ne pouvons faire aucun calcul, on pourrait directement choisir k telle que $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ de la forme $k(x, x') = \langle \varphi(x), \varphi(x') \rangle$. C'est le sujet de la section suivante qui définit les *noyaux* et introduit la théorie nécessaire dessus.

3.2 Noyaux définis positifs, Théorème de Bochner, et Théorème d'Aronszajn

Dans la partie précédente, nous avons reformulé le problème de minimisation du risque empirique à l'aide d'un plongement dans un espace de Hilbert $\mathcal{H}$. Nous avons ensuite remarqué que tous les calculs dans cet espace dépendent en réalité d'une *fonction de similitude* encodée dans un *noyau* K .

Or, en pratique, on raisonne dans le sens inverse : à partir du jeu de données, on définit un noyau K et on souhaite savoir si l'on peut effectivement utiliser ce noyau pour notre minimisation. C'est le théorème d'Aronszajn qui nous l'assure. Mais avant de l'aborder, définissons formellement la notion de noyau ainsi que ses propriétés.

3.2.1 Noyau SDP : Définition et propriétés

Au lieu de définir $\mathcal{H}$ puis φ , on choisit directement une fonction $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ et on cherche à quelles conditions elle correspond à un produit scalaire hilbertien (i.e un noyau semi-défini positif).

Définition (Noyau semi-défini positif) . Une application $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est appelée un *noyau semi-défini positif* (noyau SDP ou PSDK) si elle vérifie :

1. **Symétrie** : $\forall x, x' \in \mathcal{X}, \quad k(x, x') = k(x', x)$.
2. **Positivité** : $\forall n \geq 1, \forall (x_1, \dots, x_n) \in \mathcal{X}^n, \forall (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n :$

$$\sum_{i,j=1}^n \alpha_i \alpha_j k(x_i, x_j) \geq 0 \iff K \in \mathcal{S}_n^+(\mathbb{R}) \quad (3.2.1)$$

Propriété (Caractérisation par matrice de Gram) . La matrice de Gram $G = (\langle u_i, u_j \rangle)_{i,j}$ associée à toute famille finie $(u_1, \dots, u_n)$ est symétrique semi-définie positive.

Proposition (Tout produit scalaire définit un noyau SDP) Si $\mathcal{H}$ est un espace de Hilbert et $\varphi : \mathcal{X} \rightarrow \mathcal{H}$, alors $k(x, x') := \langle \varphi(x), \varphi(x') \rangle_{\mathcal{H}}$ est un noyau SDP.

Exemple Voici quelques exemples de noyaux SDP :

- Noyau *linéaire* : $k(x, x') = x^\top x'$ sur $\mathcal{X} = \mathbb{R}^d$.
- Noyau *polynomial* : $k(x, x') = (x^\top x')^q$ pour $q \in \mathbb{N}^*$.
- Noyau *exponentiel* : $k(x, x') = \exp(-a\|x - x'\|_2^2)$ pour $a > 0$.

Les noyaux SDP peuvent être construit par opérations. Le théorème suivant détaille les opérations possibles entre noyaux SDP.

Théorème (Opérations) . L'ensemble des noyaux semi-définis positifs sur un espace $\mathcal{X}$ est stable par :

- multiplication scalaire par un coefficient positif ou nul,
- somme finie,
- produits,
- limite ponctuelle quand elle existe,
- conjugaison par une fonction.

Grâce à ce théorème, nous pouvons montrer que beaucoup d'application k sont des noyaux. Voyons-en quelques unes.

Proposition Soit $q \geq 1$ un entier, alors $(x, x') \mapsto (x^\top x')^q$ et $(x, x') \mapsto (1 + x^\top x')^q$ sont des noyaux SDP.

Démonstration Pour le premier, $(x, x') \mapsto x^\top x'$ est un produit scalaire donc c'est un noyau. À la puissance q , c'est une multiplication finie. C'est donc un noyau par induction sur q . Pour le second, on identifie $1 + x^\top x' = k(x, x') + x^\top x'$ avec $k(x, x') = 1$. Puisque $\sum_{i,j} \alpha_i \alpha_j = (\sum_i \alpha_i)^2 \geq 0$, alors c'est un noyau. Par somme et d'après le résultat précédent, $(x, x') \mapsto (1 + x^\top x')^q$ est aussi un noyau SDP.

Proposition Soit k un noyau SDP, alors $\exp(k) : (x, x') \mapsto \exp(k(x, x'))$ est un noyau SDP.

Démonstration Si k est un noyau alors, $\forall x, x' \in \mathcal{X}$, on a :

$$\exp(k(x, x')) = \sum_{n=0}^{\infty} \frac{k(x, x')^n}{n!}.$$

Or, pour tout $n \geq 0$, $\frac{k(x, x')^n}{n!}$ est un noyau par produit fini et multiplication par un scalaire positif. Par somme, $\sum_{i=1}^n \frac{k(x, x')^i}{i!}$ en est un aussi. Enfin, par définition de l'exponentielle, $\exp a$ converge pour tout $a \in \mathbb{R}$, donc par limite de noyaux SDP, $\exp(k)$ est aussi un noyau SDP.

3.2.2 Construire des noyaux SDP : Théorème de Bochner

Montrer qu'un noyau est SDP est simple lorsqu'il dérive de produits scalaires combinés algébriquement. En revanche, si l'on cherche à mesurer la proximité géométrique locale entre deux observations, le calcul direct devient inextricable. Par exemple, pour le noyau gaussien $k(x, x') = \exp(-a\|x - x'\|_2^2)$, vérifier point par point que :

$$\forall n \geq 1, \quad \forall (x_1, \dots, x_n) \in (\mathbb{R}^d)^n, \quad \forall (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n, \quad \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \exp(-a\|x_i - x_j\|_2^2) \geq 0$$

est difficile sans outil analytique. Le théorème de Bochner permet de lever ce verrou en transposant la question de l'espace spatial à l'espace fréquentiel via la transformée de Fourier.

Théorème (Théorème de Bochner – Invariance par translation) . Soit $q : \mathbb{R}^d \rightarrow \mathbb{R}$ continue. Le noyau stationnaire $k(x, x') := q(x - x')$ est semi-défini positif si et seulement si q est la transformée de Fourier inverse d'une mesure borélienne positive finie ρ sur $\mathbb{R}^d$:

$$q(z) = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{iz^\top \omega} d\rho(\omega). \quad (3.2.2)$$

Démonstration (Preuve de la condition suffisante) Supposons que q s'écrive sous forme d'intégrale de Fourier par rapport à une mesure positive finie ρ . Pour toute famille $(x_1, \dots, x_n)$ et tout vecteur $\alpha \in \mathbb{R}^n$:

$$\begin{aligned} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j q(x_i - x_j) &= \sum_{i,j=1}^n \alpha_i \alpha_j \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{i(x_i - x_j)^\top \omega} d\rho(\omega) \\ &= \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \sum_{i=1}^n \alpha_i e^{ix_i^\top \omega} \sum_{j=1}^n \alpha_j e^{-ix_j^\top \omega} d\rho(\omega) \\ &= \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \left(\sum_{i=1}^n \alpha_i e^{ix_i^\top \omega} \right) \overline{\left(\sum_{j=1}^n \alpha_j e^{ix_j^\top \omega} \right)} d\rho(\omega) \\ &= \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \underbrace{\left| \sum_{i=1}^n \alpha_i e^{ix_i^\top \omega} \right|^2}_{\geq 0} \underbrace{d\rho(\omega)}_{\geq 0} \geq 0. \end{aligned}$$

La fonction q étant paire dès lors que la mesure est symétrique ($\rho(-\omega) = \rho(\omega)$), le noyau est bien symétrique et semi-défini positif.

Exemple (Cas du noyau Gaussien / RBF) Pour $a > 0$ et $z \in \mathbb{R}^d$, la fonction gaussienne $q(z) = \exp(-a\|z\|_2^2)$ admet pour transformée de Fourier inverse :

$$e^{-a\|z\|_2^2} = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{iz^\top \omega} \left(\frac{\pi}{a}\right)^{d/2} e^{-\frac{\|\omega\|_2^2}{4a}} d\omega.$$

La mesure $d\rho(\omega) = (\pi/a)^{d/2} e^{-\|\omega\|_2^2/(4a)} d\omega$ est une mesure gaussienne positive, finie et invariante par $\omega \mapsto -\omega$. Le théorème de Bochner garantit immédiatement que le noyau gaussien est semi-défini positif.

3.2.3 Théorème d'Aronszajn

Reprenons le raisonnement de ce chapitre. Le théorème du représentant nous a montré que pour notre problème d'optimisation, si on a un espace de Hilbert $\mathcal{H}$ et une application φ , il nous suffit seulement de calculer des produits scalaires $k(x, x') = \langle \varphi(x), \varphi(x') \rangle_{\mathcal{H}}$.

Ensuite, nous avons développé une théorie sur les noyaux SDP pour les construire facilement. Le théorème de Bochner nous permet d'en construire autant que l'on souhaite à partir de mesures positives finies.

Or, nous ne sommes pas assurés que pour un tel noyau construit spécifiquement pour nos données, il existe un espace $\mathcal{H}$ et un plongement φ qui convienne. C'est ici que le théorème d'Aronszajn intervient : il nous assure que tout noyau SDP est le produit scalaire d'un espace unique de fonctions appelé RKHS.

Théorème (Théorème d'Aronszajn) . Soit $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ un noyau symétrique semi-défini positif. Alors, il existe un unique espace de Hilbert $\mathcal{H}_k$ constitué de fonctions de $\mathcal{X}$ dans $\mathbb{R}$, et une application canonique $\varphi_k : \mathcal{X} \rightarrow \mathcal{H}_k$, tels que :

1. Pour tout $x \in \mathcal{X}$, la fonction $k_x := k(x, \cdot)$ appartient à $\mathcal{H}_k$.
2. **Propriété de reproduction** : pour toute fonction $f \in \mathcal{H}_k$ et tout $x \in \mathcal{X}$,

$$f(x) = \langle f, k_x \rangle_{\mathcal{H}_k}. \quad (3.2.3)$$

3. Pour tous $x, x' \in \mathcal{X}$:

$$k(x, x') = \langle k_x, k_{x'} \rangle_{\mathcal{H}_k} = \langle \varphi_k(x), \varphi_k(x') \rangle_{\mathcal{H}_k} \quad \text{en posant } \varphi_k(x) = k_x. \quad (3.2.4)$$

L'espace $\mathcal{H}_k$ est appelé l'*espace de Hilbert à noyau reproduisant* (RKHS) associé à k .

Démonstration (Esquisse de preuve) La construction s'effectue en trois étapes principales :

1. **Espace pré-hilbertien** : on pose $\mathcal{H}_0 = \text{vect}\{k_x \mid x \in \mathcal{X}\}$. Pour deux combinaisons linéaires $f = \sum_{i=1}^m a_i k_{x_i}$ et $g = \sum_{j=1}^{m'} b_j k_{z_j}$, on munit $\mathcal{H}_0$ de la forme bilinéaire :

$$\langle f, g \rangle_{\mathcal{H}_0} := \sum_{i=1}^m \sum_{j=1}^{m'} a_i b_j k(x_i, z_j).$$

La symétrie et la positivité de k assurent que cette forme est symétrique et positive. De plus, par définition, $\langle f, k_x \rangle_{\mathcal{H}_0} = \sum_{i=1}^m a_i k(x_i, x) = f(x)$.

2. **Caractère défini** : d'après l'inégalité de Cauchy-Schwarz appliquée à cette forme semi-définie positive, pour tout $x \in \mathcal{X}$:

$$|f(x)| = |\langle f, k_x \rangle_{\mathcal{H}_0}| \leq \|f\|_{\mathcal{H}_0} \sqrt{k(x, x)}.$$

Ainsi, $\|f\|_{\mathcal{H}_0} = 0 \implies \forall x \in \mathcal{X}, f(x) = 0$, donc f est identiquement nulle. L'espace $\mathcal{H}_0$ est donc un espace pré-hilbertien séparé.

3. **Complétion fonctionnelle** : on complète $\mathcal{H}_0$ en un espace de Hilbert $\mathcal{H}_k$. Grâce à la majoration ponctuelle issue de Cauchy-Schwarz, toute suite de Cauchy converge ponctuellement vers une fonction bien définie sur $\mathcal{X}$. Les éléments complétés restent donc de véritables fonctions, et la propriété de reproduction s'étend par continuité.

Nous avons donc l'équivalence : les noyaux semi-définis positifs sont exactement des produits scalaires de *feature maps*. Choisir un noyau k ou choisir un espace $(\mathcal{H}, \varphi)$ est donc la même chose, sauf que l'on sait explicitement calculer k . On peut donc complètement oublier $\mathcal{H}$ et φ dans le processus d'apprentissage.

Proposition (La recette) L'algorithme complet d'apprentissage supervisé à noyau se résume donc en 4 étapes :

- *Choix de k* : On définit un noyau k mesurant la "distance" de nos données en fonction de leur forme.
- *Matrice de Gram* : On calcule l'ensemble des paires $K_{i,j} = k(x_i, x_j)$ pour construire la matrice de Gram $K \in \mathbb{R}^{n \times n}$.
- *Optimisation* : On résout un problème d'optimisation pour trouver $\hat{\alpha}_S \in \mathbb{R}^n$:

$$\hat{\alpha}_S \in \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n l(y_i, (K\alpha)_i) + \frac{\lambda}{2} \alpha^\top K \alpha. \quad (3.2.5)$$

- *Inférence* : Une fois trouvé, on put prédire le label de tout nouveau x par :

$$\hat{y} = \sum_{j=1}^n \hat{\alpha}_j k(x, x_j). \quad (3.2.6)$$

3.3 Séparateurs à Vaste Marge (SVM)

L'algorithme des Séparateurs à Vaste Marge (*Support Vector Machines*) illustre parfaitement la puissance des méthodes à noyaux. On commence par formuler le problème géométrique dans le cas linéaire élémentaire, avant d'en dériver la version duale et d'y injecter le *Kernel Trick*.

3.3.1 Cas linéairement séparable : Maximisation de la marge

Soit un échantillon d'apprentissage $S = ((x_1, y_1), \dots, (x_n, y_n)) \in (\mathbb{R}^d \times \{-1, 1\})^n$. On suppose dans un premier temps les données linéairement séparables : il existe un hyperplan passant par l'origine $H(\theta) = \{z \in \mathbb{R}^d \mid \theta^\top z = 0\}$ tel que pour tout $i \in \llbracket 1, n \rrbracket$, $y_i(\theta^\top x_i) > 0$.

Proposition (Distance à l'hyperplan) Pour tout $\theta \neq 0$, la distance orthogonale d'un point $x \in \mathbb{R}^d$ à l'hyperplan $H(\theta)$ est donnée par :

$$\text{dist}(x, H(\theta)) = \frac{|\theta^\top x|}{\|\theta\|_2}. \quad (3.3.1)$$

Sous l'hypothèse de séparabilité, $y_i(\theta^\top x_i) = |\theta^\top x_i|$. L'objectif consiste à trouver l'hyperplan qui maximise la distance minimale aux observations d'entraînement (la marge géométrique) :

$$\max_{\theta \neq 0} \min_{i \in \llbracket 1, n \rrbracket} \frac{y_i(\theta^\top x_i)}{\|\theta\|_2}. \quad (3.3.2)$$

Le problème étant invariant par changement d'échelle $\theta \mapsto c\theta$ ($c > 0$), on impose la normalisation canonique $\min_i y_i(\theta^\top x_i) = 1$. Maximiser $1/\|\theta\|_2$ sous cette contrainte équivaut à minimiser $\frac{1}{2}\|\theta\|_2^2$. En relâchant l'égalité en une inégalité (qui sera saturée à l'optimum), on obtient le programme quadratique convexe :

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{2} \|\theta\|_2^2 \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad y_i(\theta^\top x_i) \geq 1. \quad (3.3.3)$$

3.3.2 Cas non séparable : Variables d'écart et perte charnière

En pratique, les données se chevauchent ou comportent du bruit, rendant la séparation stricte impossible. Pour autoriser des erreurs tout en les contrôlant, on introduit des variables d'écart (*slack variables*) $\xi_i \geq 0$ pénalisées par un coefficient $C > 0$:

$$\min_{\theta \in \mathbb{R}^d, \xi \in \mathbb{R}^n} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad y_i(\theta^\top x_i) \geq 1 - \xi_i \quad \text{et} \quad \xi_i \geq 0. \quad (3.3.4)$$

Ce problème admet toujours des solutions admissibles dès que les ξ_i sont choisis suffisamment grands.

Proposition (Pont avec la minimisation du risque empirique) À θ fixé, l'objectif est strictement croissant en chaque variable ξ_i . À l'optimum, ξ_i atteint donc sa plus petite borne autorisée par les contraintes, soit :

$$\xi_i = \max(0, 1 - y_i(\theta^\top x_i)) = (1 - y_i(\theta^\top x_i))_+. \quad (3.3.5)$$

En substituant cette expression, en divisant l'objectif par $nC > 0$ et en posant $\lambda := \frac{1}{nC}$, le problème géométrique coïncide rigoureusement avec un problème d'ERM régularisé pour la perte charnière (*hinge loss*) :

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n (1 - y_i(\theta^\top x_i))_+ + \frac{\lambda}{2} \|\theta\|_2^2. \quad (3.3.6)$$

3.3.3 Dualité de Wolfe et formulation duale

Le problème primal étant convexe avec des contraintes affines, les conditions de qualification de Slater sont vérifiées (par exemple pour $\theta = 0$ et $\xi_i = 2$), garantissant la dualité forte.

On introduit les multiplicateurs de Lagrange $\alpha_i \geq 0$ (pour les contraintes de marge) et $\beta_i \geq 0$ (pour la positivité de ξ_i) :

$$\mathcal{L}(\theta, \xi, \alpha, \beta) = \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i \theta^\top x_i + \xi_i - 1) - \sum_{i=1}^n \beta_i \xi_i. \quad (3.3.7)$$

Proposition Minimisons le Lagrangien :

- **En ξ :** Le Lagrangien s'écrit $\sum_{i=1}^n (C - \alpha_i - \beta_i) \xi_i + \dots$. L'infimum par rapport à $\xi_i \geq 0$ vaut $-\infty$ sauf si $C - \alpha_i - \beta_i = 0$. Cette condition permet d'éliminer $\beta_i \geq 0$, ce qui équivaut à la contrainte de boîte :

$$0 \leq \alpha_i \leq C \quad \forall i \in \llbracket 1, n \rrbracket. \quad (3.3.8)$$

- **En θ :** La condition d'annulation du gradient $\nabla_\theta \mathcal{L} = \theta - \sum_{i=1}^n \alpha_i y_i x_i = 0$ impose :

$$\theta^* = \sum_{i=1}^n \alpha_i y_i x_i. \quad (3.3.9)$$

En réinjectant ces relations dans $\mathcal{L}$, le problème dual de Wolfe s'écrit sous forme d'un programme quadratique concave :

$$\max_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i^\top x_j) \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad 0 \leq \alpha_i \leq C. \quad (3.3.10)$$

Remarque Les données d'entrée x_i n'interviennent dans ce problème dual que par leurs produits scalaires $x_i^\top x_j$.

3.3.4 Le Kernel SVM (SVM à noyau)

Soit k un noyau semi-défini positif sur $\mathcal{X}$. En vertu du théorème d'Aronszajn, k définit implicitement un RKHS $\mathcal{H}_k$ et une application canonique φ_k tels que $k(x, x') = \langle \varphi_k(x), \varphi_k(x') \rangle_{\mathcal{H}_k}$. On formule le problème primal directement dans $\mathcal{H}_k$:

$$\min_{\theta \in \mathcal{H}_k} \frac{1}{n} \sum_{i=1}^n (1 - y_i \langle \theta, \varphi_k(x_i) \rangle_{\mathcal{H}_k})_+ + \frac{\lambda}{2} \|\theta\|_{\mathcal{H}_k}^2. \quad (3.3.11)$$

Grâce au *Kernel Trick*, on substitue directement chaque produit scalaire par l'évaluation du noyau $k(x_i, x_j) = K_{i,j}$ dans la formulation duale. En posant le changement de variable $\mu_i = \lambda \alpha_i$ (avec $\lambda = \frac{1}{nC}$, ce qui donne $0 \leq \mu_i \leq \frac{1}{n}$), le problème dual s'écrit sous forme matricielle :

$$\boxed{\max_{\mu \in \mathbb{R}^n} \sum_{i=1}^n \mu_i - \frac{1}{2\lambda} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \mu_i \mu_j k(x_i, x_j) \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad 0 \leq \mu_i \leq \frac{1}{n}.} \quad (3.3.12)$$

Il s'agit d'un problème d'optimisation quadratique à n variables, dont la résolution numérique s'effectue uniquement à l'aide de la matrice de Gram $K \in \mathcal{S}_n^+(\mathbb{R})$.

Proposition (Règle de décision et vecteurs de support) D'après l'expression de θ^* et la propriété de reproduction dans le RKHS, la fonction de décision optimale pour classer un nouveau point $x \in \mathcal{X}$ est :

$$f(x) = \text{sign} \left(\sum_{i=1}^n \hat{\alpha}_i y_i k(x_i, x) \right). \quad (3.3.13)$$

D'après les conditions de complémentarité de Karush-Kuhn-Tucker (KKT), les coefficients $\hat{\alpha}_i$ sont strictement nuls pour tous les points situés en dehors de la marge. La décision ne dépend donc que des points vérifiant $\hat{\alpha}_i > 0$, appelés *vecteurs de support* :

$$f(x) = \text{sign} \left(\sum_{i \in \text{Support}} \hat{\alpha}_i y_i k(x_i, x) \right). \quad (3.3.14)$$

Ce résultat garantit la parcimonie du modèle et rend l'évaluation en phase d'inférence très rapide.

Chapitre 4

Théorie de l'Apprentissage et Minimisation du Risque Empirique

Contents

4.1	Convexification du risque et substituts convexes	27
4.1.1	Reparamétrisation et identité de marge	27
4.1.2	Risque de substitution et théorème de calibration	28
4.2	Décomposition du Risque et Classes Finies	28
4.2.1	Décomposition canonique de l'excès de risque	28
4.2.2	Majoration de l'erreur du risque – cas fini	29
4.2.3	Majoration de l'erreur du risque – cas infini	31
4.3	Complexité de Rademacher	32
4.3.1	Le procédé de symétrisation	33
4.3.2	Définitions et propriétés	33
4.3.3	Le retour du cas fini	34
4.3.4	Principe de contraction	36
4.3.5	Modèles linéaires contraints et dualité de normes	36
4.4	Théorèmes d'excès de risque pour les modèles linéaires	38
4.4.1	Borne en espérance	38
4.4.2	Borne à grande probabilité	39

Dans les chapitres précédents, nous avons présenté différentes méthodes d'apprentissage basées sur la minimisation du risque empirique (ERM, *Empirical Risk Minimization*). Or la seule analyse de la convergence de ces méthodes que nous ayons faite est la décomposition biais-variance du risque ainsi que la décomposition de son erreur en deux : l'erreur *d'approximation* et l'erreur *d'estimation*.

Dans la seconde partie de ce chapitre, nous nous attardons justement sur l'erreur faite sur le risque lors de l'apprentissage. Pour cela, nous développons une nouvelle théorie basée sur la complexité de l'espace de recherche $\mathcal{F}$.

Mais avant, nous développons le concept de *convexification du risque* dans la première partie. En effet, pour certaines fonction de pertes (notamment la *0-1 loss*) nous ne disposons pas de "bonnes" propriétés analytiques pour utiliser des algorithmes d'optimisation. Nous présentons ainsi une méthode permettant d'y remédier.

4.1 Convexification du risque et substituts convexes

4.1.1 Reparamétrisation et identité de marge

En classification binaire, on cherche à prédire une étiquette parmi deux classes $\mathcal{Y} = \{-1, 1\}$ via une fonction $f : \mathcal{X} \rightarrow \mathcal{Y}$. La mesure naturelle d'erreur est la perte 0-1 (*0-1 loss*) définie par :

$$l(y, \hat{y}) = \mathbb{1}_{y \neq \hat{y}}. \quad (4.1.1)$$

La minimisation exacte du risque empirique sous la perte 0-1 sur une classe d'hypothèses générale est un problème combinatoire NP-difficile. De plus, le risque empirique associé est une fonction constante par morceaux de ses paramètres : son gradient est nul presque partout, ce qui rend inapplicables les méthodes d'optimisation par descente de gradient.

Pour lever ce verrou, on reparamétrise le classifieur discret à l'aide d'une fonction à valeurs réelles.

Définition (Prédicteur par fonction signe randomisée) . Soit $g : \mathcal{X} \rightarrow \mathbb{R}$ une fonction réelle mesurable. On définit le classifieur binaire $f : \mathcal{X} \rightarrow \{-1, 1\}$ par $f(x) = \text{sgn}(g(x))$ avec la convention :

$$\text{sgn}(u) = \begin{cases} 1 & \text{si } u > 0, \\ -1 & \text{si } u < 0, \\ U \sim \text{Unif}(\{-1, 1\}) & \text{si } u = 0, \end{cases} \quad (4.1.2)$$

où U est une variable aléatoire auxiliaire indépendante du couple d'observations $(X, Y) \sim \mathbb{P}$.

Cette reparamétrisation permet de découpler la *décision brute* (donnée par $\text{sgn}(g(x))$) de la *confiance / distance à la frontière* (quantifiée par l'amplitude $|g(x)|$). On introduit alors la *marge fonctionnelle* $u = Yg(X)$:

- $u > 0$: la prédiction est correcte ($\text{sgn}(g(X)) = Y$).
- $u < 0$: la prédiction est erronée ($\text{sgn}(g(X)) \neq Y$).
- $u = 0$: le point se situe exactement sur la frontière de décision.

Proposition (Identité de marge pour la perte 0-1) Le risque théorique de classification binaire associé à $f = \text{sgn} \circ g$ s'exprime comme l'espérance d'une fonction scalaire de la marge fonctionnelle $Yg(X)$:

$$R(f) = \mathbb{E}_{(X,Y) \sim \mathbb{P}} [\Phi_{0-1}(Yg(X))], \quad (4.1.3)$$

avec la fonction de saut :

$$\Phi_{0-1}(u) = \mathbb{1}_{u < 0} + \frac{1}{2} \mathbb{1}_{u=0}. \quad (4.1.4)$$

Démonstration En explicitant l'espérance conjointe sur (X, Y) et sur la variable de randomisation U :

$$\begin{aligned} R(f) &= \mathbb{E}_{(X,Y),U} [\mathbb{1}_{f(X) \neq Y}] \\ &= \mathbb{E} [\mathbb{1}_{g(X) \neq 0} \mathbb{1}_{f(X) \neq Y}] + \mathbb{E} [\mathbb{1}_{g(X)=0} \mathbb{1}_{f(X) \neq Y}] \\ &= \mathbb{P}(Yg(X) < 0) + \mathbb{E} [\mathbb{1}_{g(X)=0} \mathbb{1}_{U \neq Y}]. \end{aligned}$$

Comme U est indépendante de (X, Y) et uniformément distribuée sur $\{-1, 1\}$, $\mathbb{P}(U \neq Y \mid g(X) = 0) = \frac{1}{2}$. D'où :

$$R(f) = \mathbb{P}(Yg(X) < 0) + \frac{1}{2} \mathbb{P}(g(X) = 0) = \mathbb{E}_{(X,Y) \sim \mathbb{P}} [\Phi_{0-1}(Yg(X))].$$

4.1.2 Risque de substitution et théorème de calibration

Dans le cas général, lorsque l'on fait face à une fonction de coût l non continue ou non convexe, on définit une fonction convexe Φ et une fonction g pour définir un risque de substitution ou *surrogate risk* $R_\Phi(g)$.

Définition (Risque de substitution – Surrogate Risk) . Soit $\Phi : \mathbb{R} \rightarrow [0, \infty[$ une fonction convexe. Le risque de substitution associé à Φ pour une fonction $g : \mathcal{X} \rightarrow \mathbb{R}$ est défini par :

$$R_\Phi(g) := \mathbb{E}_{(X,Y) \sim \mathbb{P}} [\Phi(Yg(X))]. \quad (4.1.5)$$

Exemples classiques :

- Perte charnière (Hinge) : $\Phi(u) = (1 - u)_+$,
- Perte quadratique : $\Phi(u) = (1 - u)^2$,
- Perte logistique : $\Phi(u) = \ln(1 + e^{-u})$.

Or, nous ne sommes pas assurés qu'optimiser sur $R_\Phi(g)$ nous donne une solution optimale $\hat{f}$ pour notre risque initial $R(f)$. Le théorème de calibration ci-dessous nous donne une estimation de l'erreur commise.

Théorème (Calibration – Zhang, Bartlett-Jordan-McAuliffe) . Soit $\Phi : \mathbb{R} \rightarrow [0, \infty[$ une fonction convexe, dérivable en 0 avec $\Phi'(0) < 0$. Il existe une fonction convexe, non décroissante et continue $\psi : [0, 1] \rightarrow [0, \infty[$ vérifiant $\psi(0) = 0$ telle que pour toute fonction mesurable $g : \mathcal{X} \rightarrow \mathbb{R}$:

$$\psi(R(\text{sgn} \circ g) - R^*) \leq R_\Phi(g) - \inf_{g'} R_\Phi(g'). \quad (4.1.6)$$

En particulier :

- Pour la perte charnière : $\psi(t) = t$,
- Pour la perte quadratique : $\psi(t) = t^2$,
- Pour la perte logistique : $\psi(t) \geq \frac{t^2}{2}$.

4.2 Décomposition du Risque et Classes Finies

4.2.1 Décomposition canonique de l'excès de risque

Dans les chapitres précédents, nous avons décomposé le risque empirique en une erreur *d'approximation* (liée au choix de l'espace de fonction à optimiser $\mathcal{F}$) et une erreur *d'estimation* (liée à l'échantillon restreint S de taille n que l'on considère, purement statistique) :

$$R(\hat{f}_S) - R^* = \underbrace{\left(R(\hat{f}_S) - \inf_{f \in \mathcal{F}} R(f) \right)}_{\text{estimation}} + \underbrace{\left(\inf_{f \in \mathcal{F}} R(f) + R^* \right)}_{\text{approximation}}, \quad (4.2.1)$$

avec $\hat{f}_S$ le minimiseur du risque empirique sur $\mathcal{F}$. Soit $f^\dagger \in \mathcal{F}$ le meilleur prédicteur théorique possible dans $\mathcal{F}$. On a donc :

$$R(\hat{f}_S) - R^* = R(\hat{f}_S) - R(f^\dagger) + R(f^\dagger) - R^*. \quad (4.2.2)$$

Or ici, $\hat{f}_S$ est calculé sur un échantillon fixé S , on ne peut donc pas appliquer la LGN sur la taille de l'échantillon pour obtenir une convergence p.s vers $f^\dagger$. Pour séparer ce qui dépend des

données et ce qui dépend de l'estimation dans ce risque, on introduit les risques empiriques $\hat{R}_S(\hat{f}_S)$ et $\hat{R}_S(f^\dagger)$:

$$R(\hat{f}_S) - R(f^\dagger) = \left[R(\hat{f}_S) - \hat{R}_S(\hat{f}_S) \right] + \left[\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger) \right] + \left[\hat{R}_S(f^\dagger) - R(f^\dagger) \right]. \quad (4.2.3)$$

En regardant chaque élément :

- $R(\hat{f}_S) - \hat{R}_S(\hat{f}_S)$ correspond à l'erreur commise sur le calcul du risque de l'estimateur restreint à l'échantillon S . Comme $\hat{f}_S \in \mathcal{F}$, on peut le majorer brutalement par le pire estimateur de la classe $\mathcal{F}$:

$$R(\hat{f}_S) - \hat{R}_S(\hat{f}_S) \leq \sup_{f \in \mathcal{F}} \left| R(f) - \hat{R}_S(f) \right|. \quad (4.2.4)$$

- $\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger)$ correspond à l'erreur empirique du risque entre l'optimum calculé et le meilleur théorique,
- $\hat{R}_S(f^\dagger) - R(f^\dagger)$ correspond à l'erreur commise sur le calcul du risque sur l'échantillon S du meilleur estimateur théorique $f^\dagger$. De la même façon que pour le premier, on peut le majorer par le pire estimateur de $\mathcal{F}$:

$$\hat{R}_S(\hat{f}_S) - R(f^\dagger) \leq \sup_{f \in \mathcal{F}} \left| \hat{R}_S(f) - R(f) \right|. \quad (4.2.5)$$

Le terme du milieu $\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger)$ correspond à l'erreur d'optimisation. Cette erreur est simplement due à la performance de notre algorithme ou à la puissance de notre unité de calcul. On peut donc la majorer arbitrairement par une constante ε_{opt} (qui dépend par exemple de la puissance de notre GPU, du temps de calcul, etc.).

Proposition (Décomposition canonique de l'excès de risque) Soit $\mathcal{F}$ une classe d'hypothèses, $\hat{f}_S \in \arg \min_{f \in \mathcal{F}} \hat{R}_S(f)$ le minimiseur empirique et $f^\dagger \in \arg \min_{f \in \mathcal{F}} R(f)$ le meilleur estimateur possible dans $\mathcal{F}$. L'erreur d'estimation se majore par :

$$\boxed{R(\hat{f}_S) - R(f^\dagger) \leq 2 \sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| + \varepsilon_{opt}} \quad (4.2.6)$$

où $\varepsilon_{opt} = \hat{R}_S(\hat{f}_S) - \inf_{f \in \mathcal{F}} \hat{R}_S(f)$ représente l'erreur d'optimisation numérique (nulle si la minimisation est exacte).

On souhaite maintenant estimer (ou borner) l'erreur maximale que l'on peut faire dans $\mathcal{F}$ en estimant le risque $\hat{R}_S$ sur l'échantillon S : $\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)|$. On va pour cela distinguer deux cas : si $\mathcal{F}$ est une classe finie ou non.

4.2.2 Majoration de l'erreur du risque – cas fini

On suppose ici que $\mathcal{F}$ dispose d'un nombre fini d'éléments $|\mathcal{F}| = M < \infty$ et que les pertes sont bornées par l_∞ . Pour majorer cette quantité, on utilise l'inégalité de Hoeffding.

Théorème (Inégalité de Hoeffding) . Soit $(X_k)_{1 \leq k \leq n}$ une suite de variables aléatoires réelles *indépendantes* telles que pour deux suites $(a_k)_{1 \leq k \leq n}$ et $(b_k)_{1 \leq k \leq n}$, on ait :

$$\forall k \in \llbracket 1, n \rrbracket, \quad \mathbb{P}(a_k \leq X_k \leq b_k) = 1. \quad (4.2.7)$$

Alors, pour tout $t \geq 0$, on peut minorer la concentration de $S_n = X_1 + \dots + X_n$ autour de sa moyenne en probabilité :

$$\mathbb{P}(|S_n - \mathbb{E}(S_n)| \geq t) \leq 2 \exp \left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2} \right). \quad (4.2.8)$$

Proposition Or ici, pour toute fonction $f \in \mathcal{F}$ fixée indépendante de l'échantillon S , la perte sur chaque observation $Z_i = l(y_i, f(x_i))$ est une variable aléatoire réelle telle que :

1. Les $(Z_i)_{1 \leq i \leq n}$ sont i.i.d.
2. Pour tout $i \in \llbracket 1, n \rrbracket$, on a $Z_i \in [0, l_\infty]$.
3. La moyenne empirique est : $\hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n Z_i$.
4. L'espérance est : $\mathbb{E}[Z_i] = R(f)$.

On peut donc appliquer l'inégalité de Hoeffding sur la moyenne empirique $\hat{R}_S(f)$ avec $a_k = 0$ et $b_k = l_\infty/n$ pour tout $k \in \llbracket 1, n \rrbracket$. D'où :

$$\forall t \geq 0, \quad \mathbb{P}(|R(f) - \hat{R}_S(f)| \geq t) \leq 2 \exp \left(-\frac{2nt^2}{l_\infty^2} \right). \quad (4.2.9)$$

Sachant contrôler chaque estimateur de la classe $\mathcal{F}$ indépendamment, on souhaite maintenant les contrôler tous¹. Pour contrôler simultanément tous les estimateurs de la classe, on applique l'inégalité de Boole (*Union Bound*)² sur les $M = |\mathcal{F}|$ éléments :

$$\begin{aligned} \mathbb{P} \left(\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \geq t \right) &\leq \sum_{f \in \mathcal{F}} \mathbb{P} \left(|\hat{R}_S(f) - R(f)| \geq t \right) \\ &\leq 2|\mathcal{F}| \exp \left(-\frac{2nt^2}{l_\infty^2} \right). \end{aligned}$$

En posant cette probabilité d'erreur égale à $\delta \in]0, 1[$, on obtient le seuil d'écart $t = l_\infty \sqrt{\frac{\ln(2|\mathcal{F}|/\delta)}{2n}}$.

Théorème (Borne uniforme pour les classes finies) . Sous les hypothèses $l(y, f(x)) \in [0, l_\infty]$ et $|\mathcal{F}| < \infty$, pour tout $\delta \in]0, 1[$, avec probabilité au moins $1 - \delta$ sur le tirage de $S \sim \mathbb{P}^{\otimes n}$:

$$\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \leq l_\infty \sqrt{\frac{\ln(2|\mathcal{F}|/\delta)}{2n}}. \quad (4.2.10)$$

Par conséquent, pour le minimiseur empirique exact $\hat{f}_S$, on a avec probabilité au moins $1 - \delta$:

$$R(\hat{f}_S) \leq \inf_{f \in \mathcal{F}} R(f) + 2l_\infty \sqrt{\frac{\ln(2|\mathcal{F}|/\delta)}{2n}} + \varepsilon_{\text{opt}}. \quad (4.2.11)$$

Remarque Le résultat est immédiat ici. Si les hypothèses sont vérifiées, nous sommes capables de borner le risque. En revanche, si $|\mathcal{F}| = \infty$, les bornes de celui-ci explosent. Nous devons donc décrire une nouvelle théorie pour traiter ce cas.

1. "Un anneau unique pour les contrôler tous".

2. Cette inégalité découle des propriétés des mesures. Elle affirme que pour une famille au plus dénombrable de partie mesurables $A_1, A_2, A_3, \dots$, pour toute mesure μ , on a : $\mu \left(\bigcup_n A_n \right) \leq \sum_n \mu(A_n)$.

4.2.3 Majoration de l'erreur du risque – cas infini

Analysons le résultat précédent : on calcule la probabilité que $\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \geq t$ par une somme finie d'unions d'événements sur $\mathcal{F}$. C'est donc de là que la borne explose si $\mathcal{F}$ est infini.

La solution est donc de traiter la classe entière de fonctions $\mathcal{F}$ en considérant une application g définie sur l'échantillon S qui lui associe l'erreur la plus importante possible sur la classe de fonctions $\mathcal{F}$:

$$g(S) := \sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)). \quad (4.2.12)$$

C'est donc maintenant l'échantillon qui définit la variation d'erreur. On souhaite toujours la borner : on introduit donc la *méthode des différences bornées*.

Définition (Différences Bornées) . Soit $f : Z_1 \times \cdots \times Z_n \rightarrow \mathbb{R}$ une application. On dit que f vérifie la *condition des différences bornées* pour les constantes $(c_1, \dots, c_n) \in \mathbb{R}^n$ si pour tout $i \in \llbracket 1, n \rrbracket$ on a :

$$\sup_{z_1, \dots, z_i, \dots, z_n, z'_i} |f(z_1, \dots, z_i, \dots, z_n) - f(z_1, \dots, z'_i, \dots, z_n)| \leq c_i. \quad (4.2.13)$$

Autrement dit, si l'on change la i ème entrée z_i de f en z'_i , sa sortie ne bouge pas plus de c_i , et cela pour tout i .

Proposition (Différences bornées sur g) Appliquons les différences bornées sur l'application g . Puisque pour tout $f \in \mathcal{F}$, le risque $R(f)$ ne dépend pas des données S , on a :

$$\hat{R}_S(f) - \hat{R}_{S'}(f) = \frac{1}{n} (l(z_i, f) - l(z'_i, f)). \quad (4.2.14)$$

Or, par hypothèse, la perte directe est contenue dans $[0, l_\infty]$. Nous devons passer au sup pour conclure sur g .

Lemme (Passage au sup) Soient $u, v : \mathcal{F} \rightarrow \mathbb{R}$ deux applications. Pour tout $f \in \mathcal{F}$, on a l'implication suivante :

$$|u(f) - v(f)| \leq c \longrightarrow \left| \sup_{f \in \mathcal{F}} u(f) - \sup_{f \in \mathcal{F}} v(f) \right| \leq c. \quad (4.2.15)$$

En appliquant le lemme précédent avec $c = \frac{l_\infty}{n}$, on en déduit que pour tout $i \in \llbracket 1, n \rrbracket$:

$$|g(S) - g(S')| = \left| \sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) - \sup_{f \in \mathcal{F}} (\hat{R}_{S'}(f) - R(f)) \right| \leq \frac{l_\infty}{n}. \quad (4.2.16)$$

La fonction g vérifie donc la propriété des différences bornées avec les constantes coordonnées :

$$c_i = \frac{l_\infty}{n} \quad \text{pour tout } i \in \llbracket 1, n \rrbracket. \quad (4.2.17)$$

Théorème (Inégalité de McDiarmid) . Soient $Z_1, \dots, Z_n$ des variables aléatoires indépendantes à valeurs dans un espace mesurable $\mathcal{Z}$. Soit $\phi : \mathcal{Z}^n \rightarrow \mathbb{R}$ une fonction vérifiant l'hypothèse des différences bornées pour des constantes $(c_1, \dots, c_n) \in \mathbb{R}_+^n$. Alors, pour tout $t \geq 0$:

$$\mathbb{P}(\phi(S) - \mathbb{E}_S[\phi(S)] \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right), \quad (4.2.18)$$

$$\mathbb{P}(\mathbb{E}_S[\phi(S)] - \phi(S) \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right), \quad (4.2.19)$$

$$\mathbb{P}(|\phi(S) - \mathbb{E}_S[\phi(S)]| \geq t) \leq 2 \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right). \quad (4.2.20)$$

On décompose la déviation uniforme bilatérale en deux déviations unilatérales :

$$\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \leq \sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) + \sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)). \quad (4.2.21)$$

Puisque chacune de ces deux applications admet les constantes de variations coordonnées $c_i = \frac{l_\infty}{n}$, la somme des carrés s'évalue explicitement par :

$$\sum_{i=1}^n c_i^2 = \sum_{i=1}^n \left(\frac{l_\infty}{n}\right)^2 = \frac{l_\infty^2}{n}. \quad (4.2.22)$$

L'application de la forme unilatérale de McDiarmid fournit alors le contrôle de concentration suivant :

Proposition (Concentration de la déviation uniforme unilatérale) Sous l'hypothèse d'une perte bornée $l(y, f(x)) \in [0, l_\infty]$, pour tout $\delta \in]0, 1[$, chacune des inégalités suivantes est vérifiée avec probabilité au moins $1 - \delta$ sur le tirage de $S \sim \mathbb{P}^{\otimes n}$:

$$\sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) \leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) \right] + l_\infty \sqrt{\frac{\ln(1/\delta)}{2n}}, \quad (4.2.23)$$

$$\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] + l_\infty \sqrt{\frac{\ln(1/\delta)}{2n}}. \quad (4.2.24)$$

Remarque Ce résultat marque une avancée théorique majeure : la déviation uniforme se concentre à une vitesse en $\mathcal{O}(1/\sqrt{n})$ autour de son espérance, *sans aucune hypothèse de finitude ou de structure* sur la classe $\mathcal{F}$.

Toutefois, le problème n'est pas encore résolu : la déviation se concentre autour d'une espérance théorique inconnue $\mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) \right]$. Si la classe $\mathcal{F}$ est arbitrairement riche (par exemple l'ensemble de toutes les fonctions mesurables), cette espérance vaut identiquement 1 pour tout n . L'objectif de la section suivante consiste donc à borner cette espérance résiduelle à l'aide de la *symétrisation* et de la *complexité de Rademacher*.

4.3 Complexité de Rademacher

Notation Pour alléger les calculs, on note $z = (x, y)$ et $z_i = (x_i, y_i)$ tirés selon la loi $\mathbb{P}$. Pour tout prédicteur $f \in \mathcal{F}$ et toute fonction de perte $l : \mathcal{Y} \times \mathcal{X} \rightarrow \mathbb{R}$, on associe la fonction de perte induite $h_f : \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$ définie par $h_f(z) = l(y, f(x))$. On étudie ainsi la classe de fonctions :

$$\mathcal{H} = l \circ \mathcal{F} = \{z \mapsto l(y, f(x)) \mid f \in \mathcal{F}\}. \quad (4.3.1)$$

Le risque empirique devient $\hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n h_f(z_i)$ et le risque théorique $R(f) = \mathbb{E}_z[h_f(z)]$.

La section précédente a établi que la déviation uniforme se concentre autour de son espérance théorique :

$$\mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] = \mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) \right) \right]. \quad (4.3.2)$$

Le processus de *symétrisation* permet de majorer cette espérance par une quantité calculable à partir de perturbations aléatoires de l'échantillon.

4.3.1 Le procédé de symétrisation

Proposition (Symétrisation par échantillon fantôme) Soit $S' = (z'_1, \dots, z'_n) \sim \mathbb{P}^{\otimes n}$ un second échantillon (dit *échantillon fantôme*) indépendant de S et de même loi. Par linéarité de l'espérance :

$$\mathbb{E}_z[h(z)] = \mathbb{E}_{S'} \left[\frac{1}{n} \sum_{i=1}^n h(z'_i) \right]. \quad (4.3.3)$$

Le premier échantillon S étant indépendant de S' , on regroupe les termes :

$$\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) = \mathbb{E}_{S'} \left[\frac{1}{n} \sum_{i=1}^n (h(z'_i) - h(z_i)) \right]. \quad (4.3.4)$$

Par convexité de la fonction supremum (inégalité de Jensen, $\sup \mathbb{E} \leq \mathbb{E} \sup$), puis en intégrant par rapport à S :

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) \right) \right] \leq \mathbb{E}_{S,S'} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n (h(z'_i) - h(z_i)) \right]. \quad (4.3.5)$$

Proposition (Injection des variables de Rademacher) Posons $d_i = h(z'_i) - h(z_i)$. Comme z_i et z'_i sont i.i.d., $d_i \stackrel{\mathcal{L}}{=} -d_i$. Soient $\varepsilon_1, \dots, \varepsilon_n$ des variables de Rademacher indépendantes de S, S' telles que $\mathbb{P}(\varepsilon_i = 1) = \mathbb{P}(\varepsilon_i = -1) = \frac{1}{2}$. Alors $(d_1, \dots, d_n) \stackrel{\mathcal{L}}{=} (\varepsilon_1 d_1, \dots, \varepsilon_n d_n)$ pour tout $h \in \mathcal{H}$ conjointement :

$$\begin{aligned} \mathbb{E}_{S,S'} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n d_i \right] &= \mathbb{E}_{S,S',\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \varepsilon_i (h(z'_i) - h(z_i)) \right] \\ &\leq \mathbb{E}_{S',\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \varepsilon_i h(z'_i) \right] + \mathbb{E}_{S,\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n (-\varepsilon_i) h(z_i) \right]. \end{aligned}$$

Comme $-\varepsilon_i \stackrel{\mathcal{L}}{=} \varepsilon_i$, les deux termes sont égaux et l'échantillon fantôme s'élimine :

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) \right) \right] \leq 2 \mathbb{E}_{S,\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \varepsilon_i h(z_i) \right]. \quad (4.3.6)$$

4.3.2 Définitions et propriétés

Les calculs précédents nous ont introduit une nouvelle grandeur (voir Équation 4.3.6) définissant la *complexité de Rademacher*.

Définition (Complexité de Rademacher) . Soit $\mathcal{H}$ une classe de fonctions à valeurs réelles et $S = (z_1, \dots, z_n)$. On définit la *complexité de Rademacher empirique* de l'espace $\mathcal{H}$ sous S par :

$$\mathfrak{R}_S(\mathcal{H}) = \mathbb{E}_\varepsilon \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i) \right]. \quad (4.3.7)$$

Plus généralement, lorsque $\mathcal{H}$ dépend d'une loi de probabilité $\mathbb{P}$, on définit la complexité de Rademacher par :

$$\mathfrak{R}_n(\mathcal{H}) = \mathbb{E}_{S \sim \mathbb{P}^{\otimes n}} [\mathfrak{R}_S(\mathcal{H})] \quad (4.3.8)$$

où les $\varepsilon_i \in \{-1, 1\}$.

Cette complexité traduit la capacité de l'espace de fonction $\mathcal{H}$ à approximer données S bruitées par les ε_i . Une classe pour laquelle c'est le cas a une complexité de l'ordre de $\sup_h \sup_i |h(z_i)|$, dans le cas contraire, sa complexité de Rademacher tends vers 0 à mesure que n augmente. Nous pouvons donc conclure notre procédé de symétrisation par le théorème suivant.

Théorème (Symétrisation) . Soit $\mathcal{H}$ une classe de fonctions, une famille de valeurs $z_1, \dots, z_n$ et une famille de coefficients $\varepsilon_i \in \{-1, 1\}^n$. On a le résultat suivant :

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\frac{1}{n} \sum_{i \leq n} h(z_i) - \mathbb{E}_z[h(z)] \right) \right] \leq 2\mathfrak{R}_n(\mathcal{H}) \quad (4.3.9)$$

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i \leq n} h(z_i) \right) \right] \leq 2\mathfrak{R}_n(\mathcal{H}) \quad (4.3.10)$$

Remarque Le second résultat est issu du même processus de symétrisation appliqué à la classe de fonctions $-\mathcal{H} = \{-h \mid h \in \mathcal{H}\}$.

Définissons maintenant quelques propriétés calculatoires de la complexité de Rademacher.

Propriété (Complexité de Rademacher) . Soient $\mathcal{H}$ une classe de fonctions, $h_0 \in \mathcal{H}$ et $c \in \mathbb{R}$, on a :

- *Homogénéité* : $\mathfrak{R}_S(c\mathcal{H}) = |c|\mathfrak{R}_S(\mathcal{H})$.
- *Translation* : $\mathfrak{R}_S(\mathcal{H} + h_0) = \mathfrak{R}_S(\mathcal{H})$.
- *Enveloppe convexe* : $\mathfrak{R}_S(\text{conv } \mathcal{H}) = \mathfrak{R}_S(\mathcal{H})$.

Démonstration 1. Par linéarité de l'opérateur d'application, de la somme, du sup et de l'espérance. Le cas $c < 0$ est vérifié par le fait que l'application de la fonction $\varepsilon \mapsto -\varepsilon$ ne change pas la loi des variables aléatoires et donc la valeur de l'espérance.

2. On observe que $\sup_h \frac{1}{n} \sum_{i \leq n} \varepsilon_i (h + h_0)(z_i) = \frac{1}{n} \sum_{i \leq n} \varepsilon_i h_0(z_i) + \sup_h \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i)$. Or la moyenne sur le premier terme s'annule du fait de la distribution uniforme des ε_i sur $\{-1, 1\}$.

3. Pour ε fixé, l'application $h \mapsto \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i)$ est linéaire et donc maximisée sur un point extrême de l'enveloppe convexe de $\mathcal{H}$. Point qui est déjà inclut dans le sup.

4.3.3 Le retour du cas fini

On souhaite ici appliquer les résultats théoriques précédents sur la complexité de Rademacher au cas fini vu en début de chapitre. Pour cela, on définit pour chaque fonction $h \in \mathcal{H}$ un vecteur

a_h tel que :

$$a_h = (h(z_1), \dots, h(z_n))^\top \in \mathbb{R}^n. \quad (4.3.11)$$

Si $\mathcal{H}$ est fini, cet ensemble de vecteurs forme un sous-ensemble fini A de $\mathbb{R}^n$ tel que $A = \{a_h \mid h \in \mathcal{H}\} \subset \mathbb{R}^n$. On peut donc observer l'égalité entre la complexité de Rademacher $\mathfrak{R}_S(\mathcal{H})$ de $\mathcal{H}$ et le maximum de la moyenne des a_i pondérée par les ε_i pour tout $a \in A$:

$$\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i) = \max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i. \quad (4.3.12)$$

Développons un peu de théorie pour borner le terme de gauche à l'aide du lemme de Massart.

Lemme (Massart) Soit $A \subset \mathbb{R}^n$ fini, non vide et $\rho = \max_{a \in A} \|a\|_2$. Alors on a :

$$\mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \quad (4.3.13)$$

Pour la démonstration de ce lemme, on s'appuie sur le lemme de Hoeffding ci-dessous.

Lemme (Hoeffding) Pour toute variable aléatoire réelle X centrée (i.e $\mathbb{E}[X] = 0$) et bornée $X \in [u, v]$ p.s, alors :

$$\forall \lambda \in \mathbb{R}, \quad \mathbb{E} [e^{\lambda X}] \leq \exp \left(\frac{\lambda^2 (v-u)^2}{8} \right). \quad (4.3.14)$$

On dit alors que X est *sous-gaussienne* de paramètre $\sigma^2 = \frac{(v-u)^2}{4}$. On notera alors $X \sim \mathcal{G}(\sigma^2)$.

Démonstration Soit $A \subset \mathbb{R}^n$ borné par $\rho = \max_{a \in A} \|a\|_2$. Pour tout $a = (a_1, \dots, a_n)^\top \in A$, on pose $X_i = \varepsilon_i a_i$ où les ε_i sont les variables de Rademacher.

On remarque que :

$$\mathbb{E}(X_i) = a_i \mathbb{E}(\varepsilon_i) = 0, \quad \text{et} \quad X_i \in [-|a_i|, |a_i|]. \quad (4.3.15)$$

D'après le lemme de Hoeffding, on a donc que $X_i \sim \mathcal{G}(\sigma^2)$ avec $\sigma^2 = \frac{4a_i^2}{4} = a_i^2$, d'où :

$$\forall \lambda \in \mathbb{R}, \quad \mathbb{E}_\varepsilon [e^{\lambda \varepsilon_i a_i}] \leq \exp \left(\frac{\lambda^2 a_i^2}{2} \right). \quad (4.3.16)$$

Or les ε_i sont deux à deux indépendants, donc en posant $W_a = \sum_{i \leq n} \varepsilon_i a_i$, on a :

$$\begin{aligned} \mathbb{E}_\varepsilon [e^{\lambda W_a}] &= \mathbb{E}_\varepsilon \left[\prod_{i \leq n} e^{\lambda \varepsilon_i a_i} \right] = \prod_{i \leq n} \mathbb{E}_\varepsilon [e^{\lambda \varepsilon_i a_i}] \\ &\leq \prod_{i \leq n} \exp \left(\frac{\lambda^2 a_i^2}{2} \right) = \exp \left(\frac{\lambda^2 \|a\|_2^2}{2} \right). \end{aligned}$$

Or, par construction, $\|a\|_2^2 \leq \rho^2$, donc $W_a \sim \mathcal{G}(\rho^2)$. On peut donc appliquer successivement l'inégalité de Jensen et poser $\lambda = \sqrt{2 \ln |A|} / \rho$:

$$\begin{aligned} e^{\lambda \mathbb{E}[\max_{a \in A} W_a]} &\leq \mathbb{E} [e^{\lambda \max_{a \in A} W_a}] \leq \sum_{a \in A} \mathbb{E} [e^{\lambda W_a}] \leq |A| \exp \left(\frac{\lambda^2 \rho^2}{2} \right) \\ &\iff \mathbb{E} \left[\max_{a \in A} W_a \right] \leq \frac{\ln |A|}{\lambda} + \frac{\lambda \rho^2}{2} \\ &\iff \mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \end{aligned}$$

Proposition En appliquant le lemme de Massart sur le contexte présenté en début de sous-section, on obtient l'inégalité suivante :

$$\mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \quad (4.3.17)$$

Pour faire le lien avec la complexité de Rademacher, il suffit de prendre l'espérance sur 4.3.12 et on retrouve le résultat énoncé pour le cas fini en 4.2.2 :

$$\mathfrak{R}_S(\mathcal{H}) = \mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] = \mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \quad (4.3.18)$$

4.3.4 Principe de contraction

Les résultats présentés jusqu'à maintenant sont très forts pour donner une borne supérieure de l'erreur d'approximation que l'on fait en choisissant une classe de fonction $\mathcal{F}$. Or, si l'on regarde bien l'expression de la complexité de Rademacher, on s'aperçoit que celle-ci dépend de la fonction de *loss* utilisée :

$$\mathfrak{R}_n(\mathcal{H}) = \mathfrak{R}_n(l \circ \mathcal{F}) = \mathbb{E}_{S, \varepsilon} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i \leq n} \varepsilon_i l(y_i, f(x_i)) \right]. \quad (4.3.19)$$

Or, on souhaiterait être capable de calculer cette complexité indépendamment du processus d'apprentissage, et donc de la fonction de perte l choisie. C'est le principe de contraction qui l'assure.

Proposition (Principe de contraction) Soit $A \subset \mathbb{R}^n$ et $g_1, \dots, g_n : \mathbb{R} \rightarrow \mathbb{R}$ des applications G -lipschitziennes. On a alors :

$$\mathbb{E}_\varepsilon \left[\sup_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i g_i(a_i) \right] \leq G \cdot \mathbb{E}_\varepsilon \left[\sup_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i (a_i) \right]. \quad (4.3.20)$$

Si l'on fait l'hypothèse simple que la fonction de perte utilisée $l(y_i, \cdot)$ est G -lipschitzienne, on a alors que :

$$\mathfrak{R}_S(l \circ \mathcal{F}) \leq G \cdot \mathfrak{R}_S(\mathcal{F}), \quad \text{donc} \quad \mathfrak{R}_n(l \circ \mathcal{F}) \leq G \cdot \mathfrak{R}_n(\mathcal{F}) \quad (4.3.21)$$

pour un domaine $A = \{(f(x_1), \dots, f(x_n)) \mid f \in \mathcal{F}\}$.

Remarque Ce principe de contraction permet donc de séparer complètement les erreurs d'apprentissage dues à l'échantillon de celles dues à l'approximation faite par le choix de la classe $\mathcal{F}$. Ainsi, grâce à la contraction, la borne d'excès de risque sépare les aspects du problème en trois parties : l'optimisation numérique et la régularité du critère sont prises en charge par la constante G et la *loss* l , la géométrie de l'architecture d'apprentissage est entièrement contenue dans $\mathfrak{R}_n(\mathcal{F})$, et les fluctuations statistiques de l'échantillon sont, quant à elles, contenues dans le terme de McDiarmid en $\mathcal{O}(1/\sqrt{n})$.

4.3.5 Modèles linéaires contraints et dualité de normes

On applique les résultats précédents à des prédicteurs linéaires sous contrainte de régularisation :

$$\mathcal{F} = \{f_\theta : x \mapsto \theta^\top \varphi(x) \mid \Omega(\theta) \leq D\}, \quad (4.3.22)$$

où $\varphi : \mathcal{X} \rightarrow \mathbb{R}^d$ est une *feature map*, Ω une norme sur $\mathbb{R}^d$ et $D > 0$ le rayon de la boule de contrainte. On rappelle que la *norme duale* Ω^* de Ω est définie par :

$$\Omega^*(u) = \sup_{\Omega(\theta) \leq 1} \langle \theta, u \rangle. \quad (4.3.23)$$

La complexité de Rademacher de cette classe se réduit à l'espérance de la norme duale d'une somme de vecteurs symétriques :

$$\begin{aligned} \mathfrak{R}_n(\mathcal{F}) &= \mathbb{E}_{S, \varepsilon} \left[\sup_{\Omega(\theta) \leq D} \frac{1}{n} \sum_{i \leq n} \varepsilon_i \theta^\top \varphi(x_i) \right] \\ &= \mathbb{E}_{S, \varepsilon} \left[\sup_{\Omega(\theta) \leq D} \frac{1}{n} \theta^\top (\Phi^\top \varepsilon) \right] \\ &= \frac{D}{n} \mathbb{E}_{S, \varepsilon} [\Omega^*(\Phi^\top \varepsilon)], \end{aligned}$$

où $\Phi \in \mathbb{R}^{n \times d}$ est la matrice dont la i -ème ligne est $\varphi(x_i)^\top$, et $\Phi^\top \varepsilon = \sum_{i \leq n} \varepsilon_i \varphi(x_i) \in \mathbb{R}^d$.

Proposition (Cas euclidien ℓ_2) On pose $\Omega = \|\cdot\|_2$, auto-duale ($\Omega^* = \|\cdot\|_2$). Par concavité de la racine carrée (inégalité de Jensen) et cyclicité de la trace :

$$\begin{aligned} \mathfrak{R}_n(\mathcal{F}) &= \frac{D}{n} \mathbb{E} [\|\Phi^\top \varepsilon\|_2] \\ &\leq \frac{D}{n} \sqrt{\mathbb{E} [\|\Phi^\top \varepsilon\|_2^2]} \\ &= \frac{D}{n} \sqrt{\mathbb{E} [\text{tr}(\Phi \Phi^\top \varepsilon \varepsilon^\top)]} \\ &= \frac{D}{n} \sqrt{\mathbb{E}_S [\text{tr}(\Phi \Phi^\top)]} \quad \text{car } \mathbb{E}_\varepsilon [\varepsilon \varepsilon^\top] = I_n \text{ et } \varepsilon \perp S \\ &= \frac{D}{n} \sqrt{\sum_{i=1}^n \mathbb{E}_x [\|\varphi(x)\|_2^2]} \\ &= \frac{D}{\sqrt{n}} \sqrt{\mathbb{E}_x [\|\varphi(x)\|_2^2]}. \end{aligned}$$

La dimension ambiante d a disparu : seule compte l'énergie moyenne des descripteurs $\mathbb{E}[\|\varphi(x)\|_2^2]$ et le rayon D . Le résultat reste donc valide en dimension infinie ($d = \infty$), notamment pour les méthodes à noyaux (RKHS).

Proposition (Cas parcimonieux ℓ_1 – Lasso) On pose $\Omega = \|\cdot\|_1$, dont la norme duale est $\Omega^* = \|\cdot\|_\infty$. On suppose que les descripteurs sont bornés composante par composante : $|\varphi_j(x)| \leq B_\infty$ pour tout $j \in \llbracket 1, d \rrbracket$ et tout $x \in \mathcal{X}$. On a :

$$\mathfrak{R}_n(\mathcal{F}) = \frac{D}{n} \mathbb{E}_{S, \varepsilon} [\|\Phi^\top \varepsilon\|_\infty] = \frac{D}{n} \mathbb{E}_{S, \varepsilon} \left[\max_{j \leq d} \left| \sum_{i \leq n} \varepsilon_i \varphi_j(x_i) \right| \right]. \quad (4.3.24)$$

Puisque $|u| = \max\{u, -u\}$, on ramène ce terme au maximum sur l'ensemble fini $A \subset \mathbb{R}^n$ des $2d$ vecteurs colonnes orientés :

$$A = \left\{ \pm (\varphi_j(x_1), \dots, \varphi_j(x_n))^\top \mid j \leq d \right\} \subset \mathbb{R}^n. \quad (4.3.25)$$

Ainsi, $\max_{j \leq d} |\sum_{i \leq n} \varepsilon_i \varphi_j(x_i)| = \max_{a \in A} \sum_{i \leq n} \varepsilon_i a_i$. On a $|A| \leq 2d$, et pour tout $a \in A$:

$$\|a\|_2^2 = \sum_{i \leq n} \varphi_j(x_i)^2 \leq n B_\infty^2 \implies \rho = \max_{a \in A} \|a\|_2 \leq B_\infty \sqrt{n}. \quad (4.3.26)$$

En appliquant le lemme de Massart conditionnellement à S :

$$\frac{1}{n} \mathbb{E}_\varepsilon \left[\max_{a \in A} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n} \leq B_\infty \sqrt{\frac{2 \ln(2d)}{n}}. \quad (4.3.27)$$

Comme cette borne est indépendante de S , elle survit à l'espérance $\mathbb{E}_S$:

$$\mathfrak{R}_n(\mathcal{F}) \leq D B_\infty \sqrt{\frac{2 \ln(2d)}{n}}. \quad (4.3.28)$$

Remarque (Comparaison géométrique ℓ_1 versus ℓ_2) En dimension finie d , si chaque composante vérifie $|\varphi_j(x)| \leq B_\infty$, l'énergie euclidienne est de l'ordre de $\mathbb{E}[\|\varphi(x)\|_2^2] \approx d B_\infty^2$, ce qui donne une complexité ℓ_2 en $\mathcal{O}(D B_\infty \sqrt{d/n})$.

Contraire la norme ℓ_1 remplace le facteur $\sqrt{d}$ par $\sqrt{\ln(2d)}$. C'est la justification quantitative fondamentale du Lasso : en très grande dimension ($d \gg n$), la régularisation ℓ_1 brise le fléau de la dimension dès lors que le vecteur cible admet une représentation parcimonieuse.

4.4 Théorèmes d'excès de risque pour les modèles linéaires

Nous pouvons désormais assembler l'ensemble des résultats établis au cours de ces deux sections pour borner l'erreur d'estimation des modèles linéaires.

4.4.1 Borne en espérance

Théorème (Excès de risque en espérance) . Soit $\mathcal{F} = \{f_\theta : \|\theta\|_2 \leq D\}$ et supposons que pour tout $y \in \mathcal{Y}$, la perte $u \mapsto l(y, u)$ est G -lipschitzienne. Soit $\hat{f}_S$ un minimiseur exact du risque empirique sur $\mathcal{F}$. Alors :

$$\mathbb{E}_S[R(\hat{f}_S)] \leq \inf_{\|\theta\|_2 \leq D} R(f_\theta) + \frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x[\|\varphi(x)\|_2^2]}. \quad (4.4.1)$$

Démonstration Soit $f^\dagger \in \arg \min_{f \in \mathcal{F}} R(f)$. La décomposition canonique donne :

$$\mathbb{E}_S[R(\hat{f}_S)] - R(f^\dagger) = \mathbb{E}_S[R(\hat{f}_S) - \hat{R}_S(\hat{f}_S)] + \mathbb{E}_S[\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger)] + \mathbb{E}_S[\hat{R}_S(f^\dagger) - R(f^\dagger)].$$

Par définition du minimiseur empirique exact, $\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger) \leq 0$. De plus, $f^\dagger$ étant indépendant de S , $\mathbb{E}_S[\hat{R}_S(f^\dagger)] = R(f^\dagger)$, donc le dernier terme est nul. Il reste :

$$\begin{aligned} \mathbb{E}_S[R(\hat{f}_S)] - R(f^\dagger) &\leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] \\ &\leq 2 \mathfrak{R}_n(l \circ \mathcal{F}) \quad (\text{par symétrisation}) \\ &\leq 2G \mathfrak{R}_n(\mathcal{F}) \quad (\text{par contraction de Ledoux-Talagrand}) \\ &\leq \frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x[\|\varphi(x)\|_2^2]} \quad (\text{par la borne euclidienne}). \end{aligned}$$

4.4.2 Borne à grande probabilité

Théorème (Excès de risque à grande probabilité) . On suppose de plus que la fonction de perte est bornée : $l(y, f(x)) \in [0, l_\infty]$ presque sûrement. Pour tout $\delta \in]0, 1[$, avec probabilité au moins $1 - \delta$ sur le tirage de $S \sim \mathbb{P}^{\otimes n}$:

$$R(\hat{f}_S) \leq \inf_{\|\theta\|_2 \leq D} R(f_\theta) + \frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x [\|\varphi(x)\|_2^2]} + 2l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}. \quad (4.4.2)$$

Démonstration On reprend la décomposition trajectorielle :

$$R(\hat{f}_S) - R(f^\dagger) \leq \sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) + (\hat{R}_S(f^\dagger) - R(f^\dagger)).$$

1. D'après McDiarmid, $\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] + l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}$ avec probabilité au moins $1 - \delta/2$. L'espérance est bornée par $\frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}[\|\varphi(x)\|_2^2]}$ comme démontré précédemment.
2. Pour le prédicteur fixé $f^\dagger$, l'inégalité de Hoeffding unilatérale assure que $\hat{R}_S(f^\dagger) - R(f^\dagger) \leq l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}$ avec probabilité au moins $1 - \delta/2$.

Un *Union Bound* sur les deux événements garantit que les deux inégalités ont lieu simultanément avec probabilité au moins $1 - \delta$.

Remarque (Bilan structurel : le compromis régularisation/généralisation) Cette borne synthétise tout le problème de l'apprentissage statistique dans une seule formule :

$$R(\hat{f}_S) \leq \underbrace{\inf_{\|\theta\|_2 \leq D} R(f_\theta)}_{\text{Erreur d'approximation}} + \underbrace{\frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x [\|\varphi(x)\|_2^2]} + 2l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}}_{\text{Erreur d'estimation}}.$$

- *Rôle du rayon D* : augmenter D enrichit la classe d'hypothèses, ce qui fait décroître l'erreur d'approximation mais croître linéairement l'erreur d'estimation. Le réglage de l'hyperparamètre de régularisation (le choix de D) matérialise l'arbitrage exact entre sous-apprentissage et sur-apprentissage.
- *Vitesse universelle en $n^{-1/2}$* : que la classe soit finie ou infinie, la vitesse de convergence reste universellement en $\mathcal{O}(1/\sqrt{n})$.

Chapitre A

Inégalités de concentration et régime sous-gaussien

Traitement du signal

Chapitre 1

Signaux à temps discrets et Systèmes

Contents

1.1	Systèmes et signaux à temps discret	42
1.1.1	Généralités	42
1.1.2	Opérations élémentaires	44
1.1.3	Systèmes discrets	44
1.2	Convolution et corrélation	45
1.2.1	Convolution linéaire	45
1.2.2	Convolution circulaire et Zero-Padding	46
1.2.3	Corrélation à temps discret	46
1.2.4	Formulaire de sommes classiques utiles	47

1.1 Systèmes et signaux à temps discret

1.1.1 Généralités

Définition (Signal) . On définit un signal numérique comme une suite $(x_n)_{n \in \mathbb{Z}}$ à valeurs dans $\mathbb{C}$. En pratique, elle sera finie et sera stockée sous forme de vecteur :

$$x = [\dots, x(-1), x(0), x(1), x(2), \dots]^T$$

Exemple Voyons quelques exemples de signaux caractéristiques :

- **L'échantillon unitaire**, aussi appelé Dirac :

$$x(n) = \delta(n) = \begin{cases} 1 & \text{si } n = 0 \\ 0 & \text{sinon} \end{cases} \quad (1.1.1)$$

- **Fonction de Heaviside** :

$$x(n) = u(n) = \begin{cases} 1 & \text{si } n \geq 0 \\ 0 & \text{sinon} \end{cases} \quad (1.1.2)$$

- **Sinus/Cosinus réel :**

$$x(n) = A \cos(2\pi f_0 n) \quad (1.1.3)$$

Avec $A \in \mathbb{R}_+$ l'amplitude du signal.

- **Exponentiel réel :**

$$x(n) = a^n, \quad a \in \mathbb{R} \quad (1.1.4)$$

- **Exponentiel complexe :**

$$x(n) = c^n, \quad c \in \mathbb{C} \quad (1.1.5)$$

Si $c = e^{j\pi f_0}$ (i.e. c appartient au cercle unité), alors :

$$x(n) = e^{j\pi n f_0} = \cos(\pi n f_0) + j \sin(\pi n f_0)$$

- **Porte :**

$$x(n) = \begin{cases} 1 & \text{si } N \leq n \leq M \\ 0 & \text{sinon} \end{cases} \quad N, M \in \mathbb{Z} \quad (1.1.6)$$

Remarque On peut remarquer que l'échantillon unitaire peut s'écrire en fonction de la fonction de Heaviside sous la forme :

$$\forall n \in \mathbb{Z}, \quad \delta(n) = u(n) - u(n-1)$$

De même, on a :

$$u(n) = \sum_{k=-\infty}^n \delta(k)$$

Et pour le signal porte entre N et M :

$$x(n) = u(n-N) - u(n-M-1)$$

Définition (Signal fini/périodique) . Un signal $(x_n)_{n \in \mathbb{Z}}$ est dit *de longueur finie* s'il existe $N_1, N_2 \in \mathbb{Z}$ tels que :

$$\forall n \notin \llbracket N_1, N_2 \rrbracket, \quad x(n) = 0 \quad (1.1.7)$$

On dira alors que le signal a une longueur de $N_2 - N_1 + 1$. On dira aussi qu'il est périodique s'il existe $N \in \mathbb{N}^*$ tel que :

$$\forall n \in \mathbb{Z}, \quad x(n+N) = x(n) \quad (1.1.8)$$

Définition (Énergie et Puissance) . Pour tout signal discret $(x_n)_{n \in \mathbb{Z}}$, on définit :

- Son **énergie totale** :

$$E = \sum_{n=-\infty}^{+\infty} |x(n)|^2 \quad (1.1.9)$$

Si $E < \infty$, le signal est dit à énergie finie.

- Sa **puissance moyenne** :

$$P_{\text{moy}} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=-N}^N |x(n)|^2 \quad (1.1.10)$$

Exemple Pour l'échelon unité $x(n) = u(n)$:

$$E = \sum_{n=0}^{+\infty} |1|^2 \longrightarrow +\infty \quad (\text{énergie infinie})$$

$$P_{\text{moy}} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=0}^N 1 = \lim_{N \rightarrow \infty} \frac{N+1}{2N+1} = \frac{1}{2}$$

1.1.2 Opérations élémentaires

Définition (Opérations) . Soit $(x_n)_{n \in \mathbb{Z}}$ un signal à valeurs dans $\mathbb{C}$. On définit les opérations suivantes :

- **Décalage** : Pour $n_0 \in \mathbb{Z}$, on a :

$$\forall n \in \mathbb{Z}, \quad y(n) = x(n - n_0)$$

Si $n_0 > 0$ alors y est retardé de n_0 , sinon si $n_0 < 0$ il est avancé.

- **Retournement** : $\forall n \in \mathbb{Z}, \quad y(n) = x(-n)$.
- **Sous-échantillonnage** :

$$y(n) = x(Mn)$$

où $M > 0$ est appelé *facteur de sous-échantillonnage*.

- **Sur-échantillonnage** :

$$\forall n \in \mathbb{Z}, \quad y(n) = x(n/N) \quad \Longleftrightarrow \quad y(n) = \begin{cases} x(n/N) & \text{si } n = 0, \pm N, \pm 2N, \dots \\ 0 & \text{sinon} \end{cases}$$

où $N > 0$ est le facteur de sur-échantillonnage.

Théorème (Décomposition) . Tout signal $(x_n)_{n \in \mathbb{Z}} \in \mathbb{C}^{\mathbb{Z}}$ peut être décomposé sous la forme :

$$\forall n \in \mathbb{Z}, \quad x(n) = \sum_{k \in \mathbb{Z}} x(k) \delta(n - k) \quad (1.1.11)$$

1.1.3 Systèmes discrets

Définition (Système) . Un système T est une transformation qui prend un signal $x(n)$ à son entrée et délivre un signal $y(n) = T[x(n)]$ à sa sortie.

On dira que T est *linéaire* si pour tous $\alpha_1, \alpha_2 \in \mathbb{C}$ et tous signaux x_1, x_2 , on a :

$$\forall n \in \mathbb{Z}, \quad T[\alpha_1 x_1(n) + \alpha_2 x_2(n)] = \alpha_1 T[x_1(n)] + \alpha_2 T[x_2(n)] \quad (1.1.12)$$

Propriété (Propriétés des systèmes à temps discret) . Soient $x, y \in \mathbb{C}^{\mathbb{Z}}$ deux signaux et T un système. On caractérise T par les propriétés :

- **Causalité** : Si pour tout $n_0 \in \mathbb{Z}$, la réponse $T[x(n_0)]$ ne dépend que des entrées et/ou sorties passées et présentes ($n \leq n_0$).
- **Invariance par décalage** : Si

$$T[x(n)] = y(n) \implies \forall n_0 \in \mathbb{Z}, \quad T[x(n - n_0)] = y(n - n_0) \quad (1.1.13)$$

Dans le cas contraire, le système est dit variant par décalage.

- **Stabilité (BIBO)** : Si pour toute entrée bornée, la sortie est bornée :

$$\exists A \in \mathbb{R}_+, \quad |x(n)| \leq A \implies \exists B \in \mathbb{R}_+, \quad |y(n)| \leq B \quad (1.1.14)$$

Un système linéaire et invariant par translation/décalage est désigné par l'acronyme **SLIT**.

Définition (Système physiquement réalisable) . Un système T est dit *physiquement réalisable* s'il est à la fois **stable** et **causal**.

Définition (Réponse impulsionnelle) . On appelle *réponse impulsionnelle* le signal $h(n)$ obtenu lorsque l'entrée est l'impulsion unitaire :

$$\forall n \in \mathbb{Z}, \quad h(n) = T[\delta(n)] \quad (1.1.15)$$

Proposition (Critères fondamentaux sur un SLIT) Soit un SLIT de réponse impulsionnelle $h(n)$:

- Le système est **stable** si et seulement si :

$$\sum_{n=-\infty}^{+\infty} |h(n)| < \infty \quad (1.1.16)$$

- Le système est **causal** si et seulement si :

$$\forall n < 0, \quad h(n) = 0 \quad (1.1.17)$$

1.2 Convolution et corrélation

Pour un SLIT, la décomposition de l'entrée donne :

$$y(n) = T[x(n)] = T \left[\sum_{k \in \mathbb{Z}} x(k) \delta(n - k) \right] = \sum_{k \in \mathbb{Z}} x(k) T[\delta(n - k)]$$

Puisque le système est invariant par décalage, $T[\delta(n - k)] = h(n - k)$, d'où :

$$y(n) = \sum_{k \in \mathbb{Z}} x(k) h(n - k) = (x * h)(n)$$

1.2.1 Convolution linéaire

Définition (Convolution temporelle) . Soient $x, y \in \mathbb{C}^{\mathbb{Z}}$. On définit le produit de convolution entre x et y par :

$$\forall n \in \mathbb{Z}, \quad (x * y)(n) = \sum_{k=-\infty}^{+\infty} x(k) y(n - k) \quad (1.2.1)$$

Propriété (Propriétés algébriques) . Pour tous signaux x, y, z :

- i) *Commutativité* : $x * y = y * x$.
- ii) *Associativité* : $(x * y) * z = x * (y * z)$.
- iii) *Distributivité* : $x * (y + z) = x * y + x * z$.

Propriété (Propriétés avec l'impulsion de Dirac) .

- i) Élément neutre : $(x * \delta)(n) = x(n)$.
- ii) Décalage : $x(n) * \delta(n - n_0) = x(n - n_0)$.
- iii) Composition d'impulsions : $\delta(n - n_0) * \delta(n - n_1) = \delta(n - n_0 - n_1)$.

Proposition (Signaux de longueur finie) Si x est de longueur N_x et y de longueur N_y , alors le signal convolué $z = x * y$ est de longueur finie au maximum égale à :

$$N_z = N_x + N_y - 1 \quad (1.2.2)$$

1.2.2 Convolution circulaire et Zero-Padding

Définition (Extension périodique) . Soit $x(n)$ un signal de longueur finie N . On définit son extension périodique $x_N(n)$ de période N par :

$$\forall n \in \mathbb{Z}, \quad x_N(n) = x(n \bmod N) = \sum_{p=-\infty}^{+\infty} x(n + pN) \quad (1.2.3)$$

Définition (Convolution circulaire) . Soient x et y deux signaux de même longueur finie N . La convolution circulaire est définie par :

$$\boxed{\forall n \in \llbracket 0, N - 1 \rrbracket, \quad (x \circ y)(n) = \sum_{k=0}^{N-1} y(k)x_N(n - k)} \quad (1.2.4)$$

Proposition (Formulation matricielle) En posant $x = [x(0), \dots, x(N-1)]^T$ et $y = [y(0), \dots, y(N-1)]^T$, la convolution circulaire $z = x \circ y$ s'écrit sous forme d'un produit matrice-vecteur :

$$z = C \cdot x \quad (1.2.5)$$

où C est une matrice circulante construite à partir de y . Pour $N = 3$:

$$\begin{bmatrix} z(0) \\ z(1) \\ z(2) \end{bmatrix} = \begin{bmatrix} y(0) & y(2) & y(1) \\ y(1) & y(0) & y(2) \\ y(2) & y(1) & y(0) \end{bmatrix} \begin{bmatrix} x(0) \\ x(1) \\ x(2) \end{bmatrix}$$

Théorème (Équivalence linéaire/circulaire par Zero-Padding) . Soient x et y de longueurs N_x et N_y . Pour obtenir la convolution linéaire exacte via une convolution circulaire :

1. On fixe la taille commune à $N = N_x + N_y - 1$.
2. On forme x_z en complétant x par $N_y - 1$ zéros, et y_z en complétant y par $N_x - 1$ zéros.
3. On a alors rigoureusement :

$$\boxed{\forall n \in \llbracket 0, N - 1 \rrbracket, \quad (x_z \circ y_z)(n) = (x * y)(n)} \quad (1.2.6)$$

1.2.3 Corrélation à temps discret

Définition (Intercorrélation et Autocorrélation) . Soient $x, y \in \mathbb{C}^{\mathbb{Z}}$. La fonction d'intercorrélation est définie par :

$$\forall n \in \mathbb{Z}, \quad C_{xy}(n) = \sum_{k=-\infty}^{+\infty} x(k)y(k-n) \quad (1.2.7)$$

Si $x = y$, on parle de fonction d'autocorrélation $C_{xx}(n)$.

Propriété (Propriétés de la corrélation) .

- i) Lien avec la convolution : $C_{xy}(n) = x(n) * y(-n)$.
- ii) Symétrie : $C_{xy}(n) = C_{yx}(-n)$, et pour l'autocorrélation : $C_{xx}(n) = C_{xx}(-n)$.
- iii) Maximum d'autocorrélation : $C_{xx}(0)$ est maximal et représente l'énergie du signal : $C_{xx}(0) = \sum |x(k)|^2 = E_x$.

Définition (Estimateurs pour signaux de longueur finie N) . Pour des signaux d'horizon N , on utilise :

- La forme biaisée :

$$C_{xy}(n) = \frac{1}{N} \sum_{k=0}^{N-n-1} x(k)y(k-n) \quad (1.2.8)$$

- La forme non biaisée :

$$C_{xy}(n) = \frac{1}{N-|n|} \sum_{k=0}^{N-n-1} x(k)y(k-n) \quad (1.2.9)$$

1.2.4 Formulaire de sommes classiques utiles

Proposition (Sommes finies et séries géométriques) • $\sum_{n=0}^{N-1} a^n = \frac{1-a^N}{1-a} \quad (a \neq 1)$

- $\sum_{n=0}^{+\infty} a^n = \frac{1}{1-a} \quad (|a| < 1)$
- $\sum_{n=0}^{N-1} na^n = \frac{(N-1)a^{N+1} - Na^N + a}{(1-a)^2}$
- $\sum_{n=0}^{+\infty} na^n = \frac{a}{(1-a)^2} \quad (|a| < 1)$
- $\sum_{n=0}^{N-1} n = \frac{N(N-1)}{2}, \quad \sum_{n=0}^{N-1} n^2 = \frac{N(N-1)(2N-1)}{6}$

Chapitre 2

Transformée de Fourier et TFD

Contents

2.1	Transformée de Fourier des signaux à temps discret (TFTD)	48
2.1.1	Définitions et conventions	48
2.1.2	Propriétés de la TFTD	49
2.2	Transformée de Fourier Discrète (TFD) et Algorithme FFT	50
2.2.1	Définition de la TFD	50
2.2.2	Algorithme de Fourier Rapide (FFT)	50
2.3	Troncature spectrale et Fenêtres d'apodisation	51

2.1 Transformée de Fourier des signaux à temps discret (TFTD)

2.1.1 Définitions et conventions

Définition (TFTD en convention fréquence) . Pour un signal $x(n)$ à temps discret, sa Transformée de Fourier à Temps Discret est la fonction continue $X(f)$ définie par :

$$X(f) = \sum_{n=-\infty}^{+\infty} x(n)e^{-2j\pi n f} \quad (2.1.1)$$

Remarques clés :

- Bien que $x(n)$ soit discret, $X(f)$ est une fonction continue de la fréquence f .
- $X(f) \in \mathbb{C}$, avec $X(f) = |X(f)|e^{j\text{Arg}(X(f))}$.
- $X(f)$ est périodique de période 1 : $X(f+1) = X(f)$.

Définition (TFTD inverse) . La reconstruction du signal temporel s'effectue sur une période fréquentielle unitaire :

$$x(n) = \int_{-1/2}^{+1/2} X(f)e^{2j\pi n f} df \quad (2.1.2)$$

On note symboliquement cette correspondance : $x(n) \xleftrightarrow{\mathcal{F}} X(f)$.

Remarque (Convention en pulsation ω) En posant la pulsation normalisée $\omega = 2\pi f$ ($\omega \in [-\pi, \pi]$) :

$$X(\omega) = \sum_{n=-\infty}^{+\infty} x(n)e^{-jn\omega}, \quad x(n) = \frac{1}{2\pi} \int_{-\pi}^{+\pi} X(\omega)e^{jn\omega} d\omega \quad (2.1.3)$$

$X(\omega)$ est alors périodique de période 2π . Le passage s'opère directement par $X(f) = X(\omega)|_{\omega=2\pi f}$.

2.1.2 Propriétés de la TFTD

Propriété (Propriétés fondamentales) . Soient $x(n) \xleftrightarrow{\mathcal{F}} X(f)$ et $y(n) \xleftrightarrow{\mathcal{F}} Y(f)$:

- **Linéarité** : $ax(n) + by(n) \xleftrightarrow{\mathcal{F}} aX(f) + bY(f)$.
- **Retournement temporel** : $x(-n) \xleftrightarrow{\mathcal{F}} X(-f)$.
- **Décalage temporel** : $x(n - n_0) \xleftrightarrow{\mathcal{F}} X(f)e^{-2j\pi n_0 f}$.
- **Modulation fréquentielle** : $x(n)e^{2j\pi n f_0} \xleftrightarrow{\mathcal{F}} X(f - f_0)$.
- **Convolution temporelle** : $(x * y)(n) \xleftrightarrow{\mathcal{F}} X(f) \cdot Y(f)$.
- **Multiplication temporelle** : $x(n) \cdot y(n) \xleftrightarrow{\mathcal{F}} (X * Y)(f) = \int_{-1/2}^{1/2} X(u)Y(f - u) du$.
- **Théorème de Parseval** : $\sum_{n=-\infty}^{+\infty} |x(n)|^2 = \int_{-1/2}^{1/2} |X(f)|^2 df$.

Proposition (Symétries de la TFTD)

Signal temporel $x(n)$	Spectre $X(f)$
Réel	Hermitien : $X(-f) = X^*(f)$ ($ X(f) $ pair, phase impaire)
Réel et pair	Réel et pair
Réel et impair	Imaginaire pur et impair
Imaginaire pur	Anti-hermitien
Imaginaire et pair	Imaginaire pur et pair
Imaginaire et impair	Réel et impair

Proposition (Paires usuelles de transformées)

$x(n)$	$X(f)$
$\delta(n)$	1
$\delta(n - n_0)$	$e^{-2j\pi n_0 f}$
1	$\delta(f)$ sur $[-1/2, 1/2]$
$e^{2j\pi f_0 n}$	$\delta(f - f_0)$
$\cos(2\pi f_0 n)$	$\frac{1}{2}[\delta(f - f_0) + \delta(f + f_0)]$
$\sin(2\pi f_0 n)$	$\frac{1}{2j}[\delta(f - f_0) - \delta(f + f_0)]$
$a^n u(n) \quad (a < 1)$	$\frac{1}{1 - ae^{-2j\pi f}}$

2.2 Transformée de Fourier Discrète (TFD) et Algorithme FFT

2.2.1 Définition de la TFD

On traite désormais des signaux réels ou complexes de durée finie N indexés sur $\llbracket 0, N-1 \rrbracket$.

Définition (TFD et TFD inverse) . La Transformée de Fourier Discrète (TFD) sur N points est donnée par :

$$X(m) = \sum_{n=0}^{N-1} x(n) e^{-2j\pi \frac{nm}{N}}, \quad m \in \llbracket 0, N-1 \rrbracket \quad (2.2.1)$$

Sa transformée inverse (ITFD) est définie par :

$$x(n) = \frac{1}{N} \sum_{m=0}^{N-1} X(m) e^{2j\pi \frac{nm}{N}}, \quad n \in \llbracket 0, N-1 \rrbracket \quad (2.2.2)$$

On note : $x(n) \xleftrightarrow{\text{TFD}} X(m)$.

Remarque (Échantillonnage et Résolution) La TFD correspond à l'échantillonnage de la TFTD continue $X(f)$ aux fréquences discrètes normalisées :

$$f_m = \frac{m}{N}, \quad m \in \llbracket 0, N-1 \rrbracket$$

La **résolution fréquentielle** d'une TFD à N points est donc :

$$\Delta f = \frac{1}{N} \quad (\text{ou } \Delta F = \frac{F_e}{N} \text{ en Hertz}) \quad (2.2.3)$$

Propriété (Propriétés spécifiques de la TFD) . Pour des séquences de longueur N :

- **Décalage circulaire temporel** : $x((n - n_0) \bmod N) \xleftrightarrow{\text{TFD}} X(m) e^{-2j\pi \frac{n_0 m}{N}}$.
- **Modulation** : $x(n) e^{2j\pi \frac{m_0 n}{N}} \xleftrightarrow{\text{TFD}} X((m - m_0) \bmod N)$.
- **Convolution circulaire** : $(x \circ y)(n) \xleftrightarrow{\text{TFD}} X(m) \cdot Y(m)$.
- **Produit temporel** : $x(n) \cdot y(n) \xleftrightarrow{\text{TFD}} \frac{1}{N} (X \circ Y)(m)$.

2.2.2 Algorithme de Fourier Rapide (FFT)

Proposition (Gain de complexité) Le calcul direct d'une TFD requiert N^2 multiplications et additions complexes. L'algorithme de la **FFT** (Fast Fourier Transform, e.g. Cooley-Tukey) exploite la décomposition par division de l'horizon pour $N = 2^p$ ($p \in \mathbb{N}$) et abaisse le coût algorithmique à :

$$\mathcal{O}(N \log_2 N) \quad \text{opérations complexes} \quad (2.2.4)$$

2.3 Troncature spectrale et Fenêtres d'apodisation

Traiter un signal numérique sur un horizon fini N revient à multiplier le signal théorique infini par une fenêtre temporelle de pondération $w(n)$:

$$x_{\text{tronqué}}(n) = x(n) \cdot w(n) \xleftrightarrow{\mathcal{F}} X(f) * W(f)$$

Ce produit de convolution par la réponse fréquentielle de la fenêtre $W(f)$ provoque un étalement de l'énergie :

- **Largeur du lobe principal** : régit la résolution fréquentielle (capacité à séparer deux raies proches).
- **Niveau des lobes secondaires** : régit la fuite spectrale (*spectral leakage*) vers les fréquences voisines.

Proposition (Comparatif des fenêtres usuelles d'apodisation sur N points)

Fenêtre	Définition temporelle $w(n), n \in \llbracket 0, N-1 \rrbracket$	Lobe principal	Atténuation
Rectangulaire	$w(n) = 1$	$\frac{2}{N}$	-13 dB
Triangulaire	$w(n) = 1 - \frac{ n-(N-1)/2 }{(N-1)/2}$	$\frac{4}{N}$	-25 dB
Hamming	$w(n) = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right)$	$\frac{4}{N}$	-41 dB
Blackman	$w(n) = 0.42 - 0.5 \cos\left(\frac{2\pi n}{N-1}\right) + 0.08 \cos\left(\frac{4\pi n}{N-1}\right)$	$\frac{6}{N}$	-57 dB

Chapitre 3

Filtrage par Transformée de Fourier

Contents

3.1	Transformée en Z	52
3.1.1	Définition et Domaine de Convergence (DC)	52
3.1.2	Propriétés de la Transformée en Z	53
3.2	Description des SLIT et Fonctions de Transfert	53
3.2.1	Équation aux différences linéaires à coefficients constants	53
3.2.2	Fonction de transfert en Z et Réponse fréquentielle	53
3.2.3	Classification : Filtres RIF vs Filtres RII	54
3.3	Filtres sélectifs et Synthèse de filtres RIF	54
3.3.1	Filtres sélectifs idéaux	54
3.3.2	Synthèse des filtres RIF par la méthode des fenêtres	54

3.1 Transformée en Z

3.1.1 Définition et Domaine de Convergence (DC)

Définition (Transformée en Z) . La transformée en Z d'un signal discret $(x_n)_{n \in \mathbb{Z}}$ est la fonction de la variable complexe $z \in \mathbb{C}$ définie par :

$$X(z) = \sum_{n=-\infty}^{+\infty} x(n)z^{-n} \quad (3.1.1)$$

$X(z)$ n'est définie que sur son **Domaine de Convergence (DC)** (ou *Region of Convergence, ROC*), l'ensemble des points $z \in \mathbb{C}$ pour lesquels la série converge absolument.

Propriété (Topologie du Domaine de Convergence) . La forme du DC dépend de la nature temporelle du signal :

- **Signal causal** ($x(n) = 0, \forall n < 0$) : Le DC est l'extérieur d'un disque, $|z| > R_{\max}$.
- **Signal anti-causal** ($x(n) = 0, \forall n > 0$) : Le DC est l'intérieur d'un disque, $|z| < R_{\min}$.

- **Signal bilatère** (support infini des deux côtés) : Le DC est une couronne circulaire fermée $R_{\min} < |z| < R_{\max}$.

Exemple Pour le signal $x(n) = a^n u(n)$ avec $a \in \mathbb{C}$:

$$X(z) = \sum_{n=0}^{+\infty} a^n z^{-n} = \sum_{n=0}^{+\infty} (az^{-1})^n = \frac{1}{1 - az^{-1}} = \frac{z}{z - a}, \quad \text{pour } |az^{-1}| < 1 \iff |z| > |a|$$

3.1.2 Propriétés de la Transformée en Z

Propriété (Propriétés fondamentales) . Soient $x(n) \xleftrightarrow{Z} X(z)$ et $y(n) \xleftrightarrow{Z} Y(z)$:

- **Linéarité** : $\alpha x(n) + \beta y(n) \xleftrightarrow{Z} \alpha X(z) + \beta Y(z)$.
- **Théorème du retard** :

$$\boxed{x(n - k) \xleftrightarrow{Z} z^{-k} X(z)} \quad (3.1.2)$$

L'opérateur z^{-1} modélise l'élément unitaire de retard mémoire.

- **Convolution** : $(x * y)(n) \xleftrightarrow{Z} X(z) \cdot Y(z)$.

3.2 Description des SLIT et Fonctions de Transfert

3.2.1 Équation aux différences linéaires à coefficients constants

Tout système linéaire invariant par décalage discret est régi par une équation aux différences reliant l'entrée $x(n)$ et la sortie $y(n)$:

$$y(n) = \sum_{i=0}^N a_i x(n - i) - \sum_{j=1}^M b_j y(n - j) \quad (3.2.1)$$

3.2.2 Fonction de transfert en Z et Réponse fréquentielle

En appliquant la transformée en Z aux deux membres de l'équation :

$$Y(z) = \sum_{i=0}^N a_i z^{-i} X(z) - \sum_{j=1}^M b_j z^{-j} Y(z) \iff Y(z) \left[1 + \sum_{j=1}^M b_j z^{-j} \right] = X(z) \sum_{i=0}^N a_i z^{-i}$$

Définition (Fonction de transfert) . La fonction de transfert $H(z)$ du système s'écrit sous forme rationnelle :

$$\boxed{H(z) = \frac{Y(z)}{X(z)} = \frac{\sum_{i=0}^N a_i z^{-i}}{1 + \sum_{j=1}^M b_j z^{-j}}} \quad (3.2.2)$$

Remarque (Lien avec la réponse fréquentielle) Si le cercle unité $|z| = 1$ est inclus dans le domaine de convergence du système, la réponse fréquentielle harmonique s'obtient par l'évaluation en $z = e^{j2\pi f T_e}$ (avec $T_e = 1/F_e$) :

$$H(f) = H(z) \Big|_{z=e^{j2\pi f T_e}} = \frac{\sum_{i=0}^N a_i e^{-j2\pi f i T_e}}{1 + \sum_{j=1}^M b_j e^{-j2\pi f j T_e}} \quad (3.2.3)$$

3.2.3 Classification : Filtres RIF vs Filtres RII

Proposition (Comparaison structurelle) • **Filtres RIF (Réponse Impulsionnelle Finie / Non-récurrents)** :

- Tous les coefficients récurrents sont nuls : $\forall j \geq 1, b_j = 0$.
- Équation temporelle : $y(n) = \sum_{i=0}^N a_i x(n-i)$.
- Réponse impulsionnelle finie : $h(n) = a_n$ pour $0 \leq n \leq N$, et $h(n) = 0$ ailleurs.
- Fonction de transfert : $H(z) = \sum_{i=0}^N a_i z^{-i}$ (polynôme en z^{-1} , aucun pôle non nul).
- **Propriétés** : Stabilité inconditionnelle, possibilité de concevoir des filtres à phase rigoureusement linéaire.

• **Filtres RII (Réponse Impulsionnelle Infinie / Récurrents)** :

- Au moins un coefficient $b_j \neq 0$.
- La sortie dépend des valeurs de sortie passées (rétroaction).
- $H(z)$ admet des pôles non nuls.
- **Condition de stabilité** : Tous les pôles de $H(z)$ doivent être strictement situés à l'intérieur du cercle unité ($|p_k| < 1$).

3.3 Filtres sélectifs et Synthèse de filtres RIF

3.3.1 Filtres sélectifs idéaux

Un filtre sélectif sélectionne des composantes spectrales. Les 4 gabarits idéaux symétriques sur $[-1/2, 1/2]$ sont :

- **Passe-Bas (PB)** de fréquence de coupure f_c : $|H(f)| = 1$ si $|f| \leq f_c$, 0 sinon.
- **Passe-Haut (PH)** : $|H_{PH}(f)| = 1 - |H_{PB}(f)|$.
- **Passe-Bande** entre f_{c1} et f_{c2} : $|H(f)| = 1$ si $f \in [-f_{c2}, -f_{c1}] \cup [f_{c1}, f_{c2}]$, 0 sinon.
- **Coupe-Bande (CB)** : $|H_{CB}(f)| = 1 - |H_{PBande}(f)|$.

3.3.2 Synthèse des filtres RIF par la méthode des fenêtres

Les filtres idéaux ci-dessus possèdent une réponse impulsionnelle infinie et non causale de type sinus cardinal (ex. pour le passe-bas : $h_{id}(n) = 2f_c \text{sinc}(2\pi f_c n)$). Ils sont donc physiquement irréalisables.

Définition (Méthode des fenêtres) . Pour synthétiser un filtre RIF causal d'ordre N :

1. Calcul analytique de la réponse idéale infinie par TF inverse : $h_{id}(n) = \int_{-1/2}^{1/2} H_{id}(f) e^{j2\pi f n} df$.
2. Troncature et apodisation par une fenêtre finie $w(n)$ d'ordre N :

$$h(n) = h_{id}(n - N/2) \cdot w(n), \quad n \in \llbracket 0, N-1 \rrbracket \quad (3.3.1)$$

Le décalage de $N/2$ assure la causalité du filtre synthétisé.

Chapitre 4

Traitement d'images 2D

Contents

4.1	Numérisation, Représentation de l'Image 2D et Traitements Points-à-Points	56
4.1.1	Échantillonnage, Quantification et Modèle matriciel	56
4.1.2	Traitements Ponctuels	56
4.1.3	Histogramme	57
4.1.4	Convolution 2D	57
4.2	Premiers filtres spatiaux	58
4.2.1	Filtres de lissage	59
4.2.2	Filtres de réhaussement de contours (Dérivée seconde)	59
4.2.3	Opérateur Gradient et Filtres de Sobel (Dérivée première)	60
4.3	Analyse fréquentielle bidimensionnelle (TFD 2D)	60
4.3.1	Définition et conventions	60
4.3.2	Centrage du spectre et propriétés spatiales	61
4.4	Filtrage Sélectif et Réhaussement fréquentiel 2D	62
4.4.1	Filtres Passe-Bas 2D (Lissage fréquentiel)	62
4.4.2	Filtres Passe-Haut 2D et Réhaussement	62
4.5	Modélisation des Dégradations et Filtres de Débruitage	63
4.5.1	Modèles de dégradation	63
4.5.2	Filtres moyennneurs non linéaires (Restauration spatiale)	64
4.6	Bruit périodique, Problèmes Inverses et Défloutage	65
4.6.1	Restauration fréquentielle pour bruit périodique	65
4.6.2	Restauration d'une image floutée (Problèmes inverses)	66

Ce chapitre introduit la plupart des concepts du traitement d'images. Après avoir décrit les principales étapes de numérisation d'une image ainsi que les métriques usuelles de ses objets, nous introduisons des filtres plus évolués à l'aide de la convolution. La seconde partie de ce chapitre détaille les opérations de filtrage et de réhaussement possible grâce au domaine fréquentiel d'une image, caractérisé par son spectre. Nous concluons par une brève présentation des bruits périodiques et des problèmes inverses.

4.1 Numérisation, Représentation de l'Image 2D et Traitements Points-à-Points

Cette première section pose les généralités du traitement d'images numériques. Nous commençons par définir ce qu'est une image numérique ainsi que le processus d'échantillonnage. Après avoir abordé quelques opérations ponctuelles, nous introduisons la convolution ainsi que ses propriétés.

4.1.1 Échantillonnage, Quantification et Modèle matriciel

Nous présentons ici la méthode de représentation d'une image en deux dimensions. À l'origine, une image peut se représenter comme une application continue $i : (x, y) \rightarrow \mathbb{R}$. Pour stocker notre image, nous pouvons directement stocker la fonction i . Or il n'est pas possible de définir mathématiquement une fonction pour chaque image possible, on utilise donc le principe *d'échantillonnage spatial* : on discrétise l'image en *pixels* que l'on pourra stocker dans un emplacement mémoire fini.

Définition (Échantillonnage Spatial) . Soit $i : (x, y) \rightarrow \mathbb{R}$ une image continue. On appelle *processus d'échantillonnage* l'opération qui consiste à discrétiser celle-ci en une matrice I de taille $M \times N$, à l'aide de deux pas réguliers d_x, d_y tout en respectant la condition de Shannon :

$$i(m, n) = i(md_x, nd_y). \quad (4.1.1)$$

Le second processus consiste à projeter les valeurs continues de cette image discrétisée sur un ensemble discret de L niveaux de gris. Généralement on prends $L = 2^k$ niveaux de gris si l'on dispose de k bits pour coder chaque pixel. On appellera la résultante une *image numérique*.

Définition (Image matricielle et Pixel) . Une image numérique monochrome *codée* sur k bits est une matrice I de M lignes et N colonnes telle que pour tout $(x, y) \in \llbracket 0, M-1 \rrbracket \times \llbracket 0, N-1 \rrbracket$, $I(x, y) \in \llbracket 0, 2^k - 1 \rrbracket$ représente un *pixel*.

En fonction des caractéristiques souhaitées de notre image, on peut coder la valeur de chaque pixel différemment. Il existe donc différents types d'images :

- Les *images binaires* : chaque pixel peut contenir que deux valeurs possibles : $I(x, y) \in \{0, 1\}$ (1 bit par pixel).
- Les *images à niveaux de gris* : $I(x, y) \in \llbracket 0, 255 \rrbracket$. Pour 256 valeurs différentes, il est nécessaire d'allouer 8 bits à chaque pixel en mémoire.
- Les *images en couleur (RGB)* : Chaque pixel est codé sous trois valeurs différentes correspondant à la quantité de couleur rouge, verte et bleue composant celui-ci :

$$I(x, y) = \begin{pmatrix} R(x, y) \\ G(x, y) \\ B(x, y) \end{pmatrix} \in \llbracket 0, 255 \rrbracket^3$$

Une telle image sera composée de 3 *canaux* (un pour chaque couleur) et sera stockée sous forme de *tenseur* de dimension $3 \times M \times N$.

4.1.2 Traitements Ponctuels

Chaque image étant stockée sous la forme d'une matrice, on peut dès à présent introduire quelques opérations possibles sur nos images. On parle d'opération point-à-point lorsque l'on effectue la même opération du chaque point de l'image de manière indépendante.

Proposition (Transformations ponctuelles usuelles) Une transformation ponctuelle applique une fonction de transfert $s = T(r)$ à chaque niveau de gris d'entrée $r \in \llbracket 0, L - 1 \rrbracket$ (avec $L = 256$ pour une image 8 bits) :

Transformation	Formule $s = T(r)$	Effet / Paramètres
Luminosité	$s = \text{tronc}(r + g)$	$g \in \mathbb{Z}$ ($g > 0$ éclaircit, $g < 0$ assombrit)
Contraste linéaire	$s = \text{tronc}(a[r - 127] + 127)$	$a > 1$ amplifie, $0 \leq a < 1$ réduit
Négatif	$s = (L - 1) - r = 255 - r$	Inverse la dynamique des intensités
Seuillage binaire	$s = \begin{cases} 1 & \text{si } r \geq \text{seuil} \\ 0 & \text{si } r < \text{seuil} \end{cases}$	Binarisation et segmentation du fond
Logarithmique	$s = c \log(1 + r)$	Étend les tons sombres, compresse les clairs
Loi de puissance (Gamma)	$s = c r^\gamma$	$\gamma < 1$ éclaircit, $\gamma > 1$ assombrit

4.1.3 Histogramme

Comme en statistiques, l'histogramme d'une image permet de représenter la quantité de chaque valeur possible des pixels sur un axe.

Définition (Histogramme, ddp et Fonction de répartition) . Pour une image I de taille $M \times N$ comportant $L = 256$ niveaux de gris, on définit son *histogramme* par l'application h telle que :

$$\forall g \in \llbracket 0, L - 1 \rrbracket, \quad h(g) = |\{r \in I \mid r = g\}|. \quad (4.1.2)$$

On définit sa *densité de probabilité* p par son histogramme normalisé par le nombre de pixels qu'elle contient :

$$p(g) = \frac{h(g)}{M \times N}, \quad \text{avec} \quad \sum_{g=0}^{L-1} p(g) = 1. \quad (4.1.3)$$

Enfin, sa *fonction de répartition* $\mathbb{P}$ en g est définie par la somme cumulée de la valeur de sa densité sur ses g premiers termes :

$$P(g) = \sum_{k=0}^g p(k) = \frac{1}{M \times N} \sum_{k=0}^g h(k). \quad (4.1.4)$$

Ces données permettent d'avoir un aperçu de la répartition des couleurs (ou niveaux de gris) sur une image. Son histogramme permet notamment de savoir si une image est plutôt sombre ou plutôt claire.

4.1.4 Convolution 2D

Définition (Convolution bidimensionnelle) . Soient deux signaux bidimensionnels A et B (représentant par exemple une image et un filtre). On définit le *produit de convolution 2D discret* entre A et B par :

$$(A * B)(k, l) = \sum_{x=-\infty}^{+\infty} \sum_{y=-\infty}^{+\infty} A(x, y) B(k - x, l - y). \quad (4.1.5)$$

Propriété (Propriétés de la convolution 2D) . La convolution possède plusieurs propriétés importantes à connaître car très utiles. Pour toutes images A, B, C on a :

- *Commutativité* : $A * B = B * A$.
- *Associativité* : $A * (B * C) = (A * B) * C$.
- *Distributivité* : $A * (B + C) = (A * B) + (A * C)$.

Lors du passage du masque sur les bords de l'image, les valeurs extérieures sont interpolées selon trois stratégies :

- **Zero-padding** : assignation de zéros en dehors de l'image (simple mais crée un artéfact de bordure sombre).
- **Extension périodique** : réplication de l'image par pavage toroïdal (en accord avec la TFD 2D).
- **Extension miroir (symétrie)** : réplication par réflexion par rapport au bord (atténue fortement les discontinuités de bordure).

Définition (Filtrage spatial par masque) . En pratique, on filtre une image d'entrée f à l'aide d'un *masque* (ou *noyau*) fini w de dimensions impaires $(2a + 1) \times (2b + 1)$ centré en $(0, 0)$. L'image filtrée g s'écrit alors :

$$g(x, y) = (f * w)(x, y) = \sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x - s, y - t) \quad (4.1.6)$$

De façon générale, si le masque n'est pas déjà normalisé, on divise par la somme de ses coefficients afin de conserver l'énergie moyenne de l'image :

$$g(x, y) = \frac{\sum_{s=-a}^a \sum_{t=-b}^b w(s, t) f(x + s, y + t)}{\sum_{s=-a}^a \sum_{t=-b}^b w(s, t)} \quad (4.1.7)$$

Remarque L'opération spatiale directe avec $f(x + s, y + t)$ est formellement une *corrélacion spatiale*. Pour correspondre exactement au produit de convolution théorique $f * w$, le masque w doit être retourné horizontalement et verticalement (rotation de 180°) avant l'application. Pour la majorité des masques de filtrage usuels (moyenneur, Laplacien, Gaussien), le noyau est symétrique par rapport à son centre, rendant convolution et corrélation strictement équivalentes.

4.2 Premiers filtres spatiaux

À partir de l'opération de convolution par masque discret, on peut concevoir une grande variété de filtres spatiaux pour modifier localement les propriétés de l'image.

4.2.1 Filtres de lissage

Les filtres de lissage atténuent les variations rapides d'intensité afin de réduire le bruit, au détriment de la netteté des contours :

- **Filtre moyennneur (linéaire)** : applique un masque uniforme normalisé de coefficients $w(s, t) = \frac{1}{(2a+1)(2b+1)}$. Pour une fenêtre standard 3×3 :

$$w = \frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad (4.2.1)$$

Ce filtre réduit efficacement le bruit blanc gaussien mais floute les contours de l'image.

- **Filtre médian (non-linéaire)** : remplace la valeur du pixel central par la valeur médiane de l'ensemble des pixels ordonnés de son voisinage $\mathcal{V}$:

$$J(x, y) = \text{médiane}\{I(x + s, y + t) \mid (s, t) \in \mathcal{V}\} \quad (4.2.2)$$

Ce traitement est optimal pour éliminer le bruit impulsionnel (« poivre et sel ») sans étaler les arêtes nettes.

4.2.2 Filtres de réhaussement de contours (Dérivée seconde)

L'opération de réhaussement est principalement utilisée pour augmenter le contraste et la netteté d'une image, notamment pour corriger un flou spatial. Les contours correspondent à de fortes variations locales d'intensité, mises en valeur mathématiquement par des opérateurs différentiels. Le *Laplacien* est historiquement utilisé pour les processus de réhaussement.

Définition (Laplacien continu) . Soit $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ une fonction différentiable. On définit son *Laplacien* $\nabla^2 f$ comme la somme de ses dérivées partielles secondes :

$$\nabla^2 f(x, y) = \frac{\partial^2 f(x, y)}{\partial x^2} + \frac{\partial^2 f(x, y)}{\partial y^2} \quad (4.2.3)$$

Cette application donne une mesure quantitative de la courbure locale de f autour du point (x, y) . Tandis que le gradient donne l'orientation et la pente de ses variations, le Laplacien indique à quel point la valeur de la fonction en un point s'écarte de la moyenne de son voisinage. Une valeur positive signifie que le point est en dessous de cette moyenne locale, une valeur négative qu'il est au-dessus, et une valeur nulle indique une zone localement plane.

Sur une image numérique échantillonnée, on discrétise les dérivées secondes par des différences finies centrées :

$$\frac{\partial^2 f}{\partial x^2} \approx f(x + 1, y) + f(x - 1, y) - 2f(x, y) \quad (4.2.4)$$

$$\frac{\partial^2 f}{\partial y^2} \approx f(x, y + 1) + f(x, y - 1) - 2f(x, y) \quad (4.2.5)$$

En sommant ces deux composantes, on obtient l'expression discrète du Laplacien :

$$\nabla^2 f(x, y) = f(x + 1, y) + f(x - 1, y) + f(x, y + 1) + f(x, y - 1) - 4f(x, y) \quad (4.2.6)$$

Proposition (Masques du Laplacien et Réhaussement spatial) Ici sont proposées différentes implémentations des masques du Laplacien :

- **Masques de convolution** : le Laplacien s'implémente directement par un noyau de convolution spatial à 4 voisins, ou à 8 voisins en intégrant les dérivées secondes diagonales :

$$\nabla_4^2 = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}, \quad \nabla_8^2 = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{bmatrix} \quad (4.2.7)$$

Le coefficient central négatif compare l'intensité du pixel courant à la somme de ses voisins.

- **Image réhaussée** : le Laplacien isole les contours mais élimine les composantes lentes (le fond continu de l'image). Pour restaurer la dynamique globale tout en accentuant les discontinuités, on soustrait le Laplacien à l'image originale :

$$g(x, y) = f(x, y) - \nabla^2 f(x, y) \quad (4.2.8)$$

Cette soustraction se condense en un masque spatial unique à coefficient central renforcé :

$$w_{\text{réhauss}} = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix} \quad (4.2.9)$$

- **Masquage flou (*Unsharp Masking*)** : généralisation introduisant un coefficient $A \geq 1$ pour moduler le contraste du fond par rapport aux contours :

$$g(x, y) = Af(x, y) - \nabla^2 f(x, y) \quad (4.2.10)$$

4.2.3 Opérateur Gradient et Filtres de Sobel (Dérivée première)

Le gradient d'une fonction 2D est le vecteur pointant vers la plus forte variation locale :

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} G_x \\ G_y \end{bmatrix} \quad (4.2.11)$$

La norme de ce vecteur mesure l'intensité de la transition spatiale, approchée en calcul discret par $\|\nabla f\| \approx |G_x| + |G_y|$ pour limiter les calculs de racines carrées.

Définition (Opérateur de Sobel) . Le filtre de Sobel estime ce gradient à l'aide de deux masques orthogonaux de taille 3×3 combinant dérivation discrète et lissage transverse pour limiter la sensibilité au bruit :

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad G_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (4.2.12)$$

Le masque G_x met en évidence les contours verticaux, tandis que G_y détecte les contours horizontaux.

4.3 Analyse fréquentielle bidimensionnelle (TFD 2D)

Cette section introduit une opération fondamentale dans le domaine du traitement d'image qu'est la *Transformée de Fourier 2d*. Cette opération permet d'exprimer le contenu d'une image dans le *domaine spectral* et donne une répartition en deux dimensions de l'intensité des fréquences qui composent une image.

4.3.1 Définition et conventions

Définition (TFD 2D et TFD 2D Inverse) . Soit $f(x, y)$ une image numérique de dimensions $M \times N$, où $x \in \llbracket 0, M-1 \rrbracket$ et $y \in \llbracket 0, N-1 \rrbracket$. On définit la *Transformée de Fourier Discrète 2D* de l'image $f(x, y)$, notée $F(u, v)$, par :

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) \cdot \exp \left(-2j\pi \left(\frac{ux}{M} + \frac{vy}{N} \right) \right) \quad (4.3.1)$$

pour tout $u \in \llbracket 0, M-1 \rrbracket$ et $v \in \llbracket 0, N-1 \rrbracket$.

La *Transformée de Fourier Discrète 2D Inverse* (TFDI) permet la reconstruction exacte de l'image spatiale :

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) \cdot \exp \left(2j\pi \left(\frac{ux}{M} + \frac{vy}{N} \right) \right) \quad (4.3.2)$$

Proposition (Spectre d'amplitude, Densité spectrale et Phase) La Transformée de Fourier d'un signal (image ou son) vit dans le domaine *spectral* (i.e complexe). Chacun de ses termes se décompose donc en deux sous-termes :

$$F(u, v) = \underset{\text{partie réelle}}{\text{Re}(u, v)} + j \underset{\text{partie imaginaire}}{\text{Im}(u, v)} .$$

On peut alors définir différentes métriques pour ce spectre :

- Le **spectre d'amplitude** (module) : $|F(u, v)| = \sqrt{R(u, v)^2 + I(u, v)^2}$.
- Le **spectre de phase** : $\phi(u, v) = \arctan \left(\frac{I(u, v)}{R(u, v)} \right)$.
- La **densité spectrale de puissance (DSP)** : $P(u, v) = |F(u, v)|^2 = R(u, v)^2 + I(u, v)^2$.

La phase $\phi(u, v)$ transporte l'essentiel de l'information structurelle et géométrique de l'image (contours, bords des objets). La reconstruction d'une image à partir de sa phase seule ($f' = \text{Re}[\mathcal{F}^{-1}\{e^{j\phi}\}]$) préserve les formes perceptibles, alors que la reconstruction à partir du module seul ($f' = \mathcal{F}^{-1}\{|F|\}$) détruit l'intelligibilité spatiale.

4.3.2 Centrage du spectre et propriétés spatiales

Proposition (Centrage du spectre – fftshift) Par défaut, l'origine fréquentielle continue $F(0, 0)$ est positionnée dans le coin supérieur gauche ($u = 0, v = 0$). Pour décaler la fréquence nulle au centre du spectre ($u = M/2, v = N/2$), on multiplie l'image spatiale par $(-1)^{x+y}$ avant transformation :

$$\mathcal{F} [f(x, y) \cdot (-1)^{x+y}] = F \left(u - \frac{M}{2}, v - \frac{N}{2} \right) \quad (4.3.3)$$

Proposition (Relation d'incertitude et orientation) La transformée de Fourier induit des comportements caractéristiques sur la forme des object et leur positions :

- **Principe d'incertitude** : si $\Delta x \Delta y$ est l'extension spatiale d'un motif et $\Delta u \Delta v$ son étalement fréquentiel, alors :

$$\Delta x \Delta y \cdot \Delta u \Delta v \geq \frac{1}{16\pi^2} \quad (4.3.4)$$

Un motif spatial très étroit possède un large spectre fréquentiel, et réciproquement.

- **Orientation** : une famille de lignes ou un contour incliné selon un angle θ dans l'espace engendre des composantes fréquentielles dirigées orthogonalement ($\theta + \pi/2$) dans le plan de Fourier.

4.4 Filtrage Sélectif et Réhaussement fréquentiel 2D

Lorsque l'on utilise le *spectre* d'une image, on parle souvent sur *spectre d'amplitude*. Ce dernier représente les basses fréquences au centre du spectre $((M/2, N/2))$ et les hautes fréquences sur les contours de celui-ci. On peut alors effectuer des opérations simples sur les pixels en considérant leur distance au centre du spectre $D(u, v)$: la distance euclidienne d'une fréquence (u, v) au centre du spectre :

$$D(u, v) = \sqrt{\left(u - \frac{M}{2}\right)^2 + \left(v - \frac{N}{2}\right)^2} \quad (4.4.1)$$

On définit l'opération de filtrage de la même façon que pour les signaux 2D :

Définition (Filtrage) . Soit $H \in \mathcal{M}_{M \times N}(\mathbb{R})$ une matrice de même dimension que l'image I à filtrer et J sa transformée de fourier. L'image filtrée I_f par H est définie par :

$$\forall (x, y) \in \llbracket 0, M-1 \rrbracket \times \llbracket 0, N-1 \rrbracket, \quad I_f(x, y) = \text{Re} [\text{TF}^{-1}(H \cdot J)](x, y). \quad (4.4.2)$$

4.4.1 Filtres Passe-Bas 2D (Lissage fréquentiel)

Un filtre passe-bas atténue les hautes fréquences (bruit, contours) au profit des variations lentes. Il permet d'atténuer les contours d'une image en supprimant les bords de son spectre. Soit D_0 la fréquence de coupure :

- **Passe-bas idéal** :

$$H(u, v) = \begin{cases} 1 & \text{si } D(u, v) \leq D_0 \\ 0 & \text{si } D(u, v) > D_0 \end{cases} \quad (4.4.3)$$

Provoque de sévères oscillations spatiales (phénomène de Gibbs / effet de cerclage) en raison de la discontinuité abrupte.

- **Passe-bas de Butterworth d'ordre n** :

$$H(u, v) = \frac{1}{1 + \left[\frac{D(u, v)}{D_0}\right]^{2n}} \quad (4.4.4)$$

Transition progressive qui élimine le phénomène de cerclage pour les ordres faibles ($n \leq 2$).

- **Passe-bas Gaussien** :

$$H(u, v) = e^{-\frac{D^2(u, v)}{2D_0^2}} \quad (4.4.5)$$

Transition parfaitement lisse sans aucune oscillation spatiale.

4.4.2 Filtres Passe-Haut 2D et Réhaussement

Les filtres passe-haut préservent les contours et éliminent la composante continue. Ils sont définis comme les opposés des filtres passe-bas. Ainsi, à chaque filtre passe-bas, lui correspond sont filtre passe-haut :

$$H_{\text{PH}}(u, v) = 1 - H_{\text{PB}}(u, v) \quad (4.4.6)$$

On en déduit les formes idéales, de Butterworth et Gaussienne.

Remarque Les filtres passe-haut sont généralement utilisés dans le *réhaussement* d'images.

Proposition (Réhaussement Fréquentiel) Dans le domaine fréquentiel, on peut alors appliquer n'importe quel filtre passe-haut pour accentuer les contours d'une image. Pour cela, on peut affiner les effets du filtre à l'aide de paramètres $a \geq 0$ et $b > a$ tels que :

$$H_{\text{réhauss}}(u, v) = a + b H_{\text{PH}}(u, v). \quad (4.4.7)$$

Typiquement $0,25 \leq a \leq 0,5$ et $1,5 \leq b \leq 2$. Le paramètre a conserve le fond de l'image (basses fréquences), tandis que b amplifie les contours.

4.5 Modélisation des Dégradations et Filtres de Débruitage

Dans cette section, on s'intéresse à des images bruitées : on parle de *dégradation*. Après avoir défini la notion de *bruit* sur une image et comment les simuler, nous verrons différents procédés pour les altérer/supprimer par un processus de *débruitage*.

4.5.1 Modèles de dégradation

Définition (Phénomène de bruitage) . Soit f un signal (image ou son), h une *fonction de dégradation* et n un *terme de bruit*. La dégradation g de f par un *système linéaire invariant avec bruit additif* est défini comme le signal :

$$\underbrace{g = h * f + n}_{\text{Domaine Spatial}} \iff \underbrace{G = HF + N}_{\text{Domaine Fréquentiel}} \quad (4.5.1)$$

où G, H et F sont leurs transformées de Fourier respectives. On dira que h est la *fonction de dégradation* et n le *terme de bruit*.

On identifiera souvent le bruit à un processus aléatoire que l'on peut caractériser par une densité de probabilité. Une métrique intéressante pour quantifier l'influence du bruit sur un signal est d'utiliser le rapport de leur puissances.

Définition (RSB – *Signal-to-Noise-Ratio*) . Soit f un signal (non bruité) et n un bruit. On définit le *ratio signal/bruit* par le rapport de leur deux puissances :

$$RSB = \frac{P_s}{P_b} = \frac{\sum_x |f(x)|^2}{\sum_x |n(x)|^2}. \quad (4.5.2)$$

Remarque Dans le cas d'un bruit centré $\mathbb{E}(n) = 0$ de variance σ_n^2 , sa puissance coïncide exactement avec sa variance : $P_b = \mathbb{E}(n^2) = \sigma_n^2$.

Proposition (Densités de probabilité usuelles des bruits) Soit z la variable aléatoire représentant l'intensité bruitée du pixel. Les modèles statistiques standards sont résumés ci-dessous :

Type de bruit	Densité de probabilité $p(z)$	Moyenne $\bar{z}$	Variance σ^2
Gaussien	$\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(z-\bar{z})^2}{2\sigma^2}\right)$	$\bar{z}$	σ^2
Uniforme ($a \leq z \leq b$)	$\frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Rayleigh ($z \geq a$)	$\frac{2}{b}(z-a) \exp\left(-\frac{(z-a)^2}{b}\right)$	$a + \sqrt{\frac{\pi b}{4}}$	$\frac{b(4-\pi)}{4}$
Gamma / Erlang ($z \geq 0$)	$\frac{a^b z^{b-1}}{(b-1)!} e^{-az}$	$\frac{b}{a}$	$\frac{b}{a^2}$
Exponentiel ($z \geq 0$)	ae^{-az}	$\frac{1}{a}$	$\frac{1}{a^2}$
Poivre et Sel	$\begin{cases} P_p & \text{si } z = p \text{ (noir)} \\ P_s & \text{si } z = s \text{ (blanc)} \\ 0 & \text{sinon} \end{cases}$	—	—

4.5.2 Filtres moyennneurs non linéaires (Restauration spatiale)

Dans cette sous-section, on considère uniquement des dégradation à base de bruit soit de la forme :

$$g = f + n \quad \Longleftrightarrow \quad G = F + N. \quad (4.5.3)$$

Grâce à ces modèles plus simples, il suffirait de soustraire le bruit pour retrouver l'image de départ mais sans la connaissance de ce dernier, on doit se contenter d'opérations plus simples. L'opération la plus simple serait de remplacer chaque pixel par une moyenne de ses pixels voisins. Cette méthode permet de rétablir l'image de départ pour la plupart des modèles de bruits classiques mais a tendance à flouter l'image.

Proposition (Filtres Moyennneurs) Soit S_{xy} une fenêtre d'analyse de taille $m \times n$ définie pour tout (x, y) . Différents filtres moyennneurs existent :

- **Moyennneur géométrique :**

$$\hat{f}(x, y) = \left[\prod_{(s,t) \in S_{xy}} g(s, t) \right]^{\frac{1}{mn}} \quad (4.5.4)$$

Ce filtre lisse l'image mais préserve mieux les détails qu'une moyenne arithmétique naïve.

- **Moyennneur harmonique :**

$$\hat{f}(x, y) = \frac{mn}{\sum_{(s,t) \in S_{xy}} \frac{1}{g(s, t)}} \quad (4.5.5)$$

filtre efficace sur du bruit sel ou gaussien mais inefficace sur un bruit de type poivre (pixels noirs).

- **Moyennneur contra-harmonique d'ordre R :**

$$\hat{f}(x, y) = \frac{\sum_{(s,t) \in S_{xy}} g(s, t)^{R+1}}{\sum_{(s,t) \in S_{xy}} g(s, t)^R} \quad (4.5.6)$$

Si $R > 0$, élimine le bruit poivre ; si $R < 0$, élimine le bruit sel (ne traite pas les deux simultanément). Pour $R = 0$, on retrouve le filtre arithmétique ; pour $R = -1$, le filtre harmonique.

Pour aller plus loin, on peut essayer de définir un filtre qui s'adapte localement au bruit appliqué. On considère toujours un signal bruité de la forme $g(x, y) = f(x, y) + n(x, y)$ tel que le bruit n possède une espérance nulle et une variance connue σ_n^2 .

Définition (Filtre adaptatif local) . Soit g un signal construit à partir d'un signal f bruité à partir d'un filtre n centré de variance σ_n^2 . On définit le *filtre adaptatif local* par :

$$\hat{f}(x, y) = g(x, y) - \frac{\sigma_n^2}{\sigma_L^2} [g(x, y) - m_L]. \quad (4.5.7)$$

Avec m_L , la *moyenne locale* sur un voisinage S_{xy} de (x, y) et σ_L^2 la variance locale :

$$m_L = \frac{1}{mn} \sum_{(s,t) \in S_{xy}} g(s, t), \quad \sigma_L^2 = \frac{1}{mn} \sum_{(s,t) \in S_{xy}} (g(s, t) - m_L)^2. \quad (4.5.8)$$

Remarque La plupart de ces filtres produisent un aspect flou sur l'image du fait de la moyennisation des pixels. Pour y remédier, on peut utiliser un principe de réhaussement de l'image (voir précédemment).

4.6 Bruit périodique, Problèmes Inverses et Défloutage

Dans cette dernière partie, on s'intéresse à des problèmes plus complexes tels que la suppression de bruits périodiques en reprérant des motifs dans le spectre d'une image. On s'intéresse aussi à la notion de *problèmes inverses* et au défloutage.

4.6.1 Restauration fréquentielle pour bruit périodique

Dans certains processus de capture d'un signal, on peut s'exposer à l'émission d'un bruit *périodique* (signal électromagnétique, son, etc...). Ces interférences périodiques sont facilement reconnaissables dans le domaine spectral car elles se traduisent par des pics impulsionnels isolés et symétriques par rapport à l'origine du spectre.

Pour retirer ces interférences, on applique des filtres réjecteur de bande sur la distance D_0 de l'origine à partir de laquelle apparaît ces motifs dans le spectre.

Proposition Le filtre *réjecteur idéal* annule brutalement les fréquences d'un anneau d'épaisseur W autour de D_0 :

$$H(u, v) = \begin{cases} 0 & \text{si } D_0 - \frac{W}{2} \leq D(u, v) \leq D_0 + \frac{W}{2} \\ 1 & \text{sinon.} \end{cases} \quad (4.6.1)$$

Tandis que le filtre *réjecteur gaussien* applique une transition douce sans créer d'effets de cerclage :

$$H(u, v) = 1 - \exp \left(-\frac{1}{2} \left[\frac{D^2(u, v) - D_0^2}{D(u, v) \cdot W} \right]^2 \right). \quad (4.6.2)$$

Remarque On peut aussi récupérer les fréquences responsables du bruit pour l'analyser en utilisant un *filtre passe-bande complémentaire* simplement obtenu par soustraction :

$$H_{PB} = 1 - H_{\text{Réjecteur}}. \quad (4.6.3)$$

4.6.2 Restauration d'une image floutée (Problèmes inverses)

Une image dégradée par un flou linéaire (défocalisation, bougé de capteur) et parasitée par un bruit additif s'écrit dans le domaine spatial et fréquentiel sous la forme :

$$g(x, y) = h(x, y) * f(x, y) + n(x, y) \iff G(u, v) = H(u, v)F(u, v) + N(u, v). \quad (4.6.4)$$

où $h(x, y)$ représente la réponse impulsionnelle du système de flou (*Point Spread Function* ou PSF) et $n(x, y)$ le terme de bruit.

Si l'on tente d'inverser directement le système à l'aide de l'opérateur $1/H(u, v)$, l'estimation fréquentielle devient :

$$\hat{F}(u, v) = \frac{G(u, v)}{H(u, v)} = F(u, v) + \frac{N(u, v)}{H(u, v)}. \quad (4.6.5)$$

Cette inversion naïve pose un problème dit *mal posé* : la fonction de transfert de flou $H(u, v)$ s'atténue et tend vers zéro aux moyennes et hautes fréquences. La division par des valeurs proches de zéro amplifie alors démesurément le terme de bruit $N(u, v)/H(u, v)$, dégradant totalement l'image restaurée au lieu de la rendre nette.

Pour stabiliser l'inversion, plusieurs méthodes de régularisation sont envisageables.

Proposition (Filtres inverses régularisés) Pour éviter la divergence du terme de bruit, on peut borner l'inversion de deux manières :

- Le *filtre pseudo-inverse tronqué*, qui applique un seuil minimal $T > 0$ sur l'amplitude de $H(u, v)$:

$$\hat{F}(u, v) = \begin{cases} \frac{G(u, v)}{H(u, v)} & \text{si } |H(u, v)| \geq T \\ G(u, v) & \text{sinon.} \end{cases} \quad (4.6.6)$$

- Le *filtre inverse limité aux basses fréquences*, qui tire profit du fait que la composante continue $H(0, 0)$ est importante (moyenne spatiale positive de la PSF). L'inversion est alors strictement restreinte à un disque de rayon D_0 centré sur l'origine fréquentielle :

$$\hat{F}(u, v) = \begin{cases} \frac{G(u, v)}{H(u, v)} & \text{si } D(u, v) \leq D_0 \\ G(u, v) & \text{sinon.} \end{cases} \quad (4.6.7)$$

Théorème (Filtre de Wiener) . Le *filtre de Wiener* propose une solution optimale au sens des moindres carrés en minimisant l'erreur quadratique moyenne globale $\mathbb{E}[|f(x, y) - \hat{f}(x, y)|^2]$. Son expression fréquentielle est donnée par :

$$\hat{F}(u, v) = \left[\frac{1}{H(u, v)} \frac{|H(u, v)|^2}{|H(u, v)|^2 + K} \right] G(u, v) \quad (4.6.8)$$

où la constante K modélise le rapport des densités spectrales de puissance du bruit et du signal :

$$K \approx \frac{P_n(u, v)}{P_f(u, v)} = \frac{1}{\text{RSB}(u, v)}. \quad (4.6.9)$$

Remarque Le facteur d'atténuation $\frac{|H(u, v)|^2}{|H(u, v)|^2 + K}$ effectue un arbitrage continu entre déconvolution et filtrage du bruit :

- En basses fréquences ($|H(u, v)|^2 \gg K$), le signal utile domine le bruit : le terme correcteur tend vers 1 et le filtre se comporte comme l'inverse direct $1/H(u, v)$ pour déflouter l'image.

- En hautes fréquences ($|H(u, v)|^2 \ll K$), le bruit domine le signal : le terme correcteur tend vers 0, ce qui coupe le filtre et empêche l'explosion du bruit.
- Dans le cas idéal sans bruit ($K = 0$), on retrouve exactement le filtre inverse classique.

Chapitre 5

Analyse du son et Reconnaissance vocale

Contents

5.1	Architecture des Systèmes de Reconnaissance Vocale (RAP)	68
5.1.1	Sources de variabilité et chaîne de traitement	68
5.2	Paramétrisation Acoustique : Coefficients MFCC	69
5.3	Modélisation Statistique et Modèles de Mélanges de Gaussiennes (GMM)	69
5.3.1	Cadre Bayésien et Détection d'Activité Vocale (VAD)	69
5.3.2	Mélange de Gaussiennes (GMM) et Algorithme EM	69
5.4	Alignement Temporel Dynamique (DTW)	70
5.5	Modèles de Markov Cachés (HMM / MMC)	71
5.5.1	Formalisme et Hypothèses	71
5.5.2	Algorithme de Viterbi	71
5.6	Modèles Connexionnistes (Réseaux de Neurones Récurrents)	71
5.6.1	Perceptron et Réseau Récurrent Simple (RNN)	71
5.6.2	Cellule LSTM (Long Short-Term Memory)	72
5.6.3	Cellule GRU (Gated Recurrent Unit)	72

5.1 Architecture des Systèmes de Reconnaissance Vocale (RAP)

5.1.1 Sources de variabilité et chaîne de traitement

Un système de Reconnaissance Automatique de la Parole (RAP) extrait une séquence de mots à partir d'un signal acoustique de parole. La difficulté réside dans les variabilités acoustiques (bruit, coarticulation), prosodiques (durée, intonation), lexicales et syntaxiques.




FIGURE 5.1 – Pipeline classique d'un système de reconnaissance de formes vocales.

5.2 Paramétrisation Acoustique : Coefficients MFCC

L'analyse de parole s'effectue sur des trames courtes et stationnaires de durée ≈ 20 ms avec un recouvrement de 50%.

Définition (Algorithme d'extraction des MFCC) . L'obtention des coefficients *Mel-Frequency Cepstral Coefficients* (MFCC) suit la cascade :

1. **Préaccentuation** : filtre passe-haut $y(n) = x(n) - \alpha x(n-1)$ (avec $\alpha \approx 0,97$) pour compenser la chute spectrale d'environ -6 dB/octave due au rayonnement des lèvres.
2. **Fenêtrage de Hamming** : limitation temporelle réduisant la fuite spectrale.
3. **Spectre TFD (FFT)** : calcul de la transformée de Fourier rapide sur chaque trame.
4. **Banc de filtres de Mel** : banc de filtres triangulaires espacés linéairement sous 1000 Hz et logarithmiquement au-delà (échelle psychoacoustique de Mel) :

$$\text{Mel}(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (5.2.1)$$

5. **Compression logarithmique** : calcul du logarithme de l'énergie en sortie de chaque filtre.
6. **Transformée en Cosinus Discrète (DCT)** : décorrélation spectrale équivalente à une TFD inverse.

On retient en pratique les $n_0 \leq 13$ à 30 premiers coefficients cepstraux (le premier coefficient c_0 , reflet de l'énergie globale, étant souvent traité séparément).

5.3 Modélisation Statistique et Modèles de Mélanges de Gaussiennes (GMM)

5.3.1 Cadre Bayésien et Détection d'Activité Vocale (VAD)

Pour classer une observation $y \in \mathbb{R}^d$ parmi K classes, la règle du Maximum a Posteriori (MAP) s'écrit :

$$s^*(y) = \arg \max_k P(k|y) = \arg \max_k \frac{P(y|k)P(k)}{P(y)} = \arg \max_k P(y|k)P(k) \quad (5.3.1)$$

Pour la Détection d'Activité Vocale (VAD), l'observation scalaire est l'énergie court-terme $y = \frac{1}{N} \sum s_n^2$. Le test binaire Parole / Non-Parole se réduit à une comparaison à un seuil optimal y^* séparant les deux gaussiennes $\mathcal{N}(m_P, \sigma_P^2)$ et $\mathcal{N}(m_{NP}, \sigma_{NP}^2)$.

5.3.2 Mélange de Gaussiennes (GMM) et Algorithme EM

Pour modéliser la variabilité acoustique d'un son continu, la densité d'émission est décomposée en un mélange de M composantes gaussiennes :

$$P(y|k) = \sum_{i=1}^M \alpha_k^i \mathcal{N}(y; m_k^i, \Sigma_k^i) \quad \text{avec} \quad \sum_{i=1}^M \alpha_k^i = 1 \quad (5.3.2)$$

Théorème (Algorithme Expectation-Maximization (EM)) . L'estimation des paramètres $\{\alpha_i, m_i, \Sigma_i\}$ s'effectue itérativement :

1. **Initialisation** : tirage initial des moyennes par partitionnement de Lloyd / K -means (Vector Quantization - VQ), $\Sigma_i = I$ et $\alpha_i = 1/M$.
2. **Étape E (Estimation)** : calcul des probabilités a posteriori d'appartenance de chaque observation y_t à la gaussienne i :

$$p_k^i(t) = \frac{\alpha_k^i \mathcal{N}(y_t; m_k^i, \Sigma_k^i)}{\sum_{j=1}^M \alpha_k^j \mathcal{N}(y_t; m_k^j, \Sigma_k^j)} \quad (5.3.3)$$

3. **Étape M (Maximisation)** : mise à jour des paramètres du mélange :

$$\bar{\alpha}_k^i = \frac{1}{T} \sum_{t=1}^T p_k^i(t), \quad \bar{m}_k^i = \frac{\sum_{t=1}^T p_k^i(t) y_t}{\sum_{t=1}^T p_k^i(t)}, \quad \bar{\Sigma}_k^i = \frac{\sum_{t=1}^T p_k^i(t) (y_t - \bar{m}_k^i)(y_t - \bar{m}_k^i)^T}{\sum_{t=1}^T p_k^i(t)} \quad (5.3.4)$$

5.4 Alignement Temporel Dynamique (DTW)

La méthode DTW (*Dynamic Time Warping*) mesure la dissemblance entre une séquence d'observation $A = (a_1, \dots, a_N)$ et une référence $B = (b_1, \dots, b_M)$ en absorbant les variations non-linéaires de débit d'élocution.

Définition (Chemin de déformation et contraintes) . Un chemin d'alignement est une suite $C = (c_1, \dots, c_K)$ de cases $c_k = (i_k, j_k) \in \llbracket 1, N \rrbracket \times \llbracket 1, M \rrbracket$ minimisant le coût cumulé :

$$D(A, B) = \min_C \frac{\sum_{k=1}^K w_k d(a_{i_k}, b_{j_k})}{\sum_{k=1}^K w_k} \quad (5.4.1)$$

Le chemin est soumis à trois conditions rigoureuses :

- **Coïncidence des extrémités** : $c_1 = (1, 1)$ et $c_K = (N, M)$.
- **Monotonie temporelle** : $i_k \geq i_{k-1}$ et $j_k \geq j_{k-1}$.
- **Continuité** : pas de saut temporel ($i_k - i_{k-1} \leq 1$ et $j_k - j_{k-1} \leq 1$).

Propriété (Équations de récurrence de Bellman) . Soit $g(i, j)$ le coût cumulé minimal pour atteindre la case (i, j) :

- **Schéma symétrique usuel** ($w_{\text{diag}} = 2, w_{\text{lat}} = 1$) :

$$g(i, j) = \min \begin{cases} g(i-1, j) + d(i, j) \\ g(i-1, j-1) + 2d(i, j) \\ g(i, j-1) + d(i, j) \end{cases} \quad (5.4.2)$$

Le coût final $g(N, M)$ est normalisé par le facteur constant $N + M$.

- **Schéma asymétrique** (alignement projeté sur l'axe i) :

$$g(i, j) = \min \begin{cases} g(i-1, j) + d(i, j) \\ g(i-1, j-1) + d(i, j) \\ g(i, j-1) \end{cases} \quad (5.4.3)$$

Normalisé par la longueur temporelle de l'observation N .

5.5 Modèles de Markov Cachés (HMM / MMC)

5.5.1 Formalisme et Hypothèses

Un MMC du 1er ordre est défini par le triplet $\Lambda = (\Pi, A, B)$:

- L'ensemble fini d'états cachés $Q = \{q_1, \dots, q_N\}$.
- Le vecteur des probabilités initiales $\Pi = (\pi_i)_{1 \leq i \leq N}$ avec $\pi_i = P(q_1 = i)$.
- La matrice de transition $A = (a_{ij})_{1 \leq i, j \leq N}$ avec $a_{ij} = P(s_t = j \mid s_{t-1} = i)$ vérifiant $\sum_j a_{ij} = 1$.
- Les densités de probabilité d'émission $B = \{b_j(o_t)\}$ où $b_j(o_t) = P(o_t \mid s_t = j)$, modélisées par des GMM.

5.5.2 Algorithme de Viterbi

L'algorithme de Viterbi extrait la séquence d'états optimale $S^* = (s_1^*, \dots, s_T^*)$ ayant produit la suite d'observations $O = (o_1, \dots, o_T)$. Pour éviter les sous-dépassements de capacité (*underflow*), on travaille en log-probabilités.

Théorème (Récursion de Viterbi) . Soit $\delta_t(j) = \max_{s_1, \dots, s_{t-1}} \ln P(s_1, \dots, s_t = j, o_1, \dots, o_t \mid \Lambda)$:

1. **Initialisation** ($t = 1$) :

$$\delta_1(i) = \ln \pi_i + \ln b_i(o_1), \quad \psi_1(i) = 0 \quad (5.5.1)$$

2. **Récursion temporelle** ($2 \leq t \leq T$) :

$$\delta_t(j) = \max_{1 \leq i \leq N} [\delta_{t-1}(i) + \ln a_{ij}] + \ln b_j(o_t) \quad (5.5.2)$$

$$\psi_t(j) = \arg \max_{1 \leq i \leq N} [\delta_{t-1}(i) + \ln a_{ij}] \quad (5.5.3)$$

3. **Terminaison et Rétro-traçage (*Backtracking*)** :

$$s_T^* = \arg \max_{1 \leq i \leq N} \delta_T(i), \quad s_t^* = \psi_{t+1}(s_{t+1}^*) \quad \text{pour } t = T-1, \dots, 1 \quad (5.5.4)$$

5.6 Modèles Connexionnistes (Réseaux de Neurones Récurrents)

5.6.1 Perceptron et Réseau Récurrent Simple (RNN)

Dans un RNN, la sortie d'un état caché à l'instant $t-1$ est réinjectée en entrée à l'instant t :

$$h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (5.6.1)$$

Bien qu'adapté aux séquences, le RNN simple souffre de disparition ou explosion du gradient (*vanishing/exploding gradient*) sur les longues dépendances temporelles.

5.6.2 Cellule LSTM (Long Short-Term Memory)

La cellule LSTM compense la perte de gradient grâce à une mémoire interne linéaire C_t (état de cellule) régulée par trois portes sigmoïdales :

$$\text{Porte d'oubli : } F_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (5.6.2)$$

$$\text{Porte d'entrée : } I_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (5.6.3)$$

$$\text{Candidat cellule : } \tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (5.6.4)$$

$$\text{Mise à jour mémoire : } \boxed{C_t = F_t * C_{t-1} + I_t * \tilde{C}_t} \quad (5.6.5)$$

$$\text{Porte de sortie : } O_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5.6.6)$$

$$\text{État caché délivré : } \boxed{h_t = O_t * \tanh(C_t)} \quad (5.6.7)$$

5.6.3 Cellule GRU (Gated Recurrent Unit)

La cellule GRU simplifie le LSTM en fusionnant l'état de cellule et l'état caché, réduisant le nombre de paramètres à deux portes :

$$\text{Porte de mise à jour (update) : } Z_t = \sigma(W_z[h_{t-1}, x_t] + b_z) \quad (5.6.8)$$

$$\text{Porte de réinitialisation (reset) : } R_t = \sigma(W_r[h_{t-1}, x_t] + b_r) \quad (5.6.9)$$

$$\text{État candidat : } \tilde{h}_t = \tanh(W[h_t * h_{t-1}, x_t] + b) \quad (5.6.10)$$

$$\text{État final : } \boxed{h_t = (1 - Z_t) * h_{t-1} + Z_t * \tilde{h}_t} \quad (5.6.11)$$

