

Fiches de Cours

Master IMA

Axel PIGEON

axel.pigeon@univ-tlse3.fr

Université Toulouse III – Paul Sabatier

Années universitaires 2025–2027

6 mars 2026

Table des matières

I	Statistiques	3
1	Théorie de l'Information	4
1.1	Cadre	4
1.2	Informations Qualitatives	9
1.3	Information de Kullback-Leibler	11
1.4	Informations Quantitatives	11
2	Estimation et Risque	15
2.1	Risque	15
2.2	Estimateurs	16
2.3	Risque Quadratique	19
2.4	Bornes inférieures de variance et Efficacité	21

Statistiques

Chapitre 1

Théorie de l'Information

Contents

1.1	Cadre	4
1.1.1	Modèle	4
1.1.2	Les variables aléatoires d'un modèle	5
1.1.3	Domination et Densités	6
1.1.4	Hypothèses de régularité	6
1.1.5	Vraisemblance	7
1.1.6	Maximum de Vraisemblance	8
1.2	Informations Qualitatives	9
1.2.1	Exhaustivité	9
1.2.2	Minimalité et complétude	10
1.2.3	Statistiques Libres	10
1.3	Information de Kullback-Leibler	11
1.4	Informations Quantitatives	11
1.4.1	Vecteur Score	11
1.4.2	Modèles exponentiels	12
1.4.3	Information de Fisher	13
1.4.4	Propriétés de l'information de Fisher	14

1.1 Cadre

Dans cette section, nous posons le cadre de l'étude des statistiques ainsi que l'ensemble des notations et objets utilisés.

1.1.1 Modèle

L'étude des statistiques se résume à l'étude de la loi de variables aléatoires ou de suites de variables aléatoires. Nous devons donc définir un cadre dans lequel ces différents objets vivrons. On considère ainsi des variables aléatoires X définies telles que :

$$X : \begin{cases} (\Omega, \mathcal{T}, \mathbb{P}) \longrightarrow (\mathcal{X}, \mathcal{A}, \mathbb{P}^X) \\ \omega \longmapsto X(\omega) \end{cases} \quad (1.1.1)$$

Dans notre contexte, nous n'avons accès qu'à des *réalisations* $X(\omega)$ de la variable aléatoire X et nous souhaitons déterminer sa loi $\mathbb{P}^X$. Pour cela, nous faisons une hypothèse appelée *hypothèse*

paramétrique forte qui suppose que la loi de X ne dépend que d'un paramètre $\theta \in \Theta$, où $\Theta \subset \mathbb{R}^d$. Ainsi, la recherche de la loi $\mathbb{P}^X$ se réduit à la détermination d'un paramètre θ_* tel que $\mathbb{P}^X = \mathbb{P}_{\theta_*}$.

Définition (Modèle Paramétrique) . On appellera *modèle paramétrique* l'espace probabilisé $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)$ tel que $\mathcal{P}_\Theta = \{\mathbb{P}_\theta \mid \theta \in \Theta\}$ où Θ est un ouvert convexe de $\mathbb{R}^d$.

Or cet espace ne nous permet de considérer que de simples variables aléatoires. Dans un cadre plus général, nous souhaiterions étudier des *échantillons* $(X_1, \dots, X_n)$ i.i.d d'une variable aléatoire X . Nous définissons pour cela le *modèle d'échantillonnage*.

Définition (Modèle d'échantillonnage) . Soit $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)$ un modèle paramétrique. Un *échantillon* $(X_1(\omega), \dots, X_n(\omega))$ de ce modèle est un n -uplet de réalisations indépendantes d'une variable aléatoire X de loi $\mathbb{P}_\theta \in \mathcal{P}_\Theta$. On note $\mathbb{P}^{\{X_1, \dots, X_n\}} = \mathbb{P}_{\theta_*}^{\otimes n}$ la loi de cet échantillon. Le modèle paramétrique de cet échantillon est donc :

$$(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)^{\otimes n} = (\mathcal{X}^n, \mathcal{A}^n, \mathcal{P}_\Theta^{\otimes n})$$

On a donc :

$$(X_1, \dots, X_n) : \begin{cases} (\Omega, \mathcal{T}, \mathbb{P}) & \longrightarrow (\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)^{\otimes n} \\ \omega & \longmapsto (X_1(\omega), \dots, X_n(\omega)) \end{cases}$$

Enfin, pour l'étude plus théorique de tels objets, il serait intéressant de pouvoir faire tendre vers l'infini la taille de ces échantillons $(X_1, \dots, X_n)$. On définit donc un modèle dit *asymptotique* :

$$(X_i)_{i \in \mathbb{N}^*} : \begin{cases} (\Omega, \mathcal{T}, \mathbb{P}) & \longrightarrow (\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)^\infty \\ \omega & \longmapsto \{X_i(\omega) \mid i \in \mathbb{N}_*\} \end{cases}$$

1.1.2 Les variables aléatoires d'un modèle

L'objet principal que nous allons manipuler permet d'effectuer des opérations sur des échantillons d'une variable aléatoire. On les appelle les *statistiques*, notées S .

Définition (Statistique) . Une fonction mesurable S est une *statistique* si elle ne dépend pas de θ . On a donc :

$$S(X_1, \dots, X_n) : \begin{cases} (\mathcal{X}, \mathcal{A})^n & \longrightarrow (\mathcal{Y}, \mathcal{B}) \\ (X_1, \dots, X_n) & \longmapsto S(X_1, \dots, X_n) \end{cases}$$

On notera aussi $\mathbb{P}_\theta^S = (\mathbb{P}_\theta^{\otimes n})^S$ la mesure image de $\mathbb{P}_\theta^{\otimes n}$ par S .

Cette translation de nos observations $(X_1, \dots, X_n)$ implique la définition d'un *modèle image* nous permettant de manipuler ce nouvel objet $S(X_1, \dots, X_n)$.

Définition (Modèle Image) . Le modèle image de $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)^{\otimes n}$ par S_n est donc $(\mathcal{Y}, \mathcal{B}, \mathcal{P}_\Theta^{S_n})$, avec :

$$\mathcal{P}_\Theta^{S_n} := \{\mathbb{P}_\theta \circ S_n^{-1} \mid \theta \in \Theta\} \quad (1.1.2)$$

Pour rappel, l'objectif des statistiques est de déterminer le paramètre $\theta_* \in \Theta$. Pour cela, il faut que la donnée utilisée $((X_1, \dots, X_n), X, \text{ ou } S(X_1, \dots, X_n))$ contienne le plus d'information possible sur θ . Il serait donc préférable que la translation S ne réduise pas cette quantité. De telles statistiques seront donc dites *exhaustives*. Elles seront caractérisées par la loi conditionnelle de l'échantillon.

Définition (Loi conditionnelle d'une statistique) . Soit T une statistique. La loi conditionnelle de $(X_1, \dots, X_n)$ sachant $T(X_1, \dots, X_n)$ est définie par :

$$\mathbb{P}_\theta^{(X_1, \dots, X_n) | T}(A) = \mathbb{P}((X_1, \dots, X_n) \in A | T) = \mathbb{E}_\theta(\mathbb{1}_{(X_1, \dots, X_n) \in A} | T) \quad (1.1.3)$$

pour tout $A \in \mathcal{A}^n$.

1.1.3 Domination et Densités

Définition (Domination) . On dira qu'une mesure μ positive *domine* $\mathbb{P}_\theta$ sur $(\mathcal{X}, \mathcal{A})$ si :

$$\boxed{\forall A \in \mathcal{A}, \quad \mu(A) = 0 \implies \mathbb{P}_\theta(A) = 0} \quad (1.1.4)$$

On notera alors $\mathbb{P}_\theta \ll \mu$. Si c'est le cas pour tout $\theta \in \Theta$, on dira alors que *le modèle est dominé par μ* .

Plus formellement, $\mathbb{P}_\theta \ll \mu$ ssi

$$\forall \varepsilon > 0, \exists \delta > 0 \quad \text{tel que} \quad \forall A \in \mathcal{A}, \mu(A) < \delta \implies \mathbb{P}_\theta(A) < \varepsilon \quad (1.1.5)$$

Théorème (Radon-Nikodym) . Soit μ σ -finie. On a $\mathbb{P}_\theta \ll \mu$ ssi

$$\forall \theta \in \Theta, \exists f \in L_+^1(\mu) \quad \text{telle que} \quad \forall A \in \mathcal{A}, \quad \mathbb{P}_\theta(A) = \int_A f \, d\mu \quad (1.1.6)$$

La densité f de $\mathbb{P}_\theta$ est unique à égalité μ -presque partout. Elle est notée $f = d\mathbb{P}_\theta/d\mu$ comme dérivée de Radon-Nikodym.

Remarque (Cas discret) Le cas des lois discrètes peut paraître contre-intuitif, mais s'explique bien grâce à ce théorème. Soit $\mathcal{X}$ fini ou dénombrable et $\mathcal{A} = \mathcal{P}(\mathcal{X})$. Soit m_c la mesure de comptage sur $\mathcal{A}$. Par définition de l'intégrale de Lebesgue, pour toute fonction $f : \mathcal{X} \rightarrow \mathbb{R}$ et $A \in \mathcal{A}$, on a :

$$\int_A f \, d m_c = \sum_{x \in A} f(x) m_c(x) = \sum_{x \in A} f(x)$$

Soit $\mathcal{P}_\Theta$ une famille de lois sur $\mathcal{X}$ et $n = 1$. On a $\mathcal{P}_\theta \ll m_c$ et les densités $f = d\mathbb{P}_\theta/dm_c$ existent et vérifient :

$$\forall A = \{x\} \in \mathcal{A}, \quad \mathbb{P}_\theta(\{x\}) = \int_{\{x\}} f \, d m_c = f(x)$$

On a donc bien $f(x) = \mathbb{P}_\theta(X = x)$.

1.1.4 Hypothèses de régularité

Pour tous les raisonnements suivants sur notre modèle, nous devons définir des *hypothèses*. Celles-ci nous assureront certaines propriétés nécessaires à l'application des théorèmes suivants.

Définition (Modèle Identifiable) . S'il existe μ σ -finie telle que $\mathcal{P}_\Theta \ll \mu$ et $\mu(\{f_{\theta_0} \neq f_{\theta_1}\}) > 0$ pour tout $\theta_0 \neq \theta_1$, alors le modèle $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)$ est dit *identifiable*.

Un modèle est identifiable si θ caractérise de façon unique une loi. Dans le cas contraire, un même valeur de θ pourrait correspondre à plusieurs lois initiales. L'estimation du paramètre n'aurait donc plus aucun sens.

Définition (Modèle Homogène) . Le modèle $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)$ est dit *homogène* si $\mathcal{P}_\Theta \ll \mathbb{P}_\theta$ pour tout $\theta \in \Theta$.

L'homogénéité est une propriété fondamentale d'un modèle et elle intervient sur plusieurs aspects. Un modèle homogène garantit que tous les $\mathbb{P}_\theta$ ont les mêmes ensembles négligeables. D'autre part, l'homogénéité garantit que le support des variables aléatoires ne dépend pas de θ . Sans cela, les inversion de dérivées/intégrales (voir ci-dessous) ne seraient pas possibles.

Proposition Le modèle $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)$ est homogène ssi, il existe μ σ -finie telle que :

- i) $\mathcal{P}_\Theta \ll \mu$
- ii) $\{f_\theta > 0\}$ μ -presque partout pour tout $\theta \in \Theta$.

En conséquence, pour tout $\theta \in \Theta$, $\mathcal{P}_\Theta \ll \mathbb{P}_\theta$. Donc les $\mathbb{P}_\theta$ ont tous les mêmes négligeables et la densité de $\mathbb{P}_{\theta_2}$ par rapport à $\mathbb{P}_{\theta_1}$ s'écrit :

$$\frac{d\mathbb{P}_{\theta_2}}{d\mathbb{P}_{\theta_1}} = \frac{f_{\theta_2}}{f_{\theta_1}} = \frac{d\mathbb{P}_{\theta_2}/d\mu}{d\mathbb{P}_{\theta_1}/d\mu}$$

En effet, on a pour tout $A \in \mathcal{A}$:

$$\begin{aligned} \mathbb{P}_{\theta_2}(A) &= \int_A \frac{f_{\theta_2}}{f_{\theta_1}} d\mathbb{P}_{\theta_1} = \int_A \frac{f_{\theta_2}}{f_{\theta_1}} f_{\theta_1} d\mu \\ &= \int_A f_{\theta_2} d\mu = \mathbb{P}_{\theta_2}(A). \end{aligned}$$

Définition (Hypothèses de régularité) . Définissons donc ces hypothèses :

(H_1) : Le modèle est **identifiable** et **dominé**.

$$i.e \quad \mathcal{P}_\Theta \ll \mu, \quad \text{et} \quad \forall \theta \in \Theta, f_\theta = \frac{d\mathbb{P}_\theta}{d\mu}, \quad \text{et} \quad \forall \theta_1 \neq \theta_2, \mu(\{f_{\theta_1} = f_{\theta_2}\}) = 0$$

(H_2) : Le modèle est **homogène**.

$$i.e \quad \forall \theta \in \Theta, \nabla f_\theta \in L^2(\mu)$$

(H_3) : Pour tout $A \in \mathcal{A}$, la fonction $\theta \in \Theta \mapsto \mathbb{P}_\theta(A)$, admet des dérivées partielles telles que :

$$\frac{\partial}{\partial \theta_k} \mathbb{P}_\theta(A) = \frac{\partial}{\partial \theta_k} \int_A f_\theta d\mu = \int_A \left(\frac{\partial}{\partial \theta_k} f_\theta \right) d\mu$$

(H_4) : Pour tout $A \in \mathcal{A}$, la fonction $\theta \in \Theta \mapsto \mathbb{P}_\theta(A)$, admet des dérivées partielles d'ordre 2 telles que :

$$\frac{\partial^2}{\partial \theta_j \partial \theta_k} \mathbb{P}_\theta(A) = \frac{\partial^2}{\partial \theta_j \partial \theta_k} \int_A f_\theta d\mu = \int_A \left(\frac{\partial^2}{\partial \theta_j \partial \theta_k} f_\theta \right) d\mu$$

1.1.5 Vraisemblance

Soit un échantillon $X = (X_1, \dots, X_n)$ d'un modèle vérifiant $H_{0,1}$.

Définition (Fonction de vraisemblance) . On appelle *fonction de vraisemblance* l'application L définie par :

$$L(\theta; x) = \prod_{i=1}^n f_{\theta}(x_i)$$

Pour un x observé, L est vue comme une fonction du paramètre θ . Il est crucial d'inclure les indicatrices de support $\mathbb{1}_{A(\theta)}(x_i)$ dans l'expression de f_{θ} .

Remarque (Double interprétation de la vraisemblance) La fonction $L(\theta; x)$ est un pivot entre deux mondes :

- *A priori* (Modélisation) : Pour θ fixé, $x \mapsto L(\theta; x)$ est la *densité* de l'échantillon. Elle décrit la distribution des observations possibles.
- *A posteriori* (Inférence) : Pour x observé et fixé, $\theta \mapsto L(\theta; x)$ est la *vraisemblance*. Elle mesure la *plausibilité* de chaque paramètre au vu des données.

Attention : La vraisemblance n'est pas une mesure de probabilité sur Θ . Elle permet de comparer deux paramètres entre eux via le rapport $\frac{L(\theta_1; x)}{L(\theta_0; x)}$, mais sa valeur absolue n'a pas de sens probabiliste intrinsèque.

Remarque (Log-vraisemblance) En pratique, on utilise la log-vraisemblance notée $\ell_n(\theta)$:

$$\ell_n(\theta) = \log L(\theta; x) = \sum_{i=1}^n \log f_{\theta}(x_i).$$

Elle facilite la recherche du Maximum de Vraisemblance (EMV) et le calcul du Score.

Théorème (Critère de factorisation de Fisher-Neyman) . T est une statistique exhaustive ssi il existe deux fonctions mesurables positives h et g_{θ} telles que :

$$L(\theta; x) = h(x) \cdot g_{\theta}(T(x))$$

Où h est indépendante de θ et g_{θ} ne dépend de x qu'à travers $T(x)$.

1.1.6 Maximum de Vraisemblance

Voyons à présent la vraisemblance comme fonction de θ . Elle traduit alors la plausibilité que θ soit le paramètre inconnu vis-à-vis de l'échantillon observé. On souhaiterait donc en déterminer le maximum pour trouver le θ "le plus probable". Pour cela, on utilise la méthode du *maximum de vraisemblance*.

Proposition Soit $X = (X_1, \dots, X_n)$ un n -échantillon d'une variable aléatoire de loi $\mathbb{P}_{\theta_*}$ et de densité f_{θ} . On souhaite déterminer le paramètre θ , pour cela, on considère la vraisemblance de l'échantillon définie par :

$$\forall \theta \in \Theta, \quad L(\theta, X_1, \dots, X_n) = \prod_{i=1}^n f_{\theta}(X_i)$$

dont on cherche le maximum. Or le produit n'est pas pratique à utiliser, notamment lors du calcul de la dérivée. On utilise donc la fonction log. Par sa croissance, la log-vraisemblance atteindra le même maximum de la vraisemblance. On calcule donc :

$$\ell_n(\theta) = \log \left(\prod_{i=1}^n f_{\theta}(X_i) \right) = \sum_{i=1}^n \log f_{\theta}(X_i).$$

Après quelques vérifications, on calculera sa dérivée à annuler pour trouver une valeur de θ candidate, noté $\hat{\theta}_n$, que l'on conservera après avoir confirmé la concavité de ℓ_n en étudiant le signe de sa dérivée seconde. Le $\hat{\theta}_n$ sera appelé un *estimateur* et sera une fonction de $(X_1, \dots, X_n)$.

Définition (Estimateur) . Dans un modèle $(\mathcal{X}, \mathcal{A}, \mathbb{P}_\theta)$ dominé par μ , un *estimateur du maximum de vraisemblance* est une statistique $\hat{\theta}$ telle que :

$$L(\hat{\theta}, X_1, \dots, X_n) = \max_{\theta \in \Theta} L(\theta, X_1, \dots, X_n) \quad (1.1.7)$$

pour n'importe quel échantillon $(X_1, \dots, X_n)$ de loi $\mathbb{P}_{\theta_*}$.

1.2 Informations Qualitatives

1.2.1 Exhaustivité

Une statistique T est exhaustive si elle "conserve" toute l'information utile sur θ . Mathématiquement, cela signifie qu'une fois T connue, la loi de l'échantillon ne dépend plus de θ .

Définition (Statistique Exhaustive) . T est exhaustive pour θ si la loi conditionnelle de $(X_1, \dots, X_n)$ sachant T est indépendante de θ .

$$\forall \theta \in \Theta, \quad \mathcal{L}_\theta(X_1, \dots, X_n \mid T) = \mathcal{L}(X_1, \dots, X_n \mid T)$$

Remarque En pratique, on utilise presque exclusivement le théorème de factorisation de Fisher-Neyman pour prouver l'exhaustivité.

Proposition T est une *statistique exhaustive* ssi pour toute statistique S réelle intégrable, on a :

$$\mathbb{E}_\theta(S \mid \sigma(T)) = \varphi(T) \quad (1.2.1)$$

(i.e si cela ne dépend pas de θ .)

Exemple (Statistique exhaustive) Soit $(X_1, \dots, X_n)$ un échantillon d'une variable aléatoire $X \sim \mathcal{B}(1, \theta)$. Posons $S_n = \sum_{i=1}^n X_i \sim \mathcal{B}(n, \theta)$. On a ici, $\mathcal{X} = \{0, 1\}^n$. On cherche à estimer θ . Montrons que S est une statistique exhaustive. Soit $k \in \llbracket 1, n \rrbracket$, on :

$$\begin{aligned} & \mathbb{P}_\theta((X_1, \dots, X_n) = (x_1, \dots, x_n) \mid S_n = k) \\ &= \frac{\mathbb{P}_\theta((X_1, \dots, X_n) = (x_1, \dots, x_n) \cap S_n = k)}{\mathbb{P}_\theta(S_n = k)} \\ &= \mathbb{1}_{\{\sum_{i=1}^n x_i = k\}} \times \frac{\mathbb{P}_\theta((X_1, \dots, X_n) = (x_1, \dots, x_n))}{\mathbb{P}_\theta(S_n = k)} \\ &= \mathbb{1}_{\{\sum_{i=1}^n x_i = k\}} \times \prod_{i=1}^n \frac{\mathbb{P}_\theta(X_i = x_i)}{\binom{n}{k} \theta^k (1-\theta)^{n-k}} \\ &= \frac{1}{\binom{n}{k}} \end{aligned}$$

qui est indépendant de θ donc S_n est bien une statistique exhaustive en θ .

1.2.2 Minimalité et complétude

On souhaite définir des statistiques dites minimales, contenant uniquement l'information nécessaire sur θ à partir de l'échantillon. Pour cela, on pose :

$$\mathcal{A}^* := \bigcap_{T \text{ exhaustive}} \sigma(T)$$

appelée la *tribu exhaustive minimale*. Elle contient donc toute l'information apportée par $(X_1, \dots, X_n)$ sur θ .

Définition (Statistique exhaustive minimale) . On dira d'une statistique exhaustive S^* qu'elle est *minimale* si $\sigma(S^*) = \mathcal{A}^*$.

Proposition (Caractérisation de $\mathcal{A}$) Sous H_1 , pour $\theta_0 \in \Theta$ fixé, on a :

$$\mathcal{A} = \sigma \left\{ \frac{L_\theta}{L_{\theta_0}}(X_1, \dots, X_n) \mid \theta \in \Theta \right\}$$

Proposition (Statistiques exhaustives minimales) Soit S une statistique exhaustive telle que :

$$S(x_1, \dots, x_n) = S(y_1, \dots, y_n) \iff \frac{L_\theta(x_1, \dots, x_n)}{L_\theta(y_1, \dots, y_n)} \text{ indépendants de } \theta \quad (1.2.2)$$

alors S est *minimale*.

Exemple (Loi exponentielle) Soit la densité de la loi exponentielle $f_\theta(x) = \theta e^{-\theta x}$. On cherche à déterminer S^* . Posons $S_n = \sum_{i=1}^n X_i$. On a :

$$L_\theta(X_1, \dots, X_n) = \prod_{i=1}^n f_\theta(X_i) = \theta^n e^{-\theta S_n}$$

Pour tout $\theta_0 \neq \theta_1$, on a :

$$\frac{L_{\theta_1}}{L_{\theta_2}}(X_1, \dots, X_n) = \exp((\theta_0 - \theta_1)S_n + n(\log \theta_1 - \log \theta_0))$$

Donc S est fonction mesurable du rapport $L_{\theta_1}/L_{\theta_2}$, elle est donc minimale.

Définition (Statistique Complète (ou Totale)) . Une statistique T est dite *complète* si pour toute fonction mesurable h telle que $\mathbb{E}_\theta[h(T)]$ existe :

$$\forall \theta \in \Theta, \quad \mathbb{E}_\theta[h(T)] = 0 \implies h(T) = 0 \quad \mathbb{P}_\theta\text{-p.s.}$$

Théorème (Lien entre Complétude et Minimalité) . Si une statistique T est *exhaustive* et *complète*, alors elle est *exhaustive minimale*.

Remarque Dans le cas des *modèles exponentiels* (voir plus loin), la statistique naturelle $T(X)$ est toujours exhaustive et complète (si l'espace des paramètres Θ est d'intérieur non vide). C'est le moyen le plus rapide en exercice pour obtenir une minimale.

1.2.3 Statistiques Libres

Définition (Statistique Libre) . Une statistique S est dite *libre* si sa loi ne dépend pas de θ .

$$\forall \theta, \theta' \in \Theta, \quad \mathbb{P}_\theta^S = \mathbb{P}_{\theta'}^S$$

Cette notion est fondamentale pour isoler le "bruit" du "signal" (θ). Le lien avec l'exhaustivité est donné par le théorème suivant, très utile pour montrer l'indépendance de deux variables ou pour prouver qu'une statistique n'est pas exhaustive.

Théorème (Théorème de Basu) . Si T est une statistique *exhaustive complète* et S est une statistique *libre*, alors T et S sont *indépendantes* sous toute loi $\mathbb{P}_\theta$.

Exemple Dans un modèle gaussien $\mathcal{N}(\mu, \sigma^2)$ avec σ^2 connu, la moyenne empirique $\bar{X}_n$ est exhaustive complète. La variance empirique S_n^2 (ou toute valeur centrée $X_i - \bar{X}_n$) est libre. Par le théorème de Basu, $\bar{X}_n$ et S_n^2 sont indépendantes.

1.3 Information de Kullback-Leibler

Définition (Information de Kullback-Leibler) . L'information de *Kullback-Leibler* (ou entropie relative) entre deux lois du modèle est définie par :

$$K(\theta_0 | \theta_1) = \mathbb{E}_{\theta_0} \left[\log \frac{f_{\theta_0}(X)}{f_{\theta_1}(X)} \right] = \int_{\mathcal{X}} f_{\theta_0} \log \left(\frac{f_{\theta_0}}{f_{\theta_1}} \right) d\mu \quad (1.3.1)$$

On parle de *divergence* ou de *contraste* plutôt que de distance, car cette application n'est pas symétrique ($K(\theta_0 | \theta_1) \neq K(\theta_1 | \theta_0)$) et ne respecte pas l'inégalité triangulaire.

Proposition (Propriétés fondamentales) Soit $\mathcal{P}_\Theta$ un modèle dominé.

- *Indépendance* : $K(\theta_0 | \theta_1)$ ne dépend pas du choix de la mesure dominante μ .
- *Positivité (Inégalité de Gibbs)* : $K(\theta_0 | \theta_1) \geq 0$ (découle de l'inégalité de Jensen).
- *Séparation* : $K(\theta_0 | \theta_1) = 0 \iff \mathbb{P}_{\theta_0} = \mathbb{P}_{\theta_1}$.
- *Lien Identifiabilité* : Si le modèle est identifiable, $K(\theta_0 | \theta_1) = 0 \iff \theta_0 = \theta_1$.

1.4 Informations Quantitatives

1.4.1 Vecteur Score

Durant toute cette section, nous serons amenés à calculer le gradient de log-vraisemblance. Pour simplifier les calculs et étudier leurs propriétés, nous allons les définir sous la forme de *vecteurs scores*.

Définition (Vecteur Score) . Soit $(H_{1,2})$, le vecteur aléatoire score d'un échantillon X est défini par le gradient de la log-vraisemblance de l'échantillon. On a donc :

$$S_\theta(X) = \nabla_\theta \log f_\theta(X) = \frac{1}{f_\theta(X)} \nabla f_\theta(X). \quad (1.4.1)$$

C'est une *variable aléatoire*.

Propriété (Espérance) . Sous $(H_{1,2,3})$, les vecteurs scores donc centrés.

$$i.e \quad (H_{1,2,3}) \implies \forall \theta \in \Theta, \mathbb{E}_\theta(S_\theta(X)) = 0_p$$

Démonstration Supposons $(H_{1,2,3})$, on a alors que $\int_{\mathcal{X}} f_\theta d\mu = 1$ car c'est une densité. Donc par $(H_{1,2,3})$, on a :

$$\begin{aligned} & \int_{\mathcal{X}} \frac{\partial}{\partial \theta_k} f_\theta d\mu = 0 \\ \iff & \int_{\mathcal{X}} \frac{1}{f_\theta(x)} \frac{\partial}{\partial \theta_k} f_\theta(x) \times \underbrace{f_\theta(x) d\mu(x)}_{d\mathbb{P}_\theta(x)} = 0 \\ \iff & \int_{\mathcal{X}} \frac{\partial}{\partial \theta_k} \log f_\theta d\mathbb{P}_\theta = 0 \\ \iff & \mathbb{E}_\theta \left(\frac{\partial}{\partial \theta_k} \log f_\theta \right) = 0 \end{aligned}$$

1.4.2 Modèles exponentiels

Voyons à présent un modèle régulier très utilisé : le *modèle exponentiel*.

Définition (Modèle Exponentiel) . Un modèle $(\mathcal{X}, \mathcal{A}, \mathcal{P}_\Theta)$ sera dit *exponentiel* si :

$$\boxed{\forall \theta \in \Theta, \quad f_\theta(x) = k_\theta h(x) \exp(\langle T(x), \gamma(\theta) \rangle) .}$$

Avec $\gamma(\Theta) \subset \mathbb{R}^q$, $T : \mathcal{X} \longrightarrow \mathbb{R}^q$ et $h : \mathcal{X} \longrightarrow \mathbb{R}$ la fonction de changement de mesure. Il sera qualifié *de plein rang* si $p = q$. On dira aussi qu'il est *canonique* si $p = q$ et γ est l'identité. On appellera enfin $T(X)$ la *statistique privilégiée du modèle*. Par soucis de clarté, on notera souvent $\kappa_\theta = \log k_\theta$.

Théorème (Régularité) . Un modèle exponentiel canonique de plein rang vérifie $(H_{1,2,3,4})$ et $k_\theta \in \mathcal{C}^\infty$.

Proposition Les modèles canoniques sont très pratiques à manipuler. On a :

$$f_\theta(x) = k_\theta h(x) \exp(\langle T(x), \theta \rangle)$$

Après calcul, on obtient que $S_\theta(X) = \nabla_\theta \log k_\theta + T(X) \in \mathbb{R}^p$. Or, on sait que $\mathbb{E}_\theta(S_\theta(X)) = 0$, donc :

$$\mathbb{E}_\theta(T(X)) = -\nabla_\theta \kappa_\theta.$$

Propriété (Cas général) . Dans un cadre plus général, un modèle exponentiel de plein rang admet des scores de la forme :

$$S_\theta(X) = J_\gamma^t \times T(X) + \nabla_\theta \kappa_\theta$$

avec $J_\gamma = \left(\left(\frac{\partial \gamma_i}{\partial \theta_j}(\theta) \right)_{i,j} \right)$ ma matrice Jacobienne $p \times p$ de $\gamma : \Theta \longrightarrow \mathbb{R}^p$. Si J_γ est définie positive, alors :

$$\mathbb{E}_\theta(T(X)) = - \left(J_\gamma^{-1} \right)^t \times \nabla_\theta \kappa_\theta$$

Propriété (Statistique privilégiée) . Dans le cas d'un modèle exponentiel, la statistique T est *exhaustive, complète et minimale*.

1.4.3 Information de Fisher

Passons à la définition principale de cette partie : l'information de Fisher. Elle quantifie l'information contenue sur θ dans l'acte d'observer X .

Définition (Information de Fisher) . Sous $(H_{1,2})$, la *quantité d'information de Fisher* en θ apportée par l'acte d'observer une réalisation $X(\omega)$ sous $\mathbb{P}_\theta$ est :

$$\mathcal{I}_\theta(X) = \mathbb{E}_\theta(S_\theta(X) \times S_\theta^t(X)) \quad (1.4.2)$$

Si (H_4) est vérifiée, alors $\mathcal{I}_\theta(X) = \mathbb{V}_\theta(S_\theta(X))$, la matrice de covariance du vecteur score.

Propriété (Information de Fisher) .

- Sous $(H_{1,2})$, $\mathcal{I}_\theta(X)$ est intrinsèque au modèle (i.e elle ne dépend plus de la mesure dominante μ).
- Sous $(H_{1,2,3,4})$, on a :

$$\mathcal{I}_\theta(X) = -\mathbb{E}_\theta(J_{S_\theta(X)}) = -\mathbb{E}_\theta \left(\left(\frac{\partial^2 \log f_\theta(X)}{\partial \theta_i \partial \theta_j} \right)_{i,j} \right)$$

avec $J_{S_\theta(X)}$ la Jacobienne du score.

Ces propriétés seront donc privilégiées pour le calcul pratique de l'information de Fisher.

Propriété (Cas du modèle exponentiel canonique) . Dans le cas d'un modèle exponentiel canonique, on a :

$$\mathcal{I}_\theta(X) = \mathbb{V}_\theta(T(X)) = -H_{\kappa_\theta}$$

où H_{κ_θ} est la hessienne de $\kappa_\theta = \log k_\theta$. Donc si $p = 1$, alors $\mathcal{I}_\theta(X) = -\frac{\partial^2}{\partial \theta^2} \log k_\theta$.

Proposition Comme dit précédemment, les modèles exponentiels de plein rang sont très utiles. Ils permettent de calculer simplement l'information de Fisher à partir des fonctions définissant la densité. On a donc :

$$\begin{aligned} \mathcal{I}_\theta(X) & \stackrel{\text{def}}{=} J_\gamma^t \times \mathbb{V}_\theta(T(X)) \times J_\gamma(\theta) \\ & \stackrel{\text{prop}}{=} -H_{\kappa_\theta} - H_\gamma (J_\gamma^{-1})^t \nabla_\theta \kappa_\theta \end{aligned}$$

Si $p = 1$,

$$\mathcal{I}_\theta(X) = (\gamma'(\theta))^2 \times V_\theta(T(X)) = \frac{-k'_\theta}{k_\theta} \left(\frac{k''_\theta}{k'_\theta} + \frac{\gamma''_\theta}{\gamma'_\theta} - \frac{k'_\theta}{k_\theta} \right)$$

Exemple Soit le modèle $X \sim \mathcal{N}(\theta_1, \theta_2^2)$, avec $\begin{cases} \theta_1 = \mathbb{E}_\theta(X) \\ \theta_2 = \sqrt{\mathbb{V}_\theta(X)} \end{cases}$. On a donc :

$$f_\theta(x) = \frac{1}{\sqrt{2\pi}} \exp(\langle T(x), \gamma(\theta) \rangle + \kappa_\theta)$$

où $p = q = 2$ et :

$$T(x) = (x, x^2), \quad \kappa_\theta = -\frac{\theta_1^2}{2\theta_2^2} - \log \theta_2, \quad \gamma(\theta) = \left(\frac{\theta_1}{\theta_2}, -\frac{1}{2\theta_2^2} \right)$$

On peut donc ensuite appliquer les formules :

$$J_\gamma = \begin{pmatrix} \frac{1}{\theta_2^2} & -\frac{2\theta_1}{\theta_2^2} \\ 0 & \frac{1}{\theta_2^2} \end{pmatrix} \quad \mathbb{V}_\theta(T(X)) = \begin{pmatrix} \theta_2^2 & \text{Cov}(X, X^2) \\ \text{Cov}(X, X^2) & \mathbb{V}_\theta(X^2) \end{pmatrix}$$

On a donc :

$$\begin{aligned} \mathcal{I}_\theta(X) &= Y_\gamma^t \times V_\theta(T(X)) \times J_\gamma \\ &= -\mathbb{E}_\theta \left(\frac{\partial^2}{\partial \theta_i \partial \theta_j} \left(-\frac{(X - \theta_1)^2}{2\theta_2^2} - \log \theta_2 \right) \right)_{i,j} = \begin{pmatrix} \frac{1}{\theta_2^2} & 0 \\ 0 & \frac{2}{\theta_2^2} \end{pmatrix} \end{aligned}$$

1.4.4 Propriétés de l'information de Fisher

L'information de Fisher possède des propriétés de structure fondamentales qui découlent de la linéarité du score et de la géométrie du modèle.

1. **Additivité** : Soient S et T deux statistiques $\mathcal{P}_\Theta$ -indépendantes. Si les modèles associés vérifient $(H_{1,2,3})$, l'information jointe est la somme des informations :

$$\mathcal{I}_\theta(S, T) = \mathcal{I}_\theta(S) + \mathcal{I}_\theta(T)$$

Conséquence : Dans le modèle d'échantillonnage i.i.d. $\mathcal{P}_\Theta^{\otimes n}$, on a :

$$\boxed{\mathcal{I}_\theta(X_1, \dots, X_n) = n\mathcal{I}_\theta(X_1)}$$

2. **Décroissance par transfert (Information image)** : Soit S une statistique. Si le modèle image vérifie $(H_{1,2,3})$, le score image est $S_\theta(S) = \mathbb{E}_\theta[S_\theta(X) \mid S]$. Par l'inégalité de Jensen (ou la formule de décomposition de la variance), on a :

$$\mathcal{I}_\theta(S) = \mathbb{V}_\theta(\mathbb{E}_\theta[S_\theta(X) \mid S]) \preceq \mathbb{V}_\theta(S_\theta(X)) = \mathcal{I}_\theta(X)$$

Ainsi, $\mathcal{I}_\theta(X) - \mathcal{I}_\theta(S)$ est une matrice semi-définie positive. On perd de l'information en condensant les données, sauf si la statistique est exhaustive.

3. **Conservation par exhaustivité** : Sous $(H_{1,2,3})$, une statistique S est exhaustive si et seulement s'il n'y a pas de perte d'information par transfert :

$$\boxed{S \text{ est exhaustive} \iff \mathcal{I}_\theta(S(X_1, \dots, X_n)) = n\mathcal{I}_\theta(X_1)}$$

4. **Lien avec le contraste de Kullback** : Sous $(H_{1,2,3,4})$, pour tout $\theta_0 \in \Theta$ fixé, l'information de Fisher est la matrice Hessienne du contraste de Kullback-Leibler (courbure locale de la divergence) :

$$\mathcal{I}_{\theta_0}(X) = \text{Hess}_\theta(K(\theta_0 \mid \theta)) \Big|_{\theta=\theta_0} = \left(\left(\frac{\partial^2 K(\theta_0 \mid \theta)}{\partial \theta_i \partial \theta_j} \right)_{i,j} \right)_{\theta=\theta_0}$$

Chapitre 2

Estimation et Risque

Contents

2.1	Risque	15
2.2	Estimateurs	16
2.2.1	Définition	16
2.2.2	Comparaisons	16
2.2.3	Comparaison par le risque	16
2.2.4	Optimalité	18
2.2.5	Biais	18
2.3	Risque Quadratique	19
2.3.1	Cas $q = 1$	19
2.3.2	Cas $q > 1$	20
2.3.3	Amélioration de Rao-Blackwell	20
2.3.4	Optimalité de Lehman-Scheffe	21
2.4	Bornes inférieures de variance et Efficacité	21
2.4.1	Inégalité de Fréchet-Darmois-Cramér-Rao (FDCR)	22
2.4.2	La réciproque de Koopman (Cas d'égalité)	22

En statistiques paramétriques, on cherche à déterminer la valeur d'un paramètre θ^* inconnu. Nous posons ici une autre démarche que celle des estimateurs vue précédemment.

2.1 Risque

Définition (Règle de décision) . On appelle *règle de décision* δ une statistique à valeurs dans un espace $(\mathbb{D}, \mathcal{D})$ telle que :

$$\delta : (\mathcal{X}, \mathcal{A})^{\oplus n} \longrightarrow (\mathbb{D}, \mathcal{D}).$$

Remarque Une règle de décision est donc une fonction mesurable et indépendante d'un paramètre θ puis c'est une statistique.

Proposition Il existe différents types de règles de décisions :

- **Estimation** : On choisit un paramètre θ par un estimateur $\delta(X_1, \dots, X_n)$ à partir d'informations contenues dans un échantillon. On a donc $\mathbb{D} = \Theta$ et on peut définir *l'erreur quadratique moyenne* :

$$R_Q(\delta, \theta) = \mathbb{E}_\theta(\|\delta - \theta\|_p^2)$$

sous $\mathbb{P}_\theta$. Ici, on aura $\mathbb{D} = \mathcal{P}(\Theta)$.

- **Localisation** : Ici, on choisit plutôt une région pouvant contenir θ . On veut donc une notion de *confiance* telle que :

$$\forall \theta \in \Theta, \quad \mathbb{P}_\theta(\theta \in \delta(X_1, \dots, X_n)) \geq 1 - \alpha.$$

- **Test** : On a ici $\mathbb{D} = \{0, 1\}$ ou $\mathbb{D} = [0, 1]$. On cherche à vérifier si une affirmation sur θ est vraie plutôt qu'une autre. Elles seront définies par deux types d'hypothèses : *l'hypothèse nulle* $\mathcal{H}_0$ et *l'hypothèse alternative* $\mathcal{H}_1$. On souhaite donc que :

- $\mathbb{P}(\delta(X_1, \dots, X_n) = 0)$ soit proche de 1 si $\theta \in \Theta_0$.
- $\mathbb{P}(\delta(X_1, \dots, X_n) = 1)$ soit proche de 1 si $\theta \notin \Theta_0$.

2.2 Estimateurs

2.2.1 Définition

On cherche ici à estimer une transformation $g(\theta)$ d'un paramètre θ connu. Pour cela, on dispose de :

$$g : \begin{cases} \Theta \subseteq \mathbb{R}^p \longrightarrow \mathbb{R}^q \\ \theta \longmapsto g(\theta) \end{cases}$$

Définition (Estimateur) . On appelle *estimateur* de $g(\theta)$ toute fonction mesurable :

$$\delta : (\mathcal{X}, \mathcal{A})^{\oplus n} \longrightarrow (g(\Theta), \mathcal{D})$$

qui ne dépend pas de θ . On note Δ l'ensemble des estimateurs de θ .

Remarque Si $\hat{\theta}_n$ est un "bon" estimateur de θ , alors $g(\hat{\theta}_n)$ n'est pas nécessairement un aussi bon estimateur pour $g(\theta)$. La composition doit s'étudier au cas par cas.

2.2.2 Comparaisons

On souhaite qu'un estimateur se comporte comme une boîte noire pointant toujours sur θ peu importe sa valeur.

Définition (Estimateur consistant) . Une suite d'estimateurs $\delta_n \in \Delta^{\mathbb{N}}$ sera dite *consistante* si :

$$\forall \theta \in \Theta, \quad \lim_{n \rightarrow \infty} \delta_n(X_1, \dots, X_n) = g(\theta) \quad \mathbb{P}_\theta\text{-p.s.}$$

Définition (Estimateur Asymptotiquement Gaussien) . Une suite d'estimateurs $\delta_n \in \Delta^{\mathbb{N}}$ sera dite *asymptotiquement gaussienne* si pour tout $\theta \in \Theta$, il existe une matrice V_θ semi-définie positive telle que sous P_θ^∞ , on ait :

$$\sqrt{n}(\delta_n(X_1, \dots, X_n) - g(\theta)) \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0_p, V_\theta).$$

2.2.3 Comparaison par le risque

Un autre façon de comparer deux estimateurs est d'introduire une notion de *perte* qui quantifie le degré d'erreur d'estimation de $g(\theta)$. Pour cela, on définit les fonctions de perte ou *loss* en anglais.

Définition (Fonction de perte) . Une fonction de perte ℓ est une fonction mesurable positive :

$$\ell : \Theta \times g(\Theta) \longrightarrow (\mathbb{R}_+, \mathcal{B}_{\mathbb{R}})$$

telle que :

$$\boxed{\forall (\theta, d) \in \Theta \times g(\Theta), \quad \ell(\theta, d) = 0 \iff d = g(\theta)}.$$

Comme dit précédemment, on souhaite que nos estimateurs se comportent comme des boîtes noires. Il nous faut cela minimiser la perte moyenne d'une décision pour toutes les valeurs de $g(\theta)$ possibles. Cette notion sera donc définie comme le *risque*.

Définition (Risque) . On définit la *fonction de risque* associée à une décision $\delta \in \Delta$, comme l'application :

$$\theta \longmapsto R(\theta, \delta) = \mathbb{E}_{\theta}(\ell(\theta, \delta)).$$

Ainsi, un estimateur δ sera dit *préférable* à un autre $\delta' \in \Delta$, ssi :

$$\forall \theta \in \Theta, \quad R(\theta, \delta') \leq R(\theta, \delta).$$

On notera alors $\delta \succeq \delta'$.

Remarque Se pose alors un problème fondamental dans la recherche de l'estimateur optimal. Admettons que vous ayez un ami complotiste qui croit les extraterrestres sont parmi nous. Dans tous les mondes qu'il pourrait exister, la plupart ne sont pas dirigés par une secte martienne. Or, il suffit qu'un seul monde le soit pour que vous ne soyez pas meilleur que votre ami pour une valeur spécifique de θ .

C'est exactement le problème que posent les estimateurs constants. On va donc chercher à les exclure en créant des sous-classes $\Delta_i \subset \Delta$.

Démonstration Supposons qu'il existe $\delta^* \in \Delta$ un estimateur parfait tel que :

$$\forall \theta \in \Theta, \quad \forall \delta \in \Delta, \quad R(\theta, \delta^*) \leq R(\theta, \delta).$$

alors $\delta = \delta_{\theta_0}$ qui répond θ_0 presque-partout quelque soit l'échantillon proposé (un estimateur constant). D'où :

$$R(\theta, \delta_{\theta_0}) \begin{cases} = 0 & \text{si } \theta = \theta_0 \\ > 0 & \text{si } \theta \neq \theta_0. \end{cases}$$

Donc nécessairement $\forall \theta \in \Theta, R(\theta, \delta^*) = 0$ pour faire mieux que chacun des estimateurs constants.

Définition (Estimateurs admissibles) . On définit l'ensemble des estimateurs *admissibles*, noté Δ_0 , comme l'ensemble des estimateurs "meilleurs en moyenne". Plus formellement,

$$\Delta_0 = \{\delta \in \Delta \mid \nexists \delta' \in \Delta, \delta' \succeq \delta\}.$$

Proposition Supposons que Δ_0 est stable par combinaison convexe et que ℓ est strictement convexe en la décision δ . Alors si δ_0 est admissible dans Δ_0 et si δ_1 admet la même fonction de risque, alors $\delta_1 = \delta_0$ $\mathbb{P}_{\theta}$ -p.p pour tout $\theta \in \Theta$.

Exemple Soit Δ_0 la classe des estimateurs sans biais moyen :

$$\Delta_0 := \{\delta \in \Delta \mid \mathbb{E}_{\theta}(\delta(X_1, \dots, X_n)) = g(\theta)\}.$$

Soit $\delta_0, \delta_1 \in \Delta_0$, alors :

$$\forall \alpha \in [0, 1], \quad \alpha \delta_0 + (1 - \alpha) \delta_1 \in \Delta_0$$

par linéarité de $\mathbb{E}_\theta(\cdot)$. Donc Δ_0 est bien stable et :

$$\delta \mapsto \ell(\theta, \delta) = \|g(\theta) - \delta\|_2^2$$

est convexe. Donc dans la classe des estimateurs sans biais, s'il existe un estimateur de plus petit risque, alors il est unique.

2.2.4 Optimalité

On cherche donc à déterminer des estimateurs optimaux (i.e minimisant la fonction de risque).

Définition (Estimateur Optimal) . On dira que δ_{opt} est ℓ -optimal dans Δ_0 si :

$$\forall \theta \in \Theta, \quad R(\theta, \delta_{opt}) = \min_{\delta \in \Delta_0} R(\theta, \delta).$$

Définition (Estimateur Asymptotiquement Optimal) . On dit qu'une suite $\delta_n(X_1, \dots, X_n)$ est asymptotiquement ℓ -optimale relativement à une suite Δ_n de classes d'estimateurs si :

$$\forall \theta \in \Theta, \quad \lim_{n \rightarrow \infty} \frac{R(\theta, \delta_n(X_1, \dots, X_n))}{\inf_{\delta \in \Delta_n} R(\theta, \delta)} = 1.$$

2.2.5 Biais

La notion de biais permet de quantifier la façon dont un estimateur δ approche $g(\theta)$ en moyenne. Pour cela, il existe différents types de biais.

Définition (Biais Moyen) . On dira qu'un estimateur $\delta \in \Delta$ est *sans biais moyen* pour $g(\theta)$ si :

$$\mathbb{E}_\theta(\delta(X_1, \dots, X_n)) = g(\theta).$$

On peut ainsi définir la *fonction de biais* b d'un estimateur :

$$b : \theta \in \Theta \mapsto \mathbb{E}_\theta(\delta) - g(\theta).$$

De même que pour l'optimalité, il est souhaitable que le biais d'un estimateur diminue lorsque la taille de l'échantillon augmente. On parle alors de *biais moyen asymptotique*.

Définition (Biais moyen asymptotique) . Un estimateur δ est dit *sans biais moyen asymptotique* si :

$$\forall \theta \in \Theta, \quad \lim_{n \rightarrow \infty} b(\delta_n) = 0.$$

Ce qui revient à $\mathbb{E}_\theta(\delta_n) \xrightarrow{n \rightarrow \infty} g(\theta)$.

Remarque Un estimateur centré n'est pas nécessairement sans biais moyen. La notion de centrage exprime seulement le fait que $\mathbb{E}_\theta(\delta(X_1, \dots, X_n)) = 0_q$ pour tout $\theta \in \Theta$. Or, si $g(\theta) \neq 0_q$ pour tout θ , alors l'estimateur est biaisé.

Définition (Biais Général) . Un estimateur δ est dit *sans biais général* pour une fonction de perte ℓ si :

$$\forall \theta, \theta' \in \Theta, \quad R(\theta, \delta) = \mathbb{E}_\theta(\ell(\theta, \delta)) \leq \mathbb{E}_\theta(\ell(\theta', \delta)).$$

On notera Δ_{sb} la classe des estimateurs sans biais.

Définition (Biais Médian) . Si $q = 1$, un estimateur $\delta \in \Delta$ est *sans biais médian* si :

$$\forall \theta \in \Theta, \quad \begin{cases} \mathbb{P}_\theta(\delta(X_1, \dots, X_n) > g(\theta)) \leq 1/2 \\ \mathbb{P}_\theta(\delta(X_1, \dots, X_n) < g(\theta)) \leq 1/2 \end{cases}.$$

La notion de biais médian signifie qu'un estimateur a autant de chances de surestimer $g(\theta)$ que de le sous-estimer. Elle traduit de façon plus fine la dispersion possible de l'estimateur autour de $g(\theta)$.

2.3 Risque Quadratique

La notion de biais vue précédemment traduit le fait qu'un estimateur soit en moyenne "précis" ou pas pour estimer $g(\theta)$, mais elle ne donne aucune notion sur la dispersion d'un estimateur autour du paramètre. Or, il serait parfois préférable de travailler avec un estimateur moins "précis" (biaisé) mais moins dispersé.

2.3.1 Cas $q = 1$

On cherche donc une mesure permettant d'additionner la notion de biais et de variance d'un estimateur. En effet, un estimateur sans biais peut être complètement divergent pour n grand (non consistant) et inversement.

Au lieu d'utiliser une métrique différente, on pourrait adapter celles déjà introduites telles que la *perte* et le *risque moyen*. Une bonne fonction de perte pourrait être la *perte quadratique* :

$$\ell_Q(\theta, \delta) = (\delta - g(\theta))^2$$

possédant de bonnes propriétés de convexité et de différentiabilité. De plus elle pénalise de façon égale les erreurs négatives ou positives tout en pénalisant fortement les grosses erreurs.

Définition (Risque Quadratique Moyen) . On définit le *risque quadratique moyen* R_Q d'un estimateur δ comme le risque de cet estimateur appliqué à la fonction de perte quadratique. D'où :

$$\forall \theta \in \Theta, \quad R_Q(\theta, \delta) = \mathbb{E}_\theta(\ell_Q(\theta, \delta)) = \mathbb{E}_\theta((\delta - g(\theta))^2).$$

Propriété (Décomposition) . Comme souhaité, le risque quadratique moyen vérifiera :

$$\forall \delta \in \Delta, \forall \theta \in \Theta, \quad \boxed{R_Q(\theta, \delta) = V_\theta(\delta) + b(\theta, \delta)^2}.$$

Démonstration Soient $\delta \in \Delta$ et $\theta \in \Theta$, on a :

$$\begin{aligned} R_Q(\theta, \delta) &= \mathbb{E}_\theta((\delta - g(\theta))^2) \\ &= \mathbb{E}_\theta((\delta - \mathbb{E}_\theta(\delta) + \mathbb{E}_\theta(\delta) - g(\theta))^2) \\ &= \mathbb{E}_\theta((\delta - \mathbb{E}_\theta(\delta))^2) + (\mathbb{E}_\theta(\delta) - g(\theta))^2 + 2\underbrace{\mathbb{E}_\theta((\delta - \mathbb{E}_\theta(\delta))(\mathbb{E}_\theta(\delta) - g(\theta)))}_{\text{d'esp. nulle}} \\ &= V_\theta(\delta) + b(\theta, \delta). \end{aligned}$$

Proposition Ainsi, sur Δ_{sb} , on aura $\delta \succeq \delta'$ si $R_Q(\theta, \delta) \leq R_Q(\theta, \delta')$ pour tout $\theta \in \Theta$. Ce qui équivaut donc à $V_\theta(\delta) \leq V_\theta(\delta')$. Dire que δ_{opt} est ℓ_Q -optimal signifie que δ_{opt} est *sans biais de variance minimale* pour tout $\theta \in \Theta$.

2.3.2 Cas $q > 1$

De même que précédemment, on cherche à quantifier la pertience d'un estimateur en termes de dispersion et de précision par rapport au paramètre. On souhaite ici à estimer plusieurs paramètres $\theta = (\theta_1, \dots, \theta_n)$. On notera alors un estimateur $\delta(X_1, \dots, X_n) \in \mathbb{R}^q$ simplement δ de coordonnées $\delta^t = (\delta_1, \dots, \delta_q)$. De même, on aura :

$$\mathbb{E}_\theta(\delta) = (\mathbb{E}_\theta(\delta_1), \dots, \mathbb{E}_\theta(\delta_q))$$

$$\mathbb{V}_\theta(\delta) = \mathbb{E}_\theta [(\delta - \mathbb{E}_\theta(\delta))(\delta - \mathbb{E}_\theta(\delta))^t] = \left((\text{cov}_\theta(\delta_i, \delta_j))_{i,j} \right).$$

Définition (Perte, Risque, Comparaison - Cas Multivarié) . Pour toute matrice M semi-définie positive, on définit la perte ℓ d'un estimateur par rapport à un vecteur paramètre θ comme l'application telle que :

$$\ell_M(\theta, \delta) = (\delta - g(\theta))^t M (\delta - g(\theta)).$$

Aussi le *risque quadratique associé* à M sera :

$$\mathbb{R}_M(\theta, \delta) = \mathbb{E}_\theta(\ell_M(\theta, \delta)).$$

Si $M = Id$, on retrouve alors le risque quadratique moyen. On dira ainsi que $\delta \succeq_Q \delta'$ (i.e il est Q -préférable à δ') si :

$$R_M(\theta, \delta) \leq R_M(\theta, \delta') \quad \forall M.$$

Théorème (Caractérisation) . On dira $\delta \succeq_Q \delta'$ ssi la matrice de $\mathcal{M}_q(\mathbb{R})$:

$$\mathbb{E}_\theta((\delta' - g(\theta))(\delta' - g(\theta))^t) - \mathbb{E}_\theta((\delta - g(\theta))(\delta - g(\theta))^t)$$

est semi-définie positive.

2.3.3 Amélioration de Rao-Blackwell

Théorème (Rao-Blackwell) . Soit $\delta \in L^2(\mathcal{P}_\Theta)$ sans biais (moyen) pour $g(\theta)$ et S une statistique exhaustive en θ . Alors, l'estimateur δ dit *amélioré par S* , tel que $\delta_S = \mathbb{E}_\theta(\delta \mid S)$ est Q -préférable à δ .

Donc pour réduire une variance dans L^2 sans perte d'information, il suffit de conditionner une statistique exhaustive.

Démonstration δ_S est un estimateur, car S est exhaustive dont $\mathbb{E}_\theta(\delta \mid S)$ ne dépend pas de θ . D'autre part, δ_S est sans biais, puisque :

$$\mathbb{E}_\theta(\mathbb{E}_\theta(\delta \mid S)) = \mathbb{E}_\theta(\delta) = g(\theta).$$

Enfin, δ_S est de moindre variance, comme $\mathbb{E}_\theta(\delta \mid S)$ est la projection dans $L^2(\mathbb{P}_\theta)$.

Remarque Dans le cas $q = 1$, pour $\Psi(x) = x^2$ convexe, on a :

$$\begin{aligned} \mathbb{E}_\theta((\delta - g(\theta))^2 \mid S) &\geq [\mathbb{E}_\theta(\delta - g(\theta)) \mid S]^2 \\ &= [\delta_S - g(\theta)]^2 \end{aligned}$$

par l'inégalité de Jensen conditionnelle. Donc en prenant $\mathbb{E}_\theta(\cdot)$ à gauche et à droite, on a :

$$\begin{aligned}\mathbb{E}_\theta((\delta - g(\theta))^2) &\geq \mathbb{E}_\theta(\delta_S - g(\theta))^2 \\ R_Q(\theta, \delta) &\geq R_Q(\theta, \delta_S).\end{aligned}$$

Donc conditionner par une statistique exhaustive améliore toujours la fonction de risque.

2.3.4 Optimalité de Lehman-Scheffe

Théorème (Lehman-Scheffe) . Si δ est sans biais pour $g(\theta)$ et S exhaustive complète, alors $\delta_S = \mathbb{E}_\theta(\delta | S)$ est l'unique estimateur sans biais de variance minimale (i.e l'optimal δ_Q^{opt}).

Démonstration Montrons que cet estimateur ne peut plus être amélioré. Soit $\delta' \in \Delta_{sb}$, posons $\delta'_S = \mathbb{E}_\theta(\delta' | S)$. On a :

$$\mathbb{E}_\theta(\delta') = \mathbb{E}_\theta(\delta) = g(\theta)$$

Donc, pour tout $\theta \in \Theta$:

$$\mathbb{E}_\theta(\underbrace{\delta'_S - \delta_S}_{=\varphi(\delta)}) = \mathbb{E}_\theta(\delta - \delta') = 0.$$

Avec $\mathbb{E}_\theta(\varphi(S)) = 0$ pour tout θ . Or S est complète donc $\varphi(S) = 0$. D'où $\delta'_S = \delta_S$.

Proposition Pour trouver le δ_Q^{opt} , il faut donc :

- Trouver S complète : on cherche $\varphi(S)$ telle que $\mathbb{E}_\theta(\varphi(S)) = g(\theta)$ et la solution est bien l'estimateur sans biais de variance minimale.
- On cherche $\delta \in \Delta_{sb}$ simple.
- Puis, on conditionne $\mathbb{E}_\theta(\delta | S)$. Si S est complète, alors c'est gagné.

2.4 Bornes inférieures de variance et Efficacité

Nous avons précédemment défini Δ_{sb} comme la classe des estimateurs sans biais. Par la suite, nous avons introduit le risque quadratique pour quantifier la pertinence d'un estimateur en fonction de son biais et de sa variance.

Bien que nous sachions construire des estimateurs sans biais, l'enjeu est désormais d'étudier leur variance afin de réduire leur dispersion autour du paramètre cible. Une question fondamentale se pose alors : au sein de Δ_{sb} , existe-t-il un estimateur dont la variance est minimale de manière uniforme ? Si oui, comment peut-on le caractériser ?

Pour répondre à cette question, nous nous plaçons dans le cadre des modèles réguliers $(H_{1,2,3,4})$. L'utilisation de l'information de Fisher comme mesure de précision nous impose toutefois d'ajouter des conditions sur la finitude de l'information (H_5) et sur la régularité de l'estimateur δ (H_6) pour permettre l'intervention intégrale-dérivée :

(H_5) : L'information de Fisher est finie et non nulle :

$$\forall \theta \in \Theta, \quad \mathcal{I}_\theta(X) \in]0, +\infty[$$

(H_6) : δ est de carré intégrable et permet la dérivation sous le signe somme :

$$\delta \in L^2(\mathcal{P}_\Theta), \forall \theta \in \Theta, \quad \mathbb{E}_\theta(\delta(X)) = g(\theta) \quad \text{et} \quad \frac{\partial f_\theta}{\partial \theta} \delta \in L^1(\mu)$$

Tels que pour tout $A \in \mathcal{A}$ et $\theta \in \Theta$:

$$\frac{\partial}{\partial \theta} \left(\int_A \delta f_\theta d\mu \right) = \int_A \frac{\partial f_\theta}{\partial \theta} \delta d\mu$$

2.4.1 Inégalité de Fréchet-Darmois-Cramér-Rao (FDCR)

Théorème (Borne de Cramér-Rao) . Sous les hypothèses de régularité usuelles ($H_{1...5}$) et pour un estimateur δ_n sans biais de $g(\theta)$, on a :

$$\mathbb{V}_\theta(\delta_n) \geq \frac{(g'(\theta))^2}{n\mathcal{I}_\theta(X)} \quad (2.4.1)$$

Plus l'information de Fisher est grande, plus la variance minimale possible est petite (le modèle est "précis"). Il convient alors de définir proprement les estimateurs atteignant cette borne.

Définition (Estimateur Efficace) . Un estimateur δ_n est dit *efficace* s'il est sans biais et qu'il *atteint la borne* de Cramér-Rao :

$$\mathbb{V}_\theta(\delta_n) = \frac{(g'(\theta))^2}{n\mathcal{I}_\theta(X)}$$

2.4.2 La réciproque de Koopman (Cas d'égalité)

Propriété (Lien avec les modèles exponentiels) . La borne de Cramér-Rao est atteinte (cas d'égalité) ssi le modèle est exponentiel de la forme :

$$f_\theta(x) = h(x)k_\theta \exp(\gamma(\theta)\delta(x))$$

Dans ce cas, $\delta(X)$ est l'unique estimateur efficace pour son espérance $g(\theta) = -\frac{\kappa'_\theta}{\gamma'(\theta)}$.

Exemple (Application TD) Pour une loi de Poisson $\mathcal{P}(\theta)$, on montre que $\bar{X}_n$ est efficace car le modèle est exponentiel. Pour une loi Uniforme $\mathcal{U}[0, \theta]$, la borne ne s'applique pas (support dépendant de θ) : l'estimateur peut avoir une variance *plus petite* que la borne de Fisher.

