

Fiches de Cours

Master IMA

Axel PIGEON

axel.pigeon@univ-tlse3.fr

Université Toulouse III – Paul Sabatier


Années universitaires 2025–2027

8 novembre 2025

Table des matières

I Probabilités	3
1 Chaînes de Markov	4
1.1 Définitions et Généralités	4
1.2 Propriétés de Markov	9
1.3 Mesures Invariantes	12
1.4 Classification des états	19
1.5 Mesures invariantes dans le cas dénombrable	22
1.6 Ergodicité et convergence en loi	26
2 Espérances Conditionnelles	28
2.1 Espérances conditionnelles sur un espace d'états discret	28
2.2 Définition de l'espérance conditionnelle	30

Probabilités



Chapitre 1

Chaînes de Markov

Contents

1.1 Définitions et Généralités	4
1.2 Propriétés de Markov	9
1.2.1 Propriété de Markov Faible	9
1.2.2 Temps d'arrêt et propriété de Markov Forte	10
1.3 Mesures Invariantes	12
1.3.1 Définition et propriétés	12
1.3.2 Existence des mesures invariantes	13
1.3.3 Unicité des mesures de probabilité invariantes et irréductibilité	14
1.3.4 Construction de mesures de probabilité invariantes	16
1.3.5 Réversibilité	18
1.4 Classification des états	19
1.4.1 Nombre de visites en un point	19
1.4.2 État transiant et état récurrent	20
1.5 Mesures invariantes dans le cas dénombrable	22
1.5.1 États récurrents positif ou nul	22
1.5.2 Propriétés des chaînes irréductibles	22
1.5.3 Critère de récurrence positive	24
1.6 Ergodicité et convergence en loi	26
1.6.1 Ergodicité	26
1.6.2 Convergence en loi	26

Jusqu'à maintenant, nous avons étudié des suites de variables aléatoires dites iid (indépendantes et identiquement distribuées). Ces propriétés nous ont permis de développer beaucoup d'outils pour les étudier tels que la loi forte des grands nombres ou le théorème central limite.

Or nous n'utilisons pas beaucoup ce type de suite de variables aléatoires en simulation. En effet, ces propriétés plutôt fortes ne permettent pas de modéliser des phénomènes dont l'évolution est plus complexe. Nous allons donc continuer à étudier des suites de variables aléatoires mais en rajoutant des relations de dépendance entre celles-ci. Cela nous permettra de modéliser des systèmes dynamiques plus complexes.

1.1 Définitions et Généralités

On se place ici dans un espace probabilisé $(E, \mathcal{F}, \mathbb{P})$ et E un *espace d'état* fini ou dénombrable. On s'intéresse à une suite de variables aléatoires $(X_n)_{n \in \mathbb{N}}$ ou X_k est l'état du système au temps k .

Définition (Trajectoire) . On appelle *trajectoire du système* jusqu'au temps $n \in \mathbb{N}^*$ la donnée $(X_1, \dots, X_n)$.

Définition (Chaîne de Markov) . On dit qu'une suite $(X_n)_{n \geq 0}$ est une *chaîne de Markov* si elle vérifie la *propriété de Markov* :

$$\forall n \in \mathbb{N}, \forall i_0, i_1, \dots, i_{n-1} \in E,$$

$$\boxed{\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i)}$$

Remarque Conditionnellement à l'état présent $\{X_n = i\}$, la probabilité d'arriver à l'état $\{X_{n+1} = j\}$ à l'itération suivante ne dépend pas des événements du passé $\{X_0 = i_0, \dots, X_{n-1} = i_{n-1}\}$. On parle d'*absence de mémoire*.

Définition (Chaîne de Markov Homogène) . Soit $(X_n)_{n \geq 0}$ une chaîne de Markov. On dit qu'elle est *homogène* si :

$$\forall n \in \mathbb{N}, \forall i, j \in E, \quad \mathbb{P}(X_{n+1} = j \mid X_n = i) = \mathbb{P}(X_1 = j \mid X_0 = i)$$

On se placera toujours dans ce cadre.

Remarque Une chaîne de Markov homogène est une chaîne de Markov où la probabilité de passer d'un état à un autre ne dépend pas du temps.

Exemple (Marche Aléatoire) On modélise le mouvement d'une particule sur une grille par une chaîne de Markov où X_n représente la position de la particule au temps $n \in \mathbb{N}$. On considère que la particule se déplace sur une seule dimension. Elle peut donc avancer d'une case ou reculer d'une case à chaque itération. On notera $p \in [0, 1]$ la probabilité qu'elle avance et $1 - p$ la probabilité qu'elle recule indépendamment du passé.

Soit $(\varepsilon_i)_{i \geq 0}$ à valeurs dans $\{-1, 1\}$ telle que :

$$\mathbb{P}(\varepsilon_i = 1) = 1 - \mathbb{P}(\varepsilon_i = -1) = p \in [0, 1]$$

la variable aléatoire qui représente le mouvement de la particule. Déterminons la loi de X_n :

$$X_{n+1} = X_n + \varepsilon_{n+1} = X_{n-1} + \varepsilon_n + \varepsilon_{n+1} = \dots = \sum_{i=1}^n \varepsilon_i$$

Montrons que c'est bien une chaîne de Markov :

$$\begin{aligned} X_{n+1} &= X_n + \varepsilon_{n+1} \\ &= \left(\sum_{i=1}^n \varepsilon_i \right) + \varepsilon_{n+1} \\ &= \sum_{i=1}^{n+1} \varepsilon_i \end{aligned}$$

où tous les $\varepsilon_i, i \in \llbracket 1, n+1 \rrbracket$ sont indépendants. On a donc :

$$\begin{aligned} \mathbb{P}(X_{n+1} = j \mid X_n = i, \dots, X_0 = i_0) &= \mathbb{P}(X_n + \varepsilon_{n+1} = j \mid X_n = i, \dots, X_0 = i_0) \\ &= \mathbb{P}(i + \varepsilon_{n+1} = j \mid X_n = i, \dots, X_0 = i_0) \\ &= \mathbb{P}(\varepsilon_{n+1} = j - i) \end{aligned}$$

On pourra alors s'intéresser au nombre de fois où une trajectoire passe par un point $n \in \mathbb{N}$. La théorie des chaînes de Markov permet de répondre à ce genre de questions.

Plus généralement, on peut construire récursivement des chaînes de Markov en définissant un X_0 fixé ou tiré par une loi π_0 puis en posant :

$$X_{n+1} = f(X_n, \varepsilon_{n+1})$$

où (ε_i) est une suite de variables aléatoires iid et f une fonction mesurable.

Définition (Matrice de Transition) . Soit $(X_n)_{n \geq 0}$ une chaîne de Markov. On définit la *matrice de transition* P de la chaîne comme la matrice, potentiellement infinie, telle que :

$$P(i, j) = \mathbb{P}(X_1 = j | X_0 = i)$$

Ainsi le coefficient de la i -ème ligne et de la j -ème colonne correspond à la probabilité de passer de l'état i à l'état j en une étape.

Exemple Soit $P \in \mathcal{M}_3(\mathbb{R})$ la matrice de transition suivante :

$$P = \begin{pmatrix} 1/4 & 3/4 & 0 \\ 0 & 1/2 & 1/2 \\ 1/2 & 0 & 1/2 \end{pmatrix}$$

On peut alors la représenter par un graphe pondéré orienté dont les noeuds représentent les états au temps i de la chaîne de Markov et les poids les probabilités de passer d'un état à l'autre en une étape.




FIGURE 1.1 – Graphe Orienté Pondéré de la matrice de transition P

Définition (Matrice Stochastique) . La matrice de transition P est dite *stochastique* si

$$\forall i \in E, \quad \sum_{j \in E} P(i, j) = 1$$

(i.e si la somme des poids des arrêtes de tout noeud du graphe associé est égale à 1)

Proposition La loi d'une chaîne de Markov homogène $(X_n)_{n \geq 0}$ est complètement déterminée par la loi de π_0 de la condition initiale X_0 et par la matrice de transition P . On a :

$$\forall i_0, i_1, \dots, i_n \in E, \quad \mathbb{P}(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) = \pi_0(i_0)P(i_0, i_1)P(i_1, i_2) \dots P(i_{n-1}, i_n)$$

Démonstration Démontrons ce résultat par récurrence sur $\mathbb{N}$.

— Initialisation : Pour $n = 0$, par définition, on a :

$$\mathbb{P}(X_0 = i_0) = \pi_0(i_0)$$

— Hérédité : Soient $i_0, \dots, i_n \in E$, supposons que :

$$\mathbb{P}(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) = \pi_0(i_0)P(i_0, i_1)P(i_1, i_2) \dots P(i_{n-1}, i_n)$$

Soit $i_{n+1} \in E$ alors :

$$\begin{aligned} & \mathbb{P}(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n, X_{n+1} = i_{n+1}) \\ &= \mathbb{P}(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) \times \mathbb{P}(X_{n+1} = i_{n+1} | X_0 = i_0, \dots, X_n = i_n) \\ &= \mathbb{P}(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) \times \mathbb{P}(X_{n+1} = i_{n+1} | X_n = i_n) \\ &= \pi_0(i_0)P(i_0, i_1)P(i_1, i_2) \dots P(i_{n-1}, i_n)P(i_n, i_{n+1}) \end{aligned}$$

On s'intéresse maintenant à la loi de X_n au temps $n \in \mathbb{N}$.

Propriété (Relation de Chapman-Kolmogorov) . Soit $(X_n)_{n \geq 0}$ une chaîne de markov homogène de matrice P et de loi initiale π_0 . Pour tout $i, j \in E$, on a :

$$\mathbb{P}(X_{n+m} = j | X_0 = i_0) = \sum_{k \in E} \mathbb{P}(X_{n+m} = j | X_n = k) \times \mathbb{P}(X_n = k | X_0 = i_0)$$

En particulier :

$$\mathbb{P}(X_n = j | X_0 = i_0) = P^n(i_0, j)$$

Démonstration Prouvons les résultats précédents.

Rappelons tout d'abord la formule des probabilités totales. Soit $(B_k)_{k \in \mathbb{N}}$ une partition de E , alors pour tout $A \in E$, on a :

$$\mathbb{P}(A) = \sum_{k \in \mathbb{N}} \mathbb{P}(A \cap B_k)$$

ou en conditionnel sur C :

$$\mathbb{P}(A | C) = \sum_{k \in \mathbb{N}} \mathbb{P}(A \cap B_k | C)$$

Or ici, $\{X_k | k \geq 0\}$ forme bien une partition de E puisque à chaque instant k , le processus est dans un unique état X_k . D'après la formule des probabilités totales, on a donc :

$$\begin{aligned} \mathbb{P}(X_{n+m} = j | X_0 = i_0) &= \sum_{k \in E} \mathbb{P}(X_{n+m} = j, X_n = k | X_0 = i_0) \\ &= \sum_{k \in E} \mathbb{P}(X_{n+m} = j | X_n = k, X_0 = i_0) \times \mathbb{P}(X_n = k | X_0 = i_0) \\ &= \sum_{k \in E} \mathbb{P}(X_{n+m} = j | X_n = k) \mathbb{P}(X_n = k | X_0 = i_0) \end{aligned}$$

On remarque de $\mathbb{P}(X_{n+m} = j | X_n = k)$ est la probabilité de passer de l'état k à j en m pas d'où :

$$\mathbb{P}(X_{n+m} = j | X_n = k) = \mathbb{P}(X_m = j | X_0 = k)$$

Déduisons maintenant la seconde formule de la première :

$$\begin{aligned}
 \mathbb{P}(X_2 = j | X_0 = i_0) &= \sum_{k \in E} \mathbb{P}(X_2 = j | X_1 = k) \mathbb{P}(X_1 = k | X_0 = i_0) \\
 &= \sum_{k \in E} P(i, k) P(k, i) \\
 &= P^2(i, j) \quad \text{etc} \dots
 \end{aligned}$$

Remarque (Notation) Si X_0 est distribué selon la loi π_0 , on notera :

$$\begin{aligned}
 \mathbb{P}_{\pi_0}(X_n = j) &= \sum_{i_0 \in E} \mathbb{P}(X_n = j | X_0 = i_0) \pi_0(i_0) \\
 &= \sum_{i_0 \in E} \mathbb{P}(X_n = j | X_0 = i_0) \mathbb{P}(X_0 = i_0) \\
 &= \sum_{i_0 \in E} P(i_0, j) \pi_0(i_0) \\
 &= \pi_0 P^n(j)
 \end{aligned}$$

où $P^n(j)$ est la i ème colonne de P^n et π_0 un vecteur ligne.

Exemple (Simple) Soit $(X_n)_{n \geq 0}$ une suite de variables aléatoires réelles iid de loi π .

$$\text{i.e } \forall i \in E, \mathbb{P}(X_n = i) = \pi(i)$$

On a donc :

$$P(i, j) = \mathbb{P}(X_1 = j | X_0 = i) = \mathbb{P}(X_1 = j) = \pi(j)$$

C'est un cas très simple et peu intéressant.

Exemple (Ruine du joueur) Soit $n \geq 1$ et $p \in [0, 1]$ et une suite de variables aléatoires $(X_n)_{n \in \mathbb{N}}$ à valeurs dans $\llbracket 1, n \rrbracket$. On définit X_m comme le montant gagné par le joueur après m parties. On considère que le joueur ne peut pas jouer avec un montant supérieur à n . On peut donc représenter son évolution dans le jeu par le graphe ci-dessous :




FIGURE 1.2 – Ruine du Joueur

où :

$$\begin{cases} P(k, k+1) = p & \text{si } k \in \{0, \dots, n-1\} \\ P(k, k+1) = 1-p & \text{si } k \in \{1, \dots, n\} \end{cases}$$

En pratique, on s'intéressera souvent à :

$$\mathbb{P}(X_n \text{ atteint } 0 \text{ avant } m | X_0 = i)$$

Exemple (File d'attente) On s'intéresse au nombre de personnes dans une file d'attente où, à chaque itération, une personne rentre ou sort de la file. Soit $(X_n)_{n \in \mathbb{N}}$ une suite à valeur dans $\mathbb{N}$. Ici, un pas de temps n représente un événement qui se passe. On va s'intéresser au fait que la chaîne tende vers 0 ou $+\infty$ en fonction de $i_0 \in \llbracket 1, n \rrbracket$.




FIGURE 1.3 – File d'attente

Exemple (Processus de Galton-Watson) Ici $(X_n)_{n \geq 1}$ compte le nombre d'individus d'une population dans la génération n . On suppose que chaque individu vivant a des descendants indépendamment des autres. On appelle $(\zeta_{n,k})_{n \leq 1, k \leq 1}$ la suite donnant le nombre de descendants de l'individu k vivant à la génération n .

On peut alors en déduire que $(\zeta_{n,k})_{n \leq 1, k \leq 1}$ est une suite de var iid et que :

$$X_{n+1} = \sum_{k=1}^{X_n} \zeta_{n,k}$$

1.2 Propriétés de Markov

1.2.1 Propriété de Markov Faible

Théorème (Propriété de Markov Faible) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène de matrice de transition P et de loi initiale π_0 . Soit $m \in \mathbb{N}$ fixé. Alors, conditionnellement à l'événement $\{X_m = i\}$, la chaîne décalée $(X_{m+k})_{k \in \mathbb{N}}$ est une chaîne de Markov homogène de même matrice de transition P et de loi initiale δ_i .

En particulier, le *futur* $(X_{m+1}, X_{m+2}, \dots)$ est indépendant du *passé* $(X_0, X_1, \dots, X_{m-1})$ conditionnellement à X_m . Autrement dit, pour tous événements A mesurables par rapport à $\sigma(X_{m+1}, X_{m+2}, \dots)$ et B mesurables par rapport à $\sigma(X_0, X_1, \dots, X_{m-1})$, on a :

$$\mathbb{P}(A \cap B \mid X_m = i) = \mathbb{P}(A \mid X_m = i) \mathbb{P}(B \mid X_m = i).$$

Démonstration Démontrons ce théorème en deux parties :

1. Égalité des lois :

Montrons que, pour tout $n \in \mathbb{N}$ et toute suite d'états $(y_1, \dots, y_n)$,

$$\begin{aligned} \mathbb{P}(X_{m+1} = y_1, \dots, X_{m+n} = y_n \mid X_m = i, X_{m-1} = i_{m-1}, \dots, X_0 = i_0) \\ = \mathbb{P}(X_1 = y_1, \dots, X_n = y_n \mid X_0 = i) \end{aligned}$$

On a :

$$\begin{aligned} & \mathbb{P}(X_{m+1} = y_1, \dots, X_{m+n} = y_n \mid X_m = i, X_{m-1} = i_{m-1}, \dots, X_0 = i_0) \\ &= \frac{\mathbb{P}(X_{m+1} = y_1, \dots, X_{m+n} = y_n, X_m = i, X_{m-1} = i_{m-1}, \dots, X_0 = i_0)}{\mathbb{P}(X_m = i, X_{m-1} = i_{m-1}, \dots, X_0 = i_0)} \\ &= \frac{\pi_0(i_0)P(i_0, i_1) \cdots P(i_{m-1}, i)P(i, y_1) \cdots P(y_{n-1}, y_n)}{\pi_0(i_0)P(i_0, i_1) \cdots P(i_{m-1}, i)} \\ &= P(i, y_1)P(y_1, y_2) \cdots P(y_{n-1}, y_n) \\ &= \mathbb{P}(X_1 = y_1, \dots, X_n = y_n \mid X_0 = i). \end{aligned}$$

Ainsi, la chaîne décalée $(X_{m+k})_{k \in \mathbb{N}}$, conditionnellement à $X_m = i$, suit bien la loi d'une chaîne de Markov homogène de matrice P et de loi initiale δ_i .

2. Indépendance conditionnelle :

Soient A un événement mesurable par rapport au futur $\sigma(X_{m+1}, X_{m+2}, \dots)$ et B un événement mesurable par rapport au passé $\sigma(X_0, X_1, \dots, X_{m-1})$.

Montrons que :

$$\mathbb{P}(A \cap B \mid X_m = i) = \mathbb{P}(A \mid X_m = i) \mathbb{P}(B \mid X_m = i).$$

Par définition de la probabilité conditionnelle :

$$\mathbb{P}(A \cap B \mid X_m = i) = \frac{\mathbb{P}(A \cap B, X_m = i)}{\mathbb{P}(X_m = i)}.$$

D'après la propriété de Markov, conditionnellement à $X_m = i$, le futur $(X_{m+1}, X_{m+2}, \dots)$ ne dépend pas du passé $(X_0, \dots, X_{m-1})$, donc :

$$\mathbb{P}(A \cap B, X_m = i) = \mathbb{P}(A, X_m = i) \mathbb{P}(B, X_m = i) / \mathbb{P}(X_m = i).$$

Ainsi :

$$\begin{aligned} \mathbb{P}(A \cap B \mid X_m = i) &= \frac{\mathbb{P}(A, X_m = i) \mathbb{P}(B, X_m = i)}{\mathbb{P}(X_m = i)^2} \\ &= \mathbb{P}(A \mid X_m = i) \mathbb{P}(B \mid X_m = i). \end{aligned}$$

Ce qui montre bien l'indépendance conditionnelle du passé et du futur, sachant X_m .

Remarque Cette propriété de Markov est aussi vraie de façon plus générale quand on conditionne par l'état de la chaîne en un temps aléatoire appelé temps d'arrêt. Ce sera exactement le propos de la propriété de Markov forte que nous verrons plus tard.

1.2.2 Temps d'arrêt et propriété de Markov Forte

Définition (Tribu $\mathcal{F}_n$) . On définit $\mathcal{F}_n$ la tribu engendrée par les variables aléatoires $(X_1, \dots, X_n)$ la tribu :

$$\begin{aligned} \mathcal{F}_n &= \sigma(X_0, \dots, X_n) \\ &= \sigma(\{X_0 = x_0, \dots, X_n = x_n\}, x_0, \dots, x_n \in E) \end{aligned}$$

Ainsi, la tribu engendrée par l'ensemble $\{X_0 = x_0, \dots, X_n = x_n\}$ est la plus petite tribu contenant cette ensemble.

Définition (Temps d'arrêt) . Soit $(X_n)_{n \geq 0}$ une chaîne de Markov à valeurs dans un espace d'états E , définie sur un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$, avec

$$\forall n \in \mathbb{N}, \quad X_n : \Omega \longrightarrow E$$

On note $\mathcal{F}_n = \sigma(X_0, X_1, \dots, X_n)$ la tribu engendrée par les n premières variables de la chaîne. Une application

$$\tau : \Omega \longrightarrow \mathbb{N} \cup \{\infty\}$$

est appelée *temps d'arrêt* de la chaîne de Markov (ou pour la filtration $(\mathcal{F}_n)_{n \geq 0}$) si elle

vérifie :

$$\boxed{\forall n \in \mathbb{N}, \quad \{\tau \leq n\} \in \mathcal{F}_n}$$

Donc τ est mesurable pour la tribu $\mathcal{F}_n$. Autrement dit, le fait que l'évènement $\{\tau \leq n\}$ ne dépend que de l'évolution de la chaîne jusqu'au temps n .

Exemple Soit (X_n) une chaîne de Markov sur $\mathbb{Z}$. On définit le temps d'attente du dépassement de $j \in \mathbb{Z}$ comme la variable aléatoire :

$$\tau_j = \min\{i \geq 0 \mid X_i > j\}$$

τ_j est bien un temps d'arrêt pour la CMH car :

$$\{\tau_j \leq n\} = \{\exists k \in \mathbb{N}, X_k \geq j\}$$

donc τ_j ne dépend que de $X_0, \dots, X_n$. De façon générale, soit $A \subset E$, le temps d'attente de A défini par :

$$\tau_A = \min\{i \geq 0, X_i \in A\}$$

est un temps d'arrêt. Si cet ensemble est vide (i.e la chaîne de Markov n'atteint jamais A), alors $\tau_A = +\infty$. Par contre, $S_j = \max\{i \geq 0, X_i > j\}$ n'est pas un temps d'arrêt car $\{S_j \leq n\} = X_{n+1} < j, X_{n+2} < j, \dots$ dépend de ce qui s'est passé "après".

Théorème (Propriété de Markov forte) . Soit $(X_n)_{n \geq 0}$ une chaîne de Markov homogène et τ un temps d'arrêt. Alors conditionnellement à $\{\tau < \infty\}$ et $\{X_\tau = x\}$ la chaîne décalée $(X_{\tau+n})_{n \geq 0}$ est encore une chaîne de Markov de condition initiale x .
De plus, conditionnellement à $\{\tau < \infty\} \cap \{X_\tau = x\}$ on a :

$$(X_{\tau+n})_{n \geq 0} \text{ est indépendante de } (X_0, \dots, X_{\tau-1})$$

Remarque Ici, la chaîne de Markov est décalée conditionnellement à une variable aléatoire, c'est beaucoup plus fort que la propriété précédente.

Exemple (Application - Ruine du Joueur) Soit l'espace d'état $E = \{0, \dots, m\}$ et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E telle que $X_0 = k \in \{1, \dots, m\}$. On s'intéresse à deux temps d'arrêts :

- $\tau_0 = \inf\{n \geq 0 \mid X_n = 0\}$
- $\tau_m = \inf\{n \geq 0 \mid X_n = m\}$

On souhaite estimer le temps de jeu moyen d'un joueur. Pour cela, on considère le temps d'arrêt :

$$\tau = \min(\tau_0, \tau_m)$$

On veut savoir quand $t < t_0$ (i.e quand le joueur gagne avant de perdre). Soit $m > 1$, alors τ_0 est distinct de τ_m si l'un des deux est fini. En conséquence si $\tau < \infty$, on a :

- soit $\tau = \tau_0 < \tau_m$
- soit $\tau = \tau_m < \tau_0$.

On cherche la "probabilité de ruine" :

$$f(k) = \mathbb{P}(\tau < \infty, \tau = \tau_0 \mid X_0 = k)$$

Pour cela, nous devons donc déterminer toutes les valeurs de f . On utilise donc les propriétés de Markov pour en déduire des relations de récurrence entre $f(k)$, $f(k+1)$ et $f(k-1)$. On remarque ainsi que :

$$\text{si } X_0 = 0 \text{ alors } \tau = \tau_0 = 0 \text{ donc } f(0) = 1$$

si $X_0 = m$ alors $\tau = \tau_m = 0$ donc $f(m) = 0$

Si $X_0 \notin \{0, m\}$, on doit au moins faire un pas pour atteindre τ_0 ou τ_m . On en déduit donc que :

$$\tau_0((X_n)_{n \in \mathbb{N}}) = 1 + \tau_0((X_{n+1})_{n \in \mathbb{N}})$$

$$\tau_m((X_n)_{n \in \mathbb{N}}) = 1 + \tau_m((X_{n+1})_{n \in \mathbb{N}})$$

On a donc, via l'analyse à un pas :

$$\begin{aligned} f(k) &= \mathbb{P}(\tau((X_n)_{n \in \mathbb{N}}) = \tau_0((X_n)_{n \in \mathbb{N}}) < \infty \mid X_0 = k) \\ &= \mathbb{P}(\tau((X_{n+1})_{n \in \mathbb{N}}) = \tau_0((X_{n+1})_{n \in \mathbb{N}}) < \infty \mid X_0 = k) \end{aligned}$$

En appliquant la formule des probabilités totales à X_1 , on a donc :

$$\begin{aligned} f(k) &= \mathbb{P}(X_1 = k + 1 \mid X_0 = k) \times \mathbb{P}(\tau((X_{n+1})_{n \in \mathbb{N}}) = \tau_0((X_{n+1})_{n \in \mathbb{N}}) < \infty \mid X_1 = k + 1, X_0 = k) \\ &\quad + \mathbb{P}(X_1 = k - 1 \mid X_0 = k) \times \mathbb{P}(\tau((X_{n+1})_{n \in \mathbb{N}}) = \tau_0((X_{n+1})_{n \in \mathbb{N}}) < \infty \mid X_1 = k - 1, X_0 = k) \end{aligned}$$

Or, conditionnellement à $\{X_1 = k + 1\}$, la chaîne $(X_{n+1})_{n \in \mathbb{N}}$ est une chaîne de Markov partant de $k + 1$. On a donc :

$$\begin{aligned} f(k) &= p\mathbb{P}(\tau_0((X_n)_{n \in \mathbb{N}}) = \tau((X_n)_{n \in \mathbb{N}}) \mid X_0 = k + 1) \\ &\quad + (1 - p)\mathbb{P}(\tau_0((X_n)_{n \in \mathbb{N}}) = \tau((X_n)_{n \in \mathbb{N}}) \mid X_0 = k - 1) \\ &= pf(k + 1) + (1 - p)f(k - 1) \end{aligned}$$

Résolvons cette relation de récurrence pour $p = 1/2$. On a donc $\forall k \in \llbracket 1, m \rrbracket, k \notin \{0, m\}$:

$$f(k) = \frac{f(k + 1) + f(k - 1)}{2}$$

$$\iff f(k + 1) - f(k) = f(k) - f(k - 1) = \Delta$$

On peut donc poser :

$$\begin{aligned} f(m) - f(0) &= \sum_{k=0}^{m-1} f(k + 1) - f(k) = (m - 1)\Delta \\ \iff \Delta &= -\frac{1}{m} \end{aligned}$$

D'où :

$$f(k) = 1 + k\Delta = 1 - \frac{k}{m}$$

1.3 Mesures Invariantes

Dans cette section, nous supposons tout d'abord que l'espace d'états E est fini. Au début du cours on a vu que, pour une chaîne de Markov $(X_n)_{n \in \mathbb{N}}$ de matrice P et de loi initiale π_0 , la relation de Chapman-Kolmogorov nous donne :

$$\mathbb{P}(X_n = j \mid X_0 = i_0) = P^n(i_0, j)$$

Nous allons ici chercher des mesures de probabilités telles que :

$$\pi P = \pi$$

Nous appellerons de telles mesures des *mesures de probabilités invariantes*.

1.3.1 Définition et propriétés

Définition (Mesures Invariantes) . Soit une mesure positive π sur E . On dit que π est *invariante* pour une matrice de transition P si :

$$\forall x \in E, \quad \pi(x) = \pi P(x) = \sum_{y \in E} \pi(y) P(y, x)$$

On dit alors que π est un *vecteur propre à gauche* de P pour la valeur propre 1. Par convention, les mesures sont écrites comme des vecteurs ligne.

Remarque Attention, une mesure invariante n'est pas forcément une mesure de probabilité. Pour que ce soit le cas, il faut que sa masse totale soit égale à 1.

$$\text{i.e.} \quad \sum_{x \in E} \pi(x) = 1$$

Or ici, puisque E est fini, cette somme l'est aussi donc toute mesure invariante peut être normalisée en mesure de probabilités. Nous verrons plus tard que ce n'est pas toujours le cas.

Lemme Soit π une mesure invariante pour une matrice de transition P . Alors :

$$\forall n \in \mathbb{N}^*, \quad \pi = \pi P^n$$

De plus si X_0 est distribuée selon la loi π alors la loi de X_n l'est également pour tout $n > 0$. En conséquence :

$$\forall n, m \in \mathbb{N}, \quad (X_0, X_1, \dots, X_m) \stackrel{\text{loi}}{=} (X_n, X_{n+1}, \dots, X_{n+m})$$

Propriété (Mesure Invariante et Loi) . Soit π une mesure de probabilité invariante. Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène de matrice P et de loi initiale π_0 alors, pour tout $n \in \mathbb{N}$, $X_n \sim \pi$.

Ce lemme justifie toute l'utilisation que nous ferons des mesures invariantes. En effet, une mesure invariante permet de déterminer le comportement asymptotique de la chaîne de Markov sans avoir à la simuler en entier un grand nombre de fois.

1.3.2 Existence des mesures invariantes

Théorème (Mesure invariance, existence) . Toute chaîne de Markov homogène sur un espace d'état fini admet une mesure de probabilité invariante.

Démonstration Soit ψ une mesure de probabilité quelconque sur E où $|E| = d$. Posons :

$$\forall n \in \mathbb{N}, \quad \psi_n = \frac{1}{n} \sum_{k=0}^n \psi P^k$$

On sait que pour tout $k \in \mathbb{N}$, ψP^k est une mesure de probabilité sur E . Donc ψ_n l'est aussi une par construction.

De plus, pour tout $x \in E$, $(\psi_n(x))_{n \in \mathbb{N}}$ est une suite à valeurs dans $[0, 1]^d$. Par compacité, il existe une sous-suite convergente $(\psi_{\varphi(n)}(x))_{n \in \mathbb{N}}$. Comme E est fini, il existe une extraction telle que :

$$\forall x \in E, \quad \psi_{\varphi(n)}(x) \xrightarrow{n \rightarrow \infty} \pi(x)$$

Montrons maintenant que π est une mesure de probabilités invariante pour P . On a :

$$\forall n \in \mathbb{N}, \quad \sum_{x \in E} \psi_n(x) = 1 \quad \text{et} \quad \forall x \in E, \quad \psi_n(x) \geq 0$$

Donc lorsque $n \rightarrow \infty$, on a :

$$\sum_{x \in E} \pi(x) = 1 \quad \text{et} \quad \forall x \in E, \pi(x) \geq 0$$

Donc π est une mesure de probabilités sur E . De plus, pour tout $n \in \mathbb{N}$, on a :

$$\begin{aligned} \psi_n P &= \frac{1}{n} \sum_{k=1}^n \psi P^k P = \frac{1}{n} \sum_{k=1}^n \psi P^{k+1} = \frac{1}{n} \sum_{k=2}^{n+1} \psi P^k \\ &= \frac{1}{n} \frac{n+1}{n+1} \left(\sum_{k=1}^{n+1} \psi P^k - \psi P \right) \\ &= \frac{n+1}{n} \psi_{n+1} - \frac{1}{n} \psi P \end{aligned}$$

Donc lorsque $n \rightarrow \infty$, on obtient :

$$\pi P = \pi$$

Remarque Il existe pleins de méthodes numériques pour approcher une mesure invariante d'une chaîne de Markov homogène. Ce n'est pas un problème facile car il faut en général résoudre un système de d équations à d inconnues. Nous nous intéresserons donc aux *mesures réversibles*, plus faciles à calculer et qui nous donnent une mesure invariante quand elle existe.

Exemple Soit le graphe suivant et $p, q \in]0, 1[$. Soit $\pi = (\pi_1, \pi_2)$ une mesure invariante. On a




FIGURE 1.4 – Mesure Invariante

alors $\pi P = \pi$.

$$\begin{aligned} &\iff (\pi_1, \pi_2) \begin{pmatrix} 1-p & p \\ q & 1-q \end{pmatrix} = (\pi_1, \pi_2) \\ &\iff \begin{cases} \pi_1(1-p) + q\pi_2 = \pi_1 \\ \pi_1 p + \pi_2(1-q) = \pi_2 \end{cases} \\ &\iff \pi_1 = \frac{q}{p} \pi_2 \end{aligned}$$

Or π est une mesure de probabilité ssi :

$$p\pi_1 + \pi_2 = 1 \iff \pi_1 = \frac{q}{p+q} \text{ et } \pi_2 = \frac{p}{p+q}$$

1.3.3 Unicité des mesures de probabilité invariantes et irréductibilité

Définition (Communication) . Soient $x, y \in E$. On dit que x *communique avec* y s'il existe un chemin de probabilité positive de x à y dans E . On le note alors $x \rightsquigarrow y$. Plus formellement :

$$\begin{aligned} x \rightsquigarrow y &\iff \exists x, x_1, \dots, x_{n-1}, y \in E, P(x, x_1), P(x_1, x_2), \dots, P(x_{n-1}, y) > 0 \\ &\iff \forall n \geq 1, \quad P^n(x, y) > 0 \end{aligned}$$

Propriété (Transitivité) . La relation *communique* $\rightsquigarrow$ est transitive.

Définition (Classe fermée) . Soit $E_0 \subset E$ un sous-ensemble de E que l'on appellera *classe de* E . On dit que la classe E_0 est *fermée* si :

$$\forall x \in E_0, \quad x \rightsquigarrow y \implies y \in E_0$$

Définition (Classe irréductible) . Une classe E_0 de E est dite *irréductible* si elle est fermée et si :

$$\forall x, y \in E_0, \quad x \rightsquigarrow y \text{ et } y \rightsquigarrow x$$

Par extension, on dira qu'une chaîne de Markov homogène est irréductible si son espace d'état l'est aussi.

Théorème (Unicité des mesures invariantes) . Toute chaîne de Markov homogène irréductible sur un espace d'état fini admet une *unique mesure de probabilité invariante* π et :

$$\forall x \in E, \quad \pi(x) > 0$$

Démonstration Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène d'espace d'état E . Supposons que E est irréductible et soit π une mesure invariante de $(X_n)_{n \in \mathbb{N}}$.

1. Positivité : Montrons que π est positive. On sait que π est une mesure de probabilités donc :

$$\sum_{x \in E} \pi(x) = 1$$

donc il existe nécessairement $x_0 \in E$ tel que $\pi(x_0) > 0$. Comme E est irréductible, alors pour tout $x \in E, x_0 \rightsquigarrow x$. Donc il existe $n \in \mathbb{N}$ tel que :

$$P^n(x_0, x) > 0$$

De plus, on sait que π vérifie :

$$\begin{aligned} \pi(x) &= \sum_{x \in E} \pi(x) P(x, x) = \pi P \\ \implies \pi(y) &= \sum_{x \in E} \pi(x) P^n(x, y) \\ &= \underbrace{\pi(x_0) P^n(x_0, y)}_{>0} + \underbrace{\sum_{x \in E, x \neq x_0} \pi(x) P^n(x, y)}_{\geq 0} \end{aligned}$$

Donc $\forall y \in E, \pi(y) > 0$.

2. Unicité : voir TD

1.3.4 Construction de mesures de probabilité invariantes

Nous avons vu que les mesures de probabilité invariantes jouent un rôle fondamental dans l'étude des chaînes de Markov. Elles permettent notamment de décrire le comportement stationnaire du système. Nous allons à présent présenter quelques outils permettant de construire de telles mesures.

Soit E un espace d'états fini, et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène et irréductible sur E . L'idée est de chercher à faire converger la loi de X_n lorsque n tend vers l'infini, de façon à obtenir une mesure de probabilité invariante pour la matrice de transition associée.

Définition (Temps de retour) . Soit $x \in E$, on définit le temps de retour en x comme :

$$\tau_x^+ := \inf\{n \geq 1 \mid X_n = x\} \in \overline{\mathbb{N}}$$

remarquons que c'est un *temps d'arrêt*.

Remarque Nous pouvons facilement montrer que tout temps de retour est un temps d'arrêt. En effet, pour rappel nous avons défini les temps d'arrêt comme :

Une application

$$\tau : \Omega \longrightarrow \mathbb{N} \cup \{\infty\}$$

est appelée temps d'arrêt de la chaîne de Markov (ou pour la filtration $(\mathcal{F}_n)_{n \geq 0}$) si elle vérifie :

$$\forall n \in \mathbb{N}, \quad \{\tau \leq n\} \in \mathcal{F}_n$$

Soit $n \in \mathbb{N}$ on a alors :

$$\begin{aligned} \{\tau_x^+ \leq n\} &= \{\exists k \in \llbracket 1, n \rrbracket \mid X_k = x\} \\ &= \bigcup_{k=1}^n \{X_k = x\} \end{aligned}$$

or, pour tout $k \in \llbracket 1, n \rrbracket$, l'évènement $\{X_k = x\} \in \mathcal{F}_k \subseteq \mathcal{F}_n$. Donc par union dénombrable, on a :

$$\{\tau_x^+ \leq n\} \in \mathcal{F}_n$$

Donc tout temps d'attente est un temps d'arrêt. De plus, on peut remarquer que la différence avec un temps de retour est que si $\{X_0 = x\}$ alors :

$$\tau_x = 0 \quad \text{et} \quad \tau_x^+ \geq 1$$

Lemme Pour tout $x, y \in E$, on a :

$$\mathbb{E}(\tau_y^+ \mid X_0 = x) < \infty$$

Théorème (Mesure Invariante) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène sur un espace d'états E fini. Alors son unique mesure de probabilités invariante est :

$$\pi(x) = \frac{1}{\mathbb{E}(\tau_x^+ \mid X_0 = x)} \quad \forall x \in E$$

Remarque Cette mesure charge plus les points $x \in E$ tels que $\mathbb{E}(\tau_x^+ \mid X_0 = x)$ est petit. C'est à dire les points que la chaîne de Markov visite souvent.

Démonstration Soit $x \in E$ une condition initiale. Soit $\bar{\pi} : E \rightarrow \mathbb{N}$ une application qui compte le nombre de fois que la chaîne visite un point $y \in E$.

$$\begin{aligned} \forall y \in E, \quad \bar{\pi}(y) &:= \mathbb{E} \left(\sum_{n=0}^{\tau_x^+ - 1} \mathbb{1}_{X_n=y} \mid X_0 = x \right) \\ &= \mathbb{E} \left(\sum_{n \geq 0} \mathbb{1}_{X_n=y} \times \mathbb{1}_{\tau_x^+ > n} \mid X_0 = x \right) \\ &= \sum_{n \geq 0} \mathbb{P}(X_n = y, \tau_x^+ > n \mid X_0 = x) \end{aligned}$$

On veut montrer que $\bar{\pi}$ est invariante. On veut donc :

$$\forall y \in E, \quad \bar{\pi}(y) = \sum_{z \in E} \bar{\pi}(z) P(z, y)$$

(On va également montrer que $\bar{\pi}$ ne dépend pas de la condition initiale x .) Pour tout $z \in E$, calculons donc :

$$\sum_{z \in E} \bar{\pi}(z) P(y, z) = \sum_{z \in E} \sum_{n \geq 0} \mathbb{P}(X_n = z, \tau_x^+ > n \mid X_0 = x) \times P(z, y)$$

Or on a :

$$\begin{aligned} &\mathbb{P}(X_n = z, \tau_x^+ > n, X_{n+1} = y \mid X_0 = x) \\ &= \mathbb{P}(X_{n+1} = y \mid X_n = z, \tau_x^+ > n, X_0 = x) \times \mathbb{P}(X_n = z, \tau_x^+ > n, X_0 = x) \\ &= \mathbb{P}(X_{n+1} = y \mid X_n = z) \times \mathbb{P}(X_n = z, \tau_x^+ > n, X_0 = x) \quad (\text{Propriété de Markov}) \\ &= P(z, y) \times \mathbb{P}(X_n = z, \tau_x^+ > n, X_0 = x) \end{aligned}$$

On en déduit alors que :

$$\begin{aligned} \sum_{z \in E} \bar{\pi}(z) P(y, z) &= \sum_{z \in E} \sum_{n \geq 0} \mathbb{P}(X_n = z, \tau_x^+ > n, X_{n+1} = y \mid X_0 = x) \\ &= \sum_{n \geq 0} \mathbb{P}(\tau_x^+ > n, X_{n+1} = y \mid X_0 = x) \quad (\text{Probabilités Totales}) \\ &= \sum_{n \geq 0} \mathbb{P}(\tau_x^+ \geq n+1, X_{n+1} = y \mid X_0 = x) \\ &= \sum_{n \geq 1} \mathbb{P}(\tau_x^+ \geq n, X_n = y \mid X_0 = x) \quad (\text{Changement d'indices}) \\ &= \sum_{n \geq 1} \mathbb{P}(\tau_x^+ > n, X_n = y \mid X_0 = x) + \sum_{n \geq 1} \mathbb{P}(\tau_x^+ = n, X_n = y \mid X_0 = x) \\ &= \bar{\pi}(y) - \mathbb{P}(X_0 = y, \tau_x^+ > 0 \mid X_0 = x) + \sum_{n \geq 1} \mathbb{P}(\tau_x^+ = n, X_n = y \mid X_0 = x) \end{aligned}$$

Or :

$$\begin{aligned}
& \sum_{n \geq 1} \mathbb{P}(\tau_x^+ = n, X_n = y \mid X_0 = x) \\
&= \sum_{n \geq 1} \mathbb{P}(\tau_x^+ = n, X_{\tau_x^+} = y \mid X_0 = x) \\
&= \sum_{n \geq 1} \mathbb{P}(\tau_x^+ < \infty, X_{\tau_x^+} = y \mid X_0 = x) \\
&= \mathbb{P}(X_{\tau_x^+} = y \mid X_0 = x)
\end{aligned}$$

D'où :

$$\sum_{z \in E} \bar{\pi}(z) P(z, y) = \bar{\pi}(y) - \underbrace{\mathbb{P}(X_0 = y, \tau_x^+ > 0 \mid X_0 = x)}_{1 \text{ si } y=x \text{ et } 0 \text{ sinon}} + \underbrace{\mathbb{P}(X_{\tau_x^+} = y \mid X_0 = x)}_{-1 \text{ si } y=x \text{ et } 0 \text{ sinon}} = \bar{\pi}(y)$$

Donc $\bar{\pi}$ est bien une mesure invariante de masse totale :

$$\sum_{y \in E} \bar{\pi}(y) = \mathbb{E}(\tau_x^+ \mid X_0 = x)$$

Or, d'après le lemme précédent, $\mathbb{E}(\tau_x^+ \mid X_0 = x) < \infty$. Donc l'application :

$$\forall y \in E, \quad \pi(y) = \frac{\bar{\pi}(y)}{\mathbb{E}(\tau_x^+ \mid X_0 = x)}$$

est bien une mesure de probabilités invariante. D'après le théorème d'unicité, c'est donc la seule. De plus, on a $\bar{\pi}(x) = 1$ donc :

$$\forall y \in E, \quad \pi(y) = \frac{\bar{\pi}(y)}{\mathbb{E}(\tau_x^+ \mid X_0 = x)} = \frac{1}{\mathbb{E}(\tau_x^+ \mid X_0 = x)}$$

1.3.5 Réversibilité

Trouver la mesure de probabilité invariante en résolvant le système est compliqué en général. La *réversibilité* est une propriété suffisante pour qu'une mesure soit invariante.

Définition (Mesure réversible) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène de matrice P . Une mesure μ est dite réversible pour la matrice P si :

$$\boxed{\forall x, y \in E, \quad \mu(x)P(x, y) = \mu(y)P(y, x)}$$

Remarque La réversibilité peut être vue comme le fait d'être capable de parcourir les trajectoires d'une chaîne de Markov dans le sens inverse.

$$\text{i.e } \mathbb{P}(X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) = \mathbb{P}(X_0 = x_n, X_1 = x_{n-1}, \dots, X_n = x_0)$$

Ce résultat provient de la relation de Chapman-Kolmogorov. En effet, si X_0 est choisie selon μ réversible, alors :

$$\begin{aligned}
\mathbb{P}(X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) &= \mu(x_0)P(x_0, x_1) \dots P(x_{n-1}, x_n) \\
&= P(x_1, x_0)\mu(x_1)P(x_1, x_2) \dots P(x_{n-1}, x_n) \\
&= P(x_1, x_0)P(x_2, x_1) \dots P(x_n, x_{n-1})\mu(x_n) \\
&= \mu(x_n)P(x_n, x_{n-1}) \dots P(x_2, x_1)P(x_1, x_0) \\
&= \mathbb{P}(X_0 = x_n, X_1 = x_{n-1}, \dots, X_n = x_0)
\end{aligned}$$

Proposition Une mesure réversible pour une matrice de transition est invariante.

L'étude des mesures réversibles, plus simples que les mesures invariantes, sera donc privilégiée pour déterminer des mesures invariantes.

1.4 Classification des états

Ici, on suppose maintenant que E est un espace d'états fini ou dénombrable et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène sur E de matrice de transition P .

1.4.1 Nombre de visites en un point

Définition (Nombre de visites) . Soit $x \in E$, on note V_x le nombre de visites de la chaîne de Markov $(X_n)_{n \in \mathbb{N}}$ dans x . Plus formellement :

$$V_x := |\{n \geq 1, X_n = x\}|$$

V_x est donc une variable aléatoire à valeurs dans $\overline{\mathbb{N}}$.

Théorème (Nombre de visites et temps de retour) . Soit τ_x^+ le temps de retour de la chaîne de Markov en $x \in E$. On a alors :

- si $\mathbb{P}(\tau_x^+ < \infty \mid X_0 = x) = 1$ alors $V_x = \infty$ presque sûrement.
- si $\mathbb{P}(\tau_x^+ < \infty \mid X_0 = x) = 1 - p < 1$ alors le nombre de visites est fini presque sûrement et il suit une loi géométrique.

$$\text{i.e. } \mathbb{P}(V_x = k) = p(1 - p)^k \quad \forall k \geq 0$$

Démonstration Pour démontrer ce théorème, il serait suffisant de montrer que $\forall k \in \mathbb{N}$, on ait :

$$\begin{aligned} \mathbb{P}(V_x \geq k \mid X_0 = x) &= \mathbb{P}(\tau_x^+ < \infty \mid X_0 = x)^k \\ \iff \mathbb{P}_x(V_x \geq k + 1) &= \mathbb{P}_x(\tau_x^+) \mathbb{P}_x(V_x \geq k) \end{aligned}$$

Montrons donc que :

$$\forall k \geq 0, \quad \mathbb{P}_x(V_x \geq k + 1) = \mathbb{P}_x(\tau_x^+ < \infty) \mathbb{P}_x(V_x \geq k)$$

Pour l'évènement $\{V_x \geq k + 1\}$ on a $V_x \geq 1$ donc $\tau_x^+ < \infty$ d'où :

$$\begin{aligned} \mathbb{P}_x(V_x \geq k + 1) &= \mathbb{P}_x(V_x \geq k + 1, \tau_x^+ < \infty) \\ &= \sum_{m \geq 1} \mathbb{P}_x(V_x \geq k + 1, \tau_x^+ = m) \\ &= \sum_{m \geq 1} \mathbb{P}_x(V_x \geq k + 1 \mid \tau_x^+ = m) \mathbb{P}_x(\tau_x^+ = m) \end{aligned}$$

Or on a :

$$\begin{aligned} &\mathbb{P}_x(V_x(X_n) \geq k + 1 \mid \tau_x^+ = m) \\ &= \mathbb{P}_x(V_x(X_{n+m}) + 1 \geq k + 1 \mid \tau_x^+ = m) \\ &= \mathbb{P}_x(V_x(X_n) \geq k) \end{aligned}$$

Donc :

$$\begin{aligned}\mathbb{P}_x(V_x \geq k+1) &= \sum_{m \geq 1} \mathbb{P}_x(V_x \geq k) \mathbb{P}_x(\tau_x^+ = m) \\ &= \mathbb{P}_x(V_x \geq k) \sum_{m \geq 1} \mathbb{P}_x(\tau_x^+ = m) \\ &= \mathbb{P}_x(V_x \geq k) \times \mathbb{P}_x(\tau_x^+ < \infty)\end{aligned}$$

D'où :

$$\mathbb{P}_x(V_x \geq k) = \mathbb{P}_x(\tau_x^+ < \infty)^k$$

Donc si $\mathbb{P}(\tau_x^+ < \infty) = 1$ alors $\mathbb{P}(V_x \geq k) = 1$ pour tout $k \geq 0$ donc $V_x = \infty$. D'autre part, si $\mathbb{P}(\tau_x^+ < \infty) = 1 - p < 1$ alors $\mathbb{P}(V_x \geq k) = (1 - p)^k$.

Remarque Précédemment, nous avons vu que dans le cas où E est fini et $(X_n)_{n \in \mathbb{N}}$ irréductible, alors :

$$\begin{aligned}\mathbb{E}(\tau_x^+ \mid X_0 = x) &< \infty \\ \implies \mathbb{P}(\tau_x^+ < \infty \mid X_0 = x) &= 1\end{aligned}$$

Donc on visitera le point x infiniment de fois.

Nous allons maintenant chercher à découper une trajectoire en "excursions" entre deux passages successifs par le point x . D'après la propriété de Markov forte, ces excursions auront la même loi et seront indépendantes conditionnellement.

Proposition Conditionnellement à l'évènement $\{\tau_x^+ = m\}$, $(X_{n+m})_{n \in \mathbb{N}}$ est une chaîne de Markov de condition initiale x et indépendante de $X_0, \dots, X_m$.

1.4.2 État transiant et état récurrent

Définition (État récurrent/transiant) . Si $x \in E$ tel que $\mathbb{P}_x(\tau_x^+ < \infty) = 1$, on dit alors que x est *récurrent* et $V_x = \infty$. Sinon, on dit que x est *transiant* et $V_x < \infty$ presque sûrement.

Proposition On dit qu'un état $x \in E$ est *récurrent* si :

$$\sum_{n \geq 0} P^n(x, x) = \infty$$

Or $P^n(x, x) = \mathbb{P}(X_n = x \mid X_0 = x)$ et $V_x = \sum_{n \geq 1} \mathbb{1}_{X_n = x}$ donc :

$$\mathbb{E}(V_x) = \sum_{n \geq 1} \mathbb{E}(\mathbb{1}_{X_n = x} \mid X_0 = x) = \sum_{n \geq 1} P^n(x, x)$$

Donc si x est *récurrent* alors $V_x = \infty$ presque sûrement. D'où :

$$\mathbb{E}(V_x) = \infty \implies \sum_{n \geq 1} P^n(x, x) = \infty$$

D'autre part, si x est *transiant*, alors $V_x \sim \mathcal{G}(p)$ où :

$$\mathbb{E}(V_x) < \infty \implies \sum_{n \geq 1} P^n(x, x) < \infty$$

Théorème (Récurrence et Transitivité) . Soient $x, y \in E$. Alors, si x est récurrent et que $x \rightsquigarrow y$ alors y est récurrent.

Proposition Donc $\rightsquigarrow$ est une relation d'équivalence pour les points récurrents. On peut donc partitionner l'ensemble des points récurrents de E en classes d'équivalences pour $\rightsquigarrow$ (i.e en parties connexes dans le graphe de la chaîne).

$$E = \mathcal{R} \sqcup \mathcal{C}$$

où $\mathcal{R}$ est l'ensemble des états récurrents de E et $\mathcal{C}$ l'ensemble des états transients. On a donc :

$$\mathcal{R} = \bigsqcup_{x \in E} \mathcal{R}_x$$

avec $\mathcal{R}_x$ la classe de x pour la relation $\rightsquigarrow$

$$\text{i.e } \forall x \in E, \quad \mathcal{R}_x = \{y \in E, x \rightsquigarrow y\}$$

Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E .

- Si $X_0 = x \in \mathcal{R}$ alors pour tout $n \in \mathbb{N}$, $X_n \in \mathcal{R}_x$ presque sûrement. Donc la chaîne visitera tout les états de cette classe un nombre infini de fois.
- En revanche si $x \in \mathcal{C}$ on peut distinguer deux cas :
 - Si $\mathcal{C}$ est infini, alors pour tout $n \in \mathbb{N}$, $X_n \in \mathcal{C}$ et chaque état de $\mathcal{C}$ est visité un nombre fini de fois.
 - Si $\mathcal{C}$ est fini, alors il va exister $n \in \mathbb{N}$ tel que $X_n \in \mathcal{R}$ et on se retrouve dans le premier cas.

Exemple Soit E un espace d'état fini et $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov sur E définie par le graphe suivant :




FIGURE 1.5 – Espace d'état fini

On a alors une partition de E :

$$E = \underbrace{\{1, 2, 3\}}_{\text{états transients}} \cup \underbrace{\{\{4\} \cup \{6, 7, 8, 9\}\}}_{\substack{\mathcal{R}_4 \quad \mathcal{R}_2 \\ \text{états récurrents}}}$$

1.5 Mesures invariantes dans le cas dénombrable

1.5.1 États récurrents positif ou nul

De puis le début de ce chapitre, nous nous plaçons dans un ensemble d'états E fini. Or ce n'est pas toujours le cas. En général, E est infini et dénombrable. Nous pouvons donc définir une mesure de probabilité invariante π telle que :

$$\forall x \in E, \quad \pi(x) = \frac{1}{\mathbb{E}(\tau_x^+ \mid X_0 = x)}$$

Du fait de la dénombrabilité de E , nous aurons plusieurs classes d'états qui communiquent entre eux. On peut donc redéfinir la notion d'*irréductibilité* pour ces chaînes.

Définition (Chaîne irréductible (cas dénombrable)) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov homogène sur un espace d'état E dénombrable. On dira que $(X_n)_{n \in \mathbb{N}}$ est irréductible :

- si tous les états de E sont transients
- si il existe une unique classe de récurrence dans E

$$\text{i.e. } \forall x, y \in E, \quad x \text{ et } y \text{ récurrent et } x \rightsquigarrow y$$

Remarque Si on considère une chaîne de Markov irréductible et récurrente alors :

$$\forall x \in E, \mathbb{P}_x(\tau_x^+ < \infty) = 1$$

Or quand E est fini, on n'a pas forcément :

$$\mathbb{E}(\tau_x^+ \mid X_0 = x) < \infty$$

Cela va donc nous mener à introduire une classification plus fine des états en distinguant les états récurrents selon que $\mathbb{E}(\tau_x^+ \mid X_0 = x) < \infty$ ou pas.

Définition (État récurrent positif) . On dit qu'un état $x \in E$ est *récurrent positif* s'il est récurrent et que $\mathbb{E}(\tau_x^+ \mid X_0 = x) < \infty$. On dira en revanche que x est *récurrent nul* s'il est récurrent et que :

$$\mathbb{P}_x(\tau_x^+ < \infty) = 1 \text{ et } \mathbb{E}_x(\tau_x^+) = \infty$$

La notion de récurrence positive ou nulle permet de quantifier la vitesse de retour de la chaîne dans un état x . Un état récurrent positif est donc un état où la chaîne revient souvent alors qu'un état récurrent nul est un état où la chaîne revient en temps fini mais potentiellement très long. C'est ce que traduit le fait que $\mathbb{E}_x(\tau_x^+)$ soit fini ou pas.

Remarque Dans le cas des espaces d'états finis, lors de la construction de la mesure de probabilités invariante, nous avons posé :

$$\bar{\pi}(y) = \mathbb{E} \left(\sum_{n=0}^{\tau_x^+ - 1} \mathbb{1}_{X_n = y} \right)$$

en tant que mesure invariante de masse totale $\mathbb{E}_x(\tau_x^+)$. Or dans le cas actuel si $(X_n)_{n \in \mathbb{N}}$ est récurrente positive, on aura $\mathbb{E}_x(\tau_x^+) < \infty$ donc on pourra construire notre mesure de probabilités invariante. Dans le cas contraire, notre mesure ne sera pas de probabilité.

1.5.2 Propriétés des chaînes irréductibles

Propriété (Positivité) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov irréductible récurrente. Si π est une mesure de probabilités invariante non nulle, alors :

$$\forall x \in E, \quad \pi(x) > 0.$$

Démonstration Comme π est non nulle, il existe $x_0 \in E$ tel que $\pi(x_0) > 0$. Comme la chaîne est irréductible, pour tout $y \in E$, il existe $n_0 \geq 0$ tel que :

$$P^{n_0}(x_0, y) > 0$$

En utilisant l'invariance de π et en isolant le terme $z = x_0$, on obtient :

$$\pi(y) = \sum_{z \in E} \pi(z) P^{n_0}(z, y) \geq \pi(x_0) P^{n_0}(x_0, y) > 0$$

Ainsi, chaque état $y \in E$ a une mesure strictement positive sous π .

Théorème (Unicité) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov irréductible et récurrente. Il existe alors une unique mesure invariante à constante multiplicative près.

- De plus, si tous les états sont *récurrents nuls* alors toute mesure invariante non nulle est de masse infinie.
- En revanche, si $(X_n)_{n \in \mathbb{N}}$ est *récurrente positive*, alors toutes les mesures invariantes sont de masse finie donc il existe une unique mesure de probabilités invariante telle que :

$$\forall x \in E, \quad \pi(x) = \frac{1}{\mathbb{E}_x(\tau_x^+)}$$

Exemple (Modèle de file d'attente) Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov définie par le graphe suivant :




FIGURE 1.6 – Graphe d'un modèle de file d'attente

Donc les transitions sont décrites par la matrice de transition P :

$$\begin{cases} P(k, k+1) = p & \text{si } k \geq 1 \\ P(k, k-1) = 1-p & \text{si } k \geq 1 \\ P(0, 1) = 1 \end{cases}$$

Cette chaîne de Markov est irréductible car :

$$\forall x, y \in \mathbb{N}, \exists n \in \mathbb{N}, \quad \mathbb{P}_x(X_n = y) > 0$$

$$\iff \forall x, y \in \mathbb{N}, \exists n \in \mathbb{N}, \quad P^n(x, y) > 0$$

Déterminons une mesure invariante pour cette chaîne de Markov. Soit π une mesure invariante pour P . Alors elle vérifie $\pi P = \pi$ d'où :

$$\begin{cases} \pi(0) = \sum_{k \in \mathbb{N}} \pi(k) P(k, 0) = (1-p)\pi(1) \\ \pi(1) = \pi(0) + (1-p)\pi(2) \end{cases}$$

et $\forall k \geq 1$, on a $\pi(k) = p\pi(k-1) + (1-p)\pi(k+1)$. Nous avons donc une relation de récurrence d'ordre 2 :

$$Q = (1-p)X^2 - X + p$$

de racines évidentes 1 et $p/(1-p)$. Les solutions de la relation de récurrence sont donc de la forme :

$$\forall k \geq 1, \quad \pi(k) = a1^k + b \left(\frac{p}{1-p} \right)^k$$

Déterminons a et b . On a :

$$\begin{cases} \pi(1) = \frac{\pi(0)}{1-p} = a + \frac{bp}{1-p} \\ \pi(2) = \frac{\pi(0)}{1-p} \left(\frac{1}{1-p} - 1 \right) = \frac{\pi(0)p}{(1-p)^2} = a + b \frac{p^2}{(1-p)^2} \end{cases}$$

Par identification, on obtient donc :

$$a = 0 \quad \text{et} \quad b = \frac{\pi(0)}{p}$$

Donc la solution de l'équation de récurrence s'écrit :

$$\forall k \geq 1, \quad \pi(k) = \frac{\pi(0)}{p} \left(\frac{p}{1-p} \right)^k$$

Pour aller plus loin, en considérant la série $\sum_{k \geq 0} \pi(k)$ on peut affirmer que si $p < 1/2$ alors la mesure peut être de probabilité. Dans le cas contraire, toutes les mesures invariantes seront de masse infinie.

1.5.3 Critère de récurrence positive

Il peut être très difficile de calculer $\mathbb{E}_x(\tau_x^+)$ car il faut très bien connaître les propriétés des excursions de la chaîne. En pratique, on utilisera le critère suivant :

Théorème (Réciproque) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov irréductible. Si il existe une mesure invariante π non nulle et de masse finie alors la chaîne est récurrente positive.

Ce théorème traduit le fait qu'il y a équivalence entre le fait qu'une chaîne de Markov soit récurrente positive et qu'elle admette une mesure de probabilités invariante.

Démonstration Revenons à notre théorème d'unicité des mesures invariantes. Le principe de la démonstration est le même que dans le cas discret. Soit π une mesure invariante non nulle de masse finie. On veut comparer π avec $\bar{\pi}$ qui compte le nombre moyen de passage en $y \in \mathbb{E}$.

$$\forall x \in E, \quad \bar{\pi}(x) = \mathbb{E}_x \left(\sum_{n=0}^{\tau_x^+-1} \mathbb{1}_{X_n=y} \right) = \sum_{n \geq 0} \mathbb{P}_x(X_n = y, \tau_x^+ > n)$$

or π est invariante donc $\forall y \in E$, on a :

$$\begin{aligned}
 \pi(y) &= \sum_{z \in E} \pi(z)P(z, y) \\
 &= \pi(x)P(x, y) + \sum_{z_1 \neq x} \pi(z_1)P(z_1, y) \\
 &= \pi(x)P(x, y) + \sum_{z_1 \neq x} \left(\sum_{z_2 \in E} \pi(z_2)P(z_2, z_1) \right) P(z_1, y) \\
 &= \pi(x)P(x, y) + \underbrace{\pi(x) \sum_{z_1 \neq x} P(x, z_1)P(z_1, y)}_{\text{terme } z_2=x} + \sum_{z_1 \neq x} \left(\sum_{z_2 \neq x} \pi(z_2)P(z_2, z_1)P(z_1, y) \right)
 \end{aligned}$$

où $\pi(x) \sum_{z_1 \neq x} P(x, z_1)P(z_1, x) = \mathbb{P}(X_2 = y, X_1 \neq x, X_0 = x)$. Si on itère $l \in \mathbb{N}$ fois ce processus, on aura donc :

$$\begin{aligned}
 \pi(y) &= \pi(x) \left(P(x, y) + \sum_{k=1}^{l-1} \sum_{\substack{z_1 \neq x \\ \vdots \\ z_k \neq x}} P(x, z_k)P(z_k, z_{k-1}) \dots P(z_1, y) \right) \\
 &\quad + \sum_{\substack{z_1 \neq x \\ \vdots \\ z_l \neq x}} \pi(z_l)P(z_l, z_{l-1}) \dots P(z_1, y)
 \end{aligned}$$

Donc

$$\pi(y) \geq \pi(x) \left[\sum_{k=1}^{l-1} \mathbb{P}_x(X - k = y, \tau_x^+ > k) \right]$$

or ceci est valable pour tout $l \in \mathbb{N}$ donc on peut faire tendre l vers ∞ d'où :

$$\pi(y) \geq \pi(x)\bar{\pi}(y)$$

Si on choisit $x \in E$ tel que $\pi(x) > 0$ alors :

$$\infty > \frac{\pi(y)}{\pi(x)} \geq \bar{\pi}(y)$$

donc $\bar{\pi}$ est bien définie. Or $\bar{\pi}$ est définie de telle sorte que :

$$\sum_{y \in E} \bar{\pi}(y) = \mathbb{E}_x(\tau_x^+) \leq \sum_{y \in E} \frac{\pi(y)}{\pi(x)}$$

or $\sum_{y \in E} \frac{\pi(y)}{\pi(x)} < \infty$ car π est finie donc :

$$\forall x \in E, \quad \mathbb{E}_x(\tau_x^+) < \infty$$

i.e x est récurrent positif donc la chaîne des récurrente positive irréductible. On peut donc construire l'unique mesure de probabilité invariante.

1.6 Ergodicité et convergence en loi

1.6.1 Ergodicité

On cherche ici à généraliser la loi forte des grands nombres valable pour une suite iid de variables aléatoires $(Y_i)_{i \in \mathbb{N}}$ telles que $\mathbb{E}(Y_1) < \infty$ telle que :

$$\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow[n \rightarrow \infty]{} \mathbb{E}(Y_1) \quad \text{p.s.}$$

Le théorème suivant est son équivalent pour les chaînes de Markov.

Théorème (Birhoff - Ergodique) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov irréductible récurrente positive et π sa mesure invariante. Pour toute fonction $f : E \rightarrow \mathbb{R}$ telle que :

$$\pi(|f|) = \sum_{x \in E} |f(x)| \pi(x) < \infty$$

on a :

$$\boxed{\frac{1}{n} \sum_{i=1}^n f(X_i) \xrightarrow[n \rightarrow \infty]{} \pi(f)} \quad \text{p.s.}$$

$$\stackrel{\text{def}}{\iff} \mathbb{P} \left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n f(X_i) = \pi(f) \right) = 1$$

Remarque On traitera souvent le cas où $f = \mathbb{1}_{x=y}$ pour $y \in E$. On aura alors :

$$\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i=y} \xrightarrow[n \rightarrow \infty]{} \pi(y)$$

donc le nombre moyen de passages de $(X_n)_{n \in \mathbb{N}}$ en y tend vers la mesure invariante en y . C'est très utile pour déterminer numériquement une mesure invariante.

Proposition Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov. On définit le nombre de visites de la chaîne en $y \in E$ avant le temps n comme :

$$V_{y,n} = \sum_{i=0}^n \mathbb{1}_{X_i=y}$$

Si $(X_n)_{n \in \mathbb{N}}$ est irréductible et transiente ou récurrente nulle, alors :

$$\forall y \in E, \quad \frac{V_{y,n}}{n} \xrightarrow[n \rightarrow \infty]{} 0$$

Si $(X_n)_{n \in \mathbb{N}}$ est récurrente positive, on a :

$$\forall y \in E, \quad \frac{V_{y,n}}{n} \xrightarrow[n \rightarrow \infty]{} \pi(y)$$

1.6.2 Convergence en loi

Une conséquence du théorème ergodique est que pour $(X_n)_{n \in \mathbb{N}}$ irréductible récurrente positive on ait :

$$\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i=y} \xrightarrow[n \rightarrow \infty]{} \pi(y)$$

d'où, en passant à l'espérance :

$$\frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i = y) \xrightarrow{n \rightarrow \infty} \pi(y)$$

On veut donc savoir sous quelles conditions on aura la convergence en loi suivante $\lim_{n \rightarrow \infty} \mathbb{P}(X_n = y) = \pi(y)$.

Définition (apériodicité) . Une chaîne de Markov $(X_n)_{n \in \mathbb{N}}$ irréductible est *apériodique* si :

$$\boxed{\forall x, y \in E, \exists n_0 \in \mathbb{N}, \forall n \geq n_0, P^n(x, y) > 0}$$

$$\iff \text{pgcd}(\{n \in \mathbb{N} \mid P^n(x, y) > 0\}) = 1$$

Lemme Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne irréductible. S'il existe $x_0 \in E$ et $n \in \mathbb{N}$ tel que $P^n(x_0, x_0) > 0$ alors la chaîne est apériodique.

Démonstration Soient $y, z \in E$, puisque $(X_n)_{n \in \mathbb{N}}$ est irréductible, il existe $r, s \in \mathbb{N}$ tels que $P^r(x, y) > 0$ et $P^s(y, x) > 0$ On en déduit donc que pour n suffisamment grand :

$$P^{r+n+s}(y, z) \geq P^r(y, x)P^n(x, x)P^s(x, z) > 0$$

Théorème (Convergence en Loi) . Soit $(X_n)_{n \in \mathbb{N}}$ une chaîne de Markov irréductible et apériodique. Distinguons deux cas :

1. Si $(X_n)_{n \in \mathbb{N}}$ est *récurrente positive*, alors quelque soit la loi initial π_0 , on a :

$$\mathbb{P}_{\pi_0}(X_n = x) \xrightarrow{n \rightarrow \infty} \pi(x)$$

(i.e X_n converge en loi vers π).

2. Si $(X_n)_{n \in \mathbb{N}}$ est *transiente* ou *récurrente nulle*, alors :

$$\mathbb{P}_{\pi_0}(X_n = x) \xrightarrow{n \rightarrow \infty} 0$$

Remarque On peut donc approcher π la mesure invariante de deux façons. Soit par le théorème ergodique :

$$\frac{1}{n} \sum_{i=1}^n \mathbb{P}(X_i = y) \xrightarrow{n \rightarrow \infty} \pi(y)$$

grâce à une seule réalisation de $(X_1, \dots, X_n)$. Soit grâce au théorème de convergence en loi : pour n grand, X_n aura une loi proche de $\pi(y)$. Ainsi pour m réalisations de X_n ($X_n^1, \dots, X_n^m$) on aura :

$$\frac{1}{m} \sum_{i=1}^m \mathbb{1}_{X_n^i = y} \xrightarrow{n \rightarrow \infty} \pi(y)$$

Chapitre 2

Espérances Conditionnelles

Contents

2.1	Espérances conditionnelles sur un espace d'états discret	28
2.1.1	Exemple Introductif	28
2.2	Définition de l'espérance conditionnelle	30
2.2.1	Généralités	30
2.2.2	Espérance conditionnelle	31
2.2.3	Pour les variables à densité	31

2.1 Espérances conditionnelles sur un espace d'états discret

2.1.1 Exemple Introductif

Une entreprise souhaite effectuer un questionnaire de satisfaction en vue d'améliorer ses services. Pour chaque client, le résultat du sondage peut être représenté par une variable aléatoire X à valeurs dans $E = \{1, \dots, 100\}$. le résultat du sondage sera la moyenne empirique des réponses et il donnera une bonne estimation de $\mathbb{E}(X)$.

Or, pour permettre de personnaliser un peu plus ses services, l'entreprise souhaite connaître les caractéristiques des clients ayant donné le même score au sondage. Par exemple, elle souhaite étudier les réponses moyennes des clients en fonction de leur âge, de leur sexe, etc... Par exemple si Y est la variable aléatoire qui représente l'âge d'un client, on souhaite obtenir la probabilité qu'un client d'âge y attribue la note de x . Ce sera donc la quantité suivante :

$$\mathbb{P}(X = x \mid Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}$$

que l'on appelle *probabilité conditionnelle* de x sachant y . On peut ainsi définir une nouvelle mesure de probabilités appelée *probabilité conditionnelle* telle que, pour y fixé, on ait :

$$\mathbb{P}(X = \bullet \mid Y) = \frac{\mathbb{P}(X = \bullet, Y = y)}{\mathbb{P}(Y = y)}$$

$$\sum_{x \in E} \mathbb{P}(X = x \mid Y = y) = 1$$

Ainsi, dans notre exemple, la note moyenne des clients d'âge y sera *l'espérance conditionnelle* de X sachant $Y = y$ définie par :

$$\mathbb{E}(X \mid Y = y) = \sum_{x \in E} x \mathbb{P}(X = x \mid Y = y)$$

On peut donc définir une fonction $h : E \mapsto \overline{\mathbb{R}}$ telle que :

$$h = \mathbb{E}(X \mid Y) \quad \text{i.e.} \quad \forall y \in E, h(y) = \mathbb{E}(X \mid Y = y)$$

À noter que X et Y ne sont pas nécessairement à valeurs dans le même ensemble.

Exemple Considérons l'expérience aléatoire suivante. On lance un dé équilibré à 6 faces. Soit y son résultat. On lance ensuite y fois une pièce de monnaie équilibrée. On cherche à déterminer le nombre moyen de fois où on tombe sur Pile.

Pour cela, on pose Y une variable aléatoire à valeurs dans $\llbracket 1, 6 \rrbracket$ et, conditionnellement à $\{Y = y\}$ on définit X la variable aléatoire de loi $\mathcal{B}(y, p)$ où p est la probabilité de faire Pile. On a alors :

$$\forall k \in \llbracket 0, y \rrbracket, \quad \mathbb{P}(X = k \mid Y = y) = \binom{y}{k} p^k (1-p)^{y-k}$$

d'où $\mathbb{E}(X \mid Y = y) = yp$ donc $\mathbb{E}(X \mid Y) = pY$.

Propriété (Composition) . Soient deux variables aléatoires discrètes X et Y on a l'égalité suivante :

$$\mathbb{E}(\mathbb{E}(X \mid Y)) = \mathbb{E}(X)$$

Démonstration Soient X et Y deux variables aléatoires respectivement à valeurs dans E et E' . On a :

$$\begin{aligned} \mathbb{E}(\mathbb{E}(X \mid Y)) &= \sum_{y \in E'} \mathbb{E}(X \mid Y = y) \mathbb{P}(Y = y) \quad (\text{Théorème de transfert}) \\ &= \sum_{y \in E'} \mathbb{P}(Y = y) \left(\sum_{x \in E} x \mathbb{P}(X = x \mid Y = y) \right) \\ &= \sum_{y \in E} \sum_{x \in E} x \mathbb{P}(X = x, Y = y) \\ &= \sum_{x \in E} \sum_{y \in E} x \mathbb{P}(X = x, Y = y) \\ &= \sum_{x \in E} x \mathbb{P}(X = x) \quad (\text{Probabilités Totales}) \\ &= \mathbb{E}(X) \end{aligned}$$

Proposition Pour reprendre l'exemple précédent, on se donne maintenant $y \in E'$ l'âge d'une personne et on cherche à savoir quelle réponse $x \in E$ cette personne a donnée au sondage. On souhaite donc déterminer X à partir des informations fournies par Y . On cherche donc $h(Y)$, une variable aléatoire fonction de Y , qui minimise l'erreur quadratique moyenne :

$$\inf_h \mathbb{E}[(X - h(Y))^2] = \inf_h \{ \mathbb{E}(X^2) - 2 \mathbb{E}[h(Y)X] + \mathbb{E}[h(Y)^2] \}.$$

On a, par le théorème de transfert :

$$\begin{aligned}\mathbb{E}[h(Y)\mathbb{E}(X|Y)] &= \sum_{y \in E'} h(y)\mathbb{E}(X | Y = y) \mathbb{P}(Y = y) \\ &= \sum_{x \in E} \sum_{y \in E'} x h(y) \mathbb{P}(X = x, Y = y) \\ &= \mathbb{E}[h(Y)X].\end{aligned}$$

On en déduit que

$$\mathbb{E}[h(Y)(X - \mathbb{E}[X|Y])] = 0.$$

Cette relation peut être interprétée comme une *orthogonalité* : si l'on considère le produit scalaire défini sur les variables aléatoires par

$$\langle U, V \rangle = \mathbb{E}[UV],$$

alors $X - \mathbb{E}[X|Y]$ est orthogonal à toute variable aléatoire de la forme $h(Y)$. Cette interprétation sera approfondie dans la partie suivante.

Ainsi :

$$\begin{aligned}\inf_h \left\{ \mathbb{E}(X^2) - 2\mathbb{E}[h(Y)X] + \mathbb{E}[h(Y)^2] \right\} &= \inf_h \left\{ \mathbb{E}(X^2) - 2\mathbb{E}[h(Y)\mathbb{E}(X|Y)] + \mathbb{E}[h(Y)^2] \right\} \\ &= \inf_h \left\{ \mathbb{E}(X^2) - \mathbb{E}[\mathbb{E}(X|Y)^2] + \mathbb{E}[(h(Y) - \mathbb{E}(X|Y))^2] \right\} \\ &= \mathbb{E}(X^2) - \mathbb{E}[\mathbb{E}(X|Y)^2] + \inf_h \mathbb{E}[(h(Y) - \mathbb{E}(X|Y))^2].\end{aligned}$$

Le terme d'espérance est minimal lorsque $h(Y) = \mathbb{E}(X|Y)$, ce qui prouve que l'espérance conditionnelle est la meilleure approximation quadratique de X sachant Y .

2.2 Définition de l'espérance conditionnelle

Cette section fait appel à beaucoup de connaissances de théorie de la mesure. Des rappels peuvent s'imposer. On se place ici dans un espace de variables aléatoires de carré intégrable $L^2(\Omega, \mathcal{A}, \mathbb{P})$. C'est un espace de Hilbert doté d'un produit scalaire :

$$\langle \cdot, \cdot \rangle : \begin{cases} (L^2(\Omega, \mathcal{A}, \mathbb{P}))^2 \longrightarrow \mathbb{R} \\ (X, Y) \longmapsto \mathbb{E}(XY) \end{cases}$$

et muni d'une norme quadratique :

$$\|\cdot\|_2 : \begin{cases} L^2(\Omega, \mathcal{A}, \mathbb{P}) \longrightarrow \mathbb{R} \\ X \longmapsto \sqrt{\mathbb{E}(X^2)} \end{cases}$$

2.2.1 Généralités

Définition (Tribu engendrée) . Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace de probabilité et $X : \Omega \longrightarrow \mathbb{R}$ une variable aléatoire. On définit la tribu engendrée par X , notée $\sigma(X)$, est la tribu engendrée par les sous-ensembles de Ω de la forme $\{X \leq a\}, \forall a \in \mathbb{R}$.

De même, $\sigma(X)$ contient tout les évènements de la forme $\{X \in B\}$ avec $B \in \mathcal{B}_{\mathbb{R}}$. Plus généralement, on peut définir $\sigma(X_1, \dots, X_n)$ pour une collection de n variables aléatoires $X_1, \dots, X_n$. Intuitivement, $\sigma(X)$ contient toute l'information associée à la variable X .

Définition (Variable aléatoire mesurable par rapport à X) . Soit $(\Omega, \mathcal{A}, \mathbb{P})$ un espace de probabilité et $X : \Omega \rightarrow \mathbb{R}$ une variable aléatoire. Une variable aléatoire $Z : \Omega \rightarrow \mathbb{R}$ est dite *mesurable par rapport à X* si elle est mesurable pour la tribu $\sigma(X)$, c'est-à-dire si :

$$\forall B \in \mathcal{B}_{\mathbb{R}}, \quad Z^{-1}(B) \in \sigma(X).$$

Lemme Soient Y, W deux variables aléatoires sur $(\Omega, \mathcal{A}, \mathbb{P})$ telles que Y est à valeurs dans $(E, \mathcal{E})$ et W dans $(\mathbb{R}, \mathcal{B}_{\mathbb{R}})$. W est mesurable par rapport à $\sigma(Y)$ si et seulement si il existe $f \in \mathcal{M}(E, \mathbb{R})$ telle que $W = f(Y)$.

2.2.2 Espérance conditionnelle

Nous allons maintenant définir l'espérance conditionnelle comme une projection orthogonale.

Proposition Soient $X, Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$. On souhaite approcher X par une variable aléatoire mesurable par rapport à Y . D'après le lemme précédent, toute variable aléatoire mesurable par rapport à Y est de la forme $h(Y)$ avec une fonction borélienne $h : \mathbb{R} \rightarrow \mathbb{R}$.

On cherche donc à approcher X à partir des variables du sous-espace :

$$\mathcal{H} = \{ h(Y) \mid h \in L^2(\mathbb{R}, \mathcal{B}_{\mathbb{R}}, \mathbb{P}_Y) \} \subset L^2(\Omega, \mathcal{A}, \mathbb{P}).$$

La variable aléatoire de $\mathcal{H}$ la plus proche de X est, par définition, le *projeté orthogonal* de X sur $\mathcal{H}$.

Définition (Espérance conditionnelle comme projection) . Dans le même contexte que précédemment, l'espérance conditionnelle $\mathbb{E}(X \mid Y)$ est le *projeté orthogonal* de X sur le sous-espace $\mathcal{H}$ défini ci-dessus. Elle est caractérisée par la relation d'orthogonalité :

$$\forall h(Y) \in \mathcal{H}, \quad \mathbb{E}[(X - \mathbb{E}(X \mid Y)) h(Y)] = 0.$$

On peut étendre cette définition au cas L^1 grâce au théorème suivant.

Théorème (Existence) . Soit $X \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ et $\mathcal{F}$ une sous-tribu de $\mathcal{A}$. Alors il existe une unique variable aléatoire Z , mesurable par rapport à $\mathcal{F}$, telle que :

1. $\mathbb{E}(|Z|) < \infty$,
2. pour tout $W \in L^\infty(\Omega, \mathcal{F}, \mathbb{P})$, on a

$$\mathbb{E}(XW) = \mathbb{E}(ZW).$$

On appelle Z l'*espérance conditionnelle* de X sachant $\mathcal{F}$ et on la note $\mathbb{E}(X \mid \mathcal{F})$.

2.2.3 Pour les variables à densité

Rappel (Loi jointe et lois marginales) Soit (X, Y) un couple de variables aléatoires à densité de loi jointe $f_{X,Y}$. La *loi marginale* de y par rapport à x est obtenue par :

$$f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx$$

de même pour la *loi marginale* de x :

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y) dy$$

Définition (Probabilité Conditionnelle) . De même que pour les variables discrètes, on définit la probabilité conditionnelle de X par sa densité :

$$f_{X|Y=y} = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

Ainsi pour $y \in \mathbb{R}$ fixé tel que $f_Y(y) > 0$, $f_{X|Y=y}$ définit une densité sur $\mathbb{R}$ et on peut lui associer :

$$\mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx$$

Définition (Espérance Conditionnelle (Cas continu)) . Soient deux variables aléatoires X et Y à densité de loi jointe $f_{X,Y}$. On définit l'espérance conditionnelle de X par rapport à Y comme la fonction :

$$h : y \longmapsto \mathbb{E}(X | Y = y) = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx$$

Remarque La condition d'orthogonalité du théorème précédent se vérifie de la même façon. Pour $h : \mathbb{R} \longrightarrow \mathbb{R}$ bornée, on a :

$$\begin{aligned} \mathbb{E}(\mathbb{E}(X | Y)h(Y)) &= \int_{\mathbb{R}} f_Y(y)h(y)\mathbb{E}(X | Y = y) dy \\ &= \int_{\mathbb{R}} f_Y(y)h(y) \left(\int_{\mathbb{R}} x f_{X|Y=y}(x) dx \right) dy \\ &= \int_{\mathbb{R}^2} xh(y)f_{X|Y=y}(x)f_Y(y) dx dy \\ &= \int_{\mathbb{R}^2} xh(y)f_{X,Y}(x,y) dx dy \\ &= \mathbb{E}(Xh(Y)) \end{aligned}$$

