

Fiches de Cours

Master IMA

Axel PIGEON

axel.pigeon@univ-tlse3.fr

Université Toulouse III – Paul Sabatier

Années universitaires 2025–2027

9 septembre 2026

Table des matières

I	Mathématiques du Machine Learning	3
1	Introduction à l'Apprentissage Supervisé	4
1.1	Des données et des prédictions	4
1.2	Formalisation mathématique	5
1.3	Risque et prédicteur de Bayes	6
1.4	Paradigmes classiques d'apprentissage	7
2	Régression Linéaire et Régression Ridge	11
2.1	Moindres Carrés	11
2.2	Analyse statistique – design fixe	12
2.3	Régression Ridge – design fixe	14
3	Méthodes à Noyaux	16
3.1	De la similarité au Théorème du Représentant	16
3.2	Noyaux définis positifs et théorème d'Aronszajn	17
3.3	Séparateurs à Vaste Marge (SVM)	19

Mathématiques du Machine Learning

Chapitre 1

Introduction à l'Apprentissage Supervisé

Contents

1.1	Des données et des prédictions	4
1.2	Formalisation mathématique	5
1.2.1	Fonction de Perte	5
1.2.2	Les Risques	5
1.3	Risque et prédicteur de Bayes	6
1.3.1	Forme explicite selon la tâche	7
1.4	Paradigmes classiques d'apprentissage	7
1.4.1	Minimisation du Risque Empirique (ERM)	7
1.4.2	Méthodes probabilistes et Maximum de Vraisemblance	8
1.4.3	Méthodes par moyennage local (k -plus proches voisins)	9
1.4.4	Méthodes génératives	9
1.4.5	Théorème No Free Lunch	10

L'objectif de ce cours est de formaliser le processus d'apprentissage d'un modèle dans le cas d'un apprentissage supervisé. On commencera par définir ce qu'est ce type d'apprentissage puis ce que l'on entend par "apprendre". Différentes métriques seront introduites pour le quantifier.

1.1 Des données et des prédictions

L'ensemble du processus d'apprentissage s'appuie sur les concepts de *données* et de *prédictions*.

Définition (Observations) . Formellement, on définira les *données* d'un problème de machine learning par un ensemble de couples $(x, y) \in \mathcal{X} \times \mathcal{Y}$ que l'on appellera *données d'entraînement* ou *observations*. On notera cet ensemble D qui contiendra N couples.

Ces entrées et sorties attendues peuvent être de différents types en fonction du problème considéré. Les entrées peuvent être des images, des vidéos, du son ou un texte. On les modélisera en général par des vecteurs de $\mathbb{R}^d$ lorsque c'est possible. On appellera donc $d \in \mathbb{N}$ la dimension des données à l'entrée du modèle.

Les sorties peuvent être de deux types différents en apprentissage supervisé :

- Un ensemble d'entiers $\{1, \dots, k\}$. On parlera alors de problème de *classification*.

- Un vecteur de $\mathbb{R}^{d'}$. On parlera alors d'un problème de *régression*.

L'objectif est d'être capable, à partir d'une nouvelle donnée $x \in \mathcal{X}$ d'inférer/prédire le y qui lui correspond le mieux. Plus formellement, on cherche à *apprendre* une fonction f à partir des données d'entraînement telle que :

$$y \simeq f(x) \quad (1.1.1)$$

1.2 Formalisation mathématique

Pour apprendre une telle fonction, nous devons admettre différentes hypothèses sur le jeu de données de départ D . La première est que ce jeu de données suit une certaine loi de probabilité $\mathbb{P}$. La seconde est que chaque échantillon $(x_i, y_i), i \in \llbracket 1, N \rrbracket$ est indépendant des autres (D est un ensemble de réalisation i.i.d de la loi $\mathbb{P}$).

1.2.1 Fonction de Perte

Pour effectuer cet apprentissage, nous devons être capable de savoir à quel point notre modèle se trompe sur une prédiction donnée par rapport à la vraie valeur issue du jeu de données. Nous définissons pour cela une *fonction de perte*.

Définition (Fonction de perte) . La *fonction de perte*, notée l , calcule l'erreur induite par la prédiction de $z \in \mathcal{Y}$ alors que la valeur attendue était $y \in \mathcal{Y}$ pour une entrée $x \in \mathcal{X}$. Elle vérifie donc :

$$l : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}. \quad (1.2.1)$$

Exemple Dans le cas d'une classification binaire (i.e $\mathcal{Y} = \{0, 1\}$), on peut simplement utiliser la *Zero/One Loss* définie par $l(y, z) = \mathbb{1}_{z \neq y}$.

Dans le cas de la régression, on utilisera plutôt les L^1 Loss ou L^2 Loss définies par :

$$l(y, z) = \|y - z\|^2, \quad \text{et} \quad l(y, z) = \|y - z\|$$

1.2.2 Les Risques

Ces différentes fonctions de pertes, aussi bien définies soient-elles, ne nous donnent d'un aperçu des erreurs du modèle en temps réel. Nous avons aussi besoin d'avoir une idée plus fine des performances du modèle vis-à-vis de la distribution de probabilité $\mathbb{P}$ du jeu de données D . On définit pour cela les *risques*.

Définition (Risque Moyen) . On définit le *risque moyen*, noté $\mathcal{R}(f)$, d'une fonction f sur l'espace $\mathcal{X} \times \mathcal{Y}$ par l'espérance de la perte du ce même jeu de données.

$$\mathcal{R}(f) := \int_{\mathcal{X} \times \mathcal{Y}} l(y, f(x)) dp(x, y) dx dy = \mathbb{E}(l(y, f(x))) \quad (1.2.2)$$

où p est le densité de la probabilité $\mathbb{P}$.

Exemple Dans le cas de la classification binaire, le risque moyen se simplifie facilement :

$$\begin{aligned} \mathcal{R}(f) &= \int_{\mathcal{X} \times \mathcal{Y}} \mathbb{1}_{y \neq f(x)} d\mathbb{P}(x, y) \\ &= 0 \times \mathbb{P}(f(x) = y) + 1 \times \mathbb{P}(f(x) \neq y) \\ &= \mathbb{P}(f(x) \neq y) \end{aligned}$$

À noter que ce risque est calculé sur l'espace entier des données possibles. En pratique, si celui-ci est infini, il est incalculable. On préférera donc utiliser le *risque empirique*.

Définition (Risque Empirique) . Le risque empirique, noté $\hat{\mathcal{R}}(f)$ est donné par la moyenne empirique des pertes sur un jeu de données D .

$$\hat{\mathcal{R}}(f) := \frac{1}{N} \sum_{i=1}^N l(y_i, f(x_i)). \quad (1.2.3)$$

Proposition (Convergence) Grâce aux hypothèses précédentes, on peut invoquer des théorèmes de convergence sur les suites de variables aléatoires pour caractériser la limite de ce risque empirique.

Ainsi, si $f \in L^1$ alors, d'après la *Loi Forte des Grands Nombres*, on a que :

$$\hat{\mathcal{R}}(f) \xrightarrow[n \rightarrow \infty]{\text{p.s.}} \mathcal{R}(f). \quad (1.2.4)$$

Si, de plus $f \in L^2$, alors on a une idée de la vitesse de convergence de ce risque empirique :

$$\sqrt{n}(\hat{\mathcal{R}}(f) - \mathcal{R}(f)) \xrightarrow[n \rightarrow \infty]{\text{Loi}} \mathcal{N}(0, \mathbb{V}(l(y, f(x)))). \quad (1.2.5)$$

Remarque (Indépendance) En pratique, pour toute fonction apprise f , on aura $\hat{\mathcal{R}}(f) \simeq \mathcal{R}(f)$. Or, lorsque l'on calcule f sur des données empiriques (ex : jeu de données), on casse l'indépendance de la suite de variables aléatoires et donc le TCL. Formellement, en prenant l'estimateur :

$$\frac{1}{n} \sum_{i=1}^n l(x_i, \hat{f}(x_i)),$$

on remarque que le $\hat{f}$ est calculé à partir des $(x_1, y_1), \dots, (x_n, y_n)$. On peut solutionner ce problème en séparant le jeu de données en deux : *entraînement* et *test* (et éventuellement *validation*). Puisque le modèle ne voit pas les données de test et de validation, la fonction apprise ne dépend pas de ces données, ce qui permet de conserver l'indépendance des variables. On peut ensuite utiliser le TCL pour estimer le risque $\mathcal{R}$ à partir du risque empirique $\hat{\mathcal{R}}$.

1.3 Risque et prédicteur de Bayes

L'objectif théorique de l'apprentissage statistique est de trouver une fonction f qui minimise le risque moyen $\mathcal{R}(f)$ parmi l'ensemble $\mathcal{F}_{\text{all}}$ de toutes les fonctions mesurables de $\mathcal{X}$ dans $\mathcal{Y}$.

Définition (Prédicteur et Risque de Bayes) . On appelle *prédicteur de Bayes*, noté f^* , la fonction optimale (si elle existe) qui minimise le risque moyen sur l'espace de toutes les fonctions mesurables :

$$f^* \in \arg \min_{f \in \mathcal{F}_{\text{all}}} \mathcal{R}(f) \quad (1.3.1)$$

Le risque associé, noté $\mathcal{R}^* = \mathcal{R}(f^*)$, est appelé le *risque de Bayes* (ou erreur irréductible). Pour toute fonction mesurable f , on a trivialement :

$$\mathcal{R}(f) \geq \mathcal{R}^* \quad (1.3.2)$$

Pour calculer explicitement f^* , on utilise la loi des espérances itérées (conditionnement par rapport à X) :

$$\mathcal{R}(f) = \mathbb{E}_{(X,Y)} [l(Y, f(X))] = \mathbb{E}_X [\mathbb{E}_{Y|X} [l(Y, f(X)) | X]] \quad (1.3.3)$$

Minimiser $\mathcal{R}(f)$ revient donc à minimiser l'espérance conditionnelle point par point pour chaque $x \in \mathcal{X}$:

$$f^*(x) \in \arg \min_{z \in \mathcal{Y}} \mathbb{E}_{Y|X=x} [l(Y, z) \mid X = x] \quad (1.3.4)$$

1.3.1 Forme explicite selon la tâche

Proposition (Cas de la régression quadratique (L^2)) Pour la perte quadratique $l(y, z) = (y - z)^2$, le prédicteur de Bayes est l'espérance conditionnelle de Y sachant X :

$$f^*(x) = \mathbb{E}[Y \mid X = x] \quad (1.3.5)$$

Démonstration Fixons $x \in \mathcal{X}$. On cherche $z \in \mathbb{R}$ minimisant $\phi(z) = \mathbb{E}[(Y - z)^2 \mid X = x]$.

$$\phi(z) = \mathbb{E}[Y^2 \mid X = x] - 2z\mathbb{E}[Y \mid X = x] + z^2$$

ϕ est une fonction convexe et dérivable en z . En annulant la dérivée :

$$\phi'(z) = -2\mathbb{E}[Y \mid X = x] + 2z = 0 \iff z = \mathbb{E}[Y \mid X = x]$$

Proposition (Cas de la classification binaire (perte 0/1)) Pour $\mathcal{Y} = \{0, 1\}$ et la perte 0/1 $l(y, z) = \mathbb{1}_{y \neq z}$, le prédicteur de Bayes attribue la classe la plus probable a posteriori :

$$f^*(x) = \mathbb{1}_{\mathbb{P}(Y=1|X=x) \geq 1/2} \quad (1.3.6)$$

Démonstration Pour un $x \in \mathcal{X}$ donné et pour $z \in \{0, 1\}$:

$$\begin{aligned} \mathbb{E}[\mathbb{1}_{Y \neq z} \mid X = x] &= \mathbb{P}(Y \neq z \mid X = x) \\ &= 1 - \mathbb{P}(Y = z \mid X = x) \end{aligned}$$

Minimiser cette quantité revient à maximiser $\mathbb{P}(Y = z \mid X = x)$, ce qui donne la règle du maximum a posteriori (MAP).

Pour résumer, dans le cas d'une *classification*, le prédicteur de Bayes associe la classe la plus probable selon la distribution de probabilité simulée. Dans le cas d'une *régression*, ce prédicteur retournera la moyenne de la distribution de probabilité générée sur les y_i .

1.4 Paradigmes classiques d'apprentissage

Le prédicteur de Bayes f^* étant inconnu car il dépend de la distribution $\mathbb{P}$, différentes stratégies existent pour l'approcher à partir du jeu de données $S = ((x_1, y_1), \dots, (x_n, y_n))$.

1.4.1 Minimisation du Risque Empirique (ERM)

Définition (Estimateur ERM) . On restreint la recherche à une classe paramétrique de fonctions $\mathcal{F}_\Theta = \{f_\theta : \mathcal{X} \rightarrow \mathcal{Y}, \theta \in \Theta\}$. L'estimateur par *minimisation du risque empirique* (ERM) est défini par :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \hat{\mathcal{R}}_S(f_\theta) = \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n l(y_i, f_\theta(x_i)) \quad (1.4.1)$$

Exemple (Régression linéaire et polynomiale) Pour $f_\theta(x) = \theta^\top \varphi(x)$ (où φ est un morphisme d'extraction de caractéristiques / *feature map*) et la perte quadratique L^2 , le problème s'écrit :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - \theta^\top \varphi(x_i))^2 \quad (1.4.2)$$

Si $\varphi(x) = (1, x, x^2, \dots, x^k)^\top$, on retrouve la régression polynomiale de degré k .

Proposition (Décomposition de l'erreur d'excès de risque) Pour tout estimateur $\hat{\theta}$, l'excès de risque par rapport au risque de Bayes se décompose canoniquement en :

$$\mathcal{R}(f_{\hat{\theta}}) - \mathcal{R}^* = \underbrace{\left(\mathcal{R}(f_{\hat{\theta}}) - \inf_{\theta \in \Theta} \mathcal{R}(f_\theta) \right)}_{\text{Erreur d'estimation}} + \underbrace{\left(\inf_{\theta \in \Theta} \mathcal{R}(f_\theta) - \mathcal{R}^* \right)}_{\text{Erreur d'approximation}} \quad (1.4.3)$$

- **Erreur d'approximation** : Déterministe et indépendante de n , elle mesure la perte due au choix de la classe restreinte Θ (diminue si la richesse de Θ augmente).
- **Erreur d'estimation** : Aléatoire (dépend de S), elle mesure le coût lié au nombre fini d'échantillons n (décroît avec n , croît avec la richesse/complexité de Θ).

Remarque (Contrôle de l'erreur d'estimation) En notant $\theta^* \in \arg \min_{\theta \in \Theta} \mathcal{R}(f_\theta)$, on majore l'erreur d'estimation par :

$$\mathcal{R}(f_{\hat{\theta}}) - \mathcal{R}(f_{\theta^*}) \leq 2 \sup_{\theta \in \Theta} |\hat{\mathcal{R}}_S(f_\theta) - \mathcal{R}(f_\theta)| + \sup_{\theta \in \Theta} (\hat{\mathcal{R}}_S(f_{\hat{\theta}}) - \hat{\mathcal{R}}_S(f_\theta)) \quad (1.4.4)$$

Le premier terme est une déviation uniforme (objet central de la théorie de l'apprentissage statistique), et le second représente l'erreur d'optimisation numérique (nulle si le minimum empirique est calculé exactement).

La décomposition du risque comme présentée ci-dessus peut être observée sur l'apprentissage du modèle. On parlera alors de sur-apprentissage ou de sous-apprentissage en fonction de la complexité du modèle.

- **Sous-apprentissage (*Underfitting*)** : Modèle trop simple (faible complexité de Θ), dominé par l'erreur d'approximation.
- **Sur-apprentissage (*Overfitting*)** : Modèle trop expressif (par exemple interpolation polynomiale de Lagrange de degré $n-1$), l'erreur empirique est quasi-nulle mais l'erreur d'estimation explose sur les nouvelles données.

Pour contrôler ce phénomène, on introduit une pénalisation de complexité $\Omega(\theta)$:

$$\hat{\theta}_{\text{reg}} \in \arg \min_{\theta \in \Theta} \left\{ \hat{\mathcal{R}}_S(f_\theta) + \lambda \Omega(\theta) \right\} \quad (1.4.5)$$

où $\lambda > 0$ est un hyperparamètre calibré sur le jeu de validation (exemples : Ridge avec $\Omega(\theta) = \|\theta\|_2^2$, Lasso avec $\Omega(\theta) = \|\theta\|_1$).

1.4.2 Méthodes probabilistes et Maximum de Vraisemblance

L'idée consiste à postuler une famille paramétrique de densités conditionnelles $\{p_\theta(y | x) : \theta \in \Theta\}$ et à choisir le paramètre qui maximise la log-vraisemblance sur l'échantillon i.i.d :

$$\hat{\theta}_{\text{MLE}} \in \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \ln p_\theta(x_i, y_i) \quad (1.4.6)$$

Exemple (Régression Logistique) Pour des labels $y \in \{-1, 1\}$, en posant la fonction sigmoïde $\sigma(z) = \frac{1}{1+e^{-z}}$, le modèle postule :

$$p_\theta(y | x) = \sigma(y\theta^\top x) = \frac{1}{1 + e^{-y\theta^\top x}} \quad (1.4.7)$$

Maximiser la vraisemblance revient exactement à un problème d'ERM :

$$\hat{\theta} \in \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ln \left(1 + e^{-y_i \theta^\top x_i} \right) \quad (1.4.8)$$

avec la perte logistique convexe $l(y, z) = \ln(1 + e^{-yz})$.

Remarque (Pont entre Maximum de Vraisemblance et ERM) En posant $l(y, \hat{y}) = -\ln p_\theta(y | x)$, toute maximisation de vraisemblance s'interprète comme une minimisation de risque empirique :

- Bruit gaussien $\varepsilon \sim \mathcal{N}(0, \sigma^2) \implies$ Perte quadratique (moindres carrés).
- Loi de Bernoulli $\implies$ Perte logistique.

En classification, on utilise ces fonctions de perte convexes (surrogates) car minimiser directement la perte 0/1 est un problème NP-difficile et non dérivable (gradient nul presque partout).

1.4.3 Méthodes par moyennage local (k -plus proches voisins)

Ces méthodes non paramétriques exploitent une hypothèse de régularité locale : des points proches dans $\mathcal{X}$ partagent des distributions conditionnelles $\mathbb{P}_{y|x}$ similaires.

Définition (k -Nearest Neighbours – k -NN) . Pour une entrée x' , on considère l'ensemble $\mathcal{V}_k(x')$ de ses k plus proches voisins dans le jeu d'entraînement :

- **En classification** : Règle du vote majoritaire :

$$\hat{f}(x') = \arg \max_{c \in \mathcal{Y}} \sum_{i \in \mathcal{V}_k(x')} \mathbb{1}_{y_i=c} \quad (1.4.9)$$

- **En régression** : Moyenne empirique locale :

$$\hat{f}(x') = \frac{1}{k} \sum_{i \in \mathcal{V}_k(x')} y_i \quad (1.4.10)$$

Remarque (Compromis biais-variance pour k -NN) Pour k -NN, l'axe de complexité est inversé :

- k petit (ex. $k = 1$) $\implies$ Modèle très flexible, risque de sur-apprentissage (faible approximation, forte estimation).
- k grand $\implies$ Modèle rigide/lissé, risque de sous-apprentissage (forte approximation, faible estimation).

1.4.4 Méthodes génératives

Au lieu de modéliser directement $f(x)$ ou $\mathbb{P}(Y | X)$, les modèles génératifs estiment la loi conjointe en modélisant :

1. La loi a priori des classes $p(y)$.
2. Les densités conditionnelles de chaque classe $p(x | y)$.

On en déduit ensuite la loi a posteriori par la règle de Bayes :

$$p(y | x) = \frac{p(x | y)p(y)}{\sum_c p(x | y = c)p(y = c)} \propto p(x | y)p(y) \quad (1.4.11)$$

La règle de décision optimale est donnée par le maximum a posteriori (MAP) : $\hat{f}(x') = \arg \max_{\hat{y}} p(x' | \hat{y})p(\hat{y})$.

1.4.5 Théorème No Free Lunch

Il n'existe pas d'algorithme d'apprentissage universel optimal sur toutes les distributions possibles sans hypothèse préalable sur les données.

Théorème (No Free Lunch (Devroye, Györfi, Lugosi)) . Soit le problème de classification binaire avec la perte 0/1 et $\mathcal{X}$ un ensemble infini. Soit $\mathcal{P}$ l'ensemble de toutes les lois de probabilité sur $\mathcal{X} \times \{0, 1\}$. Pour tout entier n et tout algorithme d'apprentissage $\mathcal{A}$, on a :

$$\sup_{\mathbb{P} \in \mathcal{P}} \{\mathbb{E}_{S \sim \mathbb{P}^{\otimes n}} [\mathcal{R}_{\mathbb{P}}(\mathcal{A}(S))] - \mathcal{R}_{\mathbb{P}}^*\} \geq \frac{1}{2} \quad (1.4.12)$$

Ce résultat implique que pour n'importe quel algorithme fixé, il existe une distribution sous-jacente défavorable pour laquelle l'algorithme ne fait pas mieux qu'un choix aléatoire (même si le risque de Bayes $\mathcal{R}^* = 0$). Il est donc mathématiquement indispensable de poser des hypothèses régularité, marge, séparabilité ou compacité pour garantir des résultats d'apprentissage.

Chapitre 2

Régression Linéaire et Régression Ridge

Contents

2.1	Moindres Carrés	11
2.2	Analyse statistique – design fixe	12
2.3	Régression Ridge – design fixe	14

On pose ici le contexte d'une *régression linéaire*. On cherche donc à apprendre une fonction pour décrire un jeu de données $(x_1, y_1), \dots, (x_n, y_n) \in \mathcal{X} \times \mathcal{Y}$. Dans le cas du modèle linéaire, on fera l'hypothèse forte suivante :

$$(H) : f_\theta = \varphi(x)^t \theta, \quad \theta \in \mathbb{R}^d. \quad (2.0.1)$$

Pour construire cette fonction, on utilisera l'estimateur du risque empirique (ERM) défini par :

$$\hat{R}(\theta) \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - f_\theta(x_i))^2. \quad (2.0.2)$$

Exemple La forme de l'application φ caractérisera la *feature map* (i.e l'ensemble des fonctions possibles pour interpoler le nuage de points).

- si $\varphi(x) = x$, alors on aura une estimation linéaire en x ,
- si $\varphi(x) = \begin{pmatrix} x \\ 1 \end{pmatrix}$ alors l'estimation sera *affine* en x ,
- si $\varphi(x) \in \mathbb{R}^d[x]$, alors l'estimation sera *polynomiale* en x . On pourra aller jusqu'au degré d pour utiliser des polynômes de Lagrange.

Notation On notera $y = \begin{pmatrix} y_1 \\ \dots \\ y_n \end{pmatrix}$ le vecteur des étiquettes du jeu de données et $\Phi = \begin{pmatrix} \varphi(x_1)^t \\ \dots \\ \varphi(x_n)^t \end{pmatrix} \in$

$\mathbb{R}^{n \times d}$ la matrice contenant toutes les prédictions données par la *feature map*. On aura donc : $\hat{R}(\theta) = \frac{1}{n} \|y - \Phi\theta\|_2^2$.

2.1 Moindres Carrés

Nous sommes en présence d'un problème de régression. Grâce aux notations matricielles précédemment posées, nous sommes capable de calculer une solution explicite à la main.

On cherche à calculer explicitement $\hat{\theta} \in \arg \min_{\theta \in \mathbb{R}^d} \hat{R}(\theta)$. Pour cela, on utilise la condition nécessaire d'optimalité d'ordre 1 : $\nabla_{\theta} \hat{R}(\hat{\theta}) = 0$. Commençons donc par calculer le gradient :

$$\hat{R}(\theta) = \frac{1}{n} \|y - \Phi\theta\|_2^2 \quad (2.1.1)$$

$$\nabla_{\theta} \hat{R}(\theta) = \frac{2}{n} \Phi^{\top} (\Phi\theta - y) \quad (2.1.2)$$

En résolvant l'équation $\nabla_{\theta} \hat{R}(\hat{\theta}) = 0$, on obtient les *équations normales* :

$$(*) : \Phi^{\top} \Phi \hat{\theta} = \Phi^{\top} y \quad (2.1.3)$$

En supposant que Φ est de rang plein ($rg(\Phi) = d$, soit des colonnes linéairement indépendantes), la matrice de Gram $\Phi^{\top} \Phi \in \mathbb{R}^{d \times d}$ est inversible, ce qui donne :

$$(*) \iff \boxed{\hat{\theta} = (\Phi^{\top} \Phi)^{-1} \Phi^{\top} y} \quad (2.1.4)$$

La fonction $\hat{R}$ étant convexe, ce point stationnaire est un minimum global. On calcule ainsi explicitement l'estimateur des moindres carrés (OLS), qui fournit le prédicteur linéaire optimal sur l'échantillon d'entraînement.

Proposition Géométriquement, les prédictions $\hat{y} = \Phi \hat{\theta}$ correspondent à la projection orthogonale du vecteur d'observations $y \in \mathbb{R}^n$ sur le sous-espace vectoriel $\text{Im}(\Phi) \subset \mathbb{R}^n$ engendré par les colonnes de Φ :

$$\hat{\theta} \in \arg \min_{\theta \in \mathbb{R}^d} \frac{1}{n} \|y - \Phi\theta\|_2^2 \iff \hat{y} \in \arg \min_{z \in \text{Im}(\Phi)} \frac{1}{n} \|y - z\|_2^2 \quad (2.1.5)$$




FIGURE 2.1 – Projection orthogonale du vecteur d'observations y sur le sous-espace affine $\text{Im}(\phi)$ et décomposition de l'erreur résiduelle $y - \hat{y} \perp \text{Im}(\phi)$.

2.2 Analyse statistique – design fixe

Dans cette section, on se place sous l'hypothèse du *design fixe* : les points $x_i \in \mathcal{X}$ (et donc la matrice $\Phi \in \mathbb{R}^{n \times d}$) sont déterministes et fixés. Seules les étiquettes y_i sont aléatoires.

Définition (Modèle à design fixe) . Le modèle probabiliste d'observation s'écrit :

1. $y = \Phi\theta_* + \varepsilon$, avec $\theta_* \in \mathbb{R}^d$ le paramètre vrai inconnu.
2. Le vecteur de bruit $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^\top \in \mathbb{R}^n$ vérifie $\mathbb{E}(\varepsilon) = 0$ et $\text{Var}(\varepsilon) = \mathbb{E}(\varepsilon\varepsilon^\top) = \sigma^2 I_n$.

Le risque moyen sous design fixe est défini par :

$$R(\theta) = \frac{1}{n} \mathbb{E}_y \left[\|y - \Phi\theta\|_2^2 \right]. \quad (2.2.1)$$

On introduit la matrice de covariance empirique $\hat{\Sigma} := \frac{1}{n} \Phi^\top \Phi \in \mathbb{R}^{d \times d}$, associée à la semi-norme $\|u\|_{\hat{\Sigma}}^2 := u^\top \hat{\Sigma} u = \frac{1}{n} \|\Phi u\|_2^2$.

Proposition (Décomposition Biais-Variance) Pour tout vecteur fixe $\theta \in \mathbb{R}^d$:

$$\begin{aligned} R(\theta) &= \frac{1}{n} \mathbb{E}_\varepsilon \left[\|\Phi(\theta_* - \theta) + \varepsilon\|_2^2 \right] \\ &= \frac{1}{n} \|\Phi(\theta_* - \theta)\|_2^2 + \frac{1}{n} \mathbb{E} \left[\|\varepsilon\|_2^2 \right] + \frac{2}{n} (\theta_* - \theta)^\top \Phi^\top \mathbb{E}[\varepsilon] \\ &= \|\theta - \theta_*\|_{\hat{\Sigma}}^2 + \sigma^2. \end{aligned}$$

Le risque de Bayes est atteint en θ_* : $R^* = R(\theta_*) = \sigma^2$. Par conséquent, pour un estimateur aléatoire $\hat{\theta}$ dépendant de y (donc de ε) :

$$\mathbb{E}_{\hat{\theta}} \left[R(\hat{\theta}) \right] - R^* = \underbrace{\left\| \mathbb{E}(\hat{\theta}) - \theta_* \right\|_{\hat{\Sigma}}^2}_{\text{Biais}^2} + \underbrace{\mathbb{E}_{\hat{\theta}} \left[\left\| \hat{\theta} - \mathbb{E}(\hat{\theta}) \right\|_{\hat{\Sigma}}^2 \right]}_{\text{Variance}} \quad (2.2.2)$$

Théorème (Biais et Variance des Moindres Carrés) . Dans le cas de l'estimateur des moindres carrés $\hat{\theta} = (\Phi^\top \Phi)^{-1} \Phi^\top y$:

$$\text{Biais}^2 = 0 \quad \text{et} \quad \mathbb{E} \left[R(\hat{\theta}) \right] - R^* = \frac{\sigma^2 d}{n}. \quad (2.2.3)$$

Démonstration • *Calcul du biais* :

$$\begin{aligned} \mathbb{E}(\hat{\theta}) &= \mathbb{E} \left[(\Phi^\top \Phi)^{-1} \Phi^\top (\Phi\theta_* + \varepsilon) \right] \\ &= \theta_* + (\Phi^\top \Phi)^{-1} \Phi^\top \mathbb{E}[\varepsilon] = \theta_*. \end{aligned}$$

L'estimateur est sans biais, d'où $\text{Biais}^2 = 0$.

- *Calcul de la variance* : On exprime la variance sous forme de trace :

$$\begin{aligned} \text{Variance} &= \mathbb{E} \left[(\hat{\theta} - \theta_*)^\top \hat{\Sigma} (\hat{\theta} - \theta_*) \right] \\ &= \mathbb{E} \left[\text{tr} \left(\hat{\Sigma} (\hat{\theta} - \theta_*) (\hat{\theta} - \theta_*)^\top \right) \right] \\ &= \text{tr} \left(\hat{\Sigma} \mathbb{E} \left[(\hat{\theta} - \theta_*) (\hat{\theta} - \theta_*)^\top \right] \right). \end{aligned}$$

Or, $\hat{\theta} - \theta_* = (\Phi^\top \Phi)^{-1} \Phi^\top \varepsilon$, donc :

$$\begin{aligned} \mathbb{E} \left[(\hat{\theta} - \theta_*)(\hat{\theta} - \theta_*)^\top \right] &= (\Phi^\top \Phi)^{-1} \Phi^\top \mathbb{E}[\varepsilon \varepsilon^\top] \Phi (\Phi^\top \Phi)^{-1} \\ &= \sigma^2 (\Phi^\top \Phi)^{-1} \Phi^\top I_n \Phi (\Phi^\top \Phi)^{-1} \\ &= \sigma^2 (\Phi^\top \Phi)^{-1} = \frac{\sigma^2}{n} \hat{\Sigma}^{-1}. \end{aligned}$$

En réinjectant dans l'expression de la trace :

$$\text{Variance} = \text{tr} \left(\hat{\Sigma} \cdot \frac{\sigma^2}{n} \hat{\Sigma}^{-1} \right) = \frac{\sigma^2}{n} \text{tr}(I_d) = \frac{\sigma^2 d}{n}.$$

2.3 Régression Ridge – design fixe

Dans le modèle linéaire usuel, l'erreur de variance vaut $\frac{\sigma^2 d}{n}$. Lorsque les covariables sont fortement corrélées (multicolinéarité), la matrice $\hat{\Sigma}$ possède des valeurs propres très proches de 0, ce qui rend $(\Phi^\top \Phi)^{-1}$ instable et fait exploser la norme du paramètre appris.

La régression Ridge (pénalisation de Tikhonov / régularisation L^2) remédie à ce problème en contractant les coefficients vers zéro via une pénalisation quadratique. On accepte d'introduire un léger biais en échange d'une réduction drastique de la variance.

Définition (Estimateur Ridge) . Pour un paramètre de régularisation $\lambda > 0$, l'estimateur Ridge est défini par :

$$\hat{\theta}_\lambda \in \arg \min_{\theta \in \mathbb{R}^d} \frac{1}{n} \|y - \Phi \theta\|_2^2 + \lambda \|\theta\|_2^2. \quad (2.3.1)$$

En annulant le gradient, la solution explicite est unique et donnée par :

$$\hat{\theta}_\lambda = \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \frac{1}{n} \Phi^\top y = \left(\Phi^\top \Phi + n \lambda I_d \right)^{-1} \Phi^\top y \quad (2.3.2)$$

où $\hat{\Sigma} = \frac{1}{n} \Phi^\top \Phi$. La matrice $\hat{\Sigma} + \lambda I_d$ est symétrique définie positive pour tout $\lambda > 0$, donc inversible même si $\Phi^\top \Phi$ ne l'est pas.

Proposition (Décomposition Biais-Variance de Ridge) Sous le modèle à design fixe $y = \Phi \theta_* + \varepsilon$:

- *Biais* : L'espérance de l'estimateur vaut $\mathbb{E}(\hat{\theta}_\lambda) = (\hat{\Sigma} + \lambda I_d)^{-1} \hat{\Sigma} \theta_*$. Le terme de biais s'écrit donc :

$$\text{Biais}^2 = \left\| \mathbb{E}(\hat{\theta}_\lambda) - \theta_* \right\|_{\hat{\Sigma}}^2 = \lambda^2 \theta_*^\top \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \hat{\Sigma} \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \theta_*. \quad (2.3.3)$$

- *Variance* : En utilisant $\text{Var}(\hat{\theta}_\lambda) = \frac{\sigma^2}{n} (\hat{\Sigma} + \lambda I_d)^{-1} \hat{\Sigma} (\hat{\Sigma} + \lambda I_d)^{-1}$, on obtient :

$$\text{Variance} = \frac{\sigma^2}{n} \text{tr} \left(\hat{\Sigma}^2 \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \right). \quad (2.3.4)$$

Le risque d'excès s'écrit donc :

$$\mathbb{E} \left[R(\hat{\theta}_\lambda) \right] - R^* = \lambda^2 \theta_*^\top \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \hat{\Sigma} \theta_* + \frac{\sigma^2}{n} \text{tr} \left(\hat{\Sigma}^2 \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \right). \quad (2.3.5)$$

Remarque (Degrés de liberté effectifs) La quantité $df(\lambda) = \text{tr} \left(\hat{\Sigma}(\hat{\Sigma} + \lambda I_d)^{-1} \right) = \sum_{j=1}^d \frac{\mu_j}{\mu_j + \lambda}$ mesure les *degrés de liberté effectifs* du modèle. Pour $\lambda = 0$, on retrouve $df(0) = d$ et la variance des moindres carrés $\frac{\sigma^2 d}{n}$. Lorsque $\lambda \rightarrow \infty$, $df(\lambda) \rightarrow 0$.

Proposition (Contrôle spectral et borne d'erreur) Soit $\hat{\Sigma} = U \text{diag}(\mu_1, \dots, \mu_d) U^\top$ la décomposition spectrale de $\hat{\Sigma}$ (avec $\mu_j \geq 0$).

- Pour le biais : pour tout $\mu \geq 0$ et $\lambda > 0$, on a $\frac{\lambda^2 \mu}{(\mu + \lambda)^2} \leq \frac{\lambda}{4}$ (car $(\mu + \lambda)^2 \geq 4\lambda\mu$), d'où :

$$\text{Biais}^2 \leq \frac{\lambda}{4} \|\theta_*\|_2^2. \quad (2.3.6)$$

- Pour la variance : comme $\frac{\mu_j^2}{(\mu_j + \lambda)^2} \leq \frac{\mu_j}{\lambda}$, on a :

$$\text{Variance} \leq \frac{\sigma^2}{n\lambda} \text{tr}(\hat{\Sigma}). \quad (2.3.7)$$

En équilibrant les deux bornes avec le choix optimal $\lambda^* \propto \frac{\sigma}{\sqrt{n}}$, on garantit une vitesse de convergence de l'excès de risque en $\mathcal{O}(1/\sqrt{n})$, indépendante du plus petit spectre de $\hat{\Sigma}$.

Chapitre 3

Méthodes à Noyaux

Contents

3.1 De la similarité au Théorème du Représentant	16
3.1.1 Intuition géométrique et plongement	16
3.1.2 Le Théorème du Représentant	17
3.1.3 Paramétrisation duale finie	17
3.2 Noyaux définis positifs et théorème d'Aronszajn	17
3.2.1 Définition et propriétés	17
3.2.2 Théorème d'Aronszajn et espaces de Hilbert à noyau reproduisant (RKHS)	18
3.2.3 Algèbre des noyaux et théorème de Bochner	18
3.3 Séparateurs à Vaste Marge (SVM)	19
3.3.1 Cas linéairement séparable : Maximisation de la marge	19
3.3.2 Cas non séparable : Variables d'écart et perte charnière	19
3.3.3 Dualité de Wolfe et astuce du noyau (Kernel Trick)	19

L'objectif des méthodes à noyaux est de transformer une mesure heuristique de similarité entre données en un algorithme d'apprentissage non linéaire. En s'appuyant implicitement sur un espace de Hilbert de dimension arbitraire (potentiellement infinie), on conserve toute la simplicité de l'optimisation linéaire tout en évitant d'avoir à calculer explicitement les plongements.

3.1 De la similarité au Théorème du Représentant

3.1.1 Intuition géométrique et plongement

La plupart des jeux de données ne sont pas linéairement séparables dans leur espace d'entrée d'origine $\mathcal{X}$. L'idée fondamentale consiste à envoyer les données dans un espace de caractéristiques de plus grande dimension (un espace de Hilbert $\mathcal{H}$) via une *feature map* :

$$\varphi : \mathcal{X} \longrightarrow \mathcal{H} \quad (3.1.1)$$

Dans $\mathcal{H}$, un hyperplan linéaire peut alors séparer des classes qui formaient des régions géométriques complexes ou intriquées dans $\mathcal{X}$.

On formule alors le problème sous la forme d'une minimisation de risque empirique régularisé sur la totalité de l'espace hilbertien $\mathcal{H}$:

$$\hat{\theta}_S \in \arg \min_{\theta \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n l(y_i, \langle \varphi(x_i), \theta \rangle_{\mathcal{H}}) + \frac{\lambda}{2} \|\theta\|_{\mathcal{H}}^2 \quad (3.1.2)$$

où $\lambda > 0$ contrôle la régularisation.

Remarque (Obstruction numérique) Si $\mathcal{H}$ est de dimension infinie, on ne peut ni représenter le vecteur de paramètres $\theta \in \mathcal{H}$, ni évaluer explicitement $\varphi(x)$ par descente de gradient standard. Le théorème suivant résout ce paradoxe.

3.1.2 Le Théorème du Représentant

Théorème (Théorème du Représentant) . Soit $\mathcal{X}$ un ensemble, $\mathcal{H}$ un espace de Hilbert réel muni du produit scalaire $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ et $\varphi : \mathcal{X} \rightarrow \mathcal{H}$. Soit un échantillon $S = (x_1, \dots, x_n)$ et le sous-espace engendré par les observations :

$$\mathcal{H}_D := \text{vect}\{\varphi(x_1), \dots, \varphi(x_n)\} \subset \mathcal{H} \quad (3.1.3)$$

Soit $\Psi : \mathbb{R}^n \times \mathbb{R}_+ \rightarrow \mathbb{R}$ une fonction croissante par rapport à son second argument. En notant $u(\theta) = (\langle \varphi(x_1), \theta \rangle_{\mathcal{H}}, \dots, \langle \varphi(x_n), \theta \rangle_{\mathcal{H}})^\top \in \mathbb{R}^n$, on a :

$$\inf_{\theta \in \mathcal{H}} \Psi(u(\theta), \|\theta\|_{\mathcal{H}}^2) = \inf_{\theta \in \mathcal{H}_D} \Psi(u(\theta), \|\theta\|_{\mathcal{H}}^2) \quad (3.1.4)$$

Si l'infimum est atteint, il l'est en un point $\hat{\theta}_S \in \mathcal{H}_D$. De plus, si Ψ est *strictement croissante* par rapport à son second argument, tout minimiseur appartient nécessairement à $\mathcal{H}_D$.

3.1.3 Paramétrisation duale finie

Grâce au théorème du représentant, la solution optimale s'écrit comme une combinaison linéaire finie des plongements d'entraînement :

$$\theta = \sum_{j=1}^n \alpha_j \varphi(x_j), \quad \text{avec } \alpha = (\alpha_1, \dots, \alpha_n)^\top \in \mathbb{R}^n \quad (3.1.5)$$

En introduisant la *matrice de Gram* $K \in \mathbb{R}^{n \times n}$ définie par $K_{i,j} = \langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}}$:

- Les prédictions sur les données d'entraînement deviennent $(K\alpha)_i$.
- La régularisation se réécrit quadratiquement : $\|\theta\|_{\mathcal{H}}^2 = \alpha^\top K \alpha$.

Le problème en dimension infinie se réduit alors à une minimisation sur $\mathbb{R}^n$:

$$\hat{\alpha}_S \in \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n l(y_i, (K\alpha)_i) + \frac{\lambda}{2} \alpha^\top K \alpha \quad (3.1.6)$$

Pour prédire sur une nouvelle observation $x \in \mathcal{X}$, il suffit d'évaluer :

$$f_{\hat{\theta}}(x) = \langle \varphi(x), \hat{\theta}_S \rangle_{\mathcal{H}} = \sum_{j=1}^n \hat{\alpha}_{S,j} \langle \varphi(x), \varphi(x_j) \rangle_{\mathcal{H}} \quad (3.1.7)$$

L'application φ n'a jamais besoin d'être explicitée : seuls les produits scalaires $\langle \varphi(x), \varphi(x') \rangle_{\mathcal{H}}$ sont requis.

3.2 Noyaux définis positifs et théorème d'Aronszajn

3.2.1 Définition et propriétés

Au lieu de définir $\mathcal{H}$ puis φ , on choisit directement une fonction $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ et on cherche à quelles conditions elle correspond à un produit scalaire hilbertien.

Définition (Noyau semi-défini positif) . Une application $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est appelée un *noyau semi-défini positif* (noyau SDP ou PDSK) si elle vérifie :

1. **Symétrie** : $\forall x, x' \in \mathcal{X}, \quad k(x, x') = k(x', x)$.
2. **Positivité** : $\forall n \geq 1, \forall (x_1, \dots, x_n) \in \mathcal{X}^n, \forall (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n$:

$$\sum_{i,j=1}^n \alpha_i \alpha_j k(x_i, x_j) \geq 0 \iff K \in \mathcal{S}_n^+(\mathbb{R}) \quad (3.2.1)$$

La matrice de Gram associée à toute famille finie est symétrique semi-définie positive.

Proposition (Tout produit scalaire définit un noyau SDP) Si $\mathcal{H}$ est un espace de Hilbert et $\varphi : \mathcal{X} \rightarrow \mathcal{H}$, alors $k(x, x') := \langle \varphi(x), \varphi(x') \rangle_{\mathcal{H}}$ est un noyau SDP.

3.2.2 Théorème d'Aronszajn et espaces de Hilbert à noyau reproduisant (RKHS)

La réciproque fondamentale affirme que tout noyau SDP cache une géométrie hilbertienne.

Théorème (Théorème d'Aronszajn) . Soit $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ un noyau symétrique semi-défini positif. Alors, il existe un unique espace de Hilbert $\mathcal{H}_k$ constitué de fonctions de $\mathcal{X}$ dans $\mathbb{R}$, et une application $\varphi_k : \mathcal{X} \rightarrow \mathcal{H}_k$, tels que :

1. $\forall x \in \mathcal{X}, \quad k_x := k(x, \cdot) \in \mathcal{H}_k$.
2. **Propriété de reproduction** : $\forall f \in \mathcal{H}_k, \forall x \in \mathcal{X}, \quad f(x) = \langle f, k_x \rangle_{\mathcal{H}_k}$.
3. $\forall x, x' \in \mathcal{X}, \quad k(x, x') = \langle k_x, k_{x'} \rangle_{\mathcal{H}_k} = \langle \varphi_k(x), \varphi_k(x') \rangle_{\mathcal{H}_k}$.

$\mathcal{H}_k$ est appelé *l'espace de Hilbert à noyau reproduisant* (RKHS) associé à k .

3.2.3 Algèbre des noyaux et théorème de Bochner

Théorème (Règles de clôture / Stabilité) . L'ensemble des noyaux SDP sur $\mathcal{X}$ est stable par :

- Multiplication par un scalaire positif : λk avec $\lambda \geq 0$.
- Somme finie : $k_1 + k_2$.
- Produit point par point : $k_1 \cdot k_2$ (via le produit de Schur et produit scalaire de Frobenius).
- Limite simple (si elle existe).
- Exponentiation : $\exp(k)$.

Théorème (Théorème de Bochner – Invariance par translation) . Soit $q : \mathbb{R}^d \rightarrow \mathbb{R}$ continue. Le noyau stationnaire $k(x, x') := q(x - x')$ est semi-défini positif si et seulement si q est la transformée de Fourier inverse d'une mesure borélienne positive finie ρ :

$$q(z) = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{iz^\top \omega} d\rho(\omega) \quad (3.2.2)$$

Exemple (Noyaux usuels) • **Noyau linéaire** : $k(x, x') = x^\top x'$ sur $\mathbb{R}^d$.

- **Noyau polynomial** : $k(x, x') = (x^\top x' + c)^q$, avec $c \geq 0, q \in \mathbb{N}^*$.
- **Noyau gaussien (RBF)** : $k(x, x') = \exp(-a\|x - x'\|_2^2)$ avec $a > 0$ (SDP par Bochner).

3.3 Séparateurs à Vaste Marge (SVM)

3.3.1 Cas linéairement séparable : Maximisation de la marge

On considère un problème de classification binaire $y_i \in \{-1, 1\}$. On cherche l'hyperplan de décision $\{\theta^\top x = 0\}$ qui sépare les données tout en maximisant la distance minimale aux points d'entraînement (la marge géométrique).

Proposition (Distance à l'hyperplan et formulation canonique) La distance d'un point x à l'hyperplan $H(\theta) = \{z \mid \theta^\top z = 0\}$ est donnée par $\text{dist}(x, H(\theta)) = \frac{|\theta^\top x|}{\|\theta\|_2}$. Sous l'hypothèse de séparabilité stricte ($y_i(\theta^\top x_i) > 0$), maximiser la marge géométrique $\min_i \frac{y_i(\theta^\top x_i)}{\|\theta\|_2}$ avec la normalisation $\min_i y_i(\theta^\top x_i) = 1$ équivaut au problème quadratique convexe :

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{2} \|\theta\|_2^2 \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, y_i(\theta^\top x_i) \geq 1 \quad (3.3.1)$$

3.3.2 Cas non séparable : Variables d'écart et perte charnière

Pour tolérer les erreurs de classement ou le chevauchement, on introduit des variables d'écart (*slack variables*) $\xi_i \geq 0$ pénalisées par $C > 0$:

$$\min_{\theta \in \mathbb{R}^d, \xi \in \mathbb{R}^n} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i \quad \text{s.c.} \quad \forall i, y_i(\theta^\top x_i) \geq 1 - \xi_i \quad \text{et} \quad \xi_i \geq 0 \quad (3.3.2)$$

Remarque (Équivalence avec la Hinge Loss) À l'optimum, $\xi_i = \max(0, 1 - y_i(\theta^\top x_i)) = (1 - y_i(\theta^\top x_i))_+$. En posant $\lambda = \frac{1}{nC}$, ce problème est rigoureusement identique à la minimisation du risque empirique régularisé pour la perte charnière (*hinge loss*) :

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n (1 - y_i(\theta^\top x_i))_+ + \frac{\lambda}{2} \|\theta\|_2^2 \quad (3.3.3)$$

3.3.3 Dualité de Wolfe et astuce du noyau (Kernel Trick)

Le problème primal étant convexe et qualifié (conditions de Slater vérifiées), la dualité forte s'applique.

Proposition (Problème dual des SVM linéaires) En introduisant les multiplicateurs de Lagrange et en annulant le gradient par rapport aux variables primales, le problème dual s'écrit :

$$\max_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j (x_i^\top x_j) \quad \text{s.c.} \quad \forall i, 0 \leq \alpha_i \leq C \quad (3.3.4)$$

Dans le problème dual, les données n'interviennent que par leurs produits scalaires $x_i^\top x_j$. En vertu du théorème d'Aronszajn et du théorème du représentant, on remplace simplement $x_i^\top x_j$ par un noyau SDP $k(x_i, x_j)$: c'est le **Kernel Trick**.

Théorème (SVM à noyau – Forme duale) . Pour tout noyau SDP k , le problème SVM régularisé dans le RKHS $\mathcal{H}_k$ se résout via le programme quadratique à contraintes de boîte :

$$\max_{\mu \in \mathbb{R}^n} \sum_{i=1}^n \mu_i - \frac{1}{2\lambda} \sum_{i,j=1}^n y_i y_j \mu_i \mu_j k(x_i, x_j) \quad \text{s.c.} \quad \forall i, 0 \leq \mu_i \leq \frac{1}{n} \quad (3.3.5)$$

Le classifieur optimal prend alors la forme explicite :

$$f(x) = \text{sign} \left(\sum_{i=1}^n \hat{\alpha}_{S,i} k(x, x_i) \right) \quad (3.3.6)$$

où seuls les points d'entraînement associés à un multiplicateur non nul ($\alpha_i > 0$, les *vecteurs de support*) interviennent dans la décision.

