

Fiches de Cours

Master IMA

Axel PIGEON

axel.pigeon@univ-tlse3.fr

Université Toulouse III – Paul Sabatier

Années universitaires 2025–2027

10 octobre 2026

Table des matières

I	Mathématiques du Machine Learning	3
1	Introduction à l’Apprentissage Supervisé	4
1.1	Des données et des prédictions	4
1.2	Formalisation mathématique	5
1.3	Risque et prédicteur de Bayes	6
1.4	Paradigmes classiques d’apprentissage	7
2	Régression Linéaire et Régression Ridge	11
2.1	Moindres Carrés	11
2.2	Analyse statistique – design fixe	12
2.3	Régression Ridge – design fixe	14
3	Méthodes à Noyaux	16
3.1	De la similarité au Théorème du Représentant	16
3.2	Noyaux définis positifs, Théorème de Bochner, et Théorème d’Aronszajn	18
3.3	Séparateurs à Vaste Marge (SVM)	22
4	Théorie de l’Apprentissage et Minimisation du Risque Empirique	25
4.1	Convexification du risque et substituts convexes	26
4.2	Décomposition du Risque et Classes Finies	27
4.3	Complexité de Rademacher	31
4.4	Théorèmes d’excès de risque pour les modèles linéaires	37

Mathématiques du Machine Learning

Chapitre 1

Introduction à l'Apprentissage Supervisé

Contents

1.1	Des données et des prédictions	4
1.2	Formalisation mathématique	5
1.2.1	Fonction de Perte	5
1.2.2	Les Risques	5
1.3	Risque et prédicteur de Bayes	6
1.3.1	Forme explicite selon la tâche	7
1.4	Paradigmes classiques d'apprentissage	7
1.4.1	Minimisation du Risque Empirique (ERM)	7
1.4.2	Méthodes probabilistes et Maximum de Vraisemblance	8
1.4.3	Méthodes par moyennage local (k -plus proches voisins)	9
1.4.4	Méthodes génératives	9
1.4.5	Théorème No Free Lunch	9

L'objectif de ce cours est de formaliser le processus d'apprentissage d'un modèle dans le cas d'un apprentissage supervisé. On commencera par définir ce qu'est ce type d'apprentissage puis ce que l'on entend par "apprendre". Différentes métriques seront introduites pour le quantifier.

1.1 Des données et des prédictions

L'ensemble du processus d'apprentissage s'appuie sur les concepts de *données* et de *prédictions*.

Définition (Observations) . Formellement, on définira les *données* d'un problème de machine learning par un ensemble de couples $(x, y) \in \mathcal{X} \times \mathcal{Y}$ que l'on appellera *données d'entraînement* ou *observations*. On notera cet ensemble D qui contiendra N couples.

Ces entrées et sorties attendues peuvent être de différents types en fonction du problème considéré. Les entrées peuvent être des images, des vidéos, du son ou un texte. On les modélisera en général par des vecteurs de $\mathbb{R}^d$ lorsque c'est possible. On appellera donc $d \in \mathbb{N}$ la dimension des données à l'entrée du modèle.

Les sorties peuvent être de deux types différents en apprentissage supervisé :

- Un ensemble d'entiers $\{1, \dots, k\}$. On parlera alors de problème de *classification*.

- Un vecteur de $\mathbb{R}^{d'}$. On parlera alors d'un problème de *régression*.

L'objectif est d'être capable, à partir d'une nouvelle donnée $x \in \mathcal{X}$ d'inférer/prédire le y qui lui correspond le mieux. Plus formellement, on cherche à *apprendre* une fonction f à partir des données d'entraînement telle que :

$$y \simeq f(x) \quad (1.1.1)$$

1.2 Formalisation mathématique

Pour apprendre une telle fonction, nous devons admettre différentes hypothèses sur le jeu de données de départ D . La première est que ce jeu de données suit une certaine loi de probabilité $\mathbb{P}$. La seconde est que chaque échantillon $(x_i, y_i), i \in \llbracket 1, N \rrbracket$ est indépendant des autres (D est un ensemble de réalisation i.i.d de la loi $\mathbb{P}$).

1.2.1 Fonction de Perte

Pour effectuer cet apprentissage, nous devons être capable de savoir à quel point notre modèle se trompe sur une prédiction donnée par rapport à la vraie valeur issue du jeu de données. Nous définissons pour cela une *fonction de perte*.

Définition (Fonction de perte) . La *fonction de perte*, notée l , calcule l'erreur induite par la prédiction de $z \in \mathcal{Y}$ alors que la valeur attendue était $y \in \mathcal{Y}$ pour une entrée $x \in \mathcal{X}$. Elle vérifie donc :

$$l : \mathcal{Y} \times \mathcal{Y} \longrightarrow \mathbb{R}. \quad (1.2.1)$$

Exemple Dans le cas d'une classification binaire (i.e $\mathcal{Y} = \{0, 1\}$), on peut simplement utiliser la *Zero/One Loss* définie par $l(y, z) = \mathbb{1}_{z \neq y}$.

Dans le cas de la régression, on utilisera plutôt les L^1 Loss ou L^2 Loss définies par :

$$l(y, z) = \|y - z\|^2, \quad \text{et} \quad l(y, z) = \|y - z\|$$

1.2.2 Les Risques

Ces différentes fonctions de pertes, aussi bien définies soient-elles, ne nous donnent d'un aperçu des erreurs du modèle en temps réel. Nous avons aussi besoin d'avoir une idée plus fine des performances du modèle vis-à-vis de la distribution de probabilité $\mathbb{P}$ du jeu de données D . On définit pour cela les *risques*.

Définition (Risque Moyen) . On définit le *risque moyen*, noté $\mathcal{R}(f)$, d'une fonction f sur l'espace $\mathcal{X} \times \mathcal{Y}$ par l'espérance de la perte de f sur ce même jeu de données.

$$\mathcal{R}(f) := \int_{\mathcal{X} \times \mathcal{Y}} l(y, f(x)) dp(x, y) dx dy = \mathbb{E}(l(y, f(x))) \quad (1.2.2)$$

où p est la densité de la probabilité $\mathbb{P}$.

Exemple Dans le cas de la classification binaire, le risque moyen se simplifie facilement :

$$\begin{aligned} \mathcal{R}(f) &= \int_{\mathcal{X} \times \mathcal{Y}} \mathbb{1}_{y \neq f(x)} d\mathbb{P}(x, y) \\ &= 0 \times \mathbb{P}(f(x) = y) + 1 \times \mathbb{P}(f(x) \neq y) \\ &= \mathbb{P}(f(x) \neq y) \end{aligned}$$

À noter que ce risque est calculé sur l'espace entier des données possibles. En pratique, si celui-ci est infini, il est incalculable. On préférera donc utiliser le *risque empirique*.

Définition (Risque Empirique) . Le risque empirique, noté $\hat{\mathcal{R}}(f)$ est donné par la moyenne empirique des pertes sur un jeu de données D .

$$\hat{\mathcal{R}}(f) := \frac{1}{N} \sum_{i=1}^N l(y_i, f(x_i)). \quad (1.2.3)$$

Proposition (Convergence) Grâce aux hypothèses précédentes, on peut invoquer des théorèmes de convergence sur les suites de variables aléatoires pour caractériser la limite de ce risque empirique. Ainsi, si $f \in L^1$, d'après la *Loi Forte des Grands Nombres*, on a que :

$$\hat{\mathcal{R}}(f) \xrightarrow[n \rightarrow \infty]{\text{P.s.}} \mathcal{R}(f). \quad (1.2.4)$$

Si, de plus $f \in L^2$, alors on a une idée de la vitesse de convergence de ce risque empirique :

$$\sqrt{n}(\hat{\mathcal{R}}(f) - \mathcal{R}(f)) \xrightarrow[n \rightarrow \infty]{\text{Loi}} \mathcal{N}(0, \mathbb{V}(l(y, f(x)))). \quad (1.2.5)$$

Remarque (Indépendance) En pratique, pour toute fonction apprise f , on aura $\hat{\mathcal{R}}(f) \simeq \mathcal{R}(f)$. Or, lorsque l'on calcule f sur des données empiriques (ex : jeu de données), on casse l'indépendance de la suite de variables aléatoires et donc le TCL. Formellement, en prenant l'estimateur :

$$\frac{1}{n} \sum_{i=1}^n l(x_i, \hat{f}(x_i)),$$

on remarque que le $\hat{f}$ est calculé à partir des $(x_1, y_1), \dots, (x_n, y_n)$. On peut solutionner ce problème en séparant le jeu de données en deux : *entraînement* et *test* (et éventuellement *validation*). Puisque le modèle ne voit pas les données de test et de validation, la fonction apprise ne dépend pas de ces données, ce qui permet de conserver l'indépendance des variables. On peut ensuite utiliser le TCL pour estimer le risque $\mathcal{R}$ à partir du risque empirique $\hat{\mathcal{R}}$.

1.3 Risque et prédicteur de Bayes

L'objectif théorique de l'apprentissage statistique est de trouver une fonction f qui minimise le risque moyen $\mathcal{R}(f)$ parmi l'ensemble $\mathcal{F}_{\text{all}}$ de toutes les fonctions mesurables de $\mathcal{X}$ dans $\mathcal{Y}$.

Définition (Prédicteur et Risque de Bayes) . On appelle *prédicteur de Bayes*, noté f^* , la fonction optimale (si elle existe) qui minimise le risque moyen sur l'espace de toutes les fonctions mesurables :

$$f^* \in \arg \min_{f \in \mathcal{F}_{\text{all}}} \mathcal{R}(f) \quad (1.3.1)$$

Le risque associé, noté $\mathcal{R}^* = \mathcal{R}(f^*)$, est appelé le *risque de Bayes* (ou erreur irréductible). Pour toute fonction mesurable f , on a trivialement :

$$\mathcal{R}(f) \geq \mathcal{R}^* \quad (1.3.2)$$

Pour calculer explicitement f^* , on utilise la loi des espérances itérées (conditionnement par rapport à X) :

$$\mathcal{R}(f) = \mathbb{E}_{(X,Y)} [l(Y, f(X))] = \mathbb{E}_X [\mathbb{E}_{Y|X} [l(Y, f(X)) | X]] \quad (1.3.3)$$

Minimiser $\mathcal{R}(f)$ revient donc à minimiser l'espérance conditionnelle point par point pour chaque $x \in \mathcal{X}$:

$$f^*(x) \in \arg \min_{z \in \mathcal{Y}} \mathbb{E}_{Y|X=x} [l(Y, z) | X = x] \quad (1.3.4)$$

1.3.1 Forme explicite selon la tâche

Proposition (Cas de la régression quadratique - L^2) Pour la perte quadratique $l(y, z) = (y - z)^2$, le prédicteur de Bayes est l'espérance conditionnelle de Y sachant X :

$$f^*(x) = \mathbb{E}[Y \mid X = x] \quad (1.3.5)$$

Démonstration Fixons $x \in \mathcal{X}$. On cherche $z \in \mathbb{R}$ minimisant $\phi(z) = \mathbb{E}[(Y - z)^2 \mid X = x]$.

$$\phi(z) = \mathbb{E}[Y^2 \mid X = x] - 2z\mathbb{E}[Y \mid X = x] + z^2$$

ϕ est une fonction convexe et dérivable en z . En annulant la dérivée :

$$\phi'(z) = -2\mathbb{E}[Y \mid X = x] + 2z = 0 \iff z = \mathbb{E}[Y \mid X = x]$$

Proposition (Cas de la classification binaire - perte 0/1) Pour $\mathcal{Y} = \{0, 1\}$ et la perte 0/1 $l(y, z) = \mathbb{1}_{y \neq z}$, le prédicteur de Bayes attribue la classe la plus probable a posteriori :

$$f^*(x) = \mathbb{1}_{\mathbb{P}(Y=1 \mid X=x) \geq 1/2} \quad (1.3.6)$$

Démonstration Pour un $x \in \mathcal{X}$ donné et pour $z \in \{0, 1\}$:

$$\begin{aligned} \mathbb{E}[\mathbb{1}_{Y \neq z} \mid X = x] &= \mathbb{P}(Y \neq z \mid X = x) \\ &= 1 - \mathbb{P}(Y = z \mid X = x) \end{aligned}$$

Minimiser cette quantité revient à maximiser $\mathbb{P}(Y = z \mid X = x)$, ce qui donne la règle du maximum a posteriori (MAP).

Pour résumer, dans le cas d'une *classification*, le prédicteur de Bayes associe la classe la plus probable selon la distribution de probabilité simulée. Dans le cas d'une *régression*, ce prédicteur retournera la moyenne de la distribution de probabilité générée sur les y_i .

1.4 Paradigmes classiques d'apprentissage

Le prédicteur de Bayes f^* étant inconnu car il dépend de la distribution $\mathbb{P}$, différentes stratégies existent pour l'approcher à partir du jeu de données $S = ((x_1, y_1), \dots, (x_n, y_n))$.

1.4.1 Minimisation du Risque Empirique (ERM)

Définition (Estimateur ERM) . On restreint la recherche à une classe paramétrique de fonctions $\mathcal{F}_\Theta = \{f_\theta : \mathcal{X} \rightarrow \mathcal{Y}, \theta \in \Theta\}$. L'estimateur par *minimisation du risque empirique* (ERM) est défini par :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \hat{\mathcal{R}}_S(f_\theta) = \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n l(y_i, f_\theta(x_i)) \quad (1.4.1)$$

Exemple (Régression linéaire et polynomiale) Pour $f_\theta(x) = \theta^\top \varphi(x)$ (où φ est un morphisme d'extraction de caractéristiques / *feature map*) et la perte quadratique L^2 , le problème s'écrit :

$$\hat{\theta}_n \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - \theta^\top \varphi(x_i))^2 \quad (1.4.2)$$

Si $\varphi(x) = (1, x, x^2, \dots, x^k)^\top$, on retrouve la régression polynomiale de degré k .

Proposition (Décomposition de l'erreur d'excès de risque) Pour tout estimateur $\hat{\theta}$, l'excès de risque par rapport au risque de Bayes se décompose canoniquement en :

$$\mathcal{R}(f_{\hat{\theta}}) - \mathcal{R}^* = \underbrace{\left(\mathcal{R}(f_{\hat{\theta}}) - \inf_{\theta \in \Theta} \mathcal{R}(f_{\theta}) \right)}_{\text{Erreur d'estimation}} + \underbrace{\left(\inf_{\theta \in \Theta} \mathcal{R}(f_{\theta}) - \mathcal{R}^* \right)}_{\text{Erreur d'approximation}} \quad (1.4.3)$$

- **Erreur d'approximation** : Déterministe et indépendante de n , elle mesure la perte due au choix de la classe restreinte Θ (diminue si la richesse de Θ augmente).
- **Erreur d'estimation** : Aléatoire (dépend de S), elle mesure le coût lié au nombre fini d'échantillons n (décroît avec n , croît avec la richesse/complexité de Θ).

Remarque (Contrôle de l'erreur d'estimation) En notant $\theta^* \in \arg \min_{\theta \in \Theta} \mathcal{R}(f_{\theta})$, on majore l'erreur d'estimation par :

$$\mathcal{R}(f_{\hat{\theta}}) - \mathcal{R}(f_{\theta^*}) \leq 2 \sup_{\theta \in \Theta} |\hat{\mathcal{R}}_S(f_{\theta}) - \mathcal{R}(f_{\theta})| + \sup_{\theta \in \Theta} (\hat{\mathcal{R}}_S(f_{\hat{\theta}}) - \hat{\mathcal{R}}_S(f_{\theta})) \quad (1.4.4)$$

Le premier terme est une déviation uniforme (objet central de la théorie de l'apprentissage statistique), et le second représente l'erreur d'optimisation numérique (nulle si le minimum empirique est calculé exactement).

La décomposition du risque comme présentée ci-dessus peut être observée sur l'apprentissage du modèle. On parlera alors de sur-apprentissage ou de sous-apprentissage en fonction de la complexité du modèle.

- **Sous-apprentissage (*Underfitting*)** : Modèle trop simple (faible complexité de Θ), dominé par l'erreur d'approximation.
- **Sur-apprentissage (*Overfitting*)** : Modèle trop expressif (par exemple interpolation polynomiale de Lagrange de degré $n-1$), l'erreur empirique est quasi-nulle mais l'erreur d'estimation explose sur les nouvelles données.

Pour contrôler ce phénomène, on introduit une pénalisation de complexité $\Omega(\theta)$:

$$\hat{\theta}_{\text{reg}} \in \arg \min_{\theta \in \Theta} \left\{ \hat{\mathcal{R}}_S(f_{\theta}) + \lambda \Omega(\theta) \right\} \quad (1.4.5)$$

où $\lambda > 0$ est un hyperparamètre calibré sur le jeu de validation (exemples : Ridge avec $\Omega(\theta) = \|\theta\|_2^2$, Lasso avec $\Omega(\theta) = \|\theta\|_1$).

1.4.2 Méthodes probabilistes et Maximum de Vraisemblance

L'idée consiste à postuler une famille paramétrique de densités conditionnelles $\{p_{\theta}(y | x) : \theta \in \Theta\}$ et à choisir le paramètre qui maximise la log-vraisemblance sur l'échantillon i.i.d :

$$\hat{\theta}_{\text{MLE}} \in \arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \ln p_{\theta}(x_i, y_i) \quad (1.4.6)$$

Exemple (Régression Logistique) Pour des labels $y \in \{-1, 1\}$, en posant la fonction sigmoïde $\sigma(z) = \frac{1}{1+e^{-z}}$, le modèle postule :

$$p_{\theta}(y | x) = \sigma(y \theta^{\top} x) = \frac{1}{1 + e^{-y \theta^{\top} x}} \quad (1.4.7)$$

Maximiser la vraisemblance revient exactement à un problème d'ERM :

$$\hat{\theta} \in \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \ln \left(1 + e^{-y_i \theta^{\top} x_i} \right) \quad (1.4.8)$$

avec la perte logistique convexe $l(y, z) = \ln(1 + e^{-yz})$.

Remarque (Pont entre Maximum de Vraisemblance et ERM) En posant $l(y, \hat{y}) = -\ln p_\theta(y | x)$, toute maximisation de vraisemblance s'interprète comme une minimisation de risque empirique :

- Bruit gaussien $\varepsilon \sim \mathcal{N}(0, \sigma^2) \implies$ Perte quadratique (moindres carrés).
- Loi de Bernoulli $\implies$ Perte logistique.

En classification, on utilise ces fonctions de perte convexes (surrogates) car minimiser directement la perte 0/1 est un problème NP-difficile et non dérivable (gradient nul presque partout).

1.4.3 Méthodes par moyennage local (k -plus proches voisins)

Ces méthodes non paramétriques exploitent une hypothèse de régularité locale : des points proches dans $\mathcal{X}$ partagent des distributions conditionnelles $\mathbb{P}_{y|x}$ similaires.

Définition (k -Nearest Neighbours – k -NN) . Pour une entrée x' , on considère l'ensemble $\mathcal{V}_k(x')$ de ses k plus proches voisins dans le jeu d'entraînement :

- **En classification** : Règle du vote majoritaire :

$$\hat{f}(x') = \arg \max_{c \in \mathcal{Y}} \sum_{i \in \mathcal{V}_k(x')} \mathbb{1}_{y_i=c} \quad (1.4.9)$$

- **En régression** : Moyenne empirique locale :

$$\hat{f}(x') = \frac{1}{k} \sum_{i \in \mathcal{V}_k(x')} y_i \quad (1.4.10)$$

Remarque (Compromis biais-variance pour k -NN) Pour k -NN, l'axe de complexité est inversé :

- k petit (ex. $k = 1$) $\implies$ Modèle très flexible, risque de sur-apprentissage (faible approximation, forte estimation).
- k grand $\implies$ Modèle rigide/lissé, risque de sous-apprentissage (forte approximation, faible estimation).

1.4.4 Méthodes génératives

Au lieu de modéliser directement $f(x)$ ou $\mathbb{P}(Y | X)$, les modèles génératifs estiment la loi conjointe en modélisant :

1. La loi a priori des classes $p(y)$.
2. Les densités conditionnelles de chaque classe $p(x | y)$.

On en déduit ensuite la loi a posteriori par la règle de Bayes :

$$p(y | x) = \frac{p(x | y)p(y)}{\sum_c p(x | y=c)p(y=c)} \propto p(x | y)p(y) \quad (1.4.11)$$

La règle de décision optimale est donnée par le maximum a posteriori (MAP) : $\hat{f}(x') = \arg \max_{\hat{y}} p(x' | \hat{y})p(\hat{y})$.

1.4.5 Théorème No Free Lunch

Il n'existe pas d'algorithme d'apprentissage universel optimal sur toutes les distributions possibles sans hypothèse préalable sur les données.

Théorème (No Free Lunch - Devroye, Györfi, Lugosi) . Soit le problème de classification binaire avec la perte 0/1 et $\mathcal{X}$ un ensemble infini. Soit $\mathcal{P}$ l'ensemble de toutes les lois de probabilité sur $\mathcal{X} \times \{0, 1\}$. Pour tout entier n et tout algorithme d'apprentissage $\mathcal{A}$, on a :

$$\sup_{\mathbb{P} \in \mathcal{P}} \{\mathbb{E}_{S \sim \mathbb{P}^{\otimes n}} [\mathcal{R}_{\mathbb{P}}(\mathcal{A}(S))] - \mathcal{R}_{\mathbb{P}}^*\} \geq \frac{1}{2} \quad (1.4.12)$$

Ce résultat implique que pour n'importe quel algorithme fixé, il existe une distribution sous-jacente défavorable pour laquelle l'algorithme ne fait pas mieux qu'un choix aléatoire (même si le risque de Bayes $\mathcal{R}^* = 0$). Il est donc mathématiquement indispensable de poser des hypothèses régularité, marge, séparabilité ou compacité pour garantir des résultats d'apprentissage.

Chapitre 2

Régression Linéaire et Régression Ridge

Contents

2.1	Moindres Carrés	11
2.2	Analyse statistique – design fixe	12
2.3	Régression Ridge – design fixe	14

On pose ici le contexte d'une *régression linéaire*. On cherche donc à apprendre une fonction pour décrire un jeu de données $(x_1, y_1), \dots, (x_n, y_n) \in \mathcal{X} \times \mathcal{Y}$. Dans le cas du modèle linéaire, on fera l'hypothèse forte suivante :

$$(H) : f_\theta = \varphi(x)^t \theta, \quad \theta \in \mathbb{R}^d. \quad (2.0.1)$$

Pour construire cette fonction, on utilisera l'estimateur du risque empirique (ERM) défini par :

$$\hat{R}(\theta) \in \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n (y_i - f_\theta(x_i))^2. \quad (2.0.2)$$

Exemple La forme de l'application φ caractérisera la *feature map* (i.e l'ensemble des fonctions possibles pour interpoler le nuage de points).

- si $\varphi(x) = x$, alors on aura une estimation linéaire en x ,
- si $\varphi(x) = \begin{pmatrix} x \\ 1 \end{pmatrix}$ alors l'estimation sera *affine* en x ,
- si $\varphi(x) \in \mathbb{R}^d[x]$, alors l'estimation sera *polynomiale* en x . On pourra aller jusqu'au degré d pour utiliser des polynômes de Lagrange.

Notation On notera $y = \begin{pmatrix} y_1 \\ \dots \\ y_n \end{pmatrix}$ le vecteur des étiquettes du jeu de données et $\Phi = \begin{pmatrix} \varphi(x_1)^t \\ \dots \\ \varphi(x_n)^t \end{pmatrix} \in$

$\mathbb{R}^{n \times d}$ la matrice contenant toutes les prédictions données par la *feature map*. On aura donc : $\hat{R}(\theta) = \frac{1}{n} \|y - \Phi\theta\|_2^2$.

2.1 Moindres Carrés

Nous sommes en présence d'un problème de régression. Grâce aux notations matricielles précédemment posées, nous sommes capable de calculer une solution explicite à la main.

On cherche à calculer explicitement $\hat{\theta} \in \arg \min_{\theta \in \mathbb{R}^d} \hat{R}(\theta)$. Pour cela, on utilise la condition nécessaire d'optimalité d'ordre 1 : $\nabla_{\theta} \hat{R}(\hat{\theta}) = 0$. Commençons donc par calculer le gradient :

$$\hat{R}(\theta) = \frac{1}{n} \|y - \Phi\theta\|_2^2 \quad (2.1.1)$$

$$\nabla_{\theta} \hat{R}(\theta) = \frac{2}{n} \Phi^{\top} (\Phi\theta - y) \quad (2.1.2)$$

En résolvant l'équation $\nabla_{\theta} \hat{R}(\hat{\theta}) = 0$, on obtient les *équations normales* :

$$(*) : \Phi^{\top} \Phi \hat{\theta} = \Phi^{\top} y \quad (2.1.3)$$

En supposant que Φ est de rang plein ($rg(\Phi) = d$, soit des colonnes linéairement indépendantes), la matrice de Gram $\Phi^{\top} \Phi \in \mathbb{R}^{d \times d}$ est inversible, ce qui donne :

$$(*) \iff \boxed{\hat{\theta} = (\Phi^{\top} \Phi)^{-1} \Phi^{\top} y} \quad (2.1.4)$$

La fonction $\hat{R}$ étant convexe, ce point stationnaire est un minimum global. On calcule ainsi explicitement l'estimateur des moindres carrés (OLS), qui fournit le prédicteur linéaire optimal sur l'échantillon d'entraînement.

Proposition Géométriquement, les prédictions $\hat{y} = \Phi \hat{\theta}$ correspondent à la projection orthogonale du vecteur d'observations $y \in \mathbb{R}^n$ sur le sous-espace vectoriel $\text{Im}(\Phi) \subset \mathbb{R}^n$ engendré par les colonnes de Φ :

$$\hat{\theta} \in \arg \min_{\theta \in \mathbb{R}^d} \frac{1}{n} \|y - \Phi\theta\|_2^2 \iff \hat{y} \in \arg \min_{z \in \text{Im}(\Phi)} \frac{1}{n} \|y - z\|_2^2 \quad (2.1.5)$$




FIGURE 2.1 – Projection orthogonale du vecteur d'observations y sur le sous-espace affine $\text{Im}(\phi)$ et décomposition de l'erreur résiduelle $y - \hat{y} \perp \text{Im}(\phi)$.

2.2 Analyse statistique – design fixe

Dans cette section, on se place sous l'hypothèse du *design fixe* : les points $x_i \in \mathcal{X}$ (et donc la matrice $\Phi \in \mathbb{R}^{n \times d}$) sont déterministes et fixés. Seules les étiquettes y_i sont aléatoires.

Définition (Modèle à design fixe) . Le modèle probabiliste d'observation s'écrit :

1. $y = \Phi\theta_* + \varepsilon$, avec $\theta_* \in \mathbb{R}^d$ le paramètre vrai inconnu.
2. Le vecteur de bruit $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n)^\top \in \mathbb{R}^n$ vérifie $\mathbb{E}(\varepsilon) = 0$ et $\text{Var}(\varepsilon) = \mathbb{E}(\varepsilon\varepsilon^\top) = \sigma^2 I_n$.

Le risque moyen sous design fixe est défini par :

$$R(\theta) = \frac{1}{n} \mathbb{E}_y \left[\|y - \Phi\theta\|_2^2 \right]. \quad (2.2.1)$$

On introduit la matrice de covariance empirique $\hat{\Sigma} := \frac{1}{n} \Phi^\top \Phi \in \mathbb{R}^{d \times d}$, associée à la semi-norme $\|u\|_{\hat{\Sigma}}^2 := u^\top \hat{\Sigma} u = \frac{1}{n} \|\Phi u\|_2^2$.

Proposition (Décomposition Biais-Variance) Pour tout vecteur fixe $\theta \in \mathbb{R}^d$:

$$\begin{aligned} R(\theta) &= \frac{1}{n} \mathbb{E}_\varepsilon \left[\|\Phi(\theta_* - \theta) + \varepsilon\|_2^2 \right] \\ &= \frac{1}{n} \|\Phi(\theta_* - \theta)\|_2^2 + \frac{1}{n} \mathbb{E} \left[\|\varepsilon\|_2^2 \right] + \frac{2}{n} (\theta_* - \theta)^\top \Phi^\top \mathbb{E}[\varepsilon] \\ &= \|\theta - \theta_*\|_{\hat{\Sigma}}^2 + \sigma^2. \end{aligned}$$

Le risque de Bayes est atteint en θ_* : $R^* = R(\theta_*) = \sigma^2$. Par conséquent, pour un estimateur aléatoire $\hat{\theta}$ dépendant de y (donc de ε) :

$$\mathbb{E}_{\hat{\theta}} \left[R(\hat{\theta}) \right] - R^* = \underbrace{\left\| \mathbb{E}(\hat{\theta}) - \theta_* \right\|_{\hat{\Sigma}}^2}_{\text{Biais}^2} + \underbrace{\mathbb{E}_{\hat{\theta}} \left[\left\| \hat{\theta} - \mathbb{E}(\hat{\theta}) \right\|_{\hat{\Sigma}}^2 \right]}_{\text{Variance}} \quad (2.2.2)$$

Théorème (Biais et Variance des Moindres Carrés) . Dans le cas de l'estimateur des moindres carrés $\hat{\theta} = (\Phi^\top \Phi)^{-1} \Phi^\top y$:

$$\text{Biais}^2 = 0 \quad \text{et} \quad \mathbb{E} \left[R(\hat{\theta}) \right] - R^* = \frac{\sigma^2 d}{n}. \quad (2.2.3)$$

Démonstration • *Calcul du biais* :

$$\begin{aligned} \mathbb{E}(\hat{\theta}) &= \mathbb{E} \left[(\Phi^\top \Phi)^{-1} \Phi^\top (\Phi\theta_* + \varepsilon) \right] \\ &= \theta_* + (\Phi^\top \Phi)^{-1} \Phi^\top \mathbb{E}[\varepsilon] = \theta_*. \end{aligned}$$

L'estimateur est sans biais, d'où $\text{Biais}^2 = 0$.

- *Calcul de la variance* : On exprime la variance sous forme de trace :

$$\begin{aligned} \text{Variance} &= \mathbb{E} \left[(\hat{\theta} - \theta_*)^\top \hat{\Sigma} (\hat{\theta} - \theta_*) \right] \\ &= \mathbb{E} \left[\text{tr} \left(\hat{\Sigma} (\hat{\theta} - \theta_*) (\hat{\theta} - \theta_*)^\top \right) \right] \\ &= \text{tr} \left(\hat{\Sigma} \mathbb{E} \left[(\hat{\theta} - \theta_*) (\hat{\theta} - \theta_*)^\top \right] \right). \end{aligned}$$

Or, $\hat{\theta} - \theta_* = (\Phi^\top \Phi)^{-1} \Phi^\top \varepsilon$, donc :

$$\begin{aligned} \mathbb{E} \left[(\hat{\theta} - \theta_*)(\hat{\theta} - \theta_*)^\top \right] &= (\Phi^\top \Phi)^{-1} \Phi^\top \mathbb{E}[\varepsilon \varepsilon^\top] \Phi (\Phi^\top \Phi)^{-1} \\ &= \sigma^2 (\Phi^\top \Phi)^{-1} \Phi^\top I_n \Phi (\Phi^\top \Phi)^{-1} \\ &= \sigma^2 (\Phi^\top \Phi)^{-1} = \frac{\sigma^2}{n} \hat{\Sigma}^{-1}. \end{aligned}$$

En réinjectant dans l'expression de la trace :

$$\text{Variance} = \text{tr} \left(\hat{\Sigma} \cdot \frac{\sigma^2}{n} \hat{\Sigma}^{-1} \right) = \frac{\sigma^2}{n} \text{tr}(I_d) = \frac{\sigma^2 d}{n}.$$

2.3 Régression Ridge – design fixe

Dans le modèle linéaire usuel, l'erreur de variance vaut $\frac{\sigma^2 d}{n}$. Lorsque les covariables sont fortement corrélées (multicolinéarité), la matrice $\hat{\Sigma}$ possède des valeurs propres très proches de 0, ce qui rend $(\Phi^\top \Phi)^{-1}$ instable et fait exploser la norme du paramètre appris.

La régression Ridge (pénalisation de Tikhonov / régularisation L^2) remédie à ce problème en contractant les coefficients vers zéro via une pénalisation quadratique. On accepte d'introduire un léger biais en échange d'une réduction drastique de la variance.

Définition (Estimateur Ridge) . Pour un paramètre de régularisation $\lambda > 0$, l'estimateur Ridge est défini par :

$$\hat{\theta}_\lambda \in \arg \min_{\theta \in \mathbb{R}^d} \frac{1}{n} \|y - \Phi \theta\|_2^2 + \lambda \|\theta\|_2^2. \quad (2.3.1)$$

En annulant le gradient, la solution explicite est unique et donnée par :

$$\hat{\theta}_\lambda = \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \frac{1}{n} \Phi^\top y = \left(\Phi^\top \Phi + n \lambda I_d \right)^{-1} \Phi^\top y \quad (2.3.2)$$

où $\hat{\Sigma} = \frac{1}{n} \Phi^\top \Phi$. La matrice $\hat{\Sigma} + \lambda I_d$ est symétrique définie positive pour tout $\lambda > 0$, donc inversible même si $\Phi^\top \Phi$ ne l'est pas.

Proposition (Décomposition Biais-Variance de Ridge) Sous le modèle à design fixe $y = \Phi \theta_* + \varepsilon$:

- *Biais* : L'espérance de l'estimateur vaut $\mathbb{E}(\hat{\theta}_\lambda) = (\hat{\Sigma} + \lambda I_d)^{-1} \hat{\Sigma} \theta_*$. Le terme de biais s'écrit donc :

$$\text{Biais}^2 = \left\| \mathbb{E}(\hat{\theta}_\lambda) - \theta_* \right\|_{\hat{\Sigma}}^2 = \lambda^2 \theta_*^\top \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \hat{\Sigma} \left(\hat{\Sigma} + \lambda I_d \right)^{-1} \theta_*. \quad (2.3.3)$$

- *Variance* : En utilisant $\text{Var}(\hat{\theta}_\lambda) = \frac{\sigma^2}{n} (\hat{\Sigma} + \lambda I_d)^{-1} \hat{\Sigma} (\hat{\Sigma} + \lambda I_d)^{-1}$, on obtient :

$$\text{Variance} = \frac{\sigma^2}{n} \text{tr} \left(\hat{\Sigma}^2 \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \right). \quad (2.3.4)$$

Le risque d'excès s'écrit donc :

$$\mathbb{E} \left[R(\hat{\theta}_\lambda) \right] - R^* = \lambda^2 \theta_*^\top \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \hat{\Sigma} \theta_* + \frac{\sigma^2}{n} \text{tr} \left(\hat{\Sigma}^2 \left(\hat{\Sigma} + \lambda I_d \right)^{-2} \right). \quad (2.3.5)$$

Remarque (Degrés de liberté effectifs) La quantité $df(\lambda) = \text{tr} \left(\hat{\Sigma}(\hat{\Sigma} + \lambda I_d)^{-1} \right) = \sum_{j=1}^d \frac{\mu_j}{\mu_j + \lambda}$ mesure les *degrés de liberté effectifs* du modèle. Pour $\lambda = 0$, on retrouve $df(0) = d$ et la variance des moindres carrés $\frac{\sigma^2 d}{n}$. Lorsque $\lambda \rightarrow \infty$, $df(\lambda) \rightarrow 0$.

Proposition (Contrôle spectral et borne d'erreur) Soit $\hat{\Sigma} = U \text{diag}(\mu_1, \dots, \mu_d) U^\top$ la décomposition spectrale de $\hat{\Sigma}$ (avec $\mu_j \geq 0$).

- Pour le biais : pour tout $\mu \geq 0$ et $\lambda > 0$, on a $\frac{\lambda^2 \mu}{(\mu + \lambda)^2} \leq \frac{\lambda}{4}$ (car $(\mu + \lambda)^2 \geq 4\lambda\mu$), d'où :

$$\text{Biais}^2 \leq \frac{\lambda}{4} \|\theta_*\|_2^2. \quad (2.3.6)$$

- Pour la variance : comme $\frac{\mu_j^2}{(\mu_j + \lambda)^2} \leq \frac{\mu_j}{\lambda}$, on a :

$$\text{Variance} \leq \frac{\sigma^2}{n\lambda} \text{tr}(\hat{\Sigma}). \quad (2.3.7)$$

En équilibrant les deux bornes avec le choix optimal $\lambda^* \propto \frac{\sigma}{\sqrt{n}}$, on garantit une vitesse de convergence de l'excès de risque en $\mathcal{O}(1/\sqrt{n})$, indépendante du plus petit spectre de $\hat{\Sigma}$.

Chapitre 3

Méthodes à Noyaux

Contents

3.1 De la similarité au Théorème du Représentant	16
3.1.1 Intuition géométrique et plongement	16
3.1.2 Le Théorème du Représentant	17
3.2 Noyaux définis positifs, Théorème de Bochner, et Théorème d'Aronszajn	18
3.2.1 Noyau SDP : Définition et propriétés	18
3.2.2 Construire des noyaux SDP : Théorème de Bochner	19
3.2.3 Théorème d'Aronszajn	20
3.3 Séparateurs à Vaste Marge (SVM)	22
3.3.1 Cas linéairement séparable : Maximisation de la marge	22
3.3.2 Cas non séparable : Variables d'écart et perte charnière	22
3.3.3 Dualité de Wolfe et formulation duale	23
3.3.4 Le Kernel SVM (SVM à noyau)	23

L'objectif des méthodes à noyaux est de transformer une mesure heuristique de similarité entre données en un algorithme d'apprentissage non linéaire. En s'appuyant implicitement sur un espace de Hilbert de dimension arbitraire (potentiellement infinie), on conserve toute la simplicité de l'optimisation linéaire tout en évitant d'avoir à calculer explicitement les plongements.

3.1 De la similarité au Théorème du Représentant

3.1.1 Intuition géométrique et plongement

La plupart des jeux de données ne sont pas linéairement séparables dans leur espace d'entrée d'origine $\mathcal{X}$. L'idée fondamentale consiste à envoyer les données dans un espace de caractéristiques de plus grande dimension (un espace de Hilbert $\mathcal{H}$) via une *feature map* :

$$\varphi : \mathcal{X} \longrightarrow \mathcal{H} \quad (3.1.1)$$

Dans $\mathcal{H}$, un hyperplan linéaire peut alors séparer des classes qui formaient des régions géométriques complexes ou intriquées dans $\mathcal{X}$. On formule alors le problème sous la forme d'une minimisation de risque empirique régularisé sur la totalité de l'espace hilbertien $\mathcal{H}$:

$$\hat{\theta}_S \in \arg \min_{\theta \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n l(y_i, \langle \varphi(x_i), \theta \rangle_{\mathcal{H}}) + \frac{\lambda}{2} \|\theta\|_{\mathcal{H}}^2 \quad (3.1.2)$$

où $\lambda > 0$ contrôle la régularisation.

Remarque (Obstruction numérique) Si $\mathcal{H}$ est de dimension infinie, on ne peut ni représenter le vecteur de paramètres $\theta \in \mathcal{H}$, ni évaluer explicitement $\varphi(x)$ par descente de gradient standard. Le théorème suivant résout ce paradoxe.

3.1.2 Le Théorème du Représentant

Théorème (Théorème du Représentant) . Soit $\mathcal{X}$ un ensemble, $\mathcal{H}$ un espace de Hilbert réel muni du produit scalaire $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ et $\varphi : \mathcal{X} \rightarrow \mathcal{H}$. Soit un échantillon $S = (x_1, \dots, x_n)$ et le sous-espace engendré par les observations :

$$\mathcal{H}_D := \text{vect}\{\varphi(x_1), \dots, \varphi(x_n)\} \subset \mathcal{H} \quad (3.1.3)$$

Soit $\Psi : \mathbb{R}^n \times \mathbb{R}_+ \rightarrow \mathbb{R}$ une fonction croissante par rapport à son second argument. En notant $u(\theta) = (\langle \varphi(x_1), \theta \rangle_{\mathcal{H}}, \dots, \langle \varphi(x_n), \theta \rangle_{\mathcal{H}})^\top \in \mathbb{R}^n$, on a :

$$\inf_{\theta \in \mathcal{H}} \Psi(u(\theta), \|\theta\|_{\mathcal{H}}^2) = \inf_{\theta \in \mathcal{H}_D} \Psi(u(\theta), \|\theta\|_{\mathcal{H}}^2) \quad (3.1.4)$$

Si l'infimum est atteint, il l'est en un point $\hat{\theta}_S \in \mathcal{H}_D$. De plus, si Ψ est *strictement croissante* par rapport à son second argument, tout minimiseur appartient nécessairement à $\mathcal{H}_D$.

Grâce à ce théorème, on cherche donc $\hat{\theta}_S \in \mathcal{H}_D$ de dimension finie. Puisque l'on en connaît une famille génératrice, on cherche donc :

$$\alpha = (\alpha_1, \dots, \alpha_n)^\top \in \mathbb{R}^n, \quad \text{tels que} \quad \hat{\theta}_S = \sum_{i=1}^n \alpha_i \varphi(x_i).$$

Ainsi, la dimension du problème d'optimisation ne dépend plus de celle de $\mathcal{H}$ mais seulement du nombre de d'échantillons n . Déterminons maintenant comment trouver ce $\hat{\alpha}_S$.

Proposition (Kernel Trick) Remplaçons θ par sa nouvelle expression dans le problème de départ 3.1.2 :

- La norme devient :

$$\begin{aligned} \|\theta\|_{\mathcal{H}}^2 &= \left\langle \sum_{i=1}^n \alpha_i \varphi(x_i), \sum_{j=1}^n \alpha_j \varphi(x_j) \right\rangle_{\mathcal{H}} = \sum_{i,j=1}^n \alpha_i \alpha_j \langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}} \\ &= \sum_{i,j=1}^n \alpha_i \alpha_j K_{i,j} \quad \text{avec} \quad K = (\langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}})_{i,j} \end{aligned}$$

- Les prédictions deviennent :

$$\langle \varphi(x_i), \theta \rangle_{\mathcal{H}} = \sum_{j=1}^n \alpha_j \langle \varphi(x_i), \varphi(x_j) \rangle_{\mathcal{H}} = (K\alpha)_i$$

On a donc le problème réécrit suivant :

$$\hat{\alpha}_S \in \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n l(y_i, (K\alpha)_i) + \frac{\lambda}{2} \alpha^\top K \alpha. \quad (3.1.5)$$

On remarque que l'on a plus besoin de calculer explicitement φ ni f : tout dépend de ce que l'on appellera le *noyau* K . Notons ici $K = (k(x_i, x_j))_{i,j}$ tel que $k(x, x_j) = \langle \varphi(x), \varphi(x_j) \rangle_{\mathcal{H}}$. Ainsi, pour l'entraînement nous n'avons besoin que de la matrice de Gram K de taille $n \times n$. Pour l'inférence sur un x donné, nous notons $k_x = (k(x, x_1), \dots, k(x, x_n)) \in \mathbb{R}^n$ tel que $f_{\hat{\theta}_S} = \hat{\alpha}_S^\top k_x$.

On peut maintenant remarquer que la *feature map* φ n'est jamais calculée et que les prédictions en x utilisent seulement les n valeurs $\langle \varphi(x), \varphi(x_i) \rangle_{\mathcal{H}}$. Ainsi, au lieu de définir un espace $\mathcal{H}$ dans lequel nous ne pouvons faire aucun calcul, on pourrait directement choisir k telle que $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ de la forme $k(x, x') = \langle \varphi(x), \varphi(x') \rangle$. C'est le sujet de la section suivante qui définit les *noyaux* et introduit la théorie nécessaire dessus.

3.2 Noyaux définis positifs, Théorème de Bochner, et Théorème d'Aronszajn

Dans la partie précédente, nous avons reformulé le problème de minimisation du risque empirique à l'aide d'un plongement dans un espace de Hilbert $\mathcal{H}$. Nous avons ensuite remarqué que tous les calculs dans cet espace dépendent en réalité d'une *fonction de similitude* encodée dans un *noyau* K .

Or, en pratique, on raisonne dans le sens inverse : à partir du jeu de données, on définit un noyau K et on souhaite savoir si l'on peut effectivement utiliser ce noyau pour notre minimisation. C'est le théorème d'Aronszajn qui nous l'assure. Mais avant de l'aborder, définissons formellement la notion de noyau ainsi que ses propriétés.

3.2.1 Noyau SDP : Définition et propriétés

Au lieu de définir $\mathcal{H}$ puis φ , on choisit directement une fonction $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ et on cherche à quelles conditions elle correspond à un produit scalaire hilbertien (i.e un noyau semi-défini positif).

Définition (Noyau semi-défini positif) . Une application $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ est appelée un *noyau semi-défini positif* (noyau SDP ou PSDK) si elle vérifie :

1. **Symétrie** : $\forall x, x' \in \mathcal{X}, \quad k(x, x') = k(x', x)$.
2. **Positivité** : $\forall n \geq 1, \forall (x_1, \dots, x_n) \in \mathcal{X}^n, \forall (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n :$

$$\sum_{i,j=1}^n \alpha_i \alpha_j k(x_i, x_j) \geq 0 \iff K \in \mathcal{S}_n^+(\mathbb{R}) \quad (3.2.1)$$

Propriété (Caractérisation par matrice de Gram) . La matrice de Gram $G = (\langle u_i, u_j \rangle)_{i,j}$ associée à toute famille finie $(u_1, \dots, u_n)$ est symétrique semi-définie positive.

Proposition (Tout produit scalaire définit un noyau SDP) Si $\mathcal{H}$ est un espace de Hilbert et $\varphi : \mathcal{X} \rightarrow \mathcal{H}$, alors $k(x, x') := \langle \varphi(x), \varphi(x') \rangle_{\mathcal{H}}$ est un noyau SDP.

Exemple Voici quelques exemples de noyaux SDP :

- Noyau *linéaire* : $k(x, x') = x^\top x'$ sur $\mathcal{X} = \mathbb{R}^d$.
- Noyau *polynomial* : $k(x, x') = (x^\top x')^q$ pour $q \in \mathbb{N}^*$.
- Noyau *exponentiel* : $k(x, x') = \exp(-a\|x - x'\|_2^2)$ pour $a > 0$.

Les noyaux SDP peuvent être construit par opérations. Le théorème suivant détaille les opérations possibles entre noyaux SDP.

Théorème (Opérations) . L'ensemble des noyaux semi-définis positifs sur un espace $\mathcal{X}$ est stable par :

- multiplication scalaire par un coefficient positif ou nul,
- somme finie,
- produits,
- limite ponctuelle quand elle existe,
- conjugaison par une fonction.

Grâce à ce théorème, nous pouvons montrer que beaucoup d'application k sont des noyaux. Voyons-en quelques unes.

Proposition Soit $q \geq 1$ un entier, alors $(x, x') \mapsto (x^\top x')^q$ et $(x, x') \mapsto (1 + x^\top x')^q$ sont des noyaux SDP.

Démonstration Pour le premier, $(x, x') \mapsto x^\top x'$ est un produit scalaire donc c'est un noyau. À la puissance q , c'est une multiplication finie. C'est donc un noyau par induction sur q . Pour le second, on identifie $1 + x^\top x' = k(x, x') + x^\top x'$ avec $k(x, x') = 1$. Puisque $\sum_{i,j} \alpha_i \alpha_j = (\sum_i \alpha_i)^2 \geq 0$, alors c'est un noyau. Par somme et d'après le résultat précédent, $(x, x') \mapsto (1 + x^\top x')^q$ est aussi un noyau SDP.

Proposition Soit k un noyau SDP, alors $\exp(k) : (x, x') \mapsto \exp(k(x, x'))$ est un noyau SDP.

Démonstration Si k est un noyau alors, $\forall x, x' \in \mathcal{X}$, on a :

$$\exp(k(x, x')) = \sum_{n=0}^{\infty} \frac{k(x, x')^n}{n!}.$$

Or, pour tout $n \geq 0$, $\frac{k(x, x')^n}{n!}$ est un noyau par produit fini et multiplication par un scalaire positif. Par somme, $\sum_{i=1}^n \frac{k(x, x')^i}{i!}$ en est un aussi. Enfin, par définition de l'exponentielle, $\exp a$ converge pour tout $a \in \mathbb{R}$, donc par limite de noyaux SDP, $\exp(k)$ est aussi un noyau SDP.

3.2.2 Construire des noyaux SDP : Théorème de Bochner

Montrer qu'un noyau est SDP est simple lorsqu'il dérive de produits scalaires combinés algébriquement. En revanche, si l'on cherche à mesurer la proximité géométrique locale entre deux observations, le calcul direct devient inextricable. Par exemple, pour le noyau gaussien $k(x, x') = \exp(-a\|x - x'\|_2^2)$, vérifier point par point que :

$$\forall n \geq 1, \quad \forall (x_1, \dots, x_n) \in (\mathbb{R}^d)^n, \quad \forall (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n, \quad \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j \exp(-a\|x_i - x_j\|_2^2) \geq 0$$

est difficile sans outil analytique. Le théorème de Bochner permet de lever ce verrou en transposant la question de l'espace spatial à l'espace fréquentiel via la transformée de Fourier.

Théorème (Théorème de Bochner – Invariance par translation) . Soit $q : \mathbb{R}^d \rightarrow \mathbb{R}$ continue. Le noyau stationnaire $k(x, x') := q(x - x')$ est semi-défini positif si et seulement si q est la transformée de Fourier inverse d'une mesure borélienne positive finie ρ sur $\mathbb{R}^d$:

$$q(z) = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{iz^\top \omega} d\rho(\omega). \quad (3.2.2)$$

Démonstration (Preuve de la condition suffisante) Supposons que q s'écrive sous forme d'intégrale de Fourier par rapport à une mesure positive finie ρ . Pour toute famille $(x_1, \dots, x_n)$ et tout vecteur $\alpha \in \mathbb{R}^n$:

$$\begin{aligned}
\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j q(x_i - x_j) &= \sum_{i,j=1}^n \alpha_i \alpha_j \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{i(x_i - x_j)^\top \omega} d\rho(\omega) \\
&= \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \sum_{i=1}^n \alpha_i e^{ix_i^\top \omega} \sum_{j=1}^n \alpha_j e^{-ix_j^\top \omega} d\rho(\omega) \\
&= \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \left(\sum_{i=1}^n \alpha_i e^{ix_i^\top \omega} \right) \overline{\left(\sum_{j=1}^n \alpha_j e^{ix_j^\top \omega} \right)} d\rho(\omega) \\
&= \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \underbrace{\left| \sum_{i=1}^n \alpha_i e^{ix_i^\top \omega} \right|^2}_{\geq 0} \underbrace{d\rho(\omega)}_{\geq 0} \geq 0.
\end{aligned}$$

La fonction q étant paire dès lors que la mesure est symétrique ($\rho(-\omega) = \rho(\omega)$), le noyau est bien symétrique et semi-défini positif.

Exemple (Cas du noyau Gaussien / RBF) Pour $a > 0$ et $z \in \mathbb{R}^d$, la fonction gaussienne $q(z) = \exp(-a\|z\|_2^2)$ admet pour transformée de Fourier inverse :

$$e^{-a\|z\|_2^2} = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} e^{iz^\top \omega} \left(\frac{\pi}{a}\right)^{d/2} e^{-\frac{\|\omega\|_2^2}{4a}} d\omega.$$

La mesure $d\rho(\omega) = (\pi/a)^{d/2} e^{-\|\omega\|_2^2/(4a)} d\omega$ est une mesure gaussienne positive, finie et invariante par $\omega \mapsto -\omega$. Le théorème de Bochner garantit immédiatement que le noyau gaussien est semi-défini positif.

3.2.3 Théorème d'Aronszajn

Reprenons le raisonnement de ce chapitre. Le théorème du représentant nous a montré que pour notre problème d'optimisation, si on a un espace de Hilbert $\mathcal{H}$ et une application φ , il nous suffit seulement de calculer des produits scalaires $k(x, x') = \langle \varphi(x), \varphi(x') \rangle_{\mathcal{H}}$.

Ensuite, nous avons développé une théorie sur les noyaux SDP pour les construire facilement. Le théorème de Bochner nous permet d'en construire autant que l'on souhaite à partir de mesures positives finies.

Or, nous ne sommes pas assurés que pour un tel noyau construit spécifiquement pour nos données, il existe un espace $\mathcal{H}$ et un plongement φ qui convienne. C'est ici que le théorème d'Aronszajn intervient : il nous assure que tout noyau SDP est le produit scalaire d'un espace unique de fonctions appelé RKHS.

Théorème (Théorème d'Aronszajn) . Soit $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ un noyau symétrique semi-défini positif. Alors, il existe un unique espace de Hilbert $\mathcal{H}_k$ constitué de fonctions de $\mathcal{X}$ dans $\mathbb{R}$, et une application canonique $\varphi_k : \mathcal{X} \rightarrow \mathcal{H}_k$, tels que :

1. Pour tout $x \in \mathcal{X}$, la fonction $k_x := k(x, \cdot)$ appartient à $\mathcal{H}_k$.
2. **Propriété de reproduction** : pour toute fonction $f \in \mathcal{H}_k$ et tout $x \in \mathcal{X}$,

$$f(x) = \langle f, k_x \rangle_{\mathcal{H}_k}. \quad (3.2.3)$$

3. Pour tous $x, x' \in \mathcal{X}$:

$$k(x, x') = \langle k_x, k_{x'} \rangle_{\mathcal{H}_k} = \langle \varphi_k(x), \varphi_k(x') \rangle_{\mathcal{H}_k} \quad \text{en posant } \varphi_k(x) = k_x. \quad (3.2.4)$$

L'espace $\mathcal{H}_k$ est appelé l'*espace de Hilbert à noyau reproduisant* (RKHS) associé à k .

Démonstration (Esquisse de preuve) La construction s'effectue en trois étapes principales :

1. **Espace pré-hilbertien** : on pose $\mathcal{H}_0 = \text{vect}\{k_x \mid x \in \mathcal{X}\}$. Pour deux combinaisons linéaires $f = \sum_{i=1}^m a_i k_{x_i}$ et $g = \sum_{j=1}^{m'} b_j k_{z_j}$, on munit $\mathcal{H}_0$ de la forme bilinéaire :

$$\langle f, g \rangle_{\mathcal{H}_0} := \sum_{i=1}^m \sum_{j=1}^{m'} a_i b_j k(x_i, z_j).$$

La symétrie et la positivité de k assurent que cette forme est symétrique et positive. De plus, par définition, $\langle f, k_x \rangle_{\mathcal{H}_0} = \sum_{i=1}^m a_i k(x_i, x) = f(x)$.

2. **Caractère défini** : d'après l'inégalité de Cauchy-Schwarz appliquée à cette forme semi-définie positive, pour tout $x \in \mathcal{X}$:

$$|f(x)| = |\langle f, k_x \rangle_{\mathcal{H}_0}| \leq \|f\|_{\mathcal{H}_0} \sqrt{k(x, x)}.$$

Ainsi, $\|f\|_{\mathcal{H}_0} = 0 \implies \forall x \in \mathcal{X}, f(x) = 0$, donc f est identiquement nulle. L'espace $\mathcal{H}_0$ est donc un espace pré-hilbertien séparé.

3. **Complétion fonctionnelle** : on complète $\mathcal{H}_0$ en un espace de Hilbert $\mathcal{H}_k$. Grâce à la majoration ponctuelle issue de Cauchy-Schwarz, toute suite de Cauchy converge ponctuellement vers une fonction bien définie sur $\mathcal{X}$. Les éléments complétés restent donc de véritables fonctions, et la propriété de reproduction s'étend par continuité.

Nous avons donc l'équivalence : les noyaux semi-définis positifs sont exactement des produits scalaires de *feature maps*. Choisir un noyau k ou choisir un espace $(\mathcal{H}, \varphi)$ est donc la même chose, sauf que l'on sait explicitement calculer k . On peut donc complètement oublier $\mathcal{H}$ et φ dans le processus d'apprentissage.

Proposition (La recette) L'algorithme complet d'apprentissage supervisé à noyau se résume donc en 4 étapes :

- *Choix de k* : On définit un noyau k mesurant la "distance" de nos données en fonction de leur forme.
- *Matrice de Gram* : On calcule l'ensemble des paires $K_{i,j} = k(x_i, x_j)$ pour construire la matrice de Gram $K \in \mathbb{R}^{n \times n}$.
- *Optimisation* : On résout un problème d'optimisation pour trouver $\hat{\alpha}_S \in \mathbb{R}^n$:

$$\hat{\alpha}_S \in \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n l(y_i, (K\alpha)_i) + \frac{\lambda}{2} \alpha^\top K \alpha. \quad (3.2.5)$$

- *Inférence* : Une fois trouvé, on put prédire le label de tout nouveau x par :

$$\hat{y} = \sum_{j=1}^n \hat{\alpha}_j k(x, x_j). \quad (3.2.6)$$

3.3 Séparateurs à Vaste Marge (SVM)

L'algorithme des Séparateurs à Vaste Marge (*Support Vector Machines*) illustre parfaitement la puissance des méthodes à noyaux. On commence par formuler le problème géométrique dans le cas linéaire élémentaire, avant d'en dériver la version duale et d'y injecter le *Kernel Trick*.

3.3.1 Cas linéairement séparable : Maximisation de la marge

Soit un échantillon d'apprentissage $S = ((x_1, y_1), \dots, (x_n, y_n)) \in (\mathbb{R}^d \times \{-1, 1\})^n$. On suppose dans un premier temps les données linéairement séparables : il existe un hyperplan passant par l'origine $H(\theta) = \{z \in \mathbb{R}^d \mid \theta^\top z = 0\}$ tel que pour tout $i \in \llbracket 1, n \rrbracket$, $y_i(\theta^\top x_i) > 0$.

Proposition (Distance à l'hyperplan) Pour tout $\theta \neq 0$, la distance orthogonale d'un point $x \in \mathbb{R}^d$ à l'hyperplan $H(\theta)$ est donnée par :

$$\text{dist}(x, H(\theta)) = \frac{|\theta^\top x|}{\|\theta\|_2}. \quad (3.3.1)$$

Sous l'hypothèse de séparabilité, $y_i(\theta^\top x_i) = |\theta^\top x_i|$. L'objectif consiste à trouver l'hyperplan qui maximise la distance minimale aux observations d'entraînement (la marge géométrique) :

$$\max_{\theta \neq 0} \min_{i \in \llbracket 1, n \rrbracket} \frac{y_i(\theta^\top x_i)}{\|\theta\|_2}. \quad (3.3.2)$$

Le problème étant invariant par changement d'échelle $\theta \mapsto c\theta$ ($c > 0$), on impose la normalisation canonique $\min_i y_i(\theta^\top x_i) = 1$. Maximiser $1/\|\theta\|_2$ sous cette contrainte équivaut à minimiser $\frac{1}{2}\|\theta\|_2^2$. En relâchant l'égalité en une inégalité (qui sera saturée à l'optimum), on obtient le programme quadratique convexe :

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{2} \|\theta\|_2^2 \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad y_i(\theta^\top x_i) \geq 1. \quad (3.3.3)$$

3.3.2 Cas non séparable : Variables d'écart et perte charnière

En pratique, les données se chevauchent ou comportent du bruit, rendant la séparation stricte impossible. Pour autoriser des erreurs tout en les contrôlant, on introduit des variables d'écart (*slack variables*) $\xi_i \geq 0$ pénalisées par un coefficient $C > 0$:

$$\min_{\theta \in \mathbb{R}^d, \xi \in \mathbb{R}^n} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad y_i(\theta^\top x_i) \geq 1 - \xi_i \quad \text{et} \quad \xi_i \geq 0. \quad (3.3.4)$$

Ce problème admet toujours des solutions admissibles dès que les ξ_i sont choisis suffisamment grands.

Proposition (Pont avec la minimisation du risque empirique) À θ fixé, l'objectif est strictement croissant en chaque variable ξ_i . À l'optimum, ξ_i atteint donc sa plus petite borne autorisée par les contraintes, soit :

$$\xi_i = \max(0, 1 - y_i(\theta^\top x_i)) = (1 - y_i(\theta^\top x_i))_+. \quad (3.3.5)$$

En substituant cette expression, en divisant l'objectif par $nC > 0$ et en posant $\lambda := \frac{1}{nC}$, le problème géométrique coïncide rigoureusement avec un problème d'ERM régularisé pour la perte charnière (*hinge loss*) :

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n (1 - y_i(\theta^\top x_i))_+ + \frac{\lambda}{2} \|\theta\|_2^2. \quad (3.3.6)$$

3.3.3 Dualité de Wolfe et formulation duale

Le problème primal étant convexe avec des contraintes affines, les conditions de qualification de Slater sont vérifiées (par exemple pour $\theta = 0$ et $\xi_i = 2$), garantissant la dualité forte.

On introduit les multiplicateurs de Lagrange $\alpha_i \geq 0$ (pour les contraintes de marge) et $\beta_i \geq 0$ (pour la positivité de ξ_i) :

$$\mathcal{L}(\theta, \xi, \alpha, \beta) = \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i \theta^\top x_i + \xi_i - 1) - \sum_{i=1}^n \beta_i \xi_i. \quad (3.3.7)$$

Proposition Minimisons le Lagrangien :

- **En ξ :** Le Lagrangien s'écrit $\sum_{i=1}^n (C - \alpha_i - \beta_i) \xi_i + \dots$. L'infimum par rapport à $\xi_i \geq 0$ vaut $-\infty$ sauf si $C - \alpha_i - \beta_i = 0$. Cette condition permet d'éliminer $\beta_i \geq 0$, ce qui équivaut à la contrainte de boîte :

$$0 \leq \alpha_i \leq C \quad \forall i \in \llbracket 1, n \rrbracket. \quad (3.3.8)$$

- **En θ :** La condition d'annulation du gradient $\nabla_\theta \mathcal{L} = \theta - \sum_{i=1}^n \alpha_i y_i x_i = 0$ impose :

$$\theta^* = \sum_{i=1}^n \alpha_i y_i x_i. \quad (3.3.9)$$

En réinjectant ces relations dans $\mathcal{L}$, le problème dual de Wolfe s'écrit sous forme d'un programme quadratique concave :

$$\max_{\alpha \in \mathbb{R}^n} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i^\top x_j) \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad 0 \leq \alpha_i \leq C. \quad (3.3.10)$$

Remarque Les données d'entrée x_i n'interviennent dans ce problème dual que par leurs produits scalaires $x_i^\top x_j$.

3.3.4 Le Kernel SVM (SVM à noyau)

Soit k un noyau semi-défini positif sur $\mathcal{X}$. En vertu du théorème d'Aronszajn, k définit implicitement un RKHS $\mathcal{H}_k$ et une application canonique φ_k tels que $k(x, x') = \langle \varphi_k(x), \varphi_k(x') \rangle_{\mathcal{H}_k}$. On formule le problème primal directement dans $\mathcal{H}_k$:

$$\min_{\theta \in \mathcal{H}_k} \frac{1}{n} \sum_{i=1}^n (1 - y_i \langle \theta, \varphi_k(x_i) \rangle_{\mathcal{H}_k})_+ + \frac{\lambda}{2} \|\theta\|_{\mathcal{H}_k}^2. \quad (3.3.11)$$

Grâce au *Kernel Trick*, on substitue directement chaque produit scalaire par l'évaluation du noyau $k(x_i, x_j) = K_{i,j}$ dans la formulation duale. En posant le changement de variable $\mu_i = \lambda \alpha_i$ (avec $\lambda = \frac{1}{nC}$, ce qui donne $0 \leq \mu_i \leq \frac{1}{n}$), le problème dual s'écrit sous forme matricielle :

$$\boxed{\max_{\mu \in \mathbb{R}^n} \sum_{i=1}^n \mu_i - \frac{1}{2\lambda} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \mu_i \mu_j k(x_i, x_j) \quad \text{s.c.} \quad \forall i \in \llbracket 1, n \rrbracket, \quad 0 \leq \mu_i \leq \frac{1}{n}.} \quad (3.3.12)$$

Il s'agit d'un problème d'optimisation quadratique à n variables, dont la résolution numérique s'effectue uniquement à l'aide de la matrice de Gram $K \in \mathcal{S}_n^+(\mathbb{R})$.

Proposition (Règle de décision et vecteurs de support) D'après l'expression de θ^* et la propriété de reproduction dans le RKHS, la fonction de décision optimale pour classer un nouveau point $x \in \mathcal{X}$ est :

$$f(x) = \text{sign} \left(\sum_{i=1}^n \hat{\alpha}_i y_i k(x_i, x) \right). \quad (3.3.13)$$

D'après les conditions de complémentarité de Karush-Kuhn-Tucker (KKT), les coefficients $\hat{\alpha}_i$ sont strictement nuls pour tous les points situés en dehors de la marge. La décision ne dépend donc que des points vérifiant $\hat{\alpha}_i > 0$, appelés *vecteurs de support* :

$$f(x) = \text{sign} \left(\sum_{i \in \text{Support}} \hat{\alpha}_i y_i k(x_i, x) \right). \quad (3.3.14)$$

Ce résultat garantit la parcimonie du modèle et rend l'évaluation en phase d'inférence très rapide.

Chapitre 4

Théorie de l'Apprentissage et Minimisation du Risque Empirique

Contents

4.1	Convexification du risque et substituts convexes	26
4.1.1	Reparamétrisation et identité de marge	26
4.1.2	Risque de substitution et théorème de calibration	27
4.2	Décomposition du Risque et Classes Finies	27
4.2.1	Décomposition canonique de l'excès de risque	27
4.2.2	Majoration de l'erreur du risque – cas fini	28
4.2.3	Majoration de l'erreur du risque – cas infini	30
4.3	Complexité de Rademacher	31
4.3.1	Le procédé de symétrisation	32
4.3.2	Définitions et propriétés	32
4.3.3	Le retour du cas fini	33
4.3.4	Principe de contraction	35
4.3.5	Modèles linéaires contraints et dualité de normes	35
4.4	Théorèmes d'excès de risque pour les modèles linéaires	37
4.4.1	Borne en espérance	37
4.4.2	Borne à grande probabilité	38

Dans les chapitres précédents, nous avons présenté différentes méthodes d'apprentissage basées sur la minimisation du risque empirique (ERM, *Empirical Risk Minimization*). Or la seule analyse de la convergence de ces méthodes que nous ayons faite est la décomposition biais-variance du risque ainsi que la décomposition de son erreur en deux : l'erreur *d'approximation* et l'erreur *d'estimation*.

Dans la seconde partie de ce chapitre, nous nous attardons justement sur l'erreur faite sur le risque lors de l'apprentissage. Pour cela, nous développons une nouvelle théorie basée sur la complexité de l'espace de recherche $\mathcal{F}$.

Mais avant, nous développons le concept de *convexification du risque* dans la première partie. En effet, pour certaines fonction de pertes (notamment la *0-1 loss*) nous ne disposons pas de "bonnes" propriétés analytiques pour utiliser des algorithmes d'optimisation. Nous présentons ainsi une méthode permettant d'y remédier.

4.1 Convexification du risque et substituts convexes

4.1.1 Reparamétrisation et identité de marge

En classification binaire, on cherche à prédire une étiquette parmi deux classes $\mathcal{Y} = \{-1, 1\}$ via une fonction $f : \mathcal{X} \rightarrow \mathcal{Y}$. La mesure naturelle d'erreur est la perte 0-1 (*0-1 loss*) définie par :

$$l(y, \hat{y}) = \mathbb{1}_{y \neq \hat{y}}. \quad (4.1.1)$$

La minimisation exacte du risque empirique sous la perte 0-1 sur une classe d'hypothèses générale est un problème combinatoire NP-difficile. De plus, le risque empirique associé est une fonction constante par morceaux de ses paramètres : son gradient est nul presque partout, ce qui rend inapplicables les méthodes d'optimisation par descente de gradient.

Pour lever ce verrou, on reparamétrise le classifieur discret à l'aide d'une fonction à valeurs réelles.

Définition (Prédicteur par fonction signe randomisée) . Soit $g : \mathcal{X} \rightarrow \mathbb{R}$ une fonction réelle mesurable. On définit le classifieur binaire $f : \mathcal{X} \rightarrow \{-1, 1\}$ par $f(x) = \text{sgn}(g(x))$ avec la convention :

$$\text{sgn}(u) = \begin{cases} 1 & \text{si } u > 0, \\ -1 & \text{si } u < 0, \\ U \sim \text{Unif}(\{-1, 1\}) & \text{si } u = 0, \end{cases} \quad (4.1.2)$$

où U est une variable aléatoire auxiliaire indépendante du couple d'observations $(X, Y) \sim \mathbb{P}$.

Cette reparamétrisation permet de découpler la *décision brute* (donnée par $\text{sgn}(g(x))$) de la *confiance / distance à la frontière* (quantifiée par l'amplitude $|g(x)|$). On introduit alors la *marge fonctionnelle* $u = Yg(X)$:

- $u > 0$: la prédiction est correcte ($\text{sgn}(g(X)) = Y$).
- $u < 0$: la prédiction est erronée ($\text{sgn}(g(X)) \neq Y$).
- $u = 0$: le point se situe exactement sur la frontière de décision.

Proposition (Identité de marge pour la perte 0-1) Le risque théorique de classification binaire associé à $f = \text{sgn} \circ g$ s'exprime comme l'espérance d'une fonction scalaire de la marge fonctionnelle $Yg(X)$:

$$R(f) = \mathbb{E}_{(X,Y) \sim \mathbb{P}} [\Phi_{0-1}(Yg(X))], \quad (4.1.3)$$

avec la fonction de saut :

$$\Phi_{0-1}(u) = \mathbb{1}_{u < 0} + \frac{1}{2} \mathbb{1}_{u=0}. \quad (4.1.4)$$

Démonstration En explicitant l'espérance conjointe sur (X, Y) et sur la variable de randomisation U :

$$\begin{aligned} R(f) &= \mathbb{E}_{(X,Y),U} [\mathbb{1}_{f(X) \neq Y}] \\ &= \mathbb{E} [\mathbb{1}_{g(X) \neq 0} \mathbb{1}_{f(X) \neq Y}] + \mathbb{E} [\mathbb{1}_{g(X)=0} \mathbb{1}_{f(X) \neq Y}] \\ &= \mathbb{P}(Yg(X) < 0) + \mathbb{E} [\mathbb{1}_{g(X)=0} \mathbb{1}_{U \neq Y}]. \end{aligned}$$

Comme U est indépendante de (X, Y) et uniformément distribuée sur $\{-1, 1\}$, $\mathbb{P}(U \neq Y \mid g(X) = 0) = \frac{1}{2}$. D'où :

$$R(f) = \mathbb{P}(Yg(X) < 0) + \frac{1}{2} \mathbb{P}(g(X) = 0) = \mathbb{E}_{(X,Y) \sim \mathbb{P}} [\Phi_{0-1}(Yg(X))].$$

4.1.2 Risque de substitution et théorème de calibration

Dans le cas général, lorsque l'on fait face à une fonction de coût l non continue ou non convexe, on définit une fonction convexe Φ et une fonction g pour définir un risque de substitution ou *surrogate risk* $R_\Phi(g)$.

Définition (Risque de substitution – Surrogate Risk) . Soit $\Phi : \mathbb{R} \rightarrow [0, \infty[$ une fonction convexe. Le risque de substitution associé à Φ pour une fonction $g : \mathcal{X} \rightarrow \mathbb{R}$ est défini par :

$$R_\Phi(g) := \mathbb{E}_{(X,Y) \sim \mathbb{P}} [\Phi(Yg(X))]. \quad (4.1.5)$$

Exemples classiques :

- Perte charnière (Hinge) : $\Phi(u) = (1 - u)_+$,
- Perte quadratique : $\Phi(u) = (1 - u)^2$,
- Perte logistique : $\Phi(u) = \ln(1 + e^{-u})$.

Or, nous ne sommes pas assurés qu'optimiser sur $R_\Phi(g)$ nous donne une solution optimale $\hat{f}$ pour notre risque initial $R(f)$. Le théorème de calibration ci-dessous nous donne une estimation de l'erreur commise.

Théorème (Calibration – Zhang, Bartlett-Jordan-McAuliffe) . Soit $\Phi : \mathbb{R} \rightarrow [0, \infty[$ une fonction convexe, dérivable en 0 avec $\Phi'(0) < 0$. Il existe une fonction convexe, non décroissante et continue $\psi : [0, 1] \rightarrow [0, \infty[$ vérifiant $\psi(0) = 0$ telle que pour toute fonction mesurable $g : \mathcal{X} \rightarrow \mathbb{R}$:

$$\psi(R(\text{sgn} \circ g) - R^*) \leq R_\Phi(g) - \inf_{g'} R_\Phi(g'). \quad (4.1.6)$$

En particulier :

- Pour la perte charnière : $\psi(t) = t$,
- Pour la perte quadratique : $\psi(t) = t^2$,
- Pour la perte logistique : $\psi(t) \geq \frac{t^2}{2}$.

4.2 Décomposition du Risque et Classes Finies

4.2.1 Décomposition canonique de l'excès de risque

Dans les chapitres précédents, nous avons décomposé le risque empirique en une erreur *d'approximation* (liée au choix de l'espace de fonction à optimiser $\mathcal{F}$) et une erreur *d'estimation* (liée à l'échantillon restreint S de taille n que l'on considère, purement statistique) :

$$R(\hat{f}_S) - R^* = \underbrace{\left(R(\hat{f}_S) - \inf_{f \in \mathcal{F}} R(f) \right)}_{\text{estimation}} + \underbrace{\left(\inf_{f \in \mathcal{F}} R(f) + R^* \right)}_{\text{approximation}}, \quad (4.2.1)$$

avec $\hat{f}_S$ le minimiseur du risque empirique sur $\mathcal{F}$. Soit $f^\dagger \in \mathcal{F}$ le meilleur prédicteur théorique possible dans $\mathcal{F}$. On a donc :

$$R(\hat{f}_S) - R^* = R(\hat{f}_S) - R(f^\dagger) + R(f^\dagger) - R^*. \quad (4.2.2)$$

Or ici, $\hat{f}_S$ est calculé sur un échantillon fixé S , on ne peut donc pas appliquer la LGN sur la taille de l'échantillon pour obtenir une convergence p.s vers $f^\dagger$. Pour séparer ce qui dépend des

données et ce qui dépend de l'estimation dans ce risque, on introduit les risques empiriques $\hat{R}_S(\hat{f}_S)$ et $\hat{R}_S(f^\dagger)$:

$$R(\hat{f}_S) - R(f^\dagger) = \left[R(\hat{f}_S) - \hat{R}_S(\hat{f}_S) \right] + \left[\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger) \right] + \left[\hat{R}_S(f^\dagger) - R(f^\dagger) \right]. \quad (4.2.3)$$

En regardant chaque élément :

- $R(\hat{f}_S) - \hat{R}_S(\hat{f}_S)$ correspond à l'erreur commise sur le calcul du risque de l'estimateur restreint à l'échantillon S . Comme $\hat{f}_S \in \mathcal{F}$, on peut le majorer brutalement par le pire estimateur de la classe $\mathcal{F}$:

$$R(\hat{f}_S) - \hat{R}_S(\hat{f}_S) \leq \sup_{f \in \mathcal{F}} \left| R(f) - \hat{R}_S(f) \right|. \quad (4.2.4)$$

- $\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger)$ correspond à l'erreur empirique du risque entre l'optimum calculé et le meilleur théorique,
- $\hat{R}_S(f^\dagger) - R(f^\dagger)$ correspond à l'erreur commise sur le calcul du risque sur l'échantillon S du meilleur estimateur théorique $f^\dagger$. De la même façon que pour le premier, on peut le majorer par le pire estimateur de $\mathcal{F}$:

$$\hat{R}_S(\hat{f}_S) - R(f^\dagger) \leq \sup_{f \in \mathcal{F}} \left| \hat{R}_S(f) - R(f) \right|. \quad (4.2.5)$$

Le terme du milieu $\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger)$ correspond à l'erreur d'optimisation. Cette erreur est simplement due à la performance de notre algorithme ou à la puissance de notre unité de calcul. On peut donc la majorer arbitrairement par une constante ε_{opt} (qui dépend par exemple de la puissance de notre GPU, du temps de calcul, etc.).

Proposition (Décomposition canonique de l'excès de risque) Soit $\mathcal{F}$ une classe d'hypothèses, $\hat{f}_S \in \arg \min_{f \in \mathcal{F}} \hat{R}_S(f)$ le minimiseur empirique et $f^\dagger \in \arg \min_{f \in \mathcal{F}} R(f)$ le meilleur estimateur possible dans $\mathcal{F}$. L'erreur d'estimation se majore par :

$$\boxed{R(\hat{f}_S) - R(f^\dagger) \leq 2 \sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| + \varepsilon_{opt}} \quad (4.2.6)$$

où $\varepsilon_{opt} = \hat{R}_S(\hat{f}_S) - \inf_{f \in \mathcal{F}} \hat{R}_S(f)$ représente l'erreur d'optimisation numérique (nulle si la minimisation est exacte).

On souhaite maintenant estimer (ou borner) l'erreur maximale que l'on peut faire dans $\mathcal{F}$ en estimant le risque $\hat{R}_S$ sur l'échantillon S : $\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)|$. On va pour cela distinguer deux cas : si $\mathcal{F}$ est une classe finie ou non.

4.2.2 Majoration de l'erreur du risque – cas fini

On suppose ici que $\mathcal{F}$ dispose d'un nombre fini d'éléments $|\mathcal{F}| = M < \infty$ et que les pertes sont bornées par l_∞ . Pour majorer cette quantité, on utilise l'inégalité de Hoeffding.

Théorème (Inégalité de Hoeffding) . Soit $(X_k)_{1 \leq k \leq n}$ une suite de variables aléatoires réelles *indépendantes* telles que pour deux suites $(a_k)_{1 \leq k \leq n}$ et $(b_k)_{1 \leq k \leq n}$, on ait :

$$\forall k \in \llbracket 1, n \rrbracket, \quad \mathbb{P}(a_k \leq X_k \leq b_k) = 1. \quad (4.2.7)$$

Alors, pour tout $t \geq 0$, on peut minorer la concentration de $S_n = X_1 + \dots + X_n$ autour de sa moyenne en probabilité :

$$\mathbb{P}(|S_n - \mathbb{E}(S_n)| \geq t) \leq 2 \exp \left(- \frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2} \right). \quad (4.2.8)$$

Proposition Or ici, pour toute fonction $f \in \mathcal{F}$ fixée indépendante de l'échantillon S , la perte sur chaque observation $Z_i = l(y_i, f(x_i))$ est une variable aléatoire réelle telle que :

1. Les $(Z_i)_{1 \leq i \leq n}$ sont i.i.d.
2. Pour tout $i \in \llbracket 1, n \rrbracket$, on a $Z_i \in [0, l_\infty]$.
3. La moyenne empirique est : $\hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n Z_i$.
4. L'espérance est : $\mathbb{E}[Z_i] = R(f)$.

On peut donc appliquer l'inégalité de Hoeffding sur la moyenne empirique $\hat{R}_S(f)$ avec $a_k = 0$ et $b_k = l_\infty/n$ pour tout $k \in \llbracket 1, n \rrbracket$. D'où :

$$\forall t \geq 0, \quad \mathbb{P}(|R(f) - \hat{R}_S(f)| \geq t) \leq 2 \exp \left(- \frac{2nt^2}{l_\infty^2} \right). \quad (4.2.9)$$

Sachant contrôler chaque estimateur de la classe $\mathcal{F}$ indépendamment, on souhaite maintenant les contrôler tous¹. Pour contrôler simultanément tous les estimateurs de la classe, on applique l'inégalité de Boole (*Union Bound*)² sur les $M = |\mathcal{F}|$ éléments :

$$\begin{aligned} \mathbb{P} \left(\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \geq t \right) &\leq \sum_{f \in \mathcal{F}} \mathbb{P} \left(|\hat{R}_S(f) - R(f)| \geq t \right) \\ &\leq 2|\mathcal{F}| \exp \left(- \frac{2nt^2}{l_\infty^2} \right). \end{aligned}$$

En posant cette probabilité d'erreur égale à $\delta \in]0, 1[$, on obtient le seuil d'écart $t = l_\infty \sqrt{\frac{\ln(2|\mathcal{F}|/\delta)}{2n}}$.

Théorème (Borne uniforme pour les classes finies) . Sous les hypothèses $l(y, f(x)) \in [0, l_\infty]$ et $|\mathcal{F}| < \infty$, pour tout $\delta \in]0, 1[$, avec probabilité au moins $1 - \delta$ sur le tirage de $S \sim \mathbb{P}^{\otimes n}$:

$$\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \leq l_\infty \sqrt{\frac{\ln(2|\mathcal{F}|/\delta)}{2n}}. \quad (4.2.10)$$

Par conséquent, pour le minimiseur empirique exact $\hat{f}_S$, on a avec probabilité au moins $1 - \delta$:

$$R(\hat{f}_S) \leq \inf_{f \in \mathcal{F}} R(f) + 2l_\infty \sqrt{\frac{\ln(2|\mathcal{F}|/\delta)}{2n}} + \varepsilon_{\text{opt}}. \quad (4.2.11)$$

Remarque Le résultat est immédiat ici. Si les hypothèses sont vérifiées, nous sommes capables de borner le risque. En revanche, si $|\mathcal{F}| = \infty$, les bornes de celui-ci explosent. Nous devons donc décrire une nouvelle théorie pour traiter ce cas.

1. "Un anneau unique pour les contrôler tous".

2. Cette inégalité découle des propriétés des mesures. Elle affirme que pour une famille au plus dénombrable de partie mesurables $A_1, A_2, A_3, \dots$, pour toute mesure μ , on a : $\mu \left(\bigcup_n A_n \right) \leq \sum_n \mu(A_n)$.

4.2.3 Majoration de l'erreur du risque – cas infini

Analysons le résultat précédent : on calcule la probabilité que $\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \geq t$ par une somme finie d'unions d'événements sur $\mathcal{F}$. C'est donc de là que la borne explose si $\mathcal{F}$ est infini.

La solution est donc de traiter la classe entière de fonctions $\mathcal{F}$ en considérant une application g définie sur l'échantillon S qui lui associe l'erreur la plus importante possible sur la classe de fonctions $\mathcal{F}$:

$$g(S) := \sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)). \quad (4.2.12)$$

C'est donc maintenant l'échantillon qui définit la variation d'erreur. On souhaite toujours la borner : on introduit donc la *méthode des différences bornées*.

Définition (Différences Bornées) . Soit $f : Z_1 \times \cdots \times Z_n \rightarrow \mathbb{R}$ une application. On dit que f vérifie la *condition des différences bornées* pour les constantes $(c_1, \dots, c_n) \in \mathbb{R}^n$ si pour tout $i \in \llbracket 1, n \rrbracket$ on a :

$$\sup_{z_1, \dots, z_i, \dots, z_n, z'_i} |f(z_1, \dots, z_i, \dots, z_n) - f(z_1, \dots, z'_i, \dots, z_n)| \leq c_i. \quad (4.2.13)$$

Autrement dit, si l'on change la i ème entrée z_i de f en z'_i , sa sortie ne bouge pas plus de c_i , et cela pour tout i .

Proposition (Différences bornées sur g) Appliquons les différences bornées sur l'application g . Puisque pour tout $f \in \mathcal{F}$, le risque $R(f)$ ne dépend pas des données S , on a :

$$\hat{R}_S(f) - \hat{R}_{S'}(f) = \frac{1}{n} (l(z_i, f) - l(z'_i, f)). \quad (4.2.14)$$

Or, par hypothèse, la perte directe est contenue dans $[0, l_\infty]$. Nous devons passer au sup pour conclure sur g .

Lemme (Passage au sup) Soient $u, v : \mathcal{F} \rightarrow \mathbb{R}$ deux applications. Pour tout $f \in \mathcal{F}$, on a l'implication suivante :

$$|u(f) - v(f)| \leq c \longrightarrow \left| \sup_{f \in \mathcal{F}} u(f) - \sup_{f \in \mathcal{F}} v(f) \right| \leq c. \quad (4.2.15)$$

En appliquant le lemme précédent avec $c = \frac{l_\infty}{n}$, on en déduit que pour tout $i \in \llbracket 1, n \rrbracket$:

$$|g(S) - g(S')| = \left| \sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) - \sup_{f \in \mathcal{F}} (\hat{R}_{S'}(f) - R(f)) \right| \leq \frac{l_\infty}{n}. \quad (4.2.16)$$

La fonction g vérifie donc la propriété des différences bornées avec les constantes coordonnées :

$$c_i = \frac{l_\infty}{n} \quad \text{pour tout } i \in \llbracket 1, n \rrbracket. \quad (4.2.17)$$

Théorème (Inégalité de McDiarmid) . Soient $Z_1, \dots, Z_n$ des variables aléatoires indépendantes à valeurs dans un espace mesurable $\mathcal{Z}$. Soit $\phi : \mathcal{Z}^n \rightarrow \mathbb{R}$ une fonction vérifiant l'hypothèse des différences bornées pour des constantes $(c_1, \dots, c_n) \in \mathbb{R}_+^n$. Alors, pour tout $t \geq 0$:

$$\mathbb{P}(\phi(S) - \mathbb{E}_S[\phi(S)] \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right), \quad (4.2.18)$$

$$\mathbb{P}(\mathbb{E}_S[\phi(S)] - \phi(S) \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right), \quad (4.2.19)$$

$$\mathbb{P}(|\phi(S) - \mathbb{E}_S[\phi(S)]| \geq t) \leq 2 \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right). \quad (4.2.20)$$

On décompose la déviation uniforme bilatérale en deux déviations unilatérales :

$$\sup_{f \in \mathcal{F}} |\hat{R}_S(f) - R(f)| \leq \sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) + \sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)). \quad (4.2.21)$$

Puisque chacune de ces deux applications admet les constantes de variations coordonnées $c_i = \frac{l_\infty}{n}$, la somme des carrés s'évalue explicitement par :

$$\sum_{i=1}^n c_i^2 = \sum_{i=1}^n \left(\frac{l_\infty}{n}\right)^2 = \frac{l_\infty^2}{n}. \quad (4.2.22)$$

L'application de la forme unilatérale de McDiarmid fournit alors le contrôle de concentration suivant :

Proposition (Concentration de la déviation uniforme unilatérale) Sous l'hypothèse d'une perte bornée $l(y, f(x)) \in [0, l_\infty]$, pour tout $\delta \in]0, 1[$, chacune des inégalités suivantes est vérifiée avec probabilité au moins $1 - \delta$ sur le tirage de $S \sim \mathbb{P}^{\otimes n}$:

$$\sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) \leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) \right] + l_\infty \sqrt{\frac{\ln(1/\delta)}{2n}}, \quad (4.2.23)$$

$$\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] + l_\infty \sqrt{\frac{\ln(1/\delta)}{2n}}. \quad (4.2.24)$$

Remarque Ce résultat marque une avancée théorique majeure : la déviation uniforme se concentre à une vitesse en $\mathcal{O}(1/\sqrt{n})$ autour de son espérance, *sans aucune hypothèse de finitude ou de structure* sur la classe $\mathcal{F}$.

Toutefois, le problème n'est pas encore résolu : la déviation se concentre autour d'une espérance théorique inconnue $\mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (\hat{R}_S(f) - R(f)) \right]$. Si la classe $\mathcal{F}$ est arbitrairement riche (par exemple l'ensemble de toutes les fonctions mesurables), cette espérance vaut identiquement 1 pour tout n . L'objectif de la section suivante consiste donc à borner cette espérance résiduelle à l'aide de la *symétrisation* et de la *complexité de Rademacher*.

4.3 Complexité de Rademacher

Notation Pour alléger les calculs, on note $z = (x, y)$ et $z_i = (x_i, y_i)$ tirés selon la loi $\mathbb{P}$. Pour tout prédicteur $f \in \mathcal{F}$ et toute fonction de perte $l : \mathcal{Y} \times \mathcal{X} \rightarrow \mathbb{R}$, on associe la fonction de perte induite $h_f : \mathcal{X} \times \mathcal{Y} \rightarrow \mathbb{R}$ définie par $h_f(z) = l(y, f(x))$. On étudie ainsi la classe de fonctions :

$$\mathcal{H} = l \circ \mathcal{F} = \{z \mapsto l(y, f(x)) \mid f \in \mathcal{F}\}. \quad (4.3.1)$$

Le risque empirique devient $\hat{R}_S(f) = \frac{1}{n} \sum_{i=1}^n h_f(z_i)$ et le risque théorique $R(f) = \mathbb{E}_z[h_f(z)]$.

La section précédente a établi que la déviation uniforme se concentre autour de son espérance théorique :

$$\mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] = \mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) \right) \right]. \quad (4.3.2)$$

Le processus de *symétrisation* permet de majorer cette espérance par une quantité calculable à partir de perturbations aléatoires de l'échantillon.

4.3.1 Le procédé de symétrisation

Proposition (Symétrisation par échantillon fantôme) Soit $S' = (z'_1, \dots, z'_n) \sim \mathbb{P}^{\otimes n}$ un second échantillon (dit *échantillon fantôme*) indépendant de S et de même loi. Par linéarité de l'espérance :

$$\mathbb{E}_z[h(z)] = \mathbb{E}_{S'} \left[\frac{1}{n} \sum_{i=1}^n h(z'_i) \right]. \quad (4.3.3)$$

Le premier échantillon S étant indépendant de S' , on regroupe les termes :

$$\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) = \mathbb{E}_{S'} \left[\frac{1}{n} \sum_{i=1}^n (h(z'_i) - h(z_i)) \right]. \quad (4.3.4)$$

Par convexité de la fonction supremum (inégalité de Jensen, $\sup \mathbb{E} \leq \mathbb{E} \sup$), puis en intégrant par rapport à S :

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) \right) \right] \leq \mathbb{E}_{S,S'} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n (h(z'_i) - h(z_i)) \right]. \quad (4.3.5)$$

Proposition (Injection des variables de Rademacher) Posons $d_i = h(z'_i) - h(z_i)$. Comme z_i et z'_i sont i.i.d., $d_i \stackrel{\mathcal{L}}{=} -d_i$. Soient $\varepsilon_1, \dots, \varepsilon_n$ des variables de Rademacher indépendantes de S, S' telles que $\mathbb{P}(\varepsilon_i = 1) = \mathbb{P}(\varepsilon_i = -1) = \frac{1}{2}$. Alors $(d_1, \dots, d_n) \stackrel{\mathcal{L}}{=} (\varepsilon_1 d_1, \dots, \varepsilon_n d_n)$ pour tout $h \in \mathcal{H}$ conjointement :

$$\begin{aligned} \mathbb{E}_{S,S'} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n d_i \right] &= \mathbb{E}_{S,S',\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \varepsilon_i (h(z'_i) - h(z_i)) \right] \\ &\leq \mathbb{E}_{S',\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \varepsilon_i h(z'_i) \right] + \mathbb{E}_{S,\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n (-\varepsilon_i) h(z_i) \right]. \end{aligned}$$

Comme $-\varepsilon_i \stackrel{\mathcal{L}}{=} \varepsilon_i$, les deux termes sont égaux et l'échantillon fantôme s'élimine :

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i=1}^n h(z_i) \right) \right] \leq 2 \mathbb{E}_{S,\varepsilon} \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \varepsilon_i h(z_i) \right]. \quad (4.3.6)$$

4.3.2 Définitions et propriétés

Les calculs précédents nous ont introduit une nouvelle grandeur (voir Équation 4.3.6) définissant la *complexité de Rademacher*.

Définition (Complexité de Rademacher) . Soit $\mathcal{H}$ une classe de fonctions à valeurs réelles et $S = (z_1, \dots, z_n)$. On définit la *complexité de Rademacher empirique* de l'espace $\mathcal{H}$ sous S par :

$$\mathfrak{R}_S(\mathcal{H}) = \mathbb{E}_\varepsilon \left[\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i) \right]. \quad (4.3.7)$$

Plus généralement, lorsque $\mathcal{H}$ dépend d'une loi de probabilité $\mathbb{P}$, on définit la complexité de Rademacher par :

$$\mathfrak{R}_n(\mathcal{H}) = \mathbb{E}_{S \sim \mathbb{P}^{\otimes n}} [\mathfrak{R}_S(\mathcal{H})] \quad (4.3.8)$$

où les $\varepsilon_i \in \{-1, 1\}$.

Cette complexité traduit la capacité de l'espace de fonction $\mathcal{H}$ à approximer données S bruitées par les ε_i . Une classe pour laquelle c'est le cas a une complexité de l'ordre de $\sup_h \sup_i |h(z_i)|$, dans le cas contraire, sa complexité de Rademacher tends vers 0 à mesure que n augmente. Nous pouvons donc conclure notre procédé de symétrisation par le théorème suivant.

Théorème (Symétrisation) . Soit $\mathcal{H}$ une classe de fonctions, une famille de valeurs $z_1, \dots, z_n$ et une famille de coefficients $\varepsilon_i \in \{-1, 1\}^n$. On a le résultat suivant :

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\frac{1}{n} \sum_{i \leq n} h(z_i) - \mathbb{E}_z[h(z)] \right) \right] \leq 2\mathfrak{R}_n(\mathcal{H}) \quad (4.3.9)$$

$$\mathbb{E}_S \left[\sup_{h \in \mathcal{H}} \left(\mathbb{E}_z[h(z)] - \frac{1}{n} \sum_{i \leq n} h(z_i) \right) \right] \leq 2\mathfrak{R}_n(\mathcal{H}) \quad (4.3.10)$$

Remarque Le second résultat est issu du même processus de symétrisation appliqué à la classe de fonctions $-\mathcal{H} = \{-h \mid h \in \mathcal{H}\}$.

Définissons maintenant quelques propriétés calculatoires de la complexité de Rademacher.

Propriété (Complexité de Rademacher) . Soient $\mathcal{H}$ une classe de fonctions, $h_0 \in \mathcal{H}$ et $c \in \mathbb{R}$, on a :

- *Homogénéité* : $\mathfrak{R}_S(c\mathcal{H}) = |c|\mathfrak{R}_S(\mathcal{H})$.
- *Translation* : $\mathfrak{R}_S(\mathcal{H} + h_0) = \mathfrak{R}_S(\mathcal{H})$.
- *Enveloppe convexe* : $\mathfrak{R}_S(\text{conv } \mathcal{H}) = \mathfrak{R}_S(\mathcal{H})$.

Démonstration 1. Par linéarité de l'opérateur d'application, de la somme, du sup et de l'espérance. Le cas $c < 0$ est vérifié par le fait que l'application de la fonction $\varepsilon \mapsto -\varepsilon$ ne change pas la loi des variables aléatoires et donc la valeur de l'espérance.

2. On observe que $\sup_h \frac{1}{n} \sum_{i \leq n} \varepsilon_i (h + h_0)(z_i) = \frac{1}{n} \sum_{i \leq n} \varepsilon_i h_0(z_i) + \sup_h \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i)$. Or la moyenne sur le premier terme s'annule du fait de la distribution uniforme des ε_i sur $\{-1, 1\}$.

3. Pour ε fixé, l'application $h \mapsto \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i)$ est linéaire et donc maximisée sur un point extrême de l'enveloppe convexe de $\mathcal{H}$. Point qui est déjà inclut dans le sup.

4.3.3 Le retour du cas fini

On souhaite ici appliquer les résultats théoriques précédents sur la complexité de Rademacher au cas fini vu en début de chapitre. Pour cela, on définit pour chaque fonction $h \in \mathcal{H}$ un vecteur

a_h tel que :

$$a_h = (h(z_1), \dots, h(z_n))^\top \in \mathbb{R}^n. \quad (4.3.11)$$

Si $\mathcal{H}$ est fini, cet ensemble de vecteurs forme un sous-ensemble fini A de $\mathbb{R}^n$ tel que $A = \{a_h \mid h \in \mathcal{H}\} \subset \mathbb{R}^n$. On peut donc observer l'égalité entre la complexité de Rademacher $\mathfrak{R}_S(\mathcal{H})$ de $\mathcal{H}$ et le maximum de la moyenne des a_i pondérée par les ε_i pour tout $a \in A$:

$$\sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i \leq n} \varepsilon_i h(z_i) = \max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i. \quad (4.3.12)$$

Développons un peu de théorie pour borner le terme de gauche à l'aide du lemme de Massart.

Lemme (Massart) Soit $A \subset \mathbb{R}^n$ fini, non vide et $\rho = \max_{a \in A} \|a\|_2$. Alors on a :

$$\mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \quad (4.3.13)$$

Pour la démonstration de ce lemme, on s'appuie sur le lemme de Hoeffding ci-dessous.

Lemme (Hoeffding) Pour toute variable aléatoire réelle X centrée (i.e $\mathbb{E}[X] = 0$) et bornée $X \in [u, v]$ p.s, alors :

$$\forall \lambda \in \mathbb{R}, \quad \mathbb{E} [e^{\lambda X}] \leq \exp \left(\frac{\lambda^2 (v-u)^2}{8} \right). \quad (4.3.14)$$

On dit alors que X est *sous-gaussienne* de paramètre $\sigma^2 = \frac{(v-u)^2}{4}$. On notera alors $X \sim \mathcal{G}(\sigma^2)$.

Démonstration Soit $A \subset \mathbb{R}^n$ borné par $\rho = \max_{a \in A} \|a\|_2$. Pour tout $a = (a_1, \dots, a_n)^\top \in A$, on pose $X_i = \varepsilon_i a_i$ où les ε_i sont les variables de Rademacher.

On remarque que :

$$\mathbb{E}(X_i) = a_i \mathbb{E}(\varepsilon_i) = 0, \quad \text{et} \quad X_i \in [-|a_i|, |a_i|]. \quad (4.3.15)$$

D'après le lemme de Hoeffding, on a donc que $X_i \sim \mathcal{G}(\sigma^2)$ avec $\sigma^2 = \frac{4a_i^2}{4} = a_i^2$, d'où :

$$\forall \lambda \in \mathbb{R}, \quad \mathbb{E}_\varepsilon [e^{\lambda \varepsilon_i a_i}] \leq \exp \left(\frac{\lambda^2 a_i^2}{2} \right). \quad (4.3.16)$$

Or les ε_i sont deux à deux indépendants, donc en posant $W_a = \sum_{i \leq n} \varepsilon_i a_i$, on a :

$$\begin{aligned} \mathbb{E}_\varepsilon [e^{\lambda W_a}] &= \mathbb{E}_\varepsilon \left[\prod_{i \leq n} e^{\lambda \varepsilon_i a_i} \right] = \prod_{i \leq n} \mathbb{E}_\varepsilon [e^{\lambda \varepsilon_i a_i}] \\ &\leq \prod_{i \leq n} \exp \left(\frac{\lambda^2 a_i^2}{2} \right) = \exp \left(\frac{\lambda^2 \|a\|_2^2}{2} \right). \end{aligned}$$

Or, par construction, $\|a\|_2^2 \leq \rho^2$, donc $W_a \sim \mathcal{G}(\rho^2)$. On peut donc appliquer successivement l'inégalité de Jensen et poser $\lambda = \sqrt{2 \ln |A|} / \rho$:

$$\begin{aligned} e^{\lambda \mathbb{E}[\max_{a \in A} W_a]} &\leq \mathbb{E} [e^{\lambda \max_{a \in A} W_a}] \leq \sum_{a \in A} \mathbb{E} [e^{\lambda W_a}] \leq |A| \exp \left(\frac{\lambda^2 \rho^2}{2} \right) \\ \iff \mathbb{E} \left[\max_{a \in A} W_a \right] &\leq \frac{\ln |A|}{\lambda} + \frac{\lambda \rho^2}{2} \\ \iff \mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] &\leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \end{aligned}$$

Proposition En appliquant le lemme de Massart sur le contexte présenté en début de sous-section, on obtient l'inégalité suivante :

$$\mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \quad (4.3.17)$$

Pour faire le lien avec la complexité de Rademacher, il suffit de prendre l'espérance sur 4.3.12 et on retrouve le résultat énoncé pour le cas fini en 4.2.2 :

$$\mathfrak{R}_S(\mathcal{H}) = \mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] = \mathbb{E}_\varepsilon \left[\max_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n}. \quad (4.3.18)$$

4.3.4 Principe de contraction

Les résultats présentés jusqu'à maintenant sont très forts pour donner une borne supérieure de l'erreur d'approximation que l'on fait en choisissant une classe de fonction $\mathcal{F}$. Or, si l'on regarde bien l'expression de la complexité de Rademacher, on s'aperçoit que celle-ci dépend de la fonction de *loss* utilisée :

$$\mathfrak{R}_n(\mathcal{H}) = \mathfrak{R}_n(l \circ \mathcal{F}) = \mathbb{E}_{S, \varepsilon} \left[\sup_{f \in \mathcal{F}} \frac{1}{n} \sum_{i \leq n} \varepsilon_i l(y_i, f(x_i)) \right]. \quad (4.3.19)$$

Or, on souhaiterait être capable de calculer cette complexité indépendamment du processus d'apprentissage, et donc de la fonction de perte l choisie. C'est le principe de contraction qui l'assure.

Proposition (Principe de contraction) Soit $A \subset \mathbb{R}^n$ et $g_1, \dots, g_n : \mathbb{R} \rightarrow \mathbb{R}$ des applications G -lipschitziennes. On a alors :

$$\mathbb{E}_\varepsilon \left[\sup_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i g_i(a_i) \right] \leq G \cdot \mathbb{E}_\varepsilon \left[\sup_{a \in A} \frac{1}{n} \sum_{i \leq n} \varepsilon_i (a_i) \right]. \quad (4.3.20)$$

Si l'on fait l'hypothèse simple que la fonction de perte utilisée $l(y_i, \cdot)$ est G -lipschitzienne, on a alors que :

$$\mathfrak{R}_S(l \circ \mathcal{F}) \leq G \cdot \mathfrak{R}_S(\mathcal{F}), \quad \text{donc} \quad \mathfrak{R}_n(l \circ \mathcal{F}) \leq G \cdot \mathfrak{R}_n(\mathcal{F}) \quad (4.3.21)$$

pour un domaine $A = \{(f(x_1), \dots, f(x_n)) \mid f \in \mathcal{F}\}$.

Remarque Ce principe de contraction permet donc de séparer complètement les erreurs d'apprentissage dues à l'échantillon de celles dues à l'approximation faite par le choix de la classe $\mathcal{F}$. Ainsi, grâce à la contraction, la borne d'excès de risque sépare les aspects du problème en trois parties : l'optimisation numérique et la régularité du critère sont prises en charge par la constante G et la *loss* l , la géométrie de l'architecture d'apprentissage est entièrement contenue dans $\mathfrak{R}_n(\mathcal{F})$, et les fluctuations statistiques de l'échantillon sont, quant à elles, contenues dans le terme de McDiarmid en $\mathcal{O}(1/\sqrt{n})$.

4.3.5 Modèles linéaires contraints et dualité de normes

On applique les résultats précédents à des prédicteurs linéaires sous contrainte de régularisation :

$$\mathcal{F} = \{f_\theta : x \mapsto \theta^\top \varphi(x) \mid \Omega(\theta) \leq D\}, \quad (4.3.22)$$

où $\varphi : \mathcal{X} \rightarrow \mathbb{R}^d$ est une *feature map*, Ω une norme sur $\mathbb{R}^d$ et $D > 0$ le rayon de la boule de contrainte. On rappelle que la *norme duale* Ω^* de Ω est définie par :

$$\Omega^*(u) = \sup_{\Omega(\theta) \leq 1} \langle \theta, u \rangle. \quad (4.3.23)$$

La complexité de Rademacher de cette classe se réduit à l'espérance de la norme duale d'une somme de vecteurs symétriques :

$$\begin{aligned} \mathfrak{R}_n(\mathcal{F}) &= \mathbb{E}_{S, \varepsilon} \left[\sup_{\Omega(\theta) \leq D} \frac{1}{n} \sum_{i \leq n} \varepsilon_i \theta^\top \varphi(x_i) \right] \\ &= \mathbb{E}_{S, \varepsilon} \left[\sup_{\Omega(\theta) \leq D} \frac{1}{n} \theta^\top (\Phi^\top \varepsilon) \right] \\ &= \frac{D}{n} \mathbb{E}_{S, \varepsilon} [\Omega^*(\Phi^\top \varepsilon)], \end{aligned}$$

où $\Phi \in \mathbb{R}^{n \times d}$ est la matrice dont la i -ème ligne est $\varphi(x_i)^\top$, et $\Phi^\top \varepsilon = \sum_{i \leq n} \varepsilon_i \varphi(x_i) \in \mathbb{R}^d$.

Proposition (Cas euclidien ℓ_2) On pose $\Omega = \|\cdot\|_2$, auto-duale ($\Omega^* = \|\cdot\|_2$). Par concavité de la racine carrée (inégalité de Jensen) et cyclicité de la trace :

$$\begin{aligned} \mathfrak{R}_n(\mathcal{F}) &= \frac{D}{n} \mathbb{E} [\|\Phi^\top \varepsilon\|_2] \\ &\leq \frac{D}{n} \sqrt{\mathbb{E} [\|\Phi^\top \varepsilon\|_2^2]} \\ &= \frac{D}{n} \sqrt{\mathbb{E} [\text{tr}(\Phi \Phi^\top \varepsilon \varepsilon^\top)]} \\ &= \frac{D}{n} \sqrt{\mathbb{E}_S [\text{tr}(\Phi \Phi^\top)]} \quad \text{car } \mathbb{E}_\varepsilon [\varepsilon \varepsilon^\top] = I_n \text{ et } \varepsilon \perp S \\ &= \frac{D}{n} \sqrt{\sum_{i=1}^n \mathbb{E}_x [\|\varphi(x)\|_2^2]} \\ &= \frac{D}{\sqrt{n}} \sqrt{\mathbb{E}_x [\|\varphi(x)\|_2^2]}. \end{aligned}$$

La dimension ambiante d a disparu : seule compte l'énergie moyenne des descripteurs $\mathbb{E}[\|\varphi(x)\|_2^2]$ et le rayon D . Le résultat reste donc valide en dimension infinie ($d = \infty$), notamment pour les méthodes à noyaux (RKHS).

Proposition (Cas parcimonieux ℓ_1 – Lasso) On pose $\Omega = \|\cdot\|_1$, dont la norme duale est $\Omega^* = \|\cdot\|_\infty$. On suppose que les descripteurs sont bornés composante par composante : $|\varphi_j(x)| \leq B_\infty$ pour tout $j \in \llbracket 1, d \rrbracket$ et tout $x \in \mathcal{X}$. On a :

$$\mathfrak{R}_n(\mathcal{F}) = \frac{D}{n} \mathbb{E}_{S, \varepsilon} [\|\Phi^\top \varepsilon\|_\infty] = \frac{D}{n} \mathbb{E}_{S, \varepsilon} \left[\max_{j \leq d} \left| \sum_{i \leq n} \varepsilon_i \varphi_j(x_i) \right| \right]. \quad (4.3.24)$$

Puisque $|u| = \max\{u, -u\}$, on ramène ce terme au maximum sur l'ensemble fini $A \subset \mathbb{R}^n$ des $2d$ vecteurs colonnes orientés :

$$A = \left\{ \pm (\varphi_j(x_1), \dots, \varphi_j(x_n))^\top \mid j \leq d \right\} \subset \mathbb{R}^n. \quad (4.3.25)$$

Ainsi, $\max_{j \leq d} |\sum_{i \leq n} \varepsilon_i \varphi_j(x_i)| = \max_{a \in A} \sum_{i \leq n} \varepsilon_i a_i$. On a $|A| \leq 2d$, et pour tout $a \in A$:

$$\|a\|_2^2 = \sum_{i \leq n} \varphi_j(x_i)^2 \leq n B_\infty^2 \implies \rho = \max_{a \in A} \|a\|_2 \leq B_\infty \sqrt{n}. \quad (4.3.26)$$

En appliquant le lemme de Massart conditionnellement à S :

$$\frac{1}{n} \mathbb{E}_\varepsilon \left[\max_{a \in A} \sum_{i \leq n} \varepsilon_i a_i \right] \leq \frac{\rho \sqrt{2 \ln |A|}}{n} \leq B_\infty \sqrt{\frac{2 \ln(2d)}{n}}. \quad (4.3.27)$$

Comme cette borne est indépendante de S , elle survit à l'espérance $\mathbb{E}_S$:

$$\mathfrak{R}_n(\mathcal{F}) \leq D B_\infty \sqrt{\frac{2 \ln(2d)}{n}}. \quad (4.3.28)$$

Remarque (Comparaison géométrique ℓ_1 versus ℓ_2) En dimension finie d , si chaque composante vérifie $|\varphi_j(x)| \leq B_\infty$, l'énergie euclidienne est de l'ordre de $\mathbb{E}[\|\varphi(x)\|_2^2] \approx d B_\infty^2$, ce qui donne une complexité ℓ_2 en $\mathcal{O}(D B_\infty \sqrt{d/n})$.

Contraindre la norme ℓ_1 remplace le facteur $\sqrt{d}$ par $\sqrt{\ln(2d)}$. C'est la justification quantitative fondamentale du Lasso : en très grande dimension ($d \gg n$), la régularisation ℓ_1 brise le fléau de la dimension dès lors que le vecteur cible admet une représentation parcimonieuse.

4.4 Théorèmes d'excès de risque pour les modèles linéaires

Nous pouvons désormais assembler l'ensemble des résultats établis au cours de ces deux sections pour borner l'erreur d'estimation des modèles linéaires.

4.4.1 Borne en espérance

Théorème (Excès de risque en espérance) . Soit $\mathcal{F} = \{f_\theta : \|\theta\|_2 \leq D\}$ et supposons que pour tout $y \in \mathcal{Y}$, la perte $u \mapsto l(y, u)$ est G -lipschitzienne. Soit $\hat{f}_S$ un minimiseur exact du risque empirique sur $\mathcal{F}$. Alors :

$$\mathbb{E}_S[R(\hat{f}_S)] \leq \inf_{\|\theta\|_2 \leq D} R(f_\theta) + \frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x[\|\varphi(x)\|_2^2]}. \quad (4.4.1)$$

Démonstration Soit $f^\dagger \in \arg \min_{f \in \mathcal{F}} R(f)$. La décomposition canonique donne :

$$\mathbb{E}_S[R(\hat{f}_S)] - R(f^\dagger) = \mathbb{E}_S[R(\hat{f}_S) - \hat{R}_S(\hat{f}_S)] + \mathbb{E}_S[\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger)] + \mathbb{E}_S[\hat{R}_S(f^\dagger) - R(f^\dagger)].$$

Par définition du minimiseur empirique exact, $\hat{R}_S(\hat{f}_S) - \hat{R}_S(f^\dagger) \leq 0$. De plus, $f^\dagger$ étant indépendant de S , $\mathbb{E}_S[\hat{R}_S(f^\dagger)] = R(f^\dagger)$, donc le dernier terme est nul. Il reste :

$$\begin{aligned} \mathbb{E}_S[R(\hat{f}_S)] - R(f^\dagger) &\leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] \\ &\leq 2 \mathfrak{R}_n(l \circ \mathcal{F}) \quad (\text{par symétrisation}) \\ &\leq 2G \mathfrak{R}_n(\mathcal{F}) \quad (\text{par contraction de Ledoux-Talagrand}) \\ &\leq \frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x[\|\varphi(x)\|_2^2]} \quad (\text{par la borne euclidienne}). \end{aligned}$$

4.4.2 Borne à grande probabilité

Théorème (Excès de risque à grande probabilité) . On suppose de plus que la fonction de perte est bornée : $l(y, f(x)) \in [0, l_\infty]$ presque sûrement. Pour tout $\delta \in]0, 1[$, avec probabilité au moins $1 - \delta$ sur le tirage de $S \sim \mathbb{P}^{\otimes n}$:

$$R(\hat{f}_S) \leq \inf_{\|\theta\|_2 \leq D} R(f_\theta) + \frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x [\|\varphi(x)\|_2^2]} + 2l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}. \quad (4.4.2)$$

Démonstration On reprend la décomposition trajectorielle :

$$R(\hat{f}_S) - R(f^\dagger) \leq \sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) + (\hat{R}_S(f^\dagger) - R(f^\dagger)).$$

1. D'après McDiarmid, $\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \leq \mathbb{E}_S \left[\sup_{f \in \mathcal{F}} (R(f) - \hat{R}_S(f)) \right] + l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}$ avec probabilité au moins $1 - \delta/2$. L'espérance est bornée par $\frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}[\|\varphi(x)\|_2^2]}$ comme démontré précédemment.
2. Pour le prédicteur fixé $f^\dagger$, l'inégalité de Hoeffding unilatérale assure que $\hat{R}_S(f^\dagger) - R(f^\dagger) \leq l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}$ avec probabilité au moins $1 - \delta/2$.

Un *Union Bound* sur les deux événements garantit que les deux inégalités ont lieu simultanément avec probabilité au moins $1 - \delta$.

Remarque (Bilan structurel : le compromis régularisation/généralisation) Cette borne synthétise tout le problème de l'apprentissage statistique dans une seule formule :

$$R(\hat{f}_S) \leq \underbrace{\inf_{\|\theta\|_2 \leq D} R(f_\theta)}_{\text{Erreur d'approximation}} + \underbrace{\frac{2GD}{\sqrt{n}} \sqrt{\mathbb{E}_x [\|\varphi(x)\|_2^2]} + 2l_\infty \sqrt{\frac{\ln(2/\delta)}{2n}}}_{\text{Erreur d'estimation}}.$$

- *Rôle du rayon D* : augmenter D enrichit la classe d'hypothèses, ce qui fait décroître l'erreur d'approximation mais croître linéairement l'erreur d'estimation. Le réglage de l'hyperparamètre de régularisation (le choix de D) matérialise l'arbitrage exact entre sous-apprentissage et sur-apprentissage.
- *Vitesse universelle en $n^{-1/2}$* : que la classe soit finie ou infinie, la vitesse de convergence reste universellement en $\mathcal{O}(1/\sqrt{n})$.

